

Apunte de Marketing Engineering

Marcel Goic

2026-08-08

Contents

Prólogo	6
1 Modelos de Regresión	7
1.1 Definiciones clave	7
1.2 Conceptos básicos	8
1.2.1 Notación	8
1.3 Mínimos Cuadrados Ordinarios (OLS) y supuestos	9
1.3.1 Estimación	10
1.3.2 Propiedades	11
1.4 Estrategias de Modelamiento	12
1.4.1 Arte vs. procedimiento	12
1.4.2 Aprendizajes Preliminares	12
1.5 Evaluación de modelos	19
1.5.1 ¿Qué se busca en un modelo?	19
1.5.2 Ajuste por métricas generales	19
1.5.3 Ajuste basado en la probabilidad	20
1.5.4 Errores dentro y fuera de la muestra	21
1.5.5 División de datos	22
1.5.6 Validación cruzada	23
1.5.7 Test de hipótesis	24
1.6 Usos y limitaciones del análisis de regresión	25
1.6.1 Aprendizaje de los parámetros	25
1.6.2 Interpretación de los coeficientes	25
1.6.3 Pronósticos y errores de pronóstico	26
1.6.4 Principios generales de pronóstico	27
1.6.5 Modelos lineales generalizados	28
1.7 Alternativas de Machine Learning para la regresión	29
1.7.1 Multivariate Adaptive Regression Splines (MARS)	29
1.7.2 K Nearest Neighbors Regression (KNN)	29
1.7.3 Árboles de regresión	31
1.7.4 Bagging y Random Forests	32
1.8 Resumen	33
1.9 Problemas	33
Problema 1: Efecto de la pandemia en ventas	33
Problema 2: Ventas de un cine	35
Problema 3: Programa de recompensas	39
Problema 4: Precios internacionales de arriendo	42
Problema 5: Búsqueda visual vs. texto en e-commerce	45
Problema 6: Retail y telecomunicaciones	49
Problema 7: Agentes de IA para servicio al cliente bancario	53

Problema 8: Plataforma de streaming musical	57
Problema 9: KornerK delivery de supermercado	61
Problema 10: Demanda global de cacao	65
2 Modelos Probabilísticos	69
2.1 Definiciones clave	69
2.2 Enfoque y metodología	70
2.3 Modelos de duración	71
2.3.1 Modelos de duración en tiempo discreto	72
2.3.2 Modelos de duración en tiempo continuo sin dependencia en la duración	78
2.3.3 Modelos de duración en tiempo continuo con dependencia en la duración	82
2.4 Modelos de conteo	85
2.5 Modelos de elección binaria	88
2.6 Heterogeneidad observable	90
2.6.1 Modelos de duración en tiempo discreto con heterogenei- dad observable	90
2.6.2 Modelos de duración en tiempo continuo con heterogenei- dad observable	92
2.6.3 Modelos de duración en tiempo continuo con dependencia de la duración y heterogeneidad observable	93
2.6.4 Modelos de conteo con heterogeneidad observable	94
2.6.5 Modelos de elección binaria con heterogeneidad observable	94
2.7 Esperanzas condicionales	95
2.7.1 Esperanzas de las distribuciones de mezcla	95
2.7.2 Modelo de tiempo discreto (Beta-Geométrico)	97
2.7.3 Modelo de tiempo continuo (Gamma-Exponencial)	99
2.7.4 Modelo de conteo (Gamma-Poisson)	100
2.7.5 Modelo de elección binaria (Beta-Binomial)	101
2.8 Customer Lifetime Value: caso contractual	103
2.8.1 Modelo contractual a tiempo discreto	104
2.8.2 Modelo contractual a tiempo continuo	106
2.9 Resumen	107
2.10 Problemas	108
Problema 1: VTV Seguros de Salud	108
Problema 2: Vectorix Marketing B2B	111
Problema 3: Harcor y El Club del Almacenero	115
Problema 4: Discrepancias de precios en supermercados	119
Problema 5: NotComida — Panel de compras	122
Problema 6: Creadores de contenido	125
Problema 7: Hippi — Parkas para alta montaña	129
Problema 8: Pokémon Go	131
Problema 9: Aplicación móvil con promociones georreferenciadas	133
Problema 10: Retraso en graduaciones universitarias	136
Problema 11: Tasas de respuesta en encuestas de educación superior	139

3	Modelos Estructurales	144
3.1	Introducción a modelos estructurales	144
3.1.1	Modelos estructurales versus forma reducida	144
3.1.2	Ejemplos motivadores	145
3.1.3	Ventajas de los modelos estructurales	146
3.1.4	Modelos estructurales en marketing	149
3.1.5	Taxonomía de modelos estructurales	149
3.2	Modelo logit	151
3.2.1	Modelos de elección discreta	151
3.2.2	Derivación de la probabilidad logit	155
3.2.3	Elasticidades	156
3.2.4	Propiedades del modelo logit	157
3.2.5	Estimación	160
3.3	Modelos de panel: persistencia y precios de referencia	161
3.3.1	Persistencia de elección (lealtad)	161
3.3.2	Precios de referencia	164
3.3.3	Modelo combinado	166
3.4	Modelo probit	167
3.4.1	Definición	167
3.4.2	Estimación por simulación (SMLE)	168
3.4.3	Patrones de sustitución	169
3.4.4	Variación aleatoria en preferencias	169
3.4.5	Dependencia temporal	170
3.4.6	Identificación	172
3.5	Nested logit	174
3.5.1	Motivación	174
3.5.2	Estructura del modelo	174
3.5.3	Probabilidades de elección	176
3.5.4	Relajación parcial de IIA	178
3.5.5	Elasticidades	178
3.5.6	Estimación	179
3.5.7	Ejemplo: elección de vivienda	179
3.5.8	Extensión a múltiples niveles	180
3.6	Mixed logit	181
3.6.1	Motivación	181
3.6.2	Especificación	181
3.6.3	Estimación por máxima verosimilitud simulada	182
3.6.4	Elección de distribución	183
3.6.5	Propiedades	184
3.6.6	Disposición a pagar (WTP)	185
3.6.7	Inferencia individual: medias posteriores	185
3.6.8	Ejemplo: elección de yogur	186
3.6.9	Logit con clases latentes	186
3.7	Modelos Tobit	187
3.7.1	Tobit tipo I	187
3.7.2	Tobit tipo II	189

3.8	Resumen	190
3.9	Problemas	191
	Problema 1: STUD-IA	191
	Problema 2: Categoría aceites	195
	Problema 3: Margarina y modelo probit	196
	Problema 4: Telefonía móvil en redes sociales	200
	Problema 5: Multitienda y tarjeta de crédito	202
	Problema 6: Preventa de tickets	204
	Problema 7: Gasto publicitario	206
	Problema 8: Pizza a Pieza	208
	Problema 9: Retail online	210
	Problema 10: Copa América	211
	Problema 11: Agencia de medios	214
	Problema 12: Cupones de supermercado	216
	Problema 13: ViajesDII	219
	Problema 14: Brebajes	221
	Problema 15: Toallas absorbentes	223
	Problema 16: Agente concierge de IA	225
A	Fórmulas útiles	230
	Referencias	233

Prólogo

Este apunte reúne los contenidos y ejercicios del curso de Ingeniería de Marketing, dictado en el Departamento de Ingeniería Industrial de la Universidad de Chile. El material ha sido elaborado a lo largo de varios años con la colaboración de distintos equipos docentes.

El documento está organizado en tres unidades principales: modelos de regresión, modelos probabilísticos y modelos estructurales. Cada unidad integra la exposición teórica con ejercicios resueltos, de modo que el lector pueda transitar de la formulación conceptual a la aplicación práctica sin necesidad de consultar fuentes separadas.

Cualquier sugerencia, corrección o comentario puede dirigirse a mktengnotes@gmail.com.

1. Modelos de Regresión

Para qué sirve esta unidad. La regresión es la herramienta cuantitativa más utilizada en marketing para describir relaciones entre variables, evaluar el efecto de acciones comerciales y construir pronósticos de demanda, ventas e ingresos. Comprender cómo especificar, estimar y evaluar un modelo de regresión es un requisito transversal para las unidades posteriores del curso.

Habilidades previas requeridas. Lectura de tablas, noción de variable aleatoria, interpretación de gráficos, álgebra matricial básica y manejo de porcentajes.

Qué debería poder hacer el estudiante al terminar.

- Formular un modelo de regresión lineal con la notación de índices apropiada para un problema de marketing.
- Estimar parámetros por OLS e interpretar coeficientes, signos y significancia.
- Evaluar modelos con métricas de ajuste y predicción (R^2 , RMSE, AIC, BIC).
- Elegir entre especificaciones alternativas usando criterios cuantitativos y cualitativos.
- Aplicar modelos de machine learning como alternativa a la regresión clásica.

Conexión con ejercicios. A lo largo del capítulo se incluyen ejercicios guiados que permiten verificar la comprensión de cada concepto a medida que se avanza.

1.1 Definiciones clave

Antes de introducir la notación formal, conviene estabilizar el vocabulario que se usará a lo largo de la unidad:

Definiciones clave

- *Regresión*: técnica estadística para estimar el valor esperado de una variable (dependiente) condicional en la realización de otras (independientes).
- *Variable dependiente* (y): la cantidad que se desea explicar o predecir (ventas, ingresos, demanda).
- *Variable explicativa* (x): una característica observable que puede influir en y (precio, gasto publicitario, estacionalidad).
- *Parámetro* (β): coeficiente del modelo que cuantifica la relación entre

una variable explicativa y la variable dependiente.

- *Coefficiente estimado* ($\hat{\beta}$): valor numérico obtenido al ajustar el modelo a los datos.
- *Error* (ε): diferencia entre el valor observado y el valor predicho por el modelo.
- *Pronóstico*: valor esperado de y para un conjunto dado de variables explicativas.
- *Causalidad vs. correlación*: un modelo de regresión mide correlación entre variables; afirmar causalidad requiere condiciones adicionales (experimentos, variables instrumentales, modelos estructurales).

Ejercicio guiado. ¿Cuál(es) es(son) la utilidad de un modelo de regresión?

- Permite medir correlación entre variables.
- Permite medir la magnitud de una relación causal.
- Permite determinar causalidad entre variables.
- Dependiendo de la especificación puede determinar causalidad o correlación, pero no ambas simultáneamente.

Ver solución

Respuestas correctas: i. y ii. Permite medir correlación entre variables y la magnitud de una relación causal.

1.2 Conceptos básicos

Como bien ya se ha estudiado en otros cursos de la carrera de ingeniería industrial, una *regresión* es una técnica para calcular el valor esperado de una variable condicional en la realización de otras. Por ejemplo:

- ¿Cuál debería ser el precio de venta de una casa en la comuna de Providencia, con 4 dormitorios, 170 m^2 de superficie construida?
- ¿Cuáles deberían ser las ventas de Leche semidescremada Nestlé en la última semana del mes de abril si el precio es \$723?
- ¿Cuál debería ser el número de clientes que ve un aviso publicitario si se despliega en 4 programas durante 3 semanas y el rating promedio de los programas es 8.7 puntos?

1.2.1 Notación

En general se denota con y al vector que representa todas las variables dependientes en un único vector columna, mientras que $\mathbf{X}$ representa la matriz que incluye todas las variables independientes (esto incluye una columna de 1s si se desea incluir un intercepto).

Es importante notar que:

- Cada columna corresponde a una variable.
- Cada fila corresponde a un caso.
- Las dimensiones de las filas del vector y y la matriz $\mathbf{X}$ deben ser consistentes.
- Todos los elementos de una misma fila deben tener los mismos índices.

Para estimar los parámetros de la recta de regresión se utilizan diferentes métodos, siendo uno de los más populares el método de Mínimos Cuadrados Ordinarios (OLS).

1.3 Mínimos Cuadrados Ordinarios (OLS) y supuestos

OLS proporciona una estimación óptima de los parámetros de la recta de regresión, al encontrar la recta que minimiza la suma de los cuadrados de las diferencias entre los valores reales y los valores estimados de la variable dependiente (Greene, 2018; Wooldridge, 2019). Sin embargo, para que este método sea un estimador adecuado de los parámetros, se deben cumplir ciertos supuestos:

1. Existe una *relación lineal* entre la variable dependiente y las variables independientes. Debido a esto, la relación entre las variables se puede modelar mediante una recta. Sin este supuesto, OLS no es apropiado y se debe recurrir a otros métodos.
2. Los errores tienen una *distribución normal* y tienen una *media igual a cero*. Es decir, los errores son insesgados y distribuyen de forma simétrica alrededor del cero. Si los errores no siguen una distribución normal, los resultados de la regresión pueden no ser confiables.
3. Los errores tienen una *varianza constante* (homocedasticidad). Esto significa que la varianza de los errores es la misma para todos los valores de las variables independientes. Si no se cumple este supuesto, los errores pueden estar influenciados por alguna variable independiente y los resultados pueden ser incorrectos.
4. Los errores son *independientes entre sí*. Es decir, no están correlacionados con los errores de otra observación. Si los errores están correlacionados, la varianza de los coeficientes puede ser demasiado baja, lo que puede llevar a una sobreestimación de la significancia estadística.
5. No existe *multicolinealidad* perfecta entre las variables independientes. La multicolinealidad perfecta se refiere a la existencia de una relación lineal exacta entre las variables independientes. Esto puede ocurrir cuando dos o más variables independientes están altamente correlacionadas. Si no se cumple este supuesto, los coeficientes estimados pueden no ser confiables y los resultados pueden ser incorrectos.

Errores comunes cuando no se cumplen los supuestos de OLS.

- *Violación de linealidad*: el modelo no captura la verdadera relación entre las variables. Las predicciones serán sesgadas sistemáticamente. Se debe considerar transformaciones o modelos no lineales.
- *Errores no normales*: los intervalos de confianza y los tests de hipótesis dejan de ser válidos. Con muestras grandes, el teorema central del límite puede mitigar el problema.
- *Heterocedasticidad*: los errores estándar estimados son incorrectos, lo que invalida las pruebas de significancia. Se corrige con errores robustos o mínimos cuadrados generalizados.
- *Autocorrelación*: los errores estándar subestiman la verdadera variabilidad, generando significancias espurias. Se recurre a modelos de series de tiempo o errores agrupados.
- *Multicolinealidad*: los coeficientes individuales se vuelven inestables y difíciles de interpretar, aunque las predicciones del modelo pueden seguir siendo razonables.

En general, se utiliza OLS porque proporciona una estimación óptima de los parámetros de la recta de regresión, es decir, los valores que mejor se ajustan a los datos. El método OLS minimiza la suma de los cuadrados de las diferencias entre los valores reales y los valores estimados de la variable dependiente. Esto se logra al encontrar los valores de los parámetros de la recta que minimizan esta suma de cuadrados.

1.3.1 Estimación

Considérese el problema de estimar los parámetros $\beta_0, \beta_1, \dots, \beta_n$ de la recta de regresión $Y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n + \varepsilon$, donde ε es el término de error e Y es la variable dependiente. Queremos encontrar los valores de los parámetros $\beta_0, \beta_1, \dots, \beta_n$ que minimizan la suma de los cuadrados de las diferencias entre los valores reales y los valores estimados de Y .

La idea detrás del método de Mínimos Cuadrados Ordinarios (OLS) es minimizar la función de pérdida $S(\beta_0, \beta_1, \dots, \beta_n) = \sum_{i=1}^N (Y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_n x_{in})^2$. La solución de este problema de optimización se puede encontrar a través del cálculo de las derivadas parciales de S con respecto a cada uno de los parámetros β_j , e igualar a cero. Esto lleva al siguiente sistema de ecuaciones:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (1.1)$$

donde $\mathbf{X}$ es la matriz de variables independientes, $\mathbf{y}$ es el vector de la variable dependiente y $\hat{\beta}$ es el vector de estimadores de mínimos cuadrados.

La solución de este sistema entrega los valores de los parámetros $\beta_0, \beta_1, \dots, \beta_n$ que minimizan la función de pérdida $S(\beta_0, \beta_1, \dots, \beta_n)$. Estos valores se conocen como los estimadores de mínimos cuadrados de los parámetros de la recta de regresión.

1.3.2 Propiedades

Si se cumplen los supuestos anteriormente mencionados, mínimos cuadrados ordinarios cumple con las siguientes propiedades:

1. *Insesgadez*: Los estimadores de mínimos cuadrados son insesgados, lo que significa que, en promedio, su valor esperado es igual al verdadero valor del parámetro que se está estimando.
2. *Eficiencia*: Entre todos los estimadores insesgados y lineales, los estimadores de mínimos cuadrados tienen la menor varianza posible.
3. *Linealidad*: Los estimadores de mínimos cuadrados son lineales en la variable de respuesta Y .
4. *Consistencia*: Con un tamaño de muestra lo suficientemente grande, los estimadores de mínimos cuadrados se acercan al verdadero valor del parámetro que se está estimando.
5. El estimador máximo verosímil, para el caso lineal con errores normales, coincide con el estimador de mínimos cuadrados.

Según el teorema de Gauss-Markov, al cumplirse las propiedades de *insesgadez*, *eficiencia* y *linealidad*, los estimadores de OLS son *BLUE* (Best Linear Unbiased Estimators).

Propiedades clave de OLS (resumen).

- **BLUE**: bajo los supuestos clásicos, OLS es el mejor estimador lineal insesgado (Gauss-Markov).
- **Insesgadez**: $\mathbb{E}[\hat{\beta}] = \beta$.
- **Eficiencia**: menor varianza entre estimadores lineales insesgados.
- **Consistencia**: $\hat{\beta} \rightarrow \beta$ cuando $n \rightarrow \infty$.
- **Equivalencia MV**: con errores normales, OLS coincide con máxima verosimilitud.

Ejemplo 1 (Conceptual). Una cadena de supermercados desea entender cómo el precio afecta las ventas semanales de un producto. Se propone el modelo $\ln(Q_{st}) = \alpha_s + \beta \ln(P_{st}) + \varepsilon_{st}$, donde Q_{st} son las unidades vendidas en la tienda s durante la semana t , P_{st} es el precio y α_s es un efecto fijo por tienda.

- *Especificación*: el modelo log-log implica que β se interpreta como la elasticidad precio de la demanda.
- *Estimación*: OLS entrega $\hat{\beta} = -1.8$ con error estándar 0.3.
- *Interpretación*: un aumento de 1% en el precio se asocia a una reducción de 1.8% en las ventas, controlando por diferencias entre tiendas.

1.4 Estrategias de Modelamiento

1.4.1 Arte vs. procedimiento

El debate entre el arte y el procedimiento en el campo de la modelización y análisis de datos se ha intensificado en los últimos años con el auge de la inteligencia artificial y el aprendizaje automático. Los defensores del arte argumentan que la experiencia y la intuición del analista son esenciales para identificar patrones y relaciones complejas en los datos que no son evidentes a simple vista. Por otro lado, los defensores del procedimiento insisten en que la aplicación rigurosa de algoritmos y técnicas estadísticas es la única manera de garantizar la validez y precisión del modelo.

Es importante tener en cuenta que el uso exclusivo de uno u otro enfoque puede llevar a resultados subóptimos. Por ejemplo, un modelo construido únicamente a través del arte puede ser difícil de replicar o explicar a otros, lo que limita su utilidad práctica. Por otro lado, un modelo construido únicamente a través del procedimiento puede pasar por alto aspectos importantes de los datos que son evidentes para un experto en el campo.

En la práctica, los analistas suelen combinar ambos enfoques para construir modelos efectivos y útiles. Un aspecto clave en este proceso es la exploración exhaustiva de los datos y la definición de una lista de modelos candidatos, que pueden incluir diferentes técnicas de modelización y selección de variables. Luego, se pueden utilizar diversas métricas de ajuste y predicción para evaluar la calidad de cada modelo y seleccionar el que mejor se ajuste a los datos y sea capaz de hacer predicciones precisas.

1.4.2 Aprendizajes Preliminares

En el ámbito del modelado estadístico, existen innumerables modelos de regresión, lo que hace imposible determinar cuál es el mejor en términos absolutos. Una forma de abordar este problema es equilibrar la complejidad del modelo con su capacidad explicativa.

Esto significa que el modelo debe ser lo suficientemente simple como para ser fácilmente interpretable, pero lo suficientemente complejo como para capturar todas las relaciones relevantes entre las variables.

Para seleccionar un modelo de regresión adecuado, es fundamental tener conocimientos previos del negocio y realizar una exploración exhaustiva de los datos antes de aplicar cualquier modelo. Esta exploración ex-ante puede ayudar a identificar las variables más relevantes y las posibles relaciones entre ellas. Es importante evaluar cómo se relacionan las variables, qué variables tienen mayor dispersión y qué variables se mantienen relativamente constantes.

Después de la exploración ex-ante, es necesario aplicar el modelo y evaluar su rendimiento mediante la evaluación ex-post. Esto implica evaluar el modelo en

datos nuevos y comprobar si se comporta de manera similar a cómo lo hizo en los datos de entrenamiento.

La siguiente lista organiza las decisiones clave:

1. Elegir nivel de agregación

Uno de los aspectos clave del análisis de datos es determinar el nivel adecuado de agregación para realizar el análisis. Por ejemplo, se puede analizar las ventas de un producto en un supermercado por hora, día, semana, mes o año. También se puede considerar el análisis de ventas por SKU (código de identificación), marca, cadena o sala.

Es importante tener en cuenta que el problema de gestión puede imponer restricciones al nivel de agregación mínimo. Por ejemplo, si un gerente de una cadena de supermercados necesita tomar decisiones en tiempo real sobre la reposición de un producto, es posible que necesite datos a nivel de hora o día. En este caso, analizar las ventas a nivel de semana o mes no sería útil.

En el análisis de ventas, a menudo se enfrenta un trade-off entre la sensibilidad al precio y la programación de reposición. Si el análisis se realiza a nivel de SKU, se puede obtener una comprensión más detallada de cómo el precio afecta a las ventas. Sin embargo, si el análisis se realiza a nivel de cadena o sala, se puede obtener una mejor comprensión de los patrones de reposición.

Agregar los datos a un nivel de agregación más alto puede ser más fácil, ya que se requiere menos detalle y se puede tener una visión más general. Sin embargo, puede llevar a una pérdida de precisión por underfitting. Por ejemplo, si se analiza las ventas a nivel de mes, se puede perder información valiosa sobre patrones diarios o semanales. Por otro lado, si la cantidad de datos es limitada, es posible que se necesite mantener un nivel de agregación más alto para obtener un modelo preciso. En este caso, reducir el nivel de agregación puede significar la pérdida de información importante y la reducción de la precisión del modelo por overfitting.

2. Descomposición en múltiples regresiones

La descomposición en múltiples regresiones es una técnica que permite abordar problemas complejos y de alta dimensionalidad mediante la partición del problema en componentes más pequeños y manejables. Este enfoque puede adoptar diversas formas.

- *Descomposición por índices:* Aunque en general es preferible utilizar una única regresión para analizar las relaciones entre las variables, en ciertas situaciones, como en casos de complejidad computacional elevada o cuando se abordan problemas con múltiples niveles de jerarquía, la descomposición por índices puede ser una solución adecuada. Esta técnica implica dividir el conjunto de datos en subconjuntos según algún criterio y ajustar modelos de regresión separados para cada subconjunto.

- *Regresión lineal y modelos más complejos:* La regresión lineal es un enfoque simple y fácil de estimar que puede ser suficiente en muchos casos. Sin embargo, en situaciones donde las relaciones entre las variables no son lineales o donde se requiere una mayor flexibilidad en el modelado, se pueden justificar modelos más complejos, como regresiones polinómicas, regresiones no paramétricas o modelos de regresión con variables categóricas.
- *Descomposición por componentes latentes:* En ciertos casos, la variable dependiente puede descomponerse de manera natural en componentes latentes, lo que facilita la interpretación de los resultados y la identificación de relaciones subyacentes entre las variables. Un ejemplo típico es la descomposición de las ventas en el número de compras y el número de unidades por compra. Al analizar estos componentes por separado, se puede obtener una comprensión más detallada de los factores que influyen en las ventas.
- *Caso del cero inflado (zero inflated):* En algunas situaciones, se pueden observar una gran cantidad de ceros en los datos, lo que indica una distribución inflada en cero. En estos casos, se puede utilizar un modelo de regresión de ceros inflados que distingue entre dos procesos distintos: la incidencia de compra (probabilidad de que ocurra una compra) y el monto de compra (valor de la compra, condicional a que se haya realizado una compra). Este enfoque permite analizar de manera más efectiva los factores que afectan tanto la propensión a comprar como la cantidad gastada en las compras.

3. Transformación de variables

La transformación de variables es una técnica utilizada para mejorar la interpretación y el ajuste del modelo. Esta técnica consiste en aplicar funciones matemáticas a las variables con el objetivo de modificar su distribución y hacer que el modelo sea más interpretable y significativo.

Un ejemplo común de transformación de variables es el modelo doble log, en el cual se aplican logaritmos a las variables dependientes e independientes para transformar la relación no lineal en una relación lineal. Esta técnica puede ser útil cuando se analizan datos que siguen una distribución log-normal o cuando se busca interpretar los coeficientes de manera logarítmica.

Es importante tener en cuenta que, aunque la transformación de variables puede mejorar la bondad del ajuste y la precisión de las predicciones, no siempre es necesario aplicarla. En algunos casos, las variables ya están en una forma adecuada para el modelo y cualquier transformación adicional podría reducir la interpretabilidad del modelo. Por lo tanto, es importante tener una comprensión sólida de los datos y del problema a resolver antes de aplicar cualquier transformación de variables.

Table 1.1: Interpretación de coeficientes según transformación de variables.

Modelo	Var. dependiente	Var. independiente	Interpretación
Nivel-nivel	Y	X	$\Delta Y = \beta_1 \Delta X$
Nivel-log	Y	$\log(X)$	$\Delta Y = \frac{\beta_1}{100} \% \Delta X$
Log-nivel	$\log(Y)$	X	$\% \Delta Y = (100 \beta_1) \Delta X$
Log-log	$\log(Y)$	$\log(X)$	$\% \Delta Y = \beta_1 \% \Delta X$

Ejemplo 2 (Interpretación de coeficientes). Dado el modelo $\ln(y) = \beta_0 + \beta_1 x_1 + \beta_2 \ln(x_2)$, la interpretación correcta es:

- Un aumento de una unidad en x_1 se asocia a un cambio de $(100 \cdot \beta_1)\%$ en y (relación log-nivel).
- Un aumento de 1% en x_2 se asocia a un cambio de $\beta_2\%$ en y (relación log-log).

Nótese que un aumento de una unidad en x_2 *no* causa un aumento de $\beta_2\%$ en y ; esa lectura confunde la escala log-log con la log-nivel.

Ejercicio guiado. Dado el modelo $\ln(y) = \beta_0 + \beta_1 x_1 + \beta_2 \ln(x_2)$, se puede asegurar que:

- Un aumento de una unidad en x_1 causa un aumento de β_0 unidades en y .
- Un aumento de una unidad en x_2 causa un aumento de $\beta_2\%$ unidades en y .
- Un aumento de un 1% en x_2 causa un aumento de β_2 unidades en y .
- Un aumento de un 1% en x_2 causa un aumento de $\beta_2\%$ unidades en y .
- Ninguna de las anteriores.

Ver solución

Respuesta correcta: e. Ninguna de las anteriores. Un aumento de 1% en x_2 causa un cambio de $\beta_2/100$ en $\ln(y)$.

Ejercicio guiado. ¿Cuál de las siguientes especificaciones NO permite capturar que las diferencias en el comportamiento y se van incrementando a medida que aumenta la edad de los sujetos?

- $y = \beta_0 + \sum_i \beta_i \text{Dummy}_i$, $i = \{\text{niños, jóvenes, adultos, ancianos}\}$
- $y = \beta_0 + \beta_1 \ln(\text{edad})$
- $y = \beta_0 + \beta_1 \text{edad} + \beta_2 \text{edad}^2$
- $y = \beta_0 + \beta_1 \exp(\text{edad})$
- Ninguna de las anteriores.

Ver solución

Respuesta correcta: b. $y = \beta_0 + \beta_1 \ln(\text{edad})$.

4. Selección de variables

En el campo de la regresión, existen diferentes enfoques para la selección de

variables, incluyendo métodos automáticos y manuales. Uno de los métodos automáticos más utilizados es la regresión paso a paso (*stepwise regression*), que implica la iterativa agregación o eliminación de variables en función de algún criterio de bondad de ajuste.

En el enfoque forward de la regresión paso a paso, las variables se van agregando al modelo una por una, comenzando con la variable que proporciona el mejor ajuste según el criterio establecido. En cada etapa, se evalúa si agregar una nueva variable mejora significativamente el ajuste del modelo.

Por otro lado, en el enfoque backward de la regresión paso a paso, todas las variables se incluyen inicialmente en el modelo y se van eliminando una por una, comenzando con la variable que menos contribuye al ajuste según el criterio establecido. En cada etapa, se evalúa si eliminar una variable mejora significativamente el ajuste del modelo.

Otro enfoque de selección de variables es la penalización de uso de parámetros no nulos al momento de minimizar la función de error. Dentro de este enfoque se encuentra la regresión Ridge y LASSO (Least Absolute Shrinkage and Selection Operator)

$$\text{Ridge: } \min_{\beta} \sum_i \left(y_i - \beta_0 - \sum_j \beta_j x_{ij} \right)^2 + \lambda \sum_j \beta_j^2 \quad (1.2)$$

$$\text{LASSO: } \min_{\beta} \sum_i \left(y_i - \beta_0 - \sum_j \beta_j x_{ij} \right)^2 + \lambda \sum_j |\beta_j| \quad (1.3)$$

Aunque estos enfoques automáticos de selección de variables pueden ser convenientes y ahorrar tiempo, es importante tener en cuenta algunas limitaciones. En primer lugar, las implementaciones automáticas de selección de variables no exploran todas las posibles combinaciones de variables, lo que significa que podrían pasar por alto combinaciones óptimas que un enfoque manual más exhaustivo podría descubrir.

Además, los resultados de la selección automática de variables pueden generar conjuntos de variables poco intuitivos y difíciles de interpretar. A veces, el algoritmo puede seleccionar variables que tienen una relación estadística con la variable de respuesta, pero carecen de una interpretación causal o intuitiva en el contexto del problema.

Una alternativa es utilizar una mixtura entre métodos automáticos y manuales, eligiendo aquellas variables que mejoran el modelo en ajuste y que igualmente tienen un sentido interpretativo para la resolución de la pregunta a responder.

Table 1.2: Criterios de selección de variables.

<i>Criterio</i>	<i>Ventaja</i>	<i>Riesgo</i>
Stepwise (AIC/BIC)	Automatizable, rápido	No explora todas las combinaciones

<i>Criterio</i>	<i>Ventaja</i>	<i>Riesgo</i>
LASSO	Selecciona y regulariza simultáneamente	Puede eliminar variables correlacionadas relevantes
Ridge	Reduce varianza de estimadores	No realiza selección de variables (mantiene todas)
Manual / experto	Interpretabilidad garantizada	Sesgo del analista, lento en alta dimensión

Ejercicio guiado. ¿Cuál de las siguientes afirmaciones caracterizan adecuadamente a la selección automática de variables para un modelo de regresión lineal? (Puede seleccionar más de una opción):

- Vienen predefinidas en planillas de cálculo.
- Son siempre peores que selección manual.
- Sólo pueden aplicarse sobre el subconjunto de variables continuas.
- No consideran todos los modelos posibles.

Ver solución

Respuesta correcta: iv. No consideran todos los modelos posibles.

5. Selección de índices

La selección de índices en el análisis de regresión es un proceso discrecional que puede influir significativamente en la interpretación y el rendimiento de los modelos. Para abordar este problema de manera efectiva, se pueden seguir algunas pautas generales que ayuden a identificar y justificar la inclusión de índices en el análisis.

Condiciones para Indexar un Parámetro Es recomendable considerar la inclusión de un índice en un modelo de regresión si se cumplen las siguientes tres condiciones:

- Relevancia para el problema de gestión: El índice debe ser importante para abordar el problema de gestión en cuestión, proporcionando una distinción significativa entre diferentes aspectos del problema.
- Diferencias en el comportamiento de la variable dependiente: La variable dependiente debe mostrar comportamientos distintos para cada índice, lo que sugiere que la desagregación aporta información adicional útil.
- Suficiencia de datos: Deben estar disponibles suficientes datos para estimar de manera confiable los parámetros desagregados. La falta de datos puede conducir a estimaciones poco fiables y a un mayor riesgo de sobreajuste.
- Índices y Variables Binarias: En el análisis de regresión, los índices pueden representarse mediante variables binarias, también conocidas como variables dummy. Estas variables toman el valor de 1 cuando se cumple una condición específica (por ejemplo, si un producto pertenece a una categoría determinada) y 0 en caso contrario. Aunque la representación de índices

mediante variables binarias es matemáticamente equivalente, la notación de índices suele ser más compacta y se prefiere en la mayoría de los casos.

Ejercicio guiado. Se tiene el siguiente modelo lineal de venta de productos:

$$Q_{ist} = \theta_s + \mu_{is}P_{ist} + \gamma t + \varepsilon_{ist}$$

Donde Q_{ist} es la cantidad vendida del producto i en la tienda s en el año t y P_{ist} el precio. El set de datos contiene registros para 5 productos y 5 tiendas entre 1960 y 2015. A partir de esto, se puede afirmar que (puede elegir más de una opción):

- i. Transformar γt en γ_t no influye en el modelo ya que son equivalentes.
- ii. Transformar los coeficientes μ_{is} a $\mu_i + \mu_s$ implica calcular menos parámetros.
- iii. El modelo no permite capturar comportamiento cíclico de la demanda.
- iv. Los parámetros θ_s y μ_{is} no pueden estimarse simultáneamente.

Ver solución

Respuestas correctas: ii. y iii. Transformar μ_{is} a $\mu_i + \mu_s$ reduce parámetros; el modelo no permite capturar comportamiento cíclico de la demanda.

6. Uso de jerarquías

Una jerarquía aparece cuando un parámetro del modelo aparece como una función de otros parámetros. Esta técnica es útil para detectar posibles efectos de interacción entre las variables predictoras, permitiendo escribir modelos más parsimoniosos. La inclusión de jerarquías debe estar basada en una teoría clara o una justificación empírica.

Resumen parcial: Estrategias de Modelamiento.

Las decisiones clave al construir un modelo de regresión son:

1. **Nivel de agregación:** balancear granularidad con disponibilidad de datos.
2. **Descomposición:** separar el problema en submodelos cuando la estructura lo permita.
3. **Transformaciones:** elegir la forma funcional que mejor represente la relación (nivel-nivel, log-log, etc.).
4. **Selección de variables:** combinar métodos automáticos y juicio experto.
5. **Selección de índices:** incluir efectos fijos cuando haya heterogeneidad relevante.
6. **Jerarquías:** capturar interacciones entre variables de forma parsimoniosa.

1.5 Evaluación de modelos

La evaluación de modelos estadísticos es un proceso fundamental para determinar la calidad y utilidad de los modelos, es decir, para determinar si un modelo se ajusta adecuadamente a los datos y si es útil para hacer predicciones o inferencias.

Es importante destacar que la evaluación de modelos estadísticos no es un proceso estático y que puede requerir ajustes y modificaciones a medida que se adquiere más información o se amplía el alcance del modelo. Por lo tanto, es fundamental seguir actualizando y refinando los modelos para asegurar su calidad y utilidad en la toma de decisiones basadas en datos.

1.5.1 ¿Qué se busca en un modelo?

Lo deseable en un modelo es que cualitativamente pueda contar una buena historia — proporcionar información útil para tomar decisiones — y que cuantitativamente ajuste bien a los datos, de tal manera que reduzca el error de predicción y pueda generar un pronóstico creíble.

Con esto en mente, se busca un criterio bien definido para comparar modelos y determinar si un modelo dado es suficientemente bueno.

La siguiente tabla resume las métricas más utilizadas:

Table 1.3: Resumen de métricas de evaluación.

<i>Métrica</i>	<i>Qué mide</i>	<i>Cuándo usarla</i>	<i>Riesgo si se usa sola</i>
R^2	Varianza explicada	Comparar modelos con igual n° de variables	No explica la utilidad de las variables
R^2_{adj}	Varianza explicada penalizada	Comparar modelos con distinto n° de variables	No penaliza fuertemente modelos complejos
RMSE	Error promedio en unidades de y	Medir magnitud del error	Sensible a outliers
MAE	Error promedio absoluto	Medir error robusto a outliers	No penaliza errores grandes
MAPE	Error porcentual	Comparar entre escalas distintas	Indefinido si $y_i = 0$
AIC	Ajuste penalizado por complejidad	Selección de modelos	Sólo relativo, no absoluto
BIC	Ajuste con penalización más fuerte	Selección con preferencia por parsimonia	Penalización puede ser excesiva con n grande

1.5.2 Ajuste por métricas generales

Las siguientes métricas de ajuste se basan en reducir los errores de predicción de los modelos. La tabla a continuación resume las métricas más utilizadas:

Table 1.4: Fórmulas de métricas de ajuste.

<i>Métrica</i>	<i>Fórmula</i>	<i>Interpretación</i>	<i>Limitación</i>
$R^2 \in [0, 1]$	$\frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2}$	Varianza de y explicada	Aumenta al agregar variables

Métrica	Fórmula	Interpretación	Limitación
$R^2_{adj} \in (-\infty, 1]$	$1 - \frac{(1-R^2)(n-1)}{n-k-1}$	R^2 corregido por k predictores	Puede ser negativo
$MAE \geq 0$	$\frac{1}{n} \sum y_i - \hat{y}_i $	Error absoluto promedio	No penaliza errores grandes
$MAPE \geq 0$	$\frac{1}{n} \sum \left \frac{y_i - \hat{y}_i}{y_i} \right $	Error porcentual	Indefinido si $y_i = 0$
$RMSE \geq 0$	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$	Error cuadrático medio	Sensible a valores atípicos

Métricas de evaluación: cuándo usar cada una.

- Use R^2_{adj} (no R^2) cuando compare modelos con distinto número de variables.
- Use **RMSE** cuando los errores grandes sean especialmente costosos.
- Use **MAE** cuando quiera una métrica robusta a valores atípicos.
- Use **MAPE** cuando necesite comparar errores entre variables de distinta escala.
- Use **AIC/BIC** cuando quiera penalizar explícitamente la complejidad del modelo.

1.5.3 Ajuste basado en la probabilidad

También es posible darle una interpretación probabilística al ajuste. La idea central es elegir aquellos parámetros θ que maximicen la probabilidad de observar los datos que efectivamente se observaron. Esta probabilidad se cuantifica mediante la *función de verosimilitud*:

$$L(\theta|x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta) \quad (1.4)$$

donde $f(x_i; \theta)$ es la densidad (o probabilidad) de la observación x_i evaluada en el vector de parámetros θ . Dado que el producto de probabilidades puede resultar numéricamente inestable, se trabaja con el logaritmo de la verosimilitud (*log-likelihood*):

$$\ell(\theta|\mathbf{x}) = \sum_{i=1}^n \log(f(x_i|\theta)) \quad (1.5)$$

El estimador de máxima verosimilitud (EMV) es $\hat{\theta} = \arg \max_{\theta} \ell(\theta|\mathbf{x})$. A partir de la log-verosimilitud se construyen las siguientes métricas de ajuste:

1. *Razón de verosimilitud* (pseudo R^2 de McFadden): compara la log-verosimilitud del modelo estimado $\ell(\hat{\beta})$ con la del modelo nulo $\ell(\mathbf{0})$ (solo intercepto). Valores cercanos a 1 indican un buen ajuste relativo al modelo nulo:

$$\rho = 1 - \frac{\ell(\hat{\beta})}{\ell(\mathbf{0})} \quad (1.6)$$

2. *Criterio de Información de Akaike* (AIC): penaliza la complejidad del modelo sumando $2k$, donde k es el número de parámetros estimados. Un menor AIC indica un mejor balance entre ajuste y parsimonia. Su derivación se basa en minimizar la divergencia de Kullback-Leibler entre el modelo verdadero y el estimado (Tobar, 2024):

$$AIC = -2\ell(\hat{\beta}) + 2k \quad (1.7)$$

3. *Criterio de Información Bayesiano* (BIC o criterio de Schwarz): similar al AIC, pero penaliza más fuertemente los modelos complejos al reemplazar $2k$ por $k \log(n)$, donde n es el número de observaciones. Para muestras grandes ($n > e^2 \approx 7.4$), el BIC penaliza más que el AIC y tiende a seleccionar modelos más parsimoniosos (Tobar, 2024):

$$BIC = -2\ell(\hat{\beta}) + k \log(n) \quad (1.8)$$

1.5.4 Errores dentro y fuera de la muestra

En general, se busca construir modelos que sean generalizables a datos no observados durante la estimación. Para ello se distingue entre el *error dentro de la muestra* (in-sample), calculado sobre los datos de entrenamiento, y el *error fuera de la muestra* (out-of-sample), evaluado sobre datos nuevos. Un modelo puede ajustar perfectamente los datos de entrenamiento (bajo error in-sample) pero fallar en datos nuevos si ha capturado ruido en lugar de la señal subyacente: este fenómeno se denomina *sobreajuste* (overfitting). Por el contrario, un modelo demasiado simple puede no capturar la estructura de los datos (*subajuste* o underfitting).

La tensión entre ajuste y generalización se formaliza mediante la **descomposición sesgo-varianza** (Tobar, 2024). Sea $\hat{f}(\mathbf{x}|\mathcal{D})$ un estimador de la función verdadera $f(\mathbf{x})$, construido a partir de un conjunto de entrenamiento $\mathcal{D}$, y sea $y = f(\mathbf{x}) + \varepsilon$ con $\mathbb{E}(\varepsilon) = 0$ y $\text{Var}(\varepsilon) = \sigma^2$. El error cuadrático esperado de predicción se descompone en:

$$\mathbb{E}_{\mathcal{D}}[(y - \hat{f})^2] = \underbrace{\text{Sesgo}^2(\hat{f})}_{\text{Bias}^2} + \underbrace{\text{Var}(\hat{f})}_{\text{Variance}} + \sigma^2 \quad (1.9)$$

donde:

- **Sesgo** ($\text{Bias}(\hat{f}) = \mathbb{E}_{\mathcal{D}}[\hat{f}] - f$): mide cuán lejos está, en promedio, la predicción del valor verdadero. Un modelo muy simple (pocas variables, sin interacciones) tendrá alto sesgo.

- **Varianza** ($\text{Var}(\hat{f}) = \mathbb{E}_{\mathcal{D}}[(\hat{f} - \mathbb{E}[\hat{f}])^2]$): mide cuánto cambia el estimador al variar la muestra de entrenamiento. Un modelo muy complejo (muchos parámetros) tendrá alta varianza.
- σ^2 : varianza irreducible del ruido, que no puede ser controlada por el modelo.

A medida que la complejidad del modelo aumenta, el sesgo disminuye pero la varianza crece, generando una curva convexa para el error total. El modelo óptimo se encuentra en el punto que minimiza esta suma, lo que justifica el uso de técnicas de validación para elegir la complejidad adecuada.




Figure 1.1: Error de calibración vs. predicción

1.5.5 División de datos

Para evaluar la capacidad de generalización, el conjunto de datos $\mathcal{D}$ se divide en subconjuntos con roles diferenciados:

- **Conjunto de entrenamiento** (*training set*): se utiliza para estimar los parámetros del modelo. Típicamente representa entre el 60% y el 80% de los datos.
- **Conjunto de validación** (*validation set*): se emplea para calibrar hiperparámetros (por ejemplo, el grado de un polinomio o el parámetro de regularización ρ) y seleccionar entre modelos candidatos.
- **Conjunto de prueba** (*test set*): se reserva para la evaluación final del modelo seleccionado. No debe utilizarse en ninguna decisión de modelamiento.

Una regla usual es destinar el 50% a entrenamiento y 25% a validación y test, respectivamente (Tobar, 2024). La división debe realizarse *antes* de cualquier transformación que utilice información del conjunto completo (por ejemplo, estandarización), para evitar *data leakage*. En datos con estructura temporal, la división debe respetar el orden cronológico.

1.5.6 Validación cruzada

La validación cruzada es una técnica que permite estimar el error de generalización de un modelo sin necesidad de reservar un conjunto de validación fijo (Tobar, 2024). Existen dos familias principales:

Validación cruzada exhaustiva:

- *Leave-p-out* (LpOCV): se dejan p observaciones para validación y se entrena con las $n - p$ restantes. Se repite para todas las $\binom{n}{p}$ combinaciones posibles.
- *Leave-one-out* (LOOCV): caso particular con $p = 1$. Cada observación se usa una vez como validación mientras las demás entrenan el modelo. Es computacionalmente costoso (n modelos), pero tiene bajo sesgo.

Validación cruzada no exhaustiva:

- *k-fold*: el conjunto $\mathcal{D}$ se divide en k grupos de igual tamaño. En cada iteración, uno de los k grupos sirve de validación y los restantes $k - 1$ de entrenamiento. Se repite k veces (una por fold) y se promedian los errores. Valores típicos son $k = 5$ o $k = 10$.
- *Monte Carlo CV*: se realizan particiones binarias aleatorias de $\mathcal{D}$ de forma repetida; en cada partición se entrena y evalúa el modelo.

El pipeline de validación cruzada opera así: (1) dividir $\mathcal{D}$ en k folds; (2) para cada fold j , entrenar el modelo con los folds $\{1, \dots, k\} \setminus \{j\}$; (3) evaluar el error en el fold j ; (4) promediar los k errores obtenidos. El hiperparámetro o modelo que minimice este promedio es el seleccionado.




Figure 1.2: Ejemplo de validación cruzada

Ejemplo 3 (Evaluación de modelos). Se han estimado dos modelos para predecir las ventas semanales de un producto. El Modelo A tiene $R^2 = 0.85$, $RMSE_{train} = 120$ y $RMSE_{test} = 180$. El Modelo B tiene $R^2 = 0.78$, $RMSE_{train} = 150$ y $RMSE_{test} = 160$.

Aunque el Modelo A tiene mejor ajuste en la muestra de entrenamiento, la brecha entre $RMSE_{train}$ y $RMSE_{test}$ sugiere sobreajuste. El Modelo B, con un ajuste más modesto pero mayor capacidad de generalización, es

preferible para pronóstico.

1.5.7 Test de hipótesis

Además de la evaluación del ajuste mediante métricas, los test de hipótesis permiten realizar inferencias estadísticas formales sobre los parámetros del modelo. La lógica general de un test es: (1) plantear una hipótesis nula H_0 y una alternativa H_1 ; (2) calcular un estadístico de prueba a partir de los datos; (3) comparar el estadístico con un valor crítico de su distribución bajo H_0 (o equivalentemente, calcular el *p-valor*); (4) rechazar H_0 si el estadístico supera el valor crítico al nivel de significancia α elegido.

A continuación se presentan los cuatro test más relevantes en el contexto de regresión:

1. Test t (significancia individual). Evalúa si un coeficiente individual es significativamente distinto de cero:

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_1 : \beta_j \neq 0$$

$$t_j = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)} \sim t_{n-k-1} \quad (1.10)$$

donde $\text{se}(\hat{\beta}_j)$ es el error estándar del coeficiente. Se rechaza H_0 si $|t_j| > t_{\alpha/2, n-k-1}$. Un *p-valor* bajo (típicamente < 0.05) indica que la variable x_j tiene un efecto estadísticamente significativo.

2. Test F (significancia conjunta). Evalúa si un subconjunto de coeficientes es conjuntamente significativo, es decir, si el modelo completo explica significativamente más que el modelo restringido:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$$

$$F = \frac{(SSR_R - SSR_{NR})/q}{SSR_{NR}/(n - k - 1)} \sim F_{q, n-k-1} \quad (1.11)$$

donde SSR_R y SSR_{NR} son las sumas de residuos cuadrados del modelo restringido y no restringido, respectivamente, y q es el número de restricciones. El test F global (todos los coeficientes excepto el intercepto) es reportado por defecto en la mayoría de los software de regresión.

3. Test de razón de verosimilitud (LR). Compara dos modelos anidados mediante sus log-verosimilitudes. Si el modelo B es una versión restringida del modelo A (con q restricciones):

$$LR = 2(\ell_A - \ell_B) \sim \chi_q^2 \quad (1.12)$$

Se rechaza H_0 (el modelo restringido es adecuado) si $LR > \chi_{\alpha,q}^2$. Este test es especialmente útil para modelos estimados por máxima verosimilitud donde el test F no es directamente aplicable (por ejemplo, logit, probit).

4. Test χ^2 (bondad de ajuste). Evalúa si las predicciones del modelo se ajustan a los datos observados:

$$\chi^2 = \sum_{i=1}^K \frac{(y_i - \hat{y}_i)^2}{\hat{y}_i} \sim \chi_{K-1}^2 \quad (1.13)$$

Se rechaza H_0 (el modelo describe correctamente los datos) si $\chi^2 > \chi_{K-1,\alpha}^2$. Es aplicable cuando la variable dependiente es discreta o cuando se agrupan las observaciones en categorías.

1.6 Usos y limitaciones del análisis de regresión

1.6.1 Aprendizaje de los parámetros

La principal fuente de aprendizaje que provee un modelo de regresión son los coeficientes calculados, los cuales entregan información sobre el efecto de las variables independientes sobre lo que se desea estudiar. Las preguntas clave son:

- ¿Poseen las variables del modelo el signo esperado?
- ¿Son estadísticamente significativos?
- ¿Es relevante la magnitud de su efecto?

Para responder a estas preguntas se hace necesario el uso de herramientas estadísticas tales como t -test para evaluaciones individuales o F -test para la evaluación de un conjunto de regresores.

1.6.2 Interpretación de los coeficientes

Teniendo en cuenta un modelo lineal simple definido por $y = 12 + 1.5x$. Es lógico pensar que el efecto de x sobre y al incrementar en una unidad es, en promedio, de 1.5. Sin embargo, esta afirmación sería correcta *sólo* en el caso de que se tengan buenas razones para creer que x tiene un *efecto causal* en y .

Es importante recordar que los modelos de regresión solo indican la correlación entre las variables dependientes con las independientes, pero no necesariamente una relación causal. Dentro de los fenómenos que pueden explicar la correlación sin causalidad:

- *Causalidad inversa:* y causa x .

- *Simultaneidad*: y causa x y x causa y .
- *Tercera variable*: z causa x e y .

Correlación no es causalidad. Un coeficiente $\hat{\beta}$ significativo indica que existe una asociación estadística entre x e y , pero no implica que cambiar x provoque un cambio en y . Para afirmar causalidad se requiere: (1) un diseño experimental controlado, (2) variables instrumentales, o (3) un modelo estructural con supuestos de identificación explícitos. Interpretar un coeficiente como efecto causal sin estas condiciones es uno de los errores más frecuentes en análisis de marketing.

Para investigar el mecanismo causal se puede recurrir al *análisis de mediación*, que examina la relación entre una variable independiente y una variable dependiente a través de una variable intermedia (mediador).




Figure 1.3: Modelo de mediación

Es importante no confundir el análisis de mediación con un efecto de tercera variable. Si z causa x y a la vez z causa y , estamos bajo un escenario de tercera variable. Si x causa z y z causa y , entonces z es una variable mediadora.

1.6.3 Pronósticos y errores de pronóstico

La principal razón de realizar buenas predicciones es la toma de decisiones mediante la evaluación de resultados en diversos escenarios posibles. Bajo el enfoque de regresión lineal, el pronóstico puntual está dado por $\mathbb{E}[Y] = \beta' \mathbf{X}$.

Si se utiliza una transformación funcional, la expresión del pronóstico cambia. Para una regresión log-lineal:

$$\mathbb{E}[Y] = \exp\left(\beta' \mathbf{X} + \frac{1}{2} S_{\varepsilon}^2\right) \quad (1.14)$$

donde S_{ε}^2 es la varianza muestral de ε .

El error de pronóstico contiene dos componentes: errores residuales (dispersión de los datos) y errores de muestra. El error estándar del pronóstico para una nueva observación $\mathbf{x}_0$ se calcula como:

$$\text{sef}(\mathbf{x}_0) = s \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0 + 1} \quad (1.15)$$

A partir del error estándar del pronóstico se construyen intervalos de predicción. Un intervalo de predicción al $(1 - \alpha) \cdot 100\%$ de confianza para una nueva observación se define como:

$$\hat{y}_0 \pm t_{\alpha/2, n-k-1} \cdot \text{sef}(\mathbf{x}_0) \quad (1.16)$$

donde $t_{\alpha/2, n-k-1}$ es el cuantil de la distribución t -Student con $n - k - 1$ grados de libertad. Este intervalo es más amplio que el intervalo de confianza de la media, porque incorpora la incertidumbre adicional asociada a la variabilidad de una observación individual. A medida que $\mathbf{x}_0$ se aleja de la media muestral de los regresores, el intervalo de predicción se ensancha, reflejando mayor incertidumbre en la extrapolación.

1.6.4 Principios generales de pronóstico

1. Incluir todas las variables que se esperan que contribuyan al pronóstico: A diferencia del enfoque anterior, no se está buscando el entendimiento de los parámetros sino predecir.
2. Evaluar si algunas variables pueden ser agregadas para crear índices: Puede suceder que varias variables capturan un mismo fenómeno, y por ende causar ruido en la predicción. Para evitar esto, se puede construir una variable que las agrupe a todas en una sola componente.
3. Para variables importantes agregar interacciones: Puede que exista un efecto conjunto no observado.

La evaluación de la inclusión de variables explicativas según su signo esperado y significancia estadística sigue esta regla:

Table 1.5: Guía de decisión según signo y significancia.

<i>Signo</i>	<i>Significativa</i>	<i>Acción</i>
Esperado	Sí	Mantener
Esperado	No	Mantener
Contrario	Sí	Revisar modelo, puede causar ruido
Contrario	No	Considerar más datos y/o variables

Ejercicio guiado. Al evaluar la inclusión de una variable en base a su signo esperado y significancia estadística, ¿cuál de los siguientes casos NO es una buena recomendación para un modelo de pronóstico?

- a. Si el parámetro tiene el signo esperado y no es significativo: mantener.
- b. Si el parámetro no tiene el signo esperado y no es significativo: eliminar.

- c. Si el parámetro no tiene el signo esperado y es significativo: tratar de hacer ajustes al modelo o juntar más datos y variables.
- d. El parámetro tiene el signo esperado y es significativo: mantener.
- e. Ninguna de las anteriores.

Ver solución

Respuesta correcta: e. Ninguna de las anteriores. Por ejemplo: si no tiene signo esperado y no es significativo, la recomendación también puede ser mantener.

1.6.5 Modelos lineales generalizados

Los modelos lineales generalizados (GLM) extienden la regresión clásica permitiendo que la variable dependiente siga distribuciones distintas de la normal y que la relación con los predictores opere a través de una función de enlace. Los parámetros se estiman típicamente por máxima verosimilitud. Tres casos frecuentes en marketing son:

- *Regresión de Poisson*: modela conteos no negativos (número de visitas a una tienda, cantidad de reclamos por mes). Asume que la media condicional es igual a la varianza; cuando esta condición no se cumple se recurre a extensiones como el modelo binomial negativo.
- *Regresión logística*: modela proporciones o probabilidades de éxito (tasa de conversión, respuesta a una campaña). La función de enlace logit garantiza predicciones en el intervalo $[0, 1]$.
- *Mínimos cuadrados generalizados (GLS)*: relaja el supuesto de errores i.i.d. del modelo clásico, permitiendo heterocedasticidad o correlación serial en los residuos. Es especialmente útil en datos de panel o series de tiempo.

Ejercicio guiado. ¿Qué diferencia un modelo de regresión simple de un modelo de regresión de Poisson? (Puede seleccionar más de una opción).

- i. La especificación de la distribución del término de error.
- ii. Los métodos disponibles para estimar el modelo.
- iii. La naturaleza de la variable dependiente.
- iv. La posibilidad de realizar t-tests.

Ver solución

Respuestas correctas: i., ii. y iii. La especificación de la distribución del error, los métodos disponibles para estimar el modelo y la naturaleza de la variable dependiente.

1.7 Alternativas de Machine Learning para la regresión

El aprendizaje automático (*machine learning*, ML) agrupa algoritmos que aprenden patrones directamente de los datos sin requerir una especificación funcional explícita por parte del analista (Hastie et al., 2009; James et al., 2021). Si bien la regresión también aprende de los datos, la necesidad de seleccionar variables, aplicar transformaciones y verificar supuestos estadísticos la hace menos automática. Un acercamiento más próximo a ML se da al utilizar técnicas como Ridge o LASSO. En este curso se entenderá como ML cualquier modelo que pueda aprender automáticamente sobre el conjunto de variables predictivas y sus formas funcionales. A continuación se presentan las alternativas más relevantes.

1.7.1 Multivariate Adaptive Regression Splines (MARS)

MARS extiende OLS generando para cada variable independiente x una función bisagra (*hinge*) $h(x, a) = \{\max\{0, x - a\}, \max\{0, a - x\}\}$. De esta forma, un modelo MARS genera una aproximación lineal por tramos:

$$\begin{aligned}\text{OLS: } y &= \beta_0 + \beta_1 x \\ \text{MARS: } y &= \gamma_0 + \gamma_1 \max\{0, x - a\} + \gamma_2 \max\{0, a - x\}\end{aligned}$$

Además, MARS puede incluir multiplicaciones entre dos o más funciones bisagras para diferentes predictores, capturando la interacción entre estos. MARS busca secuencialmente el punto en el rango de x donde dos relaciones lineales diferentes logran un error más pequeño, y elimina términos que provoquen una contribución marginal pequeña para evitar el sobreajuste.

El algoritmo opera en dos fases: una fase de avance (*forward pass*), donde se agregan términos de forma codiciosa (*greedy*), y una fase de retroceso (*backward pass*), donde se podan los términos con menor contribución según un criterio de validación cruzada generalizada (GCV).

Una ventaja importante de MARS es que detecta automáticamente no linealidades sin necesidad de especificar la forma funcional a priori, y cada término bisagra tiene un punto de corte identificable, lo que mantiene la interpretabilidad del modelo. Sin embargo, dado que la búsqueda es codiciosa, no se garantiza encontrar el óptimo global, y el rendimiento puede deteriorarse en espacios de alta dimensionalidad. MARS se aplica preferentemente sobre variables continuas; las categóricas requieren codificación numérica previa.

1.7.2 K Nearest Neighbors Regression (KNN)

En la regresión con KNN, el objetivo es predecir un valor numérico basándose en la similitud entre los puntos de datos. A diferencia de la regresión lineal,




Figure 1.4: Regresión MARS para distinto número de bisagras

KNN no realiza una aproximación paramétrica. Dado un nuevo punto $\mathbf{x}_0$, el algoritmo identifica los k puntos más cercanos en el conjunto de entrenamiento y predice:

$$\hat{y}_0 = \frac{1}{k} \sum_{i \in \mathcal{N}_k(\mathbf{x}_0)} y_i \quad (1.17)$$

donde $\mathcal{N}_k(\mathbf{x}_0)$ es el conjunto de los k vecinos más cercanos a $\mathbf{x}_0$. Los hiperparámetros a ajustar son:

1. *Vecinos más cercanos (k)*: número de vecinos que se tomarán en cuenta para hacer una predicción. El valor de k se calibra típicamente mediante validación cruzada.
2. *Pesos*: la ponderación que recibe cada vecino (uniforme o proporcional a la cercanía).
3. *Distancia*: la métrica utilizada (euclidiana, Manhattan, coseno, Mahalanobis).

Una ventaja del enfoque es que no requiere suponer una forma funcional y resulta conceptualmente simple y flexible. Sin embargo, sufre la maldición de la dimensionalidad: en espacios de alta dimensión, las distancias entre puntos tienden a homogeneizarse y el algoritmo pierde poder predictivo. Además, la predicción es lenta con conjuntos de datos grandes (requiere calcular distancias a todos los puntos de entrenamiento) y es sensible a variables irrelevantes que distorsionan la métrica de distancia. KNN opera con variables numéricas (las categóricas requieren codificación previa, por ejemplo *one-hot encoding*) y es

recomendable estandarizar las variables para que todas contribuyan equitativamente a la métrica de distancia.

1.7.3 Árboles de regresión

Los árboles de regresión pertenecen a la familia de modelos de *función de base adaptativa* (Tobar, 2024), donde la predicción se expresa como $f(\mathbf{x}) = \sum_{k=1}^K w_k \phi_k(\mathbf{x})$ con funciones base ϕ_k que se adaptan a los datos. En el caso de un árbol, cada ϕ_k es una función indicadora de una región del espacio y w_k es la media de y en esa región.

El **algoritmo CART** (*Classification and Regression Trees*) construye el árbol de forma recursiva: en cada nodo, busca la variable j y el punto de corte t que dividan los datos en dos regiones $R_1 = \{(\mathbf{x}_i, y_i) : x_{ij} \leq t\}$ y $R_2 = \{(\mathbf{x}_i, y_i) : x_{ij} > t\}$, minimizando la suma de costos:

$$\min_{j,t} \left\{ \sum_{i \in R_1(j,t)} (y_i - \bar{y}_{R_1(j,t)})^2 + \sum_{i \in R_2(j,t)} (y_i - \bar{y}_{R_2(j,t)})^2 \right\} \quad (1.18)$$

Este procedimiento se aplica recursivamente hasta alcanzar un criterio de parada (profundidad máxima, número mínimo de observaciones en un nodo, o reducción de costo insuficiente).

El resultado es un modelo altamente interpretable, donde cada nodo tiene una regla de decisión explícita, y que detecta automáticamente interacciones y no linealidades. Además, los árboles manejan variables numéricas y categóricas de forma nativa. No obstante, su principal limitación es la alta varianza: pequeños cambios en los datos pueden alterar significativamente la estructura del árbol. La búsqueda voraz tampoco garantiza encontrar el árbol óptimo global (problema NP-completo), y sin restricciones de profundidad tienden al sobreajuste.




Figure 1.5: Región de ejemplo




Figure 1.6: Árbol de ejemplo

1.7.4 Bagging y Random Forests

Un problema central de los árboles de regresión es su alta varianza: pequeños cambios en los datos pueden producir árboles muy distintos. La técnica de *Bagging* (Bootstrap Aggregation) (Tobar, 2024) aborda este problema promediando múltiples modelos entrenados sobre muestras bootstrap:

1. **Bootstrap:** se generan B conjuntos de datos $\{\mathcal{D}^{(b)}\}_{b=1}^B$ mediante muestreo con reemplazo del conjunto original.
2. **Entrenamiento independiente:** se ajusta un árbol profundo a cada muestra $\mathcal{D}^{(b)}$.
3. **Agregación:** la predicción final es el promedio de los B árboles:

$$\hat{f}_{\text{bagging}}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(\mathbf{x}) \quad (1.19)$$

En la práctica, los B árboles pueden estar correlacionados si una variable predictora es dominante (aparece siempre en el nodo raíz). El **Random Forest** resuelve esto introduciendo aleatoriedad adicional: en cada nodo de cada árbol, solo se consideran m variables seleccionadas aleatoriamente (de las p disponibles) para elegir el mejor corte. Esto *decorrelaciona* los árboles y reduce la varianza del promedio. Se recomienda típicamente $m \approx p/3$ para regresión y $m \approx \sqrt{p}$ para clasificación (Tobar, 2024).

Formalmente, si la correlación entre árboles es ρ y cada uno tiene varianza σ^2 , la varianza del bagging es $\rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$. Al reducir ρ mediante la selección aleatoria de variables, la varianza del ensamble disminuye.

El resultado es una reducción significativa de la varianza respecto a un solo árbol, con robustez a valores atípicos y sin necesidad de supuestos distribucionales. El modelo también permite estimar la importancia relativa de las variables y escala bien con el número de predictores. Al igual que los árboles, opera con variables numéricas y categóricas. Como contrapartida, el ensamble pierde la interpretabilidad del árbol individual (se convierte en un modelo de “caja negra”) y tiene mayor costo computacional.

1.8 Resumen

Conceptos clave: regresión, OLS, supuestos del modelo clásico, estimación, propiedades BLUE, transformaciones de variables, selección de variables (stepwise, LASSO, Ridge), selección de índices, jerarquías, descomposición sesgo-varianza, validación cruzada.

Decisiones de modelamiento: nivel de agregación, descomposición en submodelos, transformaciones funcionales, inclusión de efectos fijos, interacciones, elección entre parsimonia e interpretabilidad.

Modelos de ML como alternativa: MARS (aproximación lineal por tramos), KNN (basado en similitud), árboles de regresión (partición del espacio con CART), Random Forest (ensamble de árboles con bagging y selección aleatoria de variables).

Errores comunes:

- Confundir correlación con causalidad al interpretar $\hat{\beta}$.
- Extrapolar fuera del rango de los datos observados.
- Ignorar multicolinealidad al incluir predictores redundantes.
- Interpretar β en escala log como si fuera escala nivel.
- Usar R^2 para comparar modelos con distinto número de variables sin ajustar por complejidad.
- No separar datos de entrenamiento y validación al evaluar modelos.

Referencias principales: Wooldridge (2019), James et al. (2021), Hastie et al. (2009), Tobar (2024).

1.9 Problemas

Problema 1: Efecto de la pandemia en ventas

Un reconocido grupo empresarial que manufactura productos de aseo y limpieza le pide evaluar el impacto de la pandemia en sus ventas a partir del registro obtenido por distintas tiendas distribuidas a lo largo del país.

El foco del análisis es la variable q_{ist} , correspondiente al número de unidades vendidas del producto i en la tienda s en el día t . Junto a las ventas se cuenta con un vector de características z_t que describe cada día t , entre ellas FDS_t (fin de semana) y FER_t (feriado). También se tiene el vector x_{ist} con características que varían según producto, tienda y día, entre ellas $PRECIO_{ist}$ y $QUAR_{st}$ (si la comuna donde se encuentra la tienda estaba en cuarentena).

1. Formule un modelo de regresión lineal que capture los siguientes factores:
 - a. Existe un efecto fijo por producto y por tienda, es decir, la línea base de las ventas es distinta para cada producto dependiendo de la tienda.

- b. Si un producto no se vende en un día dado es probable que haya un quiebre de stock, y si hay quiebre, es probable que el día siguiente siga quebrado.
 - c. El conjunto $\mathcal{PN}$ registra todos los productos de primera necesidad. Las cuarentenas no tienen efecto en los productos de primera necesidad.
 - d. El efecto de las cuarentenas puede ser distinto para las ventas de un día de semana con respecto a un fin de semana.
 - e. El nivel de progresión de las infecciones ($InfMV_{st}$) afecta el nivel de ventas.
 - f. El nivel de progresión de las infecciones afecta las ventas a través de cuánto han variado las infecciones con respecto a una semana atrás.
2. Considere los siguientes dos modelos con los resultados resumidos en la tabla (parámetro y error estándar en paréntesis). ¿Cuál de los dos modelos recomendaría usar?

Table 1.6: Comparación de modelos de regresión.

	M1	M2
Quar	-0.06 (0.02)	-0.07 (0.01)
FER	0.11 (0.03)	0.12 (0.02)
FDS	0.14 (0.02)	0.13 (0.02)
Quar x FER	0.07 (0.02)	0.06 (0.03)
Quar x FDS	0.06 (0.03)	0.08 (0.01)
Npar	23	27
R^2	0.63	0.69
R^2_{adj}	0.62	0.61
RMSE train	0.34	0.33
RMSE test	0.34	0.38

3. Inspeccionando los resultados del modelo de regresión lineal que consideró en la parte anterior, ¿cómo describiría el rol que han jugado las cuarentenas en las ventas de la firma?

Solución

1. Se agregan progresivamente un término adicional a la regresión:

$$\begin{aligned}
 q_{ist} = & \alpha_{is} + \beta_1 \cdot \mathbf{1}_{[q_{ist-1}=0]} \\
 & + \beta_2 \cdot QUAR_{st} \times \mathbf{1}_{[i \notin \mathcal{PN}]} \\
 & + \beta_3 \cdot QUAR_{st} \times FDS_t \\
 & + \beta_4 \cdot InfMV_{st} + \beta_5 \cdot (InfMV_{st} - InfMV_{st-7})
 \end{aligned}$$

Observación: El modelo anterior puede permitir algunas variantes. Por ejemplo, aunque la condición (a) indique que existe un factor fijo por tienda y producto, una variante (no tan correcta) es considerar por separado los factores. Esto es, en vez de tomar α_{is} se elige $(\alpha_i + \alpha_s)$.

También, al considerar la condición (c) al momento de abordar el factor en (d), se puede decir que el efecto de las cuarentenas en los fines de

semana no afecta a los productos de primera necesidad (como lo dice la condición (c)). De este modo, este factor se puede considerar como $\beta_3 \cdot QUAR_{st} \times FDS_t \times \mathbf{1}_{[i \notin \mathcal{PN}]}$.

2. El modelo 1 es mejor que el modelo 2 en casi todas las métricas relevantes, excepto en R^2 . Esto se explica porque el modelo 2 tiene más parámetros; el R^2_{adj} corrige este efecto. Además, el RMSE test del modelo 2 es mayor, sugiriendo sobreajuste.
3. Las cuarentenas tienen un efecto negativo significativo en las ventas durante los días de semana. Sin embargo, este efecto se va a cero los fines de semana y es marginalmente positivo para feriados.

Problema 2: Ventas de un cine

Un cine pequeño quiere impulsar la venta de entradas para este verano. Para atraer de manera eficiente a los clientes deciden ser selectivos en las películas que tendrán en cartelera. Para ello, desean determinar las características de las películas que provocan un mayor ingreso. El equipo de ventas dispone de un panel de datos con el historial de las 3,800 funciones del año de las 1,250 películas presentadas con los siguientes datos:

Table 1.7: Resumen de ventas para cada función.

Variable	Descripción	Media
IdFunción	Identificador de la función	-
Fecha	Fecha de la función	-
Hora	Hora de la función	-
Película	Nombre de la película	-
Duración	Duración [minutos]	103.32
Tipo	{Base, Acción, Comedia, Romance, Drama, Terror}	-
Edad	{Base, TE, TE+7, MA+14, MA+18}	-
Estudio	{Base, Dis, WB, Para, Uni}	-
Presupuesto	Presupuesto [CLP]	160,200,000
Ingreso	Ingreso por entradas [CLP]	714,500

Para tener una mejor idea de cómo se ven los datos, se pueden observar estos 6 registros:

Table 1.8: Ejemplo de 6 registros en Tabla de Ventas.

Id _i	Fecha _i	Hora _i	Pelíc.	Dur.	Tipo	Edad	Est.	Presup.	Ingr.
14156	23/07/22	19:00	Odín 4	105	Acción	TE+7	Dis	354,97M	948,64k
14157	23/07/22	22:00	Chillido 5	132	Terror	MA+18	Para	135,60M	804,30k
14158	24/07/22	11:00	Odín 4	105	Acción	TE+7	Dis	354,97M	893,00k
14159	24/07/22	15:30	Desafiar B.	158	Romance	MA+14	WB	94,50M	569,20k
14160	24/07/22	20:15	Odín 4	105	Acción	TE+7	Dis	354,97M	832,15k
14161	25/07/22	11:00	Desafiar B.	158	Romance	MA+14	WB	94,50M	452,90k

1. Nótese que una película puede tener varias funciones y que, debido a la naturaleza de las variables, el rango de valores y el tipo de variables son

distintos. Debido a esto, elija un nivel de agregación y transforme las variables de forma que puedan modelar el éxito total en ventas para cada película.

2. El equipo escogió como variable dependiente el logaritmo de la suma de los ingresos de las funciones para cada película y generó dos modelos distintos, entregando los siguientes resultados:

Table 1.9: Resultados de comparación de modelos.

	M1 Coef.	M1 p-valor	M2 Coef.	M2 p-valor
Intercepto	-15.2	0.704	3.1	0.161
Duración	-1.04	0.452	-0.23	0.004
log(Presupuesto)	0.62	0.005	1.15	0.001
Edad.TE	4.5	0.058	-	-
Edad.TE+7	6.71	0.020	-	-
Edad.MA+14	5.16	0.017	-	-
Edad.MA+18	4.04	0.009	-	-
Tipo.Acción	-	-	4.05	0.520
Tipo.Comedia	-	-	1.63	0.017
Tipo.Romance	-	-	2.11	0.110
Tipo.Drama	-	-	-1.52	0.025
Tipo.Terror	-	-	6.72	0.001
Estudio.Dis	5.12	0.004	-	-
Estudio.WB	4.09	0.240	-	-
Estudio.Uni	3.14	0.104	-	-
Estudio.Para	-0.63	0.186	-	-
LL			-644	-650
AIC		1,304		1,295
BIC		1,366		1,350

A partir de los datos entregados elija cuál modelo es mejor para predecir el número de entradas vendidas para una película y entregue 3 argumentos de porqué lo considera mejor.

3. Interprete los coeficientes de cada modelo. Según cada modelo, ¿qué tipo de películas debería presentar el cine para tener mayores ingresos?
4. Suponga que en su base de datos posee también la variable independiente $NFun$ que representa el número de funciones que recibió la película en el cine. Proponga un modelo de regresión lineal que considere las siguientes condiciones:
 - a. Se debe considerar el efecto marginal por parte de las variables Presupuesto, Duración, Edad, Tipo, Estudio y $NFun$.
 - b. Existe un efecto en las ventas que depende simultáneamente del estudio y el Tipo de película (por ejemplo, el estudio WB puede tener más éxito con películas de terror, mientras que Dis lo puede tener con aquellas de acción).
 - c. El éxito de las películas apropiadas para niños ($Edad \in \{TE, TE+7\}$) depende de su duración.

Solución

1. Nótese que una película puede tener varias funciones y que, debido a la naturaleza de las variables, el rango de valores y el tipo de variables son distintos. Para evaluar el ingreso total en ventas obtenido por una película, se deben considerar los ingresos a nivel película. De modo que se define el ingreso para la película j como la suma del éxito de todas sus funciones i :

$$Ingreso_j = \sum_i Ingreso_i \cdot \mathbf{1}_{[Nombre_i=j]}$$

Cabe notar que las características de la película ($Presupuesto_i$, $Duración_i$, $Tipo_i$, $Edad_i$, $Estudio_i$) se mantienen para cada función i de la película j , de modo que $Presupuesto_j = Presupuesto_i$ para toda función de la película j (lo mismo para las demás características). De este modo, se tiene un vector de características por película ($Presupuesto_j$, $Duración_j$, $Tipo_j$, $Edad_j$, $Estudio_j$).

Finalmente, nótese que los valores de $Ingreso_j$ y $Presupuesto_j$ son muy elevados en comparación con la variable $Duración_j$. Similarmente, el rango no se compara con el valor de las variables dummy generadas por las categorías $Tipo_j$, $Edad_j$ y $Estudio_j$. Debido a esto, se decide estudiar el comportamiento del logaritmo de estos montos: $\log(Ingreso_j)$ y $\log(Presupuesto_j)$.

Para ser más claros, a partir de los 6 registros mostrados en la Tabla 1.8, la tabla con las transformaciones apropiadas tendría la siguiente forma:

Table 1.10: Transformaciones a nivel de película para los registros de ejemplo.

Película _j	Duración _j	Tipo _j	Edad _j	Estudio _j	log(Pre _j)	log(Ing _j)
Odín 4	105	Acción	TE+7	Dis	8.55	6.43
Chillido 5	132	Terror	MA+18	Para	8.13	5.91
Desafiar Barreras	158	Romance	MA+14	WB	7.97	6.01

2. El modelo que explica de manera más efectiva el comportamiento es el modelo 2. Se pueden considerar varias razones para esto:

- A pesar del modelo 1 tener una mejor log-verosimilitud, el BIC del modelo 2 es mejor que el del modelo 1.
- La cantidad de parámetros del modelo 1 es mayor (11 vs 8), por lo que se podría argumentar que se prefiere el modelo 2 por su parsimonia. Este argumento se refuerza al mirar la métrica BIC.
- Una gran parte de los coeficientes del modelo 1 son no significativos a un 5% de confianza, mientras que los coeficientes del modelo 2 tienden a ser menores a 5%.
- La significancia de las variables que ambos modelos comparten posee un p -valor menor en el modelo 2, de modo que sus intervalos de confianza deberían ser más acotados. Lo anterior, a pesar de algunas

variables no ser significativas al 5%, es un hecho positivo respecto al modelo 2.

- Pensando en la interpretación, el modelo 1 posee algunos comportamientos discutibles: se esperaría, por ejemplo, que la duración tenga un efecto negativo y significativo en los ingresos. Sin embargo, el modelo la considera no significativa.
 - Los valores de intercepto en el modelo 1 están demasiado desviados en magnitud respecto al resto de coeficientes. Lo anterior podría dar indicios de algún error en cuanto al escalamiento de las variables al momento de calibrar el modelo.
3. Primero, se observan aquellos coeficientes con mayor significancia estadística. Para eso se consideran aquellos cuyo p -valor sea menor a 0.01.

Para el modelo 1 se tienen las variables $\log(\text{Presupuesto})$, $\text{Edad.MA}+18$ y Estudio.Dis . De acuerdo al signo de los coeficientes, se puede concluir que las películas que generan un mayor ingreso son aquellas con un mayor presupuesto, para mayores de 18 años y producidas por Dis.

En cambio, para el modelo 2, las variables a considerar son Duración , $\log(\text{Presupuesto})$ y Tipo.Terror . Por el signo de los coeficientes, se deben proyectar películas de terror cortas con un alto presupuesto.

Observación: En el modelo 1 sería deseable considerar la variable Duración . Sin embargo, su p -valor alto refleja que no es una variable significativa en este modelo.

4. Las condiciones anteriores implican lo siguiente:
- a. La condición (a) muestra que se deben incluir las variables Presupuesto , Duración , Edad , Género , Estudio y $NFun$ en el modelo, con sus propios coeficientes.
 - b. La condición (b) dice que se debe agregar, además, las variables de estudio condicionadas al género.
 - c. Finalmente, la condición (c) dice que se quiere conocer el impacto de la duración en las películas cuya variable Edad es TE y $TE+7$.

Recuérdese que, para variables categóricas, se deben generar variables dummy para cada categoría. Sea $E = \{TE, TE + 7, MA + 14, MA + 18\}$, $T = \{\text{Acción}, \text{Comedia}, \text{Romance}, \text{Drama}, \text{Terror}\}$ y $S = \{Dis, WB, Uni, Para\}$. A partir de estos conjuntos, se pueden definir las variables dummy:

- $\text{Edad}_{j,e} = 1$ si para la película j , $\text{Edad}_j = e$ para $e \in E$.
- $\text{Tipo}_{j,t} = 1$ si para la película j , $\text{Tipo}_j = t$ para $t \in T$.
- $\text{Estudio}_{j,s} = 1$ si para la película j , $\text{Estudio}_j = s$ para $s \in S$.

De este modo, el modelo que cumple las condiciones mencionadas sería:

$$\begin{aligned}
\log(\text{Ingreso}_j) = & \beta_1 \log(\text{Presupuesto}_j) + \beta_2 \text{Duración}_j + \sum_{e \in E} \beta_e \text{Edad}_{j,e} \\
& + \sum_{t \in T} \beta_t \text{Tipo}_{j,t} + \sum_{s \in S} \beta_s \text{Estudio}_{j,s} + \beta_3 \text{NFun}_j \\
& + \sum_{t \in T} \sum_{s \in S} \gamma_{t,s} (\text{Tipo}_{j,t} \times \text{Estudio}_{j,s}) \\
& + \sum_{e \in \{TE, TE+7\}} \delta_e (\text{Edad}_{j,e} \times \text{Duración}_j)
\end{aligned}$$

Se puede realizar una notación vectorial de los coeficientes para tener una notación más concisa, pero se debe tener en cuenta los índices de estos coeficientes, de modo que el largo del vector sea la cantidad de coeficientes a buscar.

Problema 3: Programa de recompensas

Debido a la gran variedad de alternativas que tiene el consumidor para satisfacer sus necesidades, empresas de distintos sectores han buscado formas de fidelizar a sus clientes mediante programas de recompensas. Estos programas proponen premiar al consumidor con relación a su nivel de actividad, con el fin de que estos sean más leales a la firma. A continuación, nos proponemos estudiar el comportamiento de los consumidores que están inmersos en un programa de recompensas en el cual se acumulan puntos al comprar en alguna de las tiendas de la cadena, al comprar en alguna alianza comercial asociada, o utilizando la tarjeta del banco aliado a la cadena. Cuando el consumidor tiene una cantidad suficiente de puntos acumulados puede canjear algún producto que se ofrece en un catálogo, o puede hacer uso de sus puntos como medio de pago al momento de comprar cualquier producto disponible en tienda.

Para modelar los comportamientos anteriores, se cuenta con información demográfica de cada consumidor que es actualmente parte del programa, y cada una de las transacciones que ha realizado desde su inicio, como se observa en las Tablas 1.11 y 1.12:

Table 1.11: Variables Demográficas.

Variable	Descripción
IDCliente	Identificador del cliente
Ingreso	Ingreso del cliente
AñoInicio	Año en el que el cliente se une al programa
TamañoHogar	Número de personas que componen el hogar del cliente
Género	1 si el cliente es hombre
Edad	Edad del cliente
Categoría	Silver, Gold o Premium

Table 1.12: Variables Transaccionales.

Variable	Descripción
IDCliente	Identificador del cliente
Año	Año de la observación
Mes	Mes de la observación
Acreditación	Cantidad de puntos acreditados por el cliente en el mes t
Canje	Cantidad de productos canjeados por el cliente en el mes t
TipoAcreditación	Tiendas Propias, Comercios Asociados o Tarjeta Bancaria
TipoCanje	Producto o Descuento
Promoción	1 si hubo promo o descuentos adicionales en el mes t
Mail	1 si se avisó estado de cuenta al cliente via mail en el mes t

1. Como primera aproximación, se propone modelar la acreditación (A_{it}) y canje (C_{it}) de cada cliente i en el mes t como:

$$A_{it} = \alpha + \alpha_i + \alpha_t + \beta X_{it} + \dots + \epsilon_{it} \quad (1.20)$$

$$C_{it} = \gamma + \gamma_i + \gamma_t + \rho Z_{it} + \dots + \xi_{it} \quad (1.21)$$

Donde X_{it} y Z_{it} son covariables construidas a partir de la información disponible.

- a. ¿Cuál es la interpretación de los parámetros α_i , α_t , γ_i y γ_t ?
 - b. ¿Son los modelos anteriores identificables? En caso de ser su respuesta negativa, ¿cómo se corrige el problema?
2. Suponga que se han identificado los modelos anteriores (de requerirlo, con las restricciones necesarias para alcanzar identificación). Derive una expresión que permita calcular el número esperado del saldo de punto de un cliente i en cualquier período de tiempo t .
 3. Proponga especificaciones de los modelos de regresión que permitan capturar que:
 - a. El impacto que tiene informar el estado de cuenta de los puntos depende del género.
 - b. Los niveles de actividad (acreditación y canje) de un cliente varían significativamente de acuerdo a su categoría.
 - c. El nivel de actividad (acreditación y canje) depende de la antigüedad de los clientes en el programa, pero aquellos que llevan más años tienden a tener un comportamiento similar.
 4. Suponga ahora que se han estimado tres especificaciones para entender el comportamiento de acreditación (A_{it}), donde f representa alguna transformación o función de la información disponible, y cuyos resultados se encuentra en la tabla siguiente:

Table 1.13: Resultados Modelos Regresión.

Variable	Modelo 1	Modelo 2	Modelo 3
α_0	35.9 (12.8)	37.1 (8.6)	32.7 (11.5)
$f(\text{Ingreso})$	12.7 (5.1)	—	10.7 (2.9)
$f(\text{Edad})$	-1.5 (0.6)	-1.2 (2.3)	-0.6 (0.3)
$f(\text{Mail})$	—	-0.3 (0.2)	-1.9 (5.1)
$f(\text{Promoción})$	—	15.1 (6.7)	10.9 (4.2)
$f(\text{TiendasPropias})$	—	10.1 (3.7)	8.9 (2.1)
$f(\text{ComerciosAsociados})$	—	3.6 (2.5)	2.9 (2.3)
R^2 Ajustado	0.34	0.53	0.55
MAPE	45.5%	20.9%	23.4%

- ¿Qué variables ayudan a explicar el comportamiento de acreditación de los consumidores?
- ¿Cuál es el medio en que se acreditan o acumulan, en promedio, menos puntos?
- Justifique cuál de los modelos anteriores es mejor.

Solución

- Incluye:
 - Los parámetros α_i y γ_i representan el efecto fijo de cada consumidor, o el nivel promedio de actividad en creditación y canje, respectivamente, independiente de las demás covariables. Los parámetros α_t y γ_t representan un efecto fijo temporal en los niveles de acreditación y canje, respectivamente, cuya interpretación dependerá de la definición de la variable que acompañe (si las covariables son meses representaría estacionalidad, mientras que si es fecha o año representaría alguna tendencia en los niveles anteriores).
 - Al estar las constantes α y γ , junto con los parámetros anteriores, se produce un problema de colinealidad y por lo tanto los parámetros no son identificables. Para corregirlo, se debe omitir α y γ , u omitir α_i y γ_i para un individuo y especificar dummies desde $i = 1$ hasta $i = I - 1$.
- Sabemos que $\mathbb{E}(Y|X) = X'\hat{\beta}_{OLS}$. Luego, el balance promedio se obtiene como:

$$\mathbb{E}\left(\sum_{\tau=1}^t A_{\tau} - \sum_{\tau=1}^t C_{\tau} \mid X, Z\right) = \sum_{\tau=1}^t (\alpha_i + \alpha_t + X'\beta) - \sum_{\tau=1}^t (\gamma_i + \gamma_t + Z'\rho) + \epsilon_i$$

- Incluye:
 - Se debe incorporar una interacción entre las variables de *Mail* y *Género*.
 - Se debe transformar la variable categórica en dummies y omitir uno de los niveles para no tener variables colineales.

- c. Se debe construir la variable logaritmo de antigüedad como $\ln(\text{Año}_t - \text{AñoIngreso}_t)$

$$X'\beta = \beta_1 \text{Mail}_i \text{Genero}_i + \beta_2 1_{[\text{categoria}_i = \text{Gold}]} + \beta_3 1_{[\text{categoria}_i = \text{Premium}]} + \beta_4 \ln(\text{Año}_t - \text{AñoIngreso}_t) + \epsilon'_i$$

4. Detalle:

- Las variables que son significativas independiente del modelo en el que fueron estimadas, y que permiten explicar el comportamiento de interés, es decir, *Ingreso*, *Promoción*, y *TiendasPropias*.
- El parámetro asociado al medio *TarjetaBancaria* fue fijado en cero (para evitar problemas de colinealidad), y como el resto de los parámetros son positivos, es aquel en que menos puntos se acreditan.
- La respuesta dependerá del criterio de evaluación. Si se quiere evaluar en cuanto a la capacidad de ajuste, el mejor es aquel con mayor R^2 Ajustado (M3), pero si se evalúa en cuanto a la capacidad de pronóstico, se prefiere aquel con menor MAPE (M2).

Problema 4: Precios internacionales de arriendo

En un contexto de globalización, movilidad laboral y teletrabajo, comparar el costo de vida entre países se ha vuelto una preocupación frecuente para profesionales y estudiantes. Aunque la fracción de ciudadanos chilenos que deciden estudiar en el extranjero son aún limitadas, hoy en día existen amplias posibilidades tanto desarrollo académico como laboral más allá de las fronteras nacionales. Ciertamente, la decisión de emigrar es de alto involucramiento y requiere evaluar una multitud de factores. A continuación, el análisis se concentra en describir el costo del precio de arriendo de propiedades inmobiliarias en distintas ciudades del mundo.

Para estudiar las diferencias de precio de arriendos, un grupo de investigadores construyó una base de datos internacional de precios de propiedades en más de 50 ciudades de América Latina, Norteamérica y Europa. La información fue recolectada haciendo un barrido histórico en un conjunto amplio de portales especializados de corretaje. La base considera los siguientes campos.

- **ID:** Identificador de la propiedad.
- **Ciudad:** ciudad.
- **País:** país.
- **Año:** Año en la que se registra el precio de la propiedad.
- **PrecioUSD:** precio publicado de la propiedad en USD.
- M^2 : superficie en metros cuadrados.
- **Dorms:** número de dormitorios.
- **Baths:** número de baños.
- **Centro:** distancia (km) al centro de la ciudad.

- **Residencial:** 1 si la propiedad es residencial (0 si es comercial).
- **AñoConstrucción:** año de construcción de la propiedad.
- **CiudadIPC:** ingreso per cápita promedio de la ciudad (USD PPP).
- **CiudadPob:** Población total de la ciudad.
- **CiudadSup:** Superficie total de la ciudad.

El objetivo es comparar precios de propiedades entre países y explorar diferencias sistemáticas entre países, mientras controlamos por factores estructurales de las ciudades y características de las propiedades.

1. Formule un modelo de regresión para describir el log-precio (en USD) de una propiedad en una ciudad dada, en un instante del tiempo y con una lista de características definida.

Para esto considere que:

- a) Existe un efecto fijo por país-año, que permite establecer si, condicional en las características de la propiedad y la ciudad dónde está emplazada, ciertos países tienen niveles de precios mayores que otros en un año dado.
 - b) La superficie, la antigüedad, el número de dormitorios y el número de baños afectan linealmente en el log-precio, pero la magnitud en que aumenta el precio al variar estas características es distinta dependiendo de si la propiedad es residencial o comercial.
2. Adicional a lo ya expuesto, se considera que la magnitud en que el precio por metro cuadrado aumenta es mayor para ciudades más densamente pobladas. ¿Cómo modificaría el modelo ya propuesto para considerar esta descripción?
 3. Considere ahora que las expectativas de variación de precio importan. Indique cómo modificaría el modelo anterior para considerar que el log-precio se ve afectado linealmente por la variación del precio en los dos años anteriores en esa ciudad. Si necesita crear variables adicionales, explique cómo se calcularían a partir de la base de datos.
 4. En todos los modelos anteriores se ha usado como variable dependiente el log-precio en USD. Discuta qué limitaciones tiene esa variable para comparar qué tan abordable es la vivienda entre distintos países y proponga al menos una métrica alternativa que pudiera usarse para la comparación.
 5. Considerando que los precios pueden variar año a año, interesa considerar estimadores agregados de varios años. Sea lnP_{kt} el log-precio esperado para una propiedad en el país k en el año t (que se obtiene a través del producto punto entre estimadores máximo-verosímiles y las características promedio de las propiedades del país k en el año t). Explique cómo testearía que los precios de Chile son distintos a los de Argentina considerando los últimos 3 años.
 6. Disconformes con la capacidad de pronóstico de los modelos lineales, se

postula que algunos modelos sencillos de aprendizaje de máquina podrían generar mejores resultados. Para ello se considera usar un modelo de k-vecinos más cercanos. Defina una métrica de distancia y determine si la propiedad B o la propiedad C es más cercana a la propiedad A.

Table 1.14: Muestra de datos de 3 propiedades de arriendo en Chile.

Propiedad	Tiene Piscina	Tiene Calefacción Central	Tiene Estacionamiento	Ciudad
A	Sí	Sí	Sí	Santiago
B	No	No	Sí	Concepción
C	Sí	Sí	No	Antofagasta

Solución

- Se indexa cada precio como P_{ijkt} representando la observación i del país j en la ciudad k en el año t .
 - Para el efecto fijo basta incluir un coeficiente α_{jt} asociado a cada combinación país-año. Aunque no es lo que dice el enunciado, se puede dar 0.4 puntos a quienes incluyan un par de coeficientes aditivos $\alpha_j + \alpha_t$.
 - Para las otras variables se agregan términos lineales, más la interacción con el tipo de propiedad.

$$\begin{aligned} \ln(P_{ijkt}) = & \alpha_{jt} + \beta_1 M2_{ijkt} + \beta_2 Dorms_{ijkt} + \beta_3 Bath_{ijkt} \\ & + \beta_4 M2_{ijkt} \cdot Residencial_{ijkt} + \beta_5 Dorms_{ijkt} \cdot Residencial_{ijkt} \\ & + \beta_6 Bath_{ijkt} \cdot Residencial_{ijkt} + \varepsilon_{ijkt} \end{aligned}$$

- Es necesario redefinir los índices β_1 y β_4 para que dependan de la densidad poblacional.

$$\beta_1 \rightarrow \gamma_1 + \gamma_2 \cdot \frac{CiudadPob_{ijkt}}{CiudadSup_{ijkt}} \quad \text{y} \quad \beta_4 \rightarrow \gamma_3 + \gamma_4 \cdot \frac{CiudadPob_{ijkt}}{CiudadSup_{ijkt}}$$

- Para poder ingresar al modelo es necesario calcular el precio de la ciudad de cada año. Se define

$$AVGP_{kt} = \sum_{h=k} P_{ijht},$$

como el precio promedio de la ciudad k en el año t . Con esto, el modelo puede expandirse agregando un término adicional.

$$\beta_7 \cdot (AVGP_{kt-1} - AVGP_{kt-2})$$

También se considera correcto considerar la diferencia de los dos precios en t y $t - 1$ respectivamente.

4. Hay al menos dos consideraciones a tener en cuenta, aunque con nombrar cualquiera es suficiente:

- Los precios pueden estar explicados por variaciones en el tipo de cambio y no en cambios del costo en las monedas corrientes. En este caso, se podría normalizar por un promedio de tipo de cambio en un horizonte más largo.
- Los precios pueden ser altos en valores absolutos, pero no serlo relativos a los ingresos. En este caso se podría normalizar por los ingresos, i.e. usar:

$$\frac{P_{ijkt}}{CiudadIPC_{ijkt}}.$$

5. Por definición $\ln P_{kt} = \theta' \bar{x}_{kt}$, en que $\bar{x}_{kt}$ son las características promedio de las propiedades del país k en el año t . Por lo tanto, la diferencia promedio entre Chile y Argentina en el año t puede escribirse como $\theta' \bar{x}_{k=Chile,t} - \theta' \bar{x}_{k=Argentina,t}$. Si se quiere evaluar si esta diferencia es estadísticamente distinta de cero, se puede plantear el contraste de hipótesis $H_0 : \theta' \bar{x}_{k=Chile,t} - \theta' \bar{x}_{k=Argentina,t} = 0$ contra $H_1 : \theta' \bar{x}_{k=Chile,t} - \theta' \bar{x}_{k=Argentina,t} \neq 0$.

Para esto, se estima el modelo sin restricciones y luego el modelo restringido por la hipótesis nula. Con ambos modelos se construye el estadístico F de restricciones lineales conjuntas, el cual compara la pérdida de ajuste que se produce al imponer H_0 . Finalmente, se revisa el p -valor asociado al estadístico: si este es suficientemente pequeño, se rechaza H_0 y se concluye que la diferencia $\theta' \bar{x}_{k=Chile,t} - \theta' \bar{x}_{k=Argentina,t}$ es estadísticamente distinta de cero.

6. La clave de la pregunta es notar que las variables categóricas siempre pueden transformarse a numéricas a través de la generación de variables dummies (e.g. $Piscina_{ijkt} = 1$, si la propiedad tiene piscina, 0 en caso contrario). Con esto se puede utilizar cualquier medida de distancia (incluyendo euclidiana), aunque la más simple es una distancia de Manhattan o de Hamming que simplemente cuenta en cuántas dimensiones los puntos tienen distinto valor.

En este caso:

- $d(A, B) = 3$ (A y B difieren en tres atributos)
- $d(A, C) = 1$ (A y C difieren en un atributo)

por lo que C sería el vecino más cercano a A.

Problema 5: Búsqueda visual vs. texto en e-commerce

Las tecnologías tradicionales de búsqueda basadas en texto han sido durante mucho tiempo uno de los pilares del comercio electrónico, permitiendo a los usuarios ingresar palabras clave para encontrar productos. Sin embargo, en

un entorno de comercio digital en rápida evolución, donde el comportamiento del consumidor se orienta hacia experiencias más interactivas y multimedia, están ganando terreno tecnologías de búsqueda más avanzadas. En particular, la búsqueda visual representa un avance innovador, que permite a los consumidores iniciar búsquedas utilizando imágenes en lugar de texto. Al cargar una imagen en la herramienta de búsqueda, los algoritmos más avanzados de aprendizaje profundo analizan sus características visuales para identificar y recuperar productos relevantes. Estos mecanismos sofisticados generan sugerencias amplias, que incluyen productos similares y ofertas relacionadas de otras marcas.

Las plataformas líderes han sido fundamentales en el desarrollo y perfeccionamiento de la búsqueda visual. Pinterest fue pionera en esta tecnología en 2014, permitiendo a los usuarios seleccionar segmentos de una imagen para encontrar contenido visualmente similar. Otros actores relevantes, como Google (con Google Lens) y Bing (con Bing Visual Search), han desarrollado tecnologías similares. Grandes minoristas como Amazon y Aliexpress también han adoptado esta funcionalidad para mejorar la precisión del emparejamiento. La reducción en los costos tecnológicos han facilitado su acceso, permitiendo que proveedores emergentes como Impresee y Visidea ofrezcan soluciones de búsqueda visual fácilmente integrables en sitios de comercio electrónico.

En este problema buscaremos comparar la búsqueda visual con la búsqueda tradicional basada en texto, en términos de comportamiento de clics y conversiones. El análisis empírico se basa en un conjunto de datos que abarca más de 2 millones de búsquedas realizadas por cerca de 50.000 usuarios. Complementamos esta base con etiquetas y métricas de similitud derivadas de avances recientes en visión computacional, lo que nos permite controlar por la complejidad de las imágenes y la similitud entre la imagen de entradas y los productos resultantes. Estadísticas preliminares indican que, en comparación con las búsquedas por texto, las búsquedas por imagen presentan una mayor tasa de clics (CTR), y que los clics se concentran más en los resultados mejor posicionados. Este patrón podría sugerir que quienes buscan por imagen estarían en etapas más avanzadas del proceso de compra, con menor necesidad de explorar alternativas. Sin embargo, al analizar las conversiones, el mayor CTR no parece traducirse en un aumento de ventas, de modo que las búsquedas por texto están asociadas con tasas de conversión más altas.

1. Plantee un modelo de regresión para describir el número de clics del usuario i en el producto j en la instancia de búsqueda k , que permita entender las diferencias dependiendo de si la búsqueda se realiza usando imágenes o texto. Para eso considere que:
 - El *ranking* o posición en el listado de búsqueda afecta en los clics de modo que los productos listados primero tienen muchos más clics que aquellos listados después. Notar que la tasa a la que se degradan los clics con el *ranking* es distinta dependiendo de que la búsqueda sea por imágenes o texto.

- La complejidad de la búsqueda importa en los clics generados. Para las búsquedas por texto, la complejidad se puede capturar a partir del largo del texto. Para las imágenes se puede medir por el tamaño de la imagen.
 - Cada producto tiene una propensión a clics base distinta. Hay algunos productos populares que tienen a recibir más clics que otros menos populares, independientemente de los inputs de la búsqueda.
2. A partir de sus resultados de regresión, ¿cómo determinaría (explique con sus palabras) si el número total de clics generado por un producto en la quinta posición en una búsqueda por imágenes es mayor que los generados por el producto en la quinta posición de una búsqueda por texto?
 3. Considere que los modelos de regresión confirman que, aunque haya un efecto en clics, este no se traduce en más conversiones. A la luz de este resultado, parece interesante estudiar si las búsquedas de imágenes quizás generan búsquedas adicionales que generen más conversiones. Esto es, que las imágenes sean usadas en una etapa temprana del embudo de compras, ayudando a encontrar la categoría de productos, las que después se refinarían haciendo búsquedas tradicionales de texto. Formule un modelo de regresión que permita identificar si una búsqueda de imagen aumenta o no el número de búsquedas siguientes. Para esto, suponga que para cada instancia de búsqueda k del usuario i , se puede calcular $NNextSearch_{ik}$, que cuenta el número total de búsquedas hechas por el mismo usuario, dentro de la misma categoría, durante el mismo día de la búsqueda k . Para su modelo de regresión considere que, junto con el tipo de búsqueda, debe controlar por:
 - La categoría de productos, considerando que cada búsqueda se asocia principalmente a una única categoría, y cada categoría de productos tiene una mayor o menor propensión a ser buscadas. Por ejemplo, la categoría *juguetes* en general tiene más búsquedas que la categoría *colchones*.
 - El número de resultados reportados en la búsqueda $NumResult$ y el número de categorías distintas reportadas en la búsqueda $NumProdCat$. Considere que tanto $NumResult$ como $NumProdCat$ ya están calculados en la base de trabajo.
 - El número de búsquedas diarias que en promedio hace el cliente $AvgNumSearch$ (que puede suponer conocido).
 4. Suponga que, después de un par de iteraciones, se ha determinado que existen dos especificaciones de modelos lineales que funcionan relativamente bien, como indican los resultados de la tabla.
 - a) ¿Cómo interpreta los resultados de la variable $NumResult$ en el contexto de esta aplicación?

- b) ¿Cómo interpreta el dramático aumento en el valor de R_{adj}^2 entre las especificaciones (1) y (2)?

Variable dependiente: $\ln(\text{NumSubsequentSearch} + 1)$

Table 1.15: Resultados de modelos de regresión de búsquedas posteriores.

Coefficiente	(1)	(2)
IMAGE	-4.595*** (0.012)	-0.375*** (0.007)
NumResult	-0.081*** (0.000)	-0.003*** (0.000)
NumProdCategory	0.031*** (0.001)	0.00138** (0.000588)
LogImageSize	-0.075*** (0.018)	0.001 (0.010)
NumImageObject	0.023* (0.011)	-0.003 (0.007)
NumImageLabel	0.055*** (0.017)	0.003 (0.010)
KeywordLength	-0.018*** (0.000)	-0.001*** (0.000)
AvgNumSearch	1.85E-6*** (6.86E-8)	-1.03E-7** (3.28E-8)
Efecto fijo: User	No	Yes
Efecto fijo: Product Category	No	Yes
Observations	1,715,495	1,715,495
R_{adj}^2	0.19	0.825

Solución

1. Detalles de variables:

- Se incluye una variable con Ranking_{ijk} y su interacción con el tipo de búsqueda. Notar que hay dos tipos de búsqueda de carácter dummy. Para modelarlo, se debe incorporar un coeficiente para cada tipo (Imagen y texto).
- Hay que incluir el tamaño de la imagen ImageSize_{ik} y el largo del texto TextLength_{ijk} .
- Hay que incluir un efecto fijo por producto α_k .

Así, si C_{ijk} es el número de clics que recibe el producto j en la búsqueda k del cliente i, el modelo queda descrito como:

$$C_{ijk} = \alpha_k + \beta_1 \text{Image}_{ik} + \beta_2 \text{Rank}_{ijk} + \beta_3 \text{Image}_{ik} \cdot \text{Rank}_{ijk} \\ + \beta_4 \text{Image}_{ik} \cdot \text{ImageSize}_{ik} + \beta_5 (1 - \text{Image}_{ik}) \cdot \text{TextLength}_{ijk} + \varepsilon_{ijk}$$

2. Se puede utilizar un test F para evaluar que el grupo de variables de Image , Ranking y $(1 - \text{Image})$ sean distintos en su conjunto.
3. Si se define CAT_{ihk} como las dummy que toman el valor 1 si la búsqueda k del usuario i está asociada a la categoría h, entonces el modelo de regresión puede escribirse como:

$$N\text{NextSearch}_{ik} = \left(\sum_h \alpha_h CAT_{ihk} \right) + \beta_1 \text{Image}_{ik} + \beta_2 \text{NumResult}_{ik} \\ + \beta_3 \text{NumProdCat}_{ik} + \beta_4 \text{AvgNumSearch}_i + \epsilon_{ik}$$

4. Detalle:

- a. Los coeficientes son significativamente negativos en ambas especificaciones. En el contexto de la aplicación, esto sugiere que aquellas búsquedas que generan más resultados, están relacionadas a un menor número de búsquedas posteriores.
- b. La diferencia entre las especificaciones (1) y (2) es que la segunda tiene efectos fijos, tanto por usuario como por categoría de producto. Como esta segunda especificación tiene un R^2_{adj} mucho mayor, concluimos que la categoría y el usuario explican gran parte de la variabilidad en el número de búsquedas posteriores.

Problema 6: Retail y telecomunicaciones

Una de las características más relevantes de los ambientes de negocio contemporáneos, es la disponibilidad de grandes cantidades de información respecto al comportamiento de clientes. Es así como día a día aparecen nuevas fuentes de información que las compañías están constantemente incorporando a sus plataformas de analítica avanzada. *Whileus* es un conglomerado que tiene la representación de varias marcas internacionales con un centenar de tiendas en el país y está interesado en investigar si los datos derivados del uso de dispositivos móviles pueden ayudar a entender el volumen de ventas de las distintas tiendas. Para eso ha firmado un acuerdo de colaboración con una importante compañía de telecomunicaciones que posee datos de tráfico, posición y uso de aplicaciones de varios millones de clientes en todo el territorio nacional, que podría ser informativa respecto la demanda de las marcas de *Whileus*. El propósito del acuerdo es evaluar, en el plazo de un mes y a través de un prototipo a cargo de la empresa de telecomunicaciones, si la incorporación de estas nuevas variables permite generar aprendizajes valiosos para el estudio de la demanda de las tiendas de *Whileus*.

En la primera semana del piloto y después de una reunión técnica entre los equipos de *Whileus* con la empresa de telecomunicaciones se acuerda extraer los datos de los data lakes de las respectivas compañías a nivel de zona censal. Esto se fundamenta porque la provisión de datos de movilidad de individuos específicos podría poner en entredicho el uso de información privada de los usuarios. Así, luego de consolidar las bases de datos, se han propuesto los siguientes modelos de regresión para describir el número de visitas a la tienda k desde la zona censal i en la semana t q_{ikt} .

$$q_{ikt} = \alpha_i^1 + \beta_t^1 + \gamma^1 d_{ik} + \theta^1 z_k + \varepsilon_{ikt}^1 \quad (1)$$

$$q_{ikt} = \alpha_k^2 + \beta_t^2 + \gamma^2 d_{ik} + \theta^2 w_i + \varepsilon_{ikt}^2 \quad (2)$$

En estas especificaciones, d_{ik} corresponde al logaritmo de la distancia entre la tienda k y el centroide de la zona censal i , mientras que z_k y w_i son un conjunto de características de la tienda k y la zona censal i respectivamente. Para esta

primera iteración se ha considerado que z_k incluye la superficie de la tienda, un conjunto de variables binarias para denotar la marca y una última variable binaria para indicar si la tienda se encuentra dentro de un centro comercial o no. Para las variables de la zona censal, se ha considerado que w_i incluye el número de habitantes, la comuna en la que habita la zona censal, la fracción de usuarios que tienen instalada una app de las marcas y una variable binaria para indicar si la zona censal está a menos de 250 metros de alguna estación de metro.

1. Comente las ventajas teóricas de cada una de las formulaciones. Si prefiere, puede responder la pregunta argumentando en qué escenarios prefería una formulación y en cuales preferiría la otra.
2. En la Tabla 1 se despliegan los resultados de un primer ejercicio de regresión para los dos modelos anteriormente planteados. Por simplicidad, se ha considerado solo una muestra de tiendas y zonas censales. Como el modelo se ha estimado usando una técnica de descentrado, los efectos fijos no se reportan en la Tabla 1.
 - a. ¿Cómo es posible que, usando los mismos datos, las ecuaciones 1 y 2 nos reporten distintos estimadores del efecto de la distancia en la demanda de cada zona censal por cada marca?
 - b. ¿Qué información necesita para construir un intervalo de confianza para el efecto que tiene la superficie de la tienda en su demanda? Si fuera posible, reporte el valor numérico de este intervalo de confianza usando los datos de la tabla.
 - c. Si el objetivo del análisis sería tener el pronóstico más preciso de la demanda en cada tienda, ¿cómo elegiría entre estos dos modelos?
 - d. ¿Cómo testearía si hay diferencias significativas en la demanda por marca?

Table 1.16: Resultados de modelos alternativos de regresión.

Variable	Ecuación 1	Ecuación 2
Log-Distancia	-2.123 ***	-2.817 ***
Superficie	0.234 *	
Marca A	0.245 .	
Marca B	1.567 **	
Marca C	0.453 .	
Mall	2.145 ***	
Nhabitantes		3.234 ***
Fracusuarios		0.881 **
Providencia		1.233 **
Santiago		0.029
Macul		-0.913 *
La Florida		-0.372 .
Estación Central		-1.409 *
Metro		1.199 ***
Efectos fijos: Zona censal	Yes	No
Efectos fijos: Tienda	No	Yes
N. Obs	34,207	34,207
R^2	0.234	0.489
$R^2_{adj.}$	0.233	0.482

3. Para evaluar la capacidad de los modelos para apoyar la gestión del negocio, el equipo de desarrollo quiere generar algunos pronósticos con la demanda para la próxima semana para cuatro tiendas seleccionadas. Para esto, necesita ajustar la propuesta inicial de modo que los efectos temporales sean controlados por una lista de variables temporales z_t que incluyen un pronóstico del clima, tendencia, estacionalidad mensual, la intensidad de la actividad promocional de la marca, así como la intensidad de la actividad promocional de otras marcas competidoras. Considerando que variables como el clima y la actividad promocional son inciertas, se ha generado un reporte con tres escenarios: uno pesimista, uno neutro y otro optimista. Mientras en el escenario neutro se considera que las variables independientes toman valores típicamente observados, los escenarios pesimistas y optimistas se evalúan en combinaciones más extremas que favorecen y desfavorecen la demanda respectivamente. Los pronósticos generados se despliegan en la siguiente tabla.

Table 1.17: Pronóstico de demanda para cuatro tiendas seleccionadas.

Tienda	Ec. 1			Ec. 2		
	Pesim.	Neutro	Optim.	Pesim.	Neutro	Optim.
A01	316,6 (11,8)	345,1 (7,2)	392,1 (12,1)	318,5 (12,2)	352,1 (6,7)	387,7 (10,9)
A12	555,8 (12,2)	578,8 (8,1)	602,2 (11,8)	547,6 (11,0)	566,3 (9,1)	607,7 (11,6)
B09	834,4 (14,3)	888,9 (9,2)	965,4 (13,3)	811,4 (15,9)	874,9 (8,9)	954,7 (13,8)
B14	733,9 (13,6)	786,6 (8,4)	822,3 (12,8)	728,6 (11,5)	791,9 (8,7)	817,8 (12,6)

En la tabla anterior, junto con los pronósticos se despliegan los errores estándar de pronóstico (*sef*). Explique por qué los *sef* son en general menores en los escenarios neutros.

4. Habiendo revisado la primera ronda de resultados, el equipo de desarrollo se inclina por concentrarse en el modelo dado por la ecuación 1. Sin embargo, a partir de la retroalimentación de los gerentes de tienda, se reconoce que hay varios elementos adicionales que deben incorporarse. Formule un modelo de regresión lineal que expanda la ecuación (1) pero que considere los siguientes factores:
- Las tiendas en los centros comerciales suelen ser más grandes, por lo que es esperable que la superficie de la tienda tenga una influencia distinta dependiendo si la tienda está o no en un mall.
 - Para zonas censales relativamente cercanas, la distancia es un buen indicador del costo de acceder. Sin embargo, si la distancia es mayor que d^* , entonces es mejor considerar el tiempo de viaje v_{ik} .
 - El efecto de la cercanía al metro es distinto si la tienda está en un mall o no.
 - En la muestra hay marcas que son de destino u otras de conveniencia. Una marca de destino se caracteriza por clientes muy leales dispuestos a viajar con el propósito principal de visitar la tienda de esa marca. Por su parte, las marcas de conveniencia son visitadas principalmente por clientes que se encuentran con la tienda al paso. Considere que,

en el modelo, el efecto del tiempo de viaje depende de si la marca es de destino o conveniencia.

- La variable $Fracusuarios_i$ se define como la fracción de habitantes de la zona censal i que tiene instalada alguna app de cualquiera de las marcas de *Whileus* al momento de hacer el pronóstico. Los resultados de la Tabla 2 indican que, entre mayor es el número de usuarios de las aplicaciones móviles, mayor es la demanda de esa zona censal. Sin embargo, es esperable que esta variable sea endógena. Es decir, que no sea el uso de las aplicaciones las que empujan la demanda, sino que es la demanda la que impulsa el uso de las aplicaciones. Sugiera alguna modificación al modelo para aminorar la endogeneidad del uso de las aplicaciones.

Solución

1. La diferencia principal es que uno describe el efecto de características de las tiendas (Ecuación 1), mientras que la otra describe el efecto de las características de la zona censal (Ecuación 2). Es preferible (1) si el foco está en entender qué características de la tienda inciden en el tráfico, y (2) si el foco está en entender qué características de las zonas censales son las que generan más tráfico.
2. Cada pregunta tiene respuestas bastante directas:
 - a. Los estimadores dan cuenta del valor esperado de la variable dependiente **condicional** en la realización de las otras variables. Cada vez que cambiamos el conjunto de las variables sobre las que se condiona, es esperable que cambien los estimadores.
 - b. Se requiere (una estimación de) los errores estándares. Como no están reportados en la tabla, no es posible calcular su valor numérico.
 - c. Si el objetivo es pronóstico, habría que calibrar el modelo en una muestra de calibración y evaluarlo en una muestra retenida de validación. La evaluación típicamente consideraría métricas como MAE o MAPE.
 - d. Por medio de una prueba F. Por ejemplo, si se desea evaluar si hay diferencia entre las marcas A y C, es posible testear la hipótesis lineal $\beta_A - \beta_C = 0$.
3. Los errores estándares de pronóstico dependen de las variables explicativas. Técnicamente el error de pronóstico considera tanto un error residual como uno de muestreo. Este último crece al alejarse de los valores típicos de muestreo.
4. La ecuación 1, por extensión puede escribirse como:

$$q_{ikt} = \alpha_k^1 + \beta_t^1 + \gamma^1 d_{ik} + \theta^{1'}(\text{Superficie}_k, B_k, C_k, Mall_k) + \varepsilon_{ikt}^1$$

Donde el 1 es un superíndice para indicar que provienen del primer modelo, B_k y C_k son variables binarias que indican la marca de cada tienda (para que sea identificable, se debe eliminar una marca). Sobre este modelo debemos:

- Agregar $\text{Superficie}_k \cdot \text{Mall}_k$ en la función que integra $\theta^{1'}$.
 - Reemplazar el término de la distancia por $\gamma_1^1 d_{ik} 1_{[d_{ik} < d^*]} + \gamma_2^1 v_{ik} 1_{[d_{ik} > d^*]}$.
 - Agregar $\text{Metro}_i \cdot \text{Mall}_k$.
 - Agregar $v_{ik} \cdot \text{Conveniencia}_k \cdot 1_{[d_{ik} > d^*]}$ (donde $\text{Conveniencia}_k = 1$ si marca es de conveniencia) y $v_{ik} \cdot (1 - \text{Conveniencia}_k) \cdot 1_{[d_{ik} \leq d^*]}$.
5. Aunque hay otras ideas admisibles, el fraseo de la pregunta parece sugerir la solución más directa que es agregar la dinámica de adopción. Esto es, agregar un índice temporal a la variable Fracusuarios_{it} de modo de representar cómo varía en el tiempo. Así, es posible observar cómo cambia la demanda en periodos de mayor o menor uso de las aplicaciones. Observaciones:
- a. Un nivel mayor de sofisticación podría sugerir usar $\text{Fracusuarios}_{it-1}$ y/o $\text{Fracusuarios}_{it-2}$. La inclusión de rezagos presupone que la adopción antecede las compras.
 - b. Esta especificación puede ayudar a aminorar los problemas de endogeneidad, pero no los soluciona del todo. Si hay un momento específico en que se lanza la app, o si hay algunas campañas específicas que solo se promocionan a través de las apps, podrían dar elementos adicionales para reducir la endogeneidad del constructo.

Problema 7: Agentes de IA para servicio al cliente bancario

Uno de los cambios más relevantes de los últimos años, en ambientes de negocio y en la sociedad en su conjunto, ha sido la irrupción de las inteligencias artificiales (IA) generativas. En simple, las inteligencias artificiales generativas son un tipo de inteligencia artificial que puede crear contenidos nuevos, incluyendo conversaciones, historias, imágenes, videos e incluso música. Entre las ventajas de estas tecnologías es su capacidad de comprender matices del lenguaje no estructurado que les permite dar respuestas a entornos complejos. A continuación, exploraremos el potencial uso de estas tecnologías para generar sistemas automatizados de atención de clientes en la industria bancaria.

Muchas de las aplicaciones de estas tecnologías de IA generativas se basan en modelos fundacionales que son modelos de machine learning entrenados en un amplio espectro de datos generalizados y por tanto son capaces de realizar una amplia variedad de tareas generales. Los modelos de generative pre-trained transformer (GPT) de OpenAI son precisamente un ejemplo de un modelo fundacional. Aunque los modelos fundacionales tienen capacidades generales de lenguaje, en general no logran el nivel de especificidad requeridos para dar servicio a los clientes. Por ejemplo, un modelo de GPT no sabrá cuáles son las políticas internas de cada banco para resolver cada tipo de requerimiento de sus

clientes. Para dotar a las IA generativas de este conocimiento contextual, se puede hacer una etapa liviana de entrenamiento o de *fine tuning*.

En este proyecto, investigamos el rendimiento de diferentes estrategias de entrenamiento sobre el desempeño de un asistente virtual basado en IA generativas en el contexto de la industria bancaria, donde tener el control de las respuestas es especialmente sensible para las empresas. En específico se consideraron tres estrategias de entrenamiento:

- **Prompt 1:** Se instruye al agente con una lista breve y resumida de cómo debe reaccionar a los requerimientos de los usuarios.
- **Prompt 2:** Se instruye al agente con una lista detallada de cómo debe reaccionar a los requerimientos de los usuarios.
- **Prompt 3:** Se instruye al agente con una lista detallada de cómo debe reaccionar a los requerimientos de los usuarios y se le indica que solo puede responder desde un conjunto acotado de respuestas.

Para entender el desempeño de distintas estrategias de entrenamiento se diseñó un experimento en que se le pidió a un grupo de usuarios de tarjetas de crédito que, en una serie de escenarios, interactuara libremente con un agente basado en IA generativas para resolver preguntas asociada a un desconocimiento de transacción. Un desconocimiento de transacción ocurre cuando un cliente revisa su cartola de cuentas e identifica una transacción que no reconoce como propia. Al terminar cada interacción se les preguntó a los participantes una serie de preguntas para entender cómo evaluaban la interacción con el agente digital.

Como resultado de estas interacciones se generó una base de datos con las siguientes columnas:

- **customer_id:** Identificador del participante dentro del experimento.
- **task_id:** Identificador del escenario.
- **age:** Edad del participante.
- **sex:** Sexo del participante.
- **NSE:** Nivel socioeconómico del participante.
- **prompt_type:** Tipo de prompt asignado en el experimento.
- **resolutivity:** Resolutividad percibida por el participante.
- **confidence:** Confianza percibida por el participante en la correctitud de la información.
- **experience:** Satisfacción percibida por el participante.
- **efficacy_input:** Eficacia de comprensión de mensajes percibida por el participante.
- **efficacy_output:** Eficacia de generación de respuestas percibida por el participante.
- **interaction_time:** Duración total de la interacción del participante con el agente.
- **cus_res_time:** Tiempo promedio que tarda en responder el participante en la interacción.
- **agt_res_time:** Tiempo promedio que tarda en responder el agente en

la interacción.

- **n_messages**: Número de mensajes en la interacción.
- **n_words**: Número de palabras promedio por mensaje.

Adicionalmente, considerando las normativas del banco, cada interacción fue examinada para determinar el porcentaje de errores cometido por el agente. El experimento consideró la participación de 643 clientes a cada uno de los cuales se les pidió interactuar con el agente digital en tres escenarios distintos con lo que se tiene un total de 1,929 filas en la base de datos.

1. La compañía está considerando usar un(os) modelo(s) de regresión para medir el impacto de distintas estrategias de entrenamiento. Considerando que el sistema está diseñado para dar servicio de atención a los clientes del banco, ¿cuál cree usted que debieran ser las variables dependientes para analizar en un modelo de regresión?
2. Sea y_{ik} la variable de desempeño que usted considera relevante para el participante i ($i \in \{1, \dots, 643\}$) en el escenario k ($k \in \{1, 2, 3\}$). Formule un modelo de regresión que permita evaluar el desempeño de las distintas estrategias y que considere las siguientes componentes:
 - Algunos escenarios podrían ser más fáciles o más difíciles por lo que el agente podría tener desempeños sistemáticamente diferentes por tareas.
 - Los usuarios de mayor edad tienden a tener una peor actitud hacia este tipo de tecnología y por tanto hacer peores evaluaciones de desempeño.
 - Si la interacción con el agente virtual es muy corta, probablemente los usuarios evalúen el desempeño como insuficiente. Del mismo modo, si la interacción es muy larga los usuarios en general tenderán a tener malas evaluaciones de desempeño.
 - Aunque no hay diferencias en los niveles generales de la evaluación de desempeño entre género, en general los hombres tienden a preferir interacciones más cortas que el resto de los géneros.
3. ¿Qué limitaciones tiene el modelo anteriormente planteado para el entendimiento de la pregunta de investigación? ¿Cómo recomendaría corregir estas limitaciones?
4. Para una parte del análisis, se consideraron tres modelos de regresión que se reportan en la Tabla 1.
 - a) De acuerdo a los resultados de estos modelos de regresión, ¿qué rol juega las distintas estrategias de entrenamiento en el desempeño del agente virtual?
 - b) ¿Cómo podríamos determinar el impacto de la introducción de restricciones en la estrategia de entrenamiento?

Table 1.18: Resultados de modelos de regresión de agentes de IA.

Variable	Experiencia (Coeficiente)	Resolutividad (Coeficiente)	Porcentaje Errores (Coeficiente)
Intercepto	0.025	0.146	4.675
Prompt 2	-0.079 **	-0.157 ***	-4.965 **
Prompt 3	-0.005	0.109 **	-0.262
Eficacia entrada	0.174 ***	0.155 ***	0.541
Eficacia salida	0.100 ***	-0.030	1.400
Confianza	0.720 ***	0.786 ***	0.508
Tiempo Interacción	-0.006	-0.024 ***	0.094
Num Mensajes	0.007 **	0.020 ***	0.224
Edad	-0.002	-0.003 **	0.044
Mujer	0.027	-0.038	0.030
N. obs	1,929	1,929	126
R^2	0.798	0.709	0.220
$R^2_{adj.}$	0.796	0.707	0.105

Fuente: Hernández, F. (2024): “Agentes inteligentes basados en Large Language Models para la atención automatizada en canal conversacional online de servicio al cliente en una empresa financiera”. Memoria para optar al título de Ingeniero Civil Industrial.

Solución

- 1) La respuesta más clara es la satisfacción de los usuarios (Experience). Sin embargo, resulta a todas luces insuficiente. Es necesario tener un acercamiento hacia la reflexión de los siguientes puntos:
 - a) El agente debe seguir un conjunto de procedimientos definidos institucionalmente y por tanto es necesario mirar los errores cometidos. Los agentes de IA son conocidos por alucinar y podrían dejar satisfecho al usuario entregándole respuestas que son inconvenientes por la firma.
 - b) Uno de los motivos de la automatización es que el agente pueda resolver sin la necesidad de derivar los casos a un agente humano. Desde el punto de vista de la costo-efectividad, también es importante mirar su resolutividad.
- 2) El modelo de regresión puede expresarse como:

$$\begin{aligned}
 y_{ik} = & \sum_{e \in \{2,3\}} \theta_e 1_{ei} + \alpha_k + \beta_1 Age_i \\
 & + \beta_2 NW_{ik} + \beta_3 NW_{ik}^2 + \beta_4 Sex_i \\
 & + \beta_5 NW_{ik} Sex_i + \varepsilon_{ik}
 \end{aligned}$$

Donde:

- a) La variable 1_{ei} toma el valor 1 si el usuario i es asignado a la estrategia de entrenamiento e y por tanto θ_e captura el efecto que tiene la estrategia de entrenamiento e . Notar que, para que el modelo sea identificable se requiere excluir una estrategia.
- b) El efecto fijo α_k controla por diferencias entre tipos de escenarios.

- c) El término β_1 permite controlar que la evaluación dependa de la edad.
 - d) Los términos β_2 y β_3 permiten capturar el efecto no lineal del largo de la interacción. En esta especificación se utiliza el número de palabras (NW_{ik}), pero el número de mensajes es una alternativa posible.
 - e) El término β_4 captura el efecto de ser hombre, sumando al efecto de β_5 que captura la interacción entre el largo de la interacción y el sexo hombre.
- 3) Hay varias limitaciones, pero probablemente se puedan agrupar en las dos siguientes líneas:
- a) Respecto al diseño de investigación. Por ejemplo, el diseño solo compara tres estrategias específicas, pero no se sabe cuál sería el desempeño de una nueva estrategia de entrenamiento.
 - b) Respecto al modelo de regresión. Por ejemplo, hay factores que no se controlan como el NSE o, si se considera más de una variable de desempeño, cuál es la relación entre estos factores.
- 4) Las respuestas se derivan directo de las tablas.
- a) Los coeficientes del Prompt 2 es significativo en las tres variables de desempeño consideradas y por tanto esa estrategia de entrenamiento tiene peor resolutiveidad y satisfacción, pero también un menor número de errores procedurales. Similarmente, el Prompt 3 tiene una mayor resolutiveidad que la estrategia de entrenamiento base, pero las diferencias no son significativas en la satisfacción ni en los errores procedurales.
 - b) Habría que testear si $\theta_2 = \theta_3$ (por ejemplo, si $\theta_2 > \theta_3$ en la ecuación de satisfacción usuaria, implicaría que incluir restricciones en la estrategia de entrenamiento empeora la evaluación. Como el objeto a testear son restricciones lineales, entonces puede hacerse con una prueba F.

Nota: Para los curiosos, los p-valores de los test para las tres ecuaciones son (0.066, 0.000 y 0.016) por lo que si se considera un 95% las restricciones solo tendrían un impacto en la resolutiveidad.

Problema 8: Plataforma de streaming musical

Con el desarrollo de los canales digitales, muchas industrias han *desintermediarizado* la distribución de productos y servicios. Este es precisamente el caso de la industria musical en que tanto artistas consagrados como independientes pueden subir directamente su música a plataformas como Spotify, Deezer o Youtube Music. Junto con el cambio en la estructura de distribución, las plataformas digitales proveen información detallada para entender los factores que afectan la popularidad de cada canción y artista. En esta pregunta usaremos un enfoque de regresión para cuantificar la relación entre distintos factores en la audiencia de cada pieza. Para ello, se cuenta con los registros históricos

de una muestra de 123.456 canciones en una plataforma de distribución musical, en la que se observan las siguientes variables:

- **IdSong**: Identificador único para cada canción.
- **Date**: Fecha del registro.
- **Title**: Título de la canción.
- **Artist**: Intérprete de la canción.
- **Genre**: Género musical al que pertenece la canción (e.g. Rock, Pop, Indie, etc.)
- **Length**: Duración de la canción (medido en segundos).
- **LaunchDate**: Fecha en la que fue lanzada la canción.
- **Nplay**: Número de veces que ha sido escuchada la canción.
- **Tprom**: Tiempo de escucha promedio cada vez que es escuchada una canción.
- **Danceability**: Puntaje [0-1] de qué tanailable es una canción (basada en tiempo y regularidad).
- **Energy**: Puntaje [0-1] de qué tan energética es una canción (basada en timbre y volumen).
- **PromoExpend**: Monto del gasto en promoción dentro de la plataforma para esa fecha.
- **Nfollow**: Seguidores en redes sociales de artista.
- **Top50**: 1 si el artista ha tenido alguna vez una canción en el Top 50 del Billboard.

1. Considere un modelo de regresión lineal genérico

$$y_i = \beta' x_i + \varepsilon_i$$

que cuantifica la relación de una medida de la popularidad de una canción i (y_i), con un conjunto de variables observables de esa canción (x_i). Proponga dos métricas de popularidad. Para cada una de ellas indique una limitación de usar esa variable como indicador del éxito de audiencia de una canción.

Observación: Notar que la base está indexada por la canción y el tiempo, mientras la métrica pedida depende solo de la canción.

2. Describa un modelo de regresión lineal para estimar la popularidad de una canción. Para la construcción de este modelo de regresión considere que:
 - a. Es importante controlar por la popularidad que típicamente tiene cada artista y que las canciones lanzadas más recientemente tienen acceso a un mayor número de usuarios activos en la plataforma.
 - b. Las promociones aumentan la popularidad de las canciones, pero este efecto es acumulativo en el tiempo.
 - c. El efecto de la *danceability* de una canción puede ser positivo para unos géneros, pero negativo para otros.

- d. El efecto del largo de una canción es no lineal en la popularidad: mientras temas muy cortos raramente son muy populares, los temas demasiado largos también tienen dificultades en generar audiencias. Defina cuidadosamente las variables e indique cómo se obtienen a partir de los registros disponibles.
3. Suponga que se estiman tres modelos simples de regresión lineal para describir la popularidad de las canciones dentro de la plataforma. Los resultados de estos modelos se reportan en la siguiente tabla.

Table 1.19: Resultados de modelos alternativos de regresión.

	Modelo 1		Modelo 2		Modelo 3	
Variable	Coef.	SE	Coef.	SE	Coef.	SE
ln(Length)	-0.453	0.001	-0.462	0.023	-0.398	0.024
Promo	5.341	0.562	4.341	0.011	5.101	0.012
Energy	0.138	0.453	3.453	0.003	3.238	0.001
Danceability	2.345	0.002	0.091	0.645	0.192	0.345
NFollow	2.323	0.011	2.421	0.016	1.933	0.008
Top50					1.498	0.011

Fixed Effects

Table 1.20: Efectos fijos incluidos en cada modelo.

	Modelo 1	Modelo 2	Modelo 3
Artist	Yes	Yes	Yes
Year	Yes	Yes	Yes
Genre	No	Yes	Yes

Métricas

Table 1.21: Métricas de ajuste de los modelos.

	Modelo 1	Modelo 2	Modelo 3
Std. Error	5.355	4.307	4.278
R^2	0.296	0.445	0.455
R^2_{adj}	0.286	0.398	0.401

A partir de los resultados anteriores:

- ¿Qué aprendizaje puede derivar a partir de observar los R^2 ?
- ¿Cuál es el intervalo de confianza del 95% para el coeficiente *NFollow* en el modelo 2?
- ¿Qué puede explicar el cambio de significancia de *Energy* y *Danceability* en Modelos 1 y 2?
- ¿Cómo se puede testear que *Danceability* y *Energy*, de manera conjunta tienen un efecto nulo?

Solución

- Algunas posibilidades:

- $y_i^0 = \max\{NPlay_{it}\}_t$, que corresponde al máximo de veces que ha sido escuchada una canción. Una limitación de esta métrica es que las canciones se lanzan en instantes distintos del tiempo y las canciones más antiguas tendrán más escuchas, aunque no sean tan populares.
- $y_i^1 = \max\{NPlay_{it}\}_t / (LaunchDate_i)$. Aquí, el denominador corresponde al tiempo transcurrido desde el lanzamiento y, por lo tanto, la métrica mide el número de reproducciones por unidad de tiempo. Una limitación de esta métrica es que no considera el ciclo de vida del producto (ciclo de reproducción de las canciones). Las canciones recién lanzadas suelen ser muy escuchadas, pero algunas pasan rápidamente de moda.
- $y_i^2 = NPlay_{i, LaunchDate_i+365}$, que corresponde al número de reproducciones un año después de haber sido lanzada la canción. Una limitación de esta métrica es que las plataformas aumentan sus audiencias y, por tanto, favorece a canciones que han sido lanzadas más recientemente.

Hay varias otras posibilidades. Por ejemplo, usar el *share* de reproducciones dentro de la categoría, la desviación de reproducciones con respecto a la canción anterior del artista, etc. Notar que hay algunas métricas que no capturan precisamente popularidad. Por ejemplo:

- $y_i^3 = \max\{NPlay_{it}\} / \sum_t Promo_{it}$, que mide eficiencia promocional y se indefiniría para canciones que no han sido promocionadas.
- $y_i^4 = \sum\{TProm_{it}\} / \text{mean}\{Length_i\}$, que mide el *envolvimiento o lealtad* con la canción. Una canción podría ser escuchada una vez completa y aunque no diríamos que es popular, tendría el máximo en esta métrica.

2. Todas las componentes se agregan más o menos directo en la ecuación:

- Hay que agregar controles de artista ($Artist_i$) y tiempo de lanzamiento ($LaunchDate_i$).
- Hay que agregar el gasto acumulado en promoción ($\sum_t Promo_{it}$).
- Hay que agregar las interacciones entre danzabilidad y género ($Danceability_i \cdot Genre_i$).
- Hay que agregar tanto efectos lineales como cuadráticos ($Length_i + Length_i^2$).

Con esto el modelo puede expresarse como:

$$\begin{aligned}
 y_i = & \alpha_{Artist_i}^1 + \alpha_{LaunchDate_i}^2 + \beta_1 \left(\sum_t PromoExpend_{it} \right) \\
 & + \beta_2 Danceability_i + \beta_3 Genre_i \\
 & + \sum_{g \in \text{genero}} \alpha_g Danceability_i Genre_i + \beta_4 Length_i + \beta_5 Length_i^2
 \end{aligned}$$

3. Cada una de las partes tiene respuestas bastante directas:
 - a. Al comparar el Modelo 1 con el Modelo 2, se observa que el género explica bastante variabilidad en la popularidad. Al comparar el Modelo 2 con el Modelo 3, se observa que la distinción de *Top50* ayuda a explicar una fracción muy menor de la varianza en popularidad.
 - b. El intervalo de confianza viene dado por:

$$(2.421 - 1.96 \cdot 0.016, 2.421 + 1.96 \cdot 0.016)$$

- c. En ambos casos una de las variables es significativa, pero la otra no. Aunque hay otras explicaciones posibles, la más directa es que estas dos variables estén altamente correlacionadas y, por tanto, el efecto conjunto es identificable. Es difícil separar el efecto de una con respecto a la otra.
- d. Se desea testear que $\beta_{dance} = 0$ y $\beta_{Energy} = 0$. Este es un sistema de restricciones lineales que puede testearse directamente a través de una prueba F.

Problema 9: KornerK delivery de supermercado

KornerK introdujo hace un par de años un modelo de negocio innovador en que, a través de una aplicación móvil, los clientes de la industria supermercadista podían hacer sus compras remotamente. Para llevar a cabo sus compras, los clientes listan el conjunto de productos que desean adquirir y ponen una orden a la plataforma, la que contacta a alguno de los numerosos *shoppers* que tiene afiliados, los que se encargan de recoger los productos desde la sala de supermercado y transportarlo hasta el domicilio del cliente. La asignación de *shoppers* se hace considerando la cercanía al domicilio del usuario, por lo que la compañía se ha preocupado de tener suficientes afiliados disponibles para cubrir la demanda en cada geografía y bloque horario.

Después de un par de años de un crecimiento constante, lo que incluye un período de crecimiento explosivo durante los confinamientos de la pandemia, en los últimos meses se ha visto afectado por importantes cambios tanto regulatorios como de los patrones de la demanda. A partir de esta coyuntura, *KornerK* se ha visto obligado a rediseñar su dotación y ha considerado hacer una reducción de hasta un 20% de los *shoppers* en aquellas zonas con mayor caída en la demanda. Con este propósito, se han propuesto analizar los patrones de demanda históricos para hacer un pronóstico de la demanda.

Para sostener el análisis, se ha preparado un set de datos con las ventas agregadas por bloque horario en cada una de las zonas en que opera *KornerK*. En esta base, cada fila se compone de las siguientes variables:

- **IdZip:** Identificador de la zona geográfica.
- **Date:** Fecha en formato dd/mm/yyyy.
- **Hour:** Un entero que representa la hora que define el bloque horario (8, 9, 10, ..., 22).

- **NOrdersC**: Número de órdenes por servicio que fueron exitosamente completadas.
- **NOrdersN**: Número de órdenes por servicio que no pudieron ser completadas por falta de *shoppers*.
- **Day**: Día de la semana que se registra la discrepancia (con lunes=1, hasta domingo=7).
- **Mes**: Correlativo del número de meses desde inicio de operación (1, 2, 3, ...).
- **Rain**: 1 si llovió en el bloque horario.
- **IMACEC**: Variación del índice mensual de actividad económica.

Como ilustración, se muestran las primeras seis entradas en la siguiente tabla.

Table 1.22: Muestra de los primeros 6 registros de la base de datos.

Zip	Fecha	Hr	Compl.	Perd.	Día	Mes	Lluvia	IMACEC
15217	02/01/18	8	248	0	2	1	0	0.02
15217	02/01/18	9	325	0	2	1	0	0.02
15217	02/01/18	10	331	13	2	1	0	0.02
23156	03/01/18	8	1345	1	3	1	0	0.02
23156	03/01/18	9	1221	0	3	1	0	0.02
23156	03/01/18	10	1436	54	3	1	0	0.02

1. Describa un modelo de regresión lineal para estimar la **demanda total** por servicios en cada zona y bloque horario que considere **al menos cuatro** de los siguientes elementos:
 - a) Efectos fijos geográficos para capturar que gran parte de la variabilidad de la demanda se explica por diferencias en los patrones de consumo de las distintas zonas.
 - b) El patrón de demanda a lo largo del día es altamente estacional, por lo que es esperable que la inclusión de efectos fijos por hora sea relevante.
 - c) Aunque hay alguna variación de la demanda dependiendo del día de semana, es despreciable en relación con la diferencia que hay entre días de semana y fin de semana, la que es muy relevante.
 - d) El nivel de actividad económica parece estar positivamente correlacionado con la demanda. Sin embargo, este efecto parece estar rezagado, por lo que parece razonable considerar los valores de actividad económica de los últimos 3 meses.
 - e) La demanda ha ido creciendo sostenidamente a lo largo del tiempo, por lo que se necesita incluir un factor que capture una tendencia de crecimiento lineal de la demanda como función del tiempo.
 - f) La demanda tiende a crecer en los bloques en que llueve. Sin embargo, la magnitud del crecimiento es distinta dependiendo de si es un día de semana o un fin de semana.

Defina cuidadosamente las variables dependientes e independientes e indique cómo se obtienen a partir de los registros disponibles en la base de datos.

2. Suponga que se estiman dos modelos simples de regresión lineal para describir la demanda por servicios de *KornerK*. Los resultados de estos dos modelos se reportan en la siguiente tabla:

Table 1.23: Resultados de modelos alternativos de regresión.

	Modelo 1		Modelo 2		Modelo 3	
Variable	Coef.	p-val	Coef.	p-val	Coef.	p-val
Intercepto	589.415	0.000	-	-	-	-
FinDeSemana	120.732	0.001	89.462	0.023	88.559	0.024
Rain	20.341	0.562	14.341	0.011	11.101	0.012
IMACEC	65.323	0.011	59.021	0.016	62.774	0.019

Fixed Effects

Table 1.24: Efectos fijos incluidos en cada modelo.

	Modelo 1	Modelo 2	Modelo 3
Zip	No	No	Yes
Hour	No	Yes	Yes

Resumen

Table 1.25: Métricas de ajuste de los modelos.

Métrica	Modelo 1	Modelo 2	Modelo 3
Std. Error	5.355	4.307	4.278
R^2	0.196	0.445	0.544
R^2_{adj}	0.186	0.392	0.417

A partir de los resultados anteriores:

- ¿Por qué no se reporta un intercepto para los modelos 2 y 3?
 - ¿Qué modelo explica la mayor varianza de la demanda observada?
 - ¿Qué se puede afirmar con respecto al rol de los efectos fijos regionales para describir la variabilidad en la demanda?
 - ¿Qué rol juega la actividad económica en la demanda por servicios de *KornerK*?
3. Volviendo al problema de gestión al que se enfrenta la compañía, *KornerK* está interesado en evaluar cómo podría impactar la reducción de *shoppers* en la capacidad de responder a la demanda. Para esto, ha elaborado un plan preliminar en que quedarían N_{ith} *shoppers* disponibles para trabajar en el bloque horario h del día t en la zona i .
- Usando el modelo 1, calcule el valor esperado de la demanda para un bloque en un día de semana, en que no llueve y en que hay una variabilidad en la actividad económica del 10% ($IMACEC = 0.1$).
 - Para el mismo bloque horario de la parte anterior, escriba una expresión para calcular la probabilidad de que la demanda total exceda la capacidad disponible expresada para ese bloque $N_{ith} = 600$.

Solución

1. Primero que todo, cabe clarificar que la variable dependiente es la demanda total en una zona i , fecha t y hora h , que corresponde tanto a las órdenes completadas como aquellas que excedieron la capacidad:

$$DT_{iht} = NOrdersC_{iht} + NOrdersN_{iht}$$

En el lado derecho de la regresión se pueden considerar cualquiera de los siguientes puntos:

- Efectos fijos geográficos: α_i^1
- Efectos fijos por hora: α_h^2
- Diferencia entre día de semana y fin de semana: $\beta_1 FDS_t$ donde $FDS_t = 1_{\{Day \in \{\text{Sábado}, \text{Domingo}\}\}}$
- El nivel de actividad económica de los últimos 3 meses $\beta_2 IMACEC_t + \beta_3 IMACEC_{t-1} + \beta_4 IMACEC_{t-2}$. Un modelo admisible es suponer que $\beta_2 = \beta_3 = \beta_4$. En vez de tener un parámetro por cada mes, se tiene un único para el promedio de los tres.
- La demanda ha ido creciendo sostenidamente: $\beta_5 MES_t$
- Lluvia y fin de semana: $\beta_6 RAIN_{th} + \beta_7 RAIN_{th} FDS_t$

Así, la ecuación de regresión que considera todos los factores viene dada por:

$$DT_{iht} = \alpha_i^1 + \alpha_h^2 + \beta_1 FDS_t + \beta_2 IMACEC_t + \beta_3 IMACEC_{t-1} + \beta_4 IMACEC_{t-2} + \beta_5 MES_t + \beta_6 RAIN_{th} + \beta_7 (RAIN_{th} \cdot FDS_t)$$

2. Incluye:
 - a. Los modelos 2 y 3 tienen efectos fijos y, por tanto, hay un intercepto distinto para cada hora (Modelo 2) o para cada (geografía-hora). En general, los efectos fijos no se reportan porque suelen ser una secuencia larga de dummies por las que solo se desea controlar.
 - b. El R^2 captura la varianza explicada. En este caso el modelo con mayor R^2 es el modelo 3.
 - c. Al agregar efectos fijos por región, el R^2 (varianza explicada) aumenta bastante, por lo que concluimos que una parte relevante de la variación en la demanda se explica porque hay regiones que tienen más demanda que en otras.
 - d. En los tres modelos es positiva y significativa (p-valor < 0.05), por lo que se puede afirmar que mayor actividad económica correlaciona positivamente con mayor demanda para KornerK.
3. Detalle:
 - a. El valor esperado viene dado por:

$$\mu = 589.4 + 65.3 \cdot 0.1 = 595.9$$

b. La probabilidad viene dada por:

$$Pr(DT_{iht} \geq 600)$$

Donde DT_{iht} se distribuye normal con media $\mu = 595.9$ y varianza $\sigma^2 = (5.355)^2$. Este cálculo se puede hacer directamente en cualquier paquete estadístico. En R:

$$1 - pnorm(600, mean = 595.9, sd = 5.355)$$

Problema 10: Demanda global de cacao

En un contexto de comercio global, el precio de los insumos tiende a moverse de forma coordinada en gran parte de los mercados, lo que motiva un análisis de la demanda global para la planificación de la demanda a nivel planetario. A continuación, revisaremos enfoques de regresión para describir la demanda del cacao en distintos mercados. Este análisis resulta particularmente pertinente en el contexto de las restricciones de producción a nivel global, que han provocado aumentos importantes del precio del cacao, con un máximo histórico en 2025 y un declive sostenido en lo que va de 2026.

Para el análisis se considera usar la base de datos histórica de ventas por mercado que recopila los niveles de precio y ventas para los 256 mercados más relevantes a nivel global. La base registra transacciones agregadas a nivel semanal desde 1984 hasta la fecha y considera algunas covariables adicionales que pueden resultar funcionales al estudio de la demanda. Así, la lista de columnas de la base está compuesta por:

- **nweek**: número de semana correlativo.
- **idmarket**: identificador del mercado.
- **idcountry**: identificador del país.
- **idregion**: identificador de la región.
- **idcontinent**: identificador del continente.
- **PIBmarket**: producto interno bruto per cápita del mercado.
- **PRICEmarket**: precio promedio, convertido a USD, en el mercado.
- **SALESmarket**: cantidad de cacao vendido, en kilogramos, en el mercado.
- **Valentine**: 1 si la semana incluye el 14 de febrero.
- **Eastern**: 1 si la semana incluye Pascua de Resurrección.
- **Mother**: 1 si la semana incluye el día de la madre.

1. Como primera aproximación, se ha propuesto describir q_{rt} , la demanda por cacao en la región r en la semana t , a través del siguiente modelo de regresión lineal:

$$\ln(q_{rt}) = \alpha + \beta_1 \ln(p_{rt}) + \beta_2 \ln(p_{rt}) PIBpc_r + \varepsilon_{rt}$$

donde $q_{rt} = \sum_{i \in r} q_{it}$ es la demanda agregada de la región r , $p_{rt} = (\sum_{i \in r} p_{it} q_{it}) / (\sum_{i \in r} q_{it})$ es el precio promedio ponderado de la región, y $PIBpc_r$ es el producto interno bruto per cápita de la región. Usando estos datos agregados se han estimado dos variantes del modelo de regresión, como indica la Tabla 1.26.

Table 1.26: Resultados de los modelos de regresión.

Variable	Modelo 1	Modelo 2
Intercepto	6.114 *** (0.287)	5.943 *** (0.301)
$\ln(\text{precio})$	0.634 *** (0.071)	0.138 * (0.107)
$\ln(\text{precio}) \times PIBpc$		0.00921 *** (0.00148)
N. Obs	65,760	65,760
R^2	0.3214	0.5034
Adj. R^2	0.3213	0.5033

- a. ¿Cuál de los dos modelos prefiere? ¿Cómo se interpretan los parámetros del modelo preferido?
 - b. Sea $PIBpc$ el producto interno bruto promedio en los mercados considerados. Explique cómo testearía si, en el modelo preferido, el precio tiene un efecto positivo en la demanda para una región promedio, es decir, si a mayor precio se observa mayor demanda.
 - c. Describa cómo podría aliviar, con los datos disponibles, el potencial sesgo que explica los coeficientes de precio positivos a nivel de región.
2. Suponga ahora que quiere hacer uso de todo el potencial del conjunto de datos, estimando modelos a nivel de cada mercado. Para eso, proponga un modelo de regresión que, además de los elementos ya propuestos en el modelo agregado, considere los siguientes factores:
- a. Los mercados más ricos tienden a presentar un mayor consumo de cacao. Los mercados orientales suelen tener un menor consumo de cacao.
 - b. La demanda por cacao es estacional, con mayores ventas en Semana Santa, la semana del 14 de febrero y el día de la madre.
 - c. La magnitud de los factores estacionales varía según la región. Por ejemplo, el aumento del consumo en Semana Santa es relevante solo para los países de tradición cristiana.
 - d. El precio ciertamente importa, pero también importa cómo varía el precio. En particular, se ha detectado una caída más marcada cuando el precio excede el precio promedio del último año.
3. Suponga que se estimó un modelo de *random forest* para predecir la demanda de cacao en cada uno de los mercados, usando un conjunto amplio de variables explicativas. Suponga, además, que este modelo exhibe menores errores en el conjunto de calibración. Sin embargo, el modelo no se comporta mejor al evaluar los errores en el conjunto de validación. ¿Deberíamos descartar el modelo de *machine learning*? ¿Hay algo que se

pueda hacer en términos del conjunto de variables explicativas y de los hiperparámetros del problema?

Solución

Respondemos cada parte independientemente:

1. Respecto del modelo agregado:

- a. Según lo que observamos, deberíamos preferir el Modelo 2. En efecto, el Modelo 2 explica más varianza y la única variable en la que difieren los modelos parece ser significativa, por lo que valdría la pena mantenerla. En términos de los parámetros, encontramos que el coeficiente de precio es positivo, lo cual no es consistente con la teoría económica; esto puede explicarse porque los precios son endógenos. El coeficiente de la interacción indica que los mercados de mayores ingresos son menos sensibles al precio.

Una justificación basada solamente en el valor de los coeficientes responde parcialmente la pregunta, ya que omite el significado económico del modelo. En este caso, un aumento de 1% en el precio se asocia con un aumento de 0.138% en la demanda. Por cada unidad adicional de $PIBpc$, el efecto de un aumento de 1% en el precio sobre la demanda cambia en 0.00921 puntos porcentuales.

Observación: Al controlar por riqueza, el coeficiente se hace menos positivo, sugiriendo que el signo del coeficiente del precio puede explicarse al menos parcialmente por diferencias de base entre los mercados.

- b. Se tendría que testear la hipótesis nula $\beta_1 + \beta_2 \overline{PIBpc} = 0$. Como $\overline{PIBpc}$ es una constante, la ecuación es lineal en los parámetros y, por tanto, podemos usar un test F. Un test t no es viable a simple vista, ya que el precio interactúa individualmente y con la constante $\overline{PIBpc}$, lo que no permite crear una restricción solo con un parámetro.
- c. Para proponer soluciones es útil tener una idea de por qué el coeficiente de precio podría ser positivo. Basta mencionar y justificar un mecanismo plausible.

Un motivo es que mercados más ricos consumen más cacao. Esto se puede aliviar controlando por $PIBpc_g$, no solo en la interacción, o, mejor aún, agregando un efecto fijo de región.

Otro motivo es que los precios suban cuando hay más demanda, aunque esto es menos plausible en mercados globales. En este caso, agregar efectos fijos de semana ayuda a controlar variaciones de demanda a nivel global. También podemos controlar por eventos de mayor demanda como Pascua de Resurrección, día de la madre y otras festividades, o controlar por la demanda de la semana pasada

$\ln(q_{g,t-1})$, suponiendo que los ajustes de precios demoran una semana en hacer efecto.

Observación 1: Alguien podría proponer hacer un experimento, pero es difícil de implementar en este contexto global. Eventualmente podrían usarse variables instrumentales, aunque es difícil encontrar buenos instrumentos en este conjunto acotado de datos.

Observación 2: Puede que existan otros mecanismos, pero deben explicar por qué afectarían el signo del coeficiente de precio.

2. Partimos del modelo base y vamos agregando progresivamente todos los elementos descritos:
 - a. Agregamos un control para el nivel de ingreso ($PIBpc_i$) y otro para los mercados asiáticos ($ASIA_i$, que toma el valor 1 si el continente del mercado i es Asia).
 - b. Agregamos tres dummies de tiempo, $EASTERN_t$, $VALENTINE_t$ y $MOTHER_t$, que toman el valor 1 si la semana contiene Pascua de Resurrección, día de los enamorados o día de la madre, respectivamente.
 - c. Los coeficientes de las dummies de tiempo deben depender del mercado, representados por β_{5i} , β_{6i} y β_{7i} .
 - d. Agregamos una dummy de mercado y tiempo $EXCEDE_{it}$, que toma el valor 1 si $p_{it} > \frac{1}{52} \sum_{\tau=1}^{52} p_{i,t-\tau}$.

Con esto, el modelo de regresión puede escribirse como:

$$\begin{aligned} \ln(q_{it}) = & \alpha + \beta_1 \ln(p_{it}) + \beta_2 \ln(p_{it})PIBpc_i + \beta_3 PIBpc_i \\ & + \beta_4 ASIA_i + \beta_{5i} EASTERN_t + \beta_{6i} VALENTINE_t + \beta_{7i} MOTHER_t \\ & + \beta_8 EXCEDE_{it} + \varepsilon_{it}. \end{aligned}$$

3. En general, los errores de calibración no son tan informativos en un esquema de aprendizaje de máquina porque podrían estar sobreajustados. Si el modelo de *random forest* no es capaz de mejorar los errores de pronóstico en validación, efectivamente no debiera ser considerado por sobre lo ya existente. Sin embargo, hay al menos dos cosas que podemos hacer para reducir los grados de libertad del modelo e intentar evitar el sobreajuste:
 - Desde el punto de vista de las variables explicativas, podemos restringir el número de columnas que ingresan al modelo.
 - Desde el punto de vista de los hiperparámetros, podemos limitar la complejidad de cada árbol, por ejemplo reduciendo la profundidad máxima, o aumentar la diversidad de árboles, por ejemplo aumentando el número de árboles.

2. Modelos Probabilísticos

Para qué sirve esta unidad. En marketing, resulta frecuente enfrentar situaciones en las que la información disponible sobre el comportamiento individual de los clientes es limitada o agregada: ¿cuánto tiempo permanecerá un suscriptor?, ¿cuántas veces visitará un portal web?, ¿responderá o no a una campaña promocional? Los modelos probabilísticos permiten abordar estas preguntas asumiendo que las decisiones de los agentes provienen de un proceso estocástico, lo cual posibilita describir, predecir y gestionar el comportamiento de los clientes sin requerir grandes volúmenes de datos individuales.

Habilidades previas requeridas. Variable aleatoria y distribuciones de probabilidad básicas (Bernoulli, Binomial, Poisson, Exponencial), cálculo integral elemental, noción de función de verosimilitud y estimación por máxima verosimilitud, conceptos de valor esperado y varianza.

Qué debería poder hacer el estudiante al terminar.

- Identificar cuándo un fenómeno de marketing corresponde a un problema de duración, conteo o elección binaria.
- Formular la distribución individual y la distribución de heterogeneidad adecuadas para cada problema.
- Derivar la distribución agregada mediante integración (mezcla).
- Construir funciones de log-verosimilitud para estimar los parámetros de los modelos propuestos.
- Calcular esperanzas condicionales (actualización bayesiana) para personalizar predicciones a nivel individual.
- Incorporar heterogeneidad observable mediante regresiones sobre los parámetros del modelo.
- Evaluar y comparar modelos mediante criterios de información (AIC, BIC) y log-verosimilitud.

Conexión con ejercicios. A lo largo del capítulo se intercalan ejercicios guiados (E1–E7) que permiten verificar la comprensión de cada concepto a medida que se avanza. Al final del capítulo se incluyen problemas aplicados (P1–P9) con soluciones completas.

2.1 Definiciones clave

Antes de introducir la notación formal, conviene precisar los conceptos centrales que se emplearán a lo largo de la unidad:

Definiciones clave

- *Modelo probabilístico*: representación de un fenómeno en la que el comportamiento de los agentes se describe mediante distribuciones de probabilidad, en contraste con el enfoque estructural que supone maximización racional de utilidad.
- *Comportamiento individual*: conducta observable de un agente (abandonar, comprar, responder), caracterizada por una distribución con parámetro latente θ .
- *Heterogeneidad no observable*: variación en los parámetros latentes entre individuos de la población, representada por una distribución de mezcla $g(\theta)$.
- *Distribución agregada*: distribución resultante de integrar el comportamiento individual sobre la distribución de heterogeneidad; es la que se confronta con los datos observados.
- *Función de supervivencia* $S(t)$: probabilidad de que un evento no haya ocurrido hasta el instante t .
- *Tasa de riesgo (hazard rate)* $h(t)$: probabilidad instantánea de que el evento ocurra en t , condicionada a que no ha ocurrido hasta ese momento.
- *Esperanza condicional*: valor esperado del parámetro latente de un individuo, actualizado a la luz de su comportamiento observado (actualización bayesiana).
- *Customer Lifetime Value (CLV)*: valor presente neto de los flujos futuros esperados de un cliente, considerando su probabilidad de permanencia (Fader et al., 2005b; Fader & Hardie, 2010).

2.2 Enfoque y metodología

En el contexto de marketing, interesa estudiar el comportamiento de las personas para realizar acciones estratégicas. Es posible distinguir dos enfoques según los supuestos sobre el comportamiento de los agentes:

- *Enfoque estructural*: supone que los agentes se comportan de manera racional, tomando decisiones que maximizan su utilidad. Resulta apropiado cuando se dispone de grandes volúmenes de datos individuales.
- *Modelos probabilísticos*: suponen que las decisiones de los agentes pueden describirse como realizaciones de procesos aleatorios. Resultan adecuados cuando la información disponible es reducida o agregada.

La metodología de modelamiento probabilístico (Fader et al., 2005a; Schmittlein et al., 1987) sigue una secuencia de siete pasos:

1. Determinar el problema de decisión a estudiar y la información requerida.
2. Identificar el comportamiento observable de interés a nivel individual.
3. Seleccionar la distribución de probabilidad que caracterice el compor-

tamiento individual. Los parámetros de esta distribución se interpretan como *características latentes* a nivel individual.

4. Escoger la distribución que describa cómo las características latentes están distribuidas en la población (*distribución de mezcla o heterogénea*), típicamente denotada $g(\theta)$.
5. Derivar la *distribución agregada* del comportamiento de interés:

$$f(x) = \int f(x | \theta) g(\theta) d\theta \quad (\text{caso continuo}) \quad (2.1)$$

$$p(x) = \sum_i f(x | \theta) \Pr(\theta = \theta_i) \quad (\text{caso discreto}) \quad (2.2)$$

6. Estimar los parámetros del modelo mediante el ajuste de la distribución agregada a los datos observados (máxima verosimilitud).
7. Usar los resultados para tomar decisiones sobre el problema de marketing en cuestión.

Ejemplo 1 (Motivación). Un cliente realizó 2 compras el año pasado. ¿Esto implica que mantendrá ese patrón de consumo? ¿Existe alguna posibilidad de que incremente o disminuya su nivel de compra? ¿Cuál es el proceso subyacente? Los modelos probabilísticos permiten responder estas preguntas asumiendo que el número de compras proviene de una distribución (por ejemplo, Poisson) cuyo parámetro varía entre individuos.

El enfoque probabilístico permite abordar tres tipos fundamentales de problemas en marketing:

- *Duración:* ¿cuándo ocurre un evento? Situaciones ligadas a la permanencia de un cliente en una compañía, al tiempo de adopción de un producto innovador, entre otras.
- *Conteo:* ¿cuántas veces ocurre un evento? Situaciones ligadas al número de visitas a un portal web, la cantidad de productos comprados, el número de exposiciones publicitarias.
- *Elección binaria:* ¿ocurre o no el evento? Situaciones asociadas a la decisión de responder a una campaña publicitaria, de comprar o no un producto, de cambiar o no de proveedor.

Comportamientos más complejos pueden describirse mediante combinaciones de estos modelos básicos.

2.3 Modelos de duración

En años recientes, las mejoras en las tecnologías de información han generado como resultado un aumento en la disponibilidad de data acerca de los individuos en determinadas situaciones de consumo. Esta tendencia se relaciona íntimamente con el creciente deseo de los gerentes de marketing respecto a utilizar esta

data disponible para aprender de manera exhaustiva sobre el comportamiento de los clientes. Muchos analistas tratan de describir y predecir el comportamiento de los consumidores usando variables observables, como lo son variables transaccionales (monto gastado, tienda donde se adquirió un determinado producto, fecha de la compra, etc.), como así también variables que caracterizan a los individuos (edad, nivel socio-económico, estado civil, etc.). A partir de esta información es posible aplicar modelos de regresión lineal o árboles de decisión, con el objetivo de poder proyectar comportamientos, o bien rebatir hipótesis que previamente se tenían respecto a un escenario determinado.

En este capítulo, se considera un enfoque distinto al anterior, en el cual las decisiones de los individuos se desprenden de un comportamiento **aleatorio**, en que las decisiones no dependen únicamente de variables descriptivas del modelo, sino que también provienen del resultado de un proceso estocástico no observable que opera intrínsecamente en los individuos. Es decir, la asunción que el comportamiento se desprende de una distribución de probabilidades que puede variar dependiendo del modelo a estimar y de la complejidad del mismo. Alternativamente, se puede considerar el enfoque racionalista que contempla a los individuos que siempre actúan racionalmente, lo que, de acuerdo a la experiencia empírica, no se cumple siempre.

Ejemplo 1: Supongamos que un cliente hizo 2 compras el año pasado de nuestro producto. ¿Esto implica inmediatamente que el consumidor mantendrá ese patrón y este año volverá a ese nivel de consumo? ¿O existe alguna posibilidad de que el cliente incremente o disminuya su consumo? ¿Cuál es el proceso que hay detrás?

En lo que sigue, se considera 3 tipos de modelos de duración a estimar:

1. **Modelos de duración en tiempo discreto.**
2. **Modelos de duración en tiempo continuo sin dependencia en la duración.**
3. **Modelos de duración en tiempo continuo con dependencia en la duración.**

2.3.1 Modelos de duración en tiempo discreto

Como ejemplo, se tiene el siguiente escenario: a través de una propuesta de valor atractiva, una empresa consigue un cliente. ¿Durante cuántos periodos estará afiliado a la compañía?

Se considera que cada periodo se puede cuantificar en términos discretos (días, semanas, meses, años). Algunos ejemplos a considerar:

- Un usuario descarga una aplicación para su teléfono inteligente. ¿Por cuántos meses la utilizará?
- Adquirimos un cliente en un banco. ¿Durante cuántos años permanecerá como cliente?

- Un cliente se suscribe a un plan telefónico o de internet. ¿Por cuántos periodos se mantendrá suscrito?

Modelo Geométrico Desplazado

Como ejemplo, se asume que se tiene una cartera de clientes que van abandonando la relación comercial para **nunca más retomarla** en cualquier periodo definido. Al final de cada periodo, un cliente decide de manera aleatoria si continúa afiliado. De acuerdo a un proceso de Bernoulli, hay una probabilidad θ de cancelar la relación comercial con la empresa y con el complemento $1 - \theta$ decide su permanencia.

Para cada individuo, se asume que la probabilidad con la que decide no cambia en el tiempo. Como primer acercamiento, se asume que dicha probabilidad es igual e idénticamente distribuida (iid). Sea T la variable aleatoria relativa a la duración de la relación comercial entre el cliente y la compañía, es decir la variable que describe el instante en el cual esta relación se acaba. De acuerdo a la descripción anterior, la variable aleatoria T sigue una distribución Geométrica Desplazada (sG) con parámetro θ , es decir, el comportamiento de los individuos puede ser descrito formalmente de acuerdo a la siguiente relación:

1. Probabilidad de que un individuo cualquiera abandone la relación comercial exactamente en el periodo t :

$$P(T = t \mid \theta) = \theta(1 - \theta)^{t-1} \quad (2.3)$$

2. Probabilidad de que un individuo cualquiera abandone la relación comercial en un periodo posterior al periodo t :

$$P(T > t \mid \theta) = (1 - \theta)^t \quad (2.4)$$

No es muy difícil aplicar un modelamiento a partir de lo anterior para intentar dilucidar de qué forma se debería comportar un determinado grupo de individuos a partir de la data transaccional que se tiene.

Ejemplo 2 (Modelo Geométrico Desplazado). Se considera una cohorte inicial de 1.000 clientes (indexado por el año 0). Se asume que, año a año, un determinado número de clientes se retira del negocio de acuerdo a un proceso de Bernoulli con probabilidad θ de abandono. La data histórica se presenta a continuación:

Año	# de Clientes	% de Permanencia	% de Retención
0	1.000	100%	—
1	631	63%	63%
2	468	47%	74%
3	382	38%	82%
4	326	33%	85%
5	289	29%	89%

6	262	26%	91%
7	241	24%	92%

El porcentaje de retención corresponde al porcentaje de clientes que se mantuvo en la relación comercial respecto al período anterior.

Sin embargo, aún no se desconoce el valor de θ (es un parámetro poblacional). Dicho valor se estima mediante el método de máxima verosimilitud, que busca encontrar el valor del parámetro óptimo de acuerdo a los datos observados y asumiendo independencia entre las muestras:

- Densidad de probabilidades conjunta:

$$f(x_1, x_2, \dots, x_n | \theta) = f(x_1 | \theta) \cdot f(x_2 | \theta) \cdot \dots \cdot f(x_n | \theta) \quad (2.5)$$

- Función de verosimilitud:

$$\begin{aligned} L(\theta) &= \left\{ \prod_{t=1}^{\tau} P(T = t | \theta)^{n_t} \right\} P(T > \tau | \theta)^{n_{\tau}} \\ &= \left\{ \prod_{t=1}^{\tau} [\theta(1 - \theta)^{t-1}]^{n_t} \right\} [(1 - \theta)^{\tau}]^{n_{\tau}} \end{aligned} \quad (2.6)$$

Notar que n_{τ} es el número de clientes activos después del máximo tiempo observable τ , n_t es el número de abandonos (si hay 369 abandonos, se multiplica 369 veces), y x_i el año. A partir de esto y de la data disponible, las contribuciones a la verosimilitud son las siguientes (asumiendo como modelo de comportamiento la distribución geométrica desplazada)

Table 2.1: Contribuciones a la verosimilitud en el modelo geométrico desplazado.

Año	# de Clientes	# de Abandonos	Pr
0	1000	-	-
1	631	369	$P(T = 1 \theta) = \theta^{369}$
2	468	163	$P(T = 2 \theta) = ((1 - \theta)^{(2-1)} \cdot \theta)^{163}$
3	382	86	$P(T = 3 \theta) = ((1 - \theta)^{(3-1)} \cdot \theta)^{86}$
4	326	56	$P(T = 4 \theta) = ((1 - \theta)^{(4-1)} \cdot \theta)^{56}$
5	289	37	$P(T = 5 \theta) = ((1 - \theta)^{(5-1)} \cdot \theta)^{37}$
6	262	27	$P(T = 6 \theta) = ((1 - \theta)^{(6-1)} \cdot \theta)^{27}$
7	241	21	$P(T = 7 \theta) = ((1 - \theta)^{(7-1)} \cdot \theta)^{21}$
>7	-	-	$P(T > 7 \theta) = ((1 - \theta)^7)^{241}$

Dado que maximizar un producto es complicado, se aplica logaritmo a lo anterior, de modo de construir la función de log verosimilitud:

- Función de log verosimilitud:

$$\begin{aligned}\hat{\ell}(\theta) &= \sum_{t=1}^{\tau} n_t \ln P(T = t \mid \theta) + n_{\tau} \ln P(T > \tau \mid \theta) \\ &= \sum_{t=1}^{\tau} n_t [\ln \theta + (t-1) \ln(1-\theta)] + n_{\tau} \tau \ln(1-\theta)\end{aligned}\quad (2.7)$$

Con lo anterior, es sencillo maximizar la función de log verosimilitud para un θ desconocido utilizando un paquete estadístico como R, con lo que se tiene:

$$\begin{aligned}\hat{\theta} &= 0,226027 \\ \hat{l} &= -1794,62\end{aligned}$$

El modelo presentado, si bien permite tomar medidas de gestión a partir de un modelo sencillo, es poco realista, pues se asume que la población posee igual probabilidad de abandono.

Una manera de incluir mayor complejidad al modelo y hacerlo más robusto, se asume que la población no es homogénea, sino que existen segmentos de individuos quienes al ser agrupados, presentan un comportamiento similar (heterogéneo). La forma más sencilla de modelar esto es asumiendo que la población presenta 2 patrones de comportamiento o 2 segmentos. Para un segmento de individuos, la decisión de abandonar o permanecer se identifica a partir de un parámetro θ_1 (del mismo modo que en el caso anterior) y, para el otro segmento, la decisión se determina a partir de un parámetro θ_2 distinto de θ_1 .

Formalmente, las relaciones que describen de mejor manera esto son las siguientes:

$$P(T = t \mid \theta_1, \theta_2, \pi) = \theta_1(1 - \theta_1)^{t-1}\pi + \theta_2(1 - \theta_2)^{t-1}(1 - \pi) \quad (2.8)$$

$$P(T > t \mid \theta_1, \theta_2, \pi) = (1 - \theta_1)^t\pi + (1 - \theta_2)^t(1 - \pi) \quad (2.9)$$

En el modelo anterior, π representa el porcentaje de la población que pertenece al segmento 1, de tal forma que su complemento $1 - \pi$ representa el porcentaje de la población que pertenece al segmento 2. Cabe mencionar que se puede expandir a más segmentos, siempre que sepamos su proporción π .

Ejercicio guiado E1: Tasa de respuesta.

Una compañía de venta de ropa por catálogo busca decidir a qué segmento enviar los catálogos de la próxima colección. Para ello analiza la tasa de respuesta de una muestra de clientes de cada segmento (el ratio entre número de clientes que compra y número de catálogos enviados). Al mirar el primer segmento observa que de los 18 clientes a quienes se les envió el

catálogo, ninguno compró y, por tanto, decide no enviar catálogos a ningún cliente de ese segmento. Esta compañía:

- (a) Muy probablemente esté subestimando la tasa de respuesta de ese segmento.
- (b) Debiera redefinir los criterios de segmentación para hacer grupos más grandes y accionables.
- (c) Ha definido una política que da cuenta de su aversión al riesgo.
- (d) Debiera usar un modelo de duración en tiempo continuo con dependencia en la duración.
- (e) Debiera incorporar variables explicativas en su modelo predictivo.

Solución

Respuesta correcta: **(a)**.

Con una muestra de solo 18 observaciones y cero respuestas, la estimación empírica $\hat{p} = 0/18 = 0$ resulta poco confiable. La probabilidad real de respuesta del segmento es muy probablemente mayor que cero; la observación de ninguna compra en una muestra tan pequeña no implica que la tasa de respuesta sea nula. Un enfoque bayesiano (por ejemplo, con un prior $\text{Beta}(\alpha, \beta)$) produciría una estimación positiva incluso con cero éxitos observados.

Modelo Beta-Geométrico Desplazado

Los modelos anteriores funcionan bien cuando la población se comporta de manera distinta entre clases latentes, y similar al interior de cada clase latente. Sin embargo, puede ser mucho más realista e interesante asumir que existe una heterogeneidad continua en la población, es decir, que existe un número infinito de segmentos (o al menos tendiente a infinito) de manera de capturar todas las preferencias individuales de cada miembro de la población considerada.

Para estos propósitos, ya no asumiremos que la probabilidad de abandono θ sigue una distribución discreta de Bernoulli (éxito-fracaso), sino que asumiremos que el parámetro proviene de una distribución continua Beta de parámetros α y β .

Por tanto, es posible calcular las probabilidades antes presentadas en forma análoga, aplicando el enfoque antes mencionado (probabilidades totales):

1. Probabilidad de que un individuo cualquiera abandone la relación comercial exactamente en el periodo t :

$$P(T = t|\alpha, \beta) = \int_0^1 P(T = t|\theta)B(\theta|\alpha, \beta)d\theta \quad (2.10)$$

Donde:

$$B(\theta|\alpha, \beta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \quad (2.11a)$$

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)} \quad (2.11b)$$

2. Probabilidad de que un individuo cualquiera abandone la relación comercial en un periodo posterior al periodo t :

$$P(T > t | \alpha, \beta) = \int_0^1 P(T > t | \theta) B(\theta | \alpha, \beta) d\theta \quad (2.12)$$

Al desarrollar la primera integral antes mencionada, y reconociendo las relaciones de la distribución *Beta*, se tiene que:

$$\begin{aligned} P(T = t | \alpha, \beta) &= \int_0^1 (\theta(1-\theta)^{t-1}) \left(\frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \right) d\theta \\ &= \frac{1}{B(\alpha, \beta)} \int_0^1 (\theta \cdot \theta^{\alpha-1}) \cdot ((1-\theta)^{t-1} \cdot (1-\theta)^{\beta-1}) d\theta \\ &= \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^\alpha (1-\theta)^{t+\beta-2} d\theta \\ &= \frac{B(\alpha+1, t+\beta-1)}{B(\alpha, \beta)} \end{aligned} \quad (2.13)$$

Notar que se usa indistintamente el $B(\alpha, \beta)$ para hacer alusión tanto a la **función** como a la **distribución Beta**. Bajo ninguna circunstancia dichos objetos son iguales.

El desarrollo de la segunda integral es:

$$\begin{aligned} P(T > t | \alpha, \beta) &= \int_0^1 (1-\theta)^t \left(\frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \right) d\theta \\ &= \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^{\alpha-1} \cdot ((1-\theta)^t \cdot (1-\theta)^{\beta-1}) d\theta \\ &= \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^{\alpha-1} (1-\theta)^{t+\beta-1} d\theta \\ &= \frac{B(\alpha, t+\beta)}{B(\alpha, \beta)} \end{aligned} \quad (2.14)$$

Ejemplo 3 (Recursividad en el modelo Beta-Geométrico). Usando la misma cohorte del Ejemplo 2, pero asumiendo heterogeneidad continua, es posible identificar una recursividad en la fórmula de abandono:

Caso base ($t = 1$):

$$P(T = 1 \mid \alpha, \beta) = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}$$

Paso recursivo ($t > 1$):

$$\frac{P(T = t \mid \alpha, \beta)}{P(T = t - 1 \mid \alpha, \beta)} = \frac{\beta + t - 2}{\alpha + \beta + t - 1}$$

Al estimar el modelo Beta-Geométrico Desplazado con los datos del Ejemplo 2, se obtiene:

$$\hat{\alpha} = 0,7041 \quad \hat{\beta} = 1,1820 \quad \hat{\ell} = -1680,27 \quad (2.15)$$

La diferencia en log-verosimilitud respecto al modelo homogéneo ($\hat{\ell} = -1794,62$) es notable. Si bien esto sugiere una mejora, la comparación rigurosa debe realizarse mediante criterios como AIC o BIC, que penalizan por el número de parámetros.

2.3.2 Modelos de duración en tiempo continuo sin dependencia en la duración

Para algunos modelos, medir el tiempo como si fueran períodos discretos puede ser una buena aproximación de acuerdo a los objetivos del análisis que se desea llevar a cabo.

En otros casos, puede ser en cambio más útil considerar el tiempo como una variable continua, debido a que podría interesar medir la ocurrencia de un suceso de manera más exacta. Algunos casos relativos a este enfoque son:

- Tiempos de respuesta a una campaña promocional de marketing directo.
- Tiempo entre visitas a nuestro website.
- Tiempos entre llamadas en un *call center*.
- Tiempos de operación en la industria de servicios.

Al igual que en el caso de los modelos en tiempo discreto, lo que interesa estudiar es poder implementar un modelo que tenga una forma funcional flexible para ser trabajada y modificada fácilmente, que logre ajustar a la data histórica que se tiene y proyectar el comportamiento futuro de los clientes, es decir, que sea un buen modelo predictivo para tomar acciones en función de aquello.

Modelo Exponencial

Se puede medir el tiempo que pasa desde que se lanza un producto hasta que el consumidor decide adquirirlo. Existen muchos factores externos que determinan esta decisión: exposición a publicidad, número de visitas a la tienda, llamadas

recibidas por call center, entre otras. Nuevamente se asume que el comportamiento es aleatorio, es decir, que los consumidores deciden el momento en el cuál van a consumir a partir de una distribución de probabilidades.

Esto puede verse con una distribución exponencial, con la variable aleatoria t definida como el tiempo en que un cliente va a consumir el producto por primera vez. Se asume que esta variable está exponencialmente distribuida con una tasa λ . De esta forma, se tiene que el comportamiento de los consumidores puede verse como:

1. Probabilidad de que ocurra en t o antes:

$$P(T \leq t) = 1 - e^{-\lambda t} \quad (2.16)$$

2. Probabilidad de que ocurra después de t :

$$P(T > t) = e^{-\lambda t} \quad (2.17)$$

Verosimilitud:

$$\begin{aligned} L(\lambda) &= \prod_{i \in A} f(t_i | \lambda) \prod_{i \notin A} (1 - P(T \leq t)) \\ &= \prod_{i \in A} (\lambda e^{-\lambda t_i}) \prod_{i \notin A} (e^{-\lambda \tau_i}) \end{aligned} \quad (2.18)$$

Log-verosimilitud:

$$\ell(\lambda) = \sum_{i \in A} [\ln \lambda - \lambda t_i] - \lambda \sum_{i \notin A} \tau_i \quad (2.19)$$

donde $f(t_i | \theta)$ es la función de densidad, es decir, la derivada de la función de probabilidad acumulada $P(T \leq t)$. El índice i corresponde a cada cliente y A es el conjunto de clientes que adquiere un producto o servicio. El parámetro τ , al igual que en el modelo de duración discreta, corresponde al tiempo máximo observado.

Ahora bien, esto inmediatamente deja en evidencia una limitante a este modelo: para un t muy grande, todos los consumidores van a tener un caso de éxito (Recordar que $\lim e^{-t} = 0$), lo cual no es una situación del todo realista. Es necesario, en consecuencia, imponer que existe una fracción de clientes dentro de la muestra considerada que nunca probará el producto (caso de éxito) y, así, es posible solucionar la limitante encontrada (2 clases latentes).

1. Segmento que prueba: Tamaño π :

$$\begin{aligned} \lambda &= \theta \\ \Rightarrow P(T \leq t) &= 1 - e^{-\theta t} \end{aligned}$$

2. Segmento que no prueba: Tamaño $(1 - \pi)$:

$$\begin{aligned} \lambda &= 0 \\ \Rightarrow P(T \leq t) &= 0 \end{aligned}$$

Luego, la probabilidad total será:

$$\begin{aligned} P(T \leq t) &= P(T \leq t | \text{Prueba})P(\text{Prueba}) + P(T \leq t | \text{No Prueba})P(\text{No Prueba}) \\ &= 1 - e^{-\theta t} \pi \end{aligned} \quad (2.20)$$

Implementación práctica. Aunque el modelo describe probabilidades en tiempo continuo, los datos suelen presentarse en intervalos discretos. La log-verosimilitud se construye calculando la probabilidad de que el evento ocurra dentro de cada intervalo temporal: $P(t_0 \leq T \leq t_1) = F(t_1) - F(t_0)$.

Es importante notar que si bien el modelo describe probabilidades en tiempo continuo, la data aún se presenta y obtiene en tiempo discreto. Incorporando esto, es posible construir la función de log verosimilitud calculando las probabilidades de adopción del producto entre los límites del intervalo temporal definido por el periodo de medición, es decir:

$$P(t_0 \leq T \leq t_1) = F(t_1) - F(t_0) \quad (2.21)$$

Considerando n periodos discretos para el cálculo, la log-verosimilitud es:

$$LL(\pi, \theta | \text{data}) = N_1 \ln[P(1 \leq T \leq 2)] + \dots + (N_{\text{panel}} - \sum_{i=1}^n N_i) \ln[P(T > n)] \quad (2.22)$$

Adicionalmente, es de interés calcular los valores predichos por el modelo, de modo de realizar predicciones futuras. $F(t)$ representa la probabilidad que un cliente escogido aleatoriamente pruebe el producto en t , tal que $t = 0$ corresponde al instante de lanzamiento del producto. La estimación del futuro se puede hacer a través de la esperanza:

$$\mathbb{E}[T(t)] = N_{\text{panel}} \cdot \hat{F}(t) \quad (2.23)$$

Antes de avanzar, es importante aclarar la distinción de un modelo *sin dependencia en la duración*. Esto se puede explicar con la propiedad fundamental de la distribución exponencial:

Propiedad fundamental: La distribución exponencial no tiene memoria, es decir, poseer información de que un elemento ha sobrevivido un tiempo 's' hasta

este momento no modifica la probabilidad de que sobreviva un periodo t más. Es decir la probabilidad de que ocurra un suceso no depende del tiempo en que aún no ha ocurrido. Se puede demostrar matemáticamente:

$$P(T > s + t | T > s) = \frac{P(T > s + t)}{P(T > s)} = \frac{1 - P(T \leq s + t)}{1 - P(T \leq s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} \quad (2.24)$$

Modelo Gamma-Exponencial

Análogamente al caso de duración discreta, hay casos en que el comportamiento de la población heterogéneo. Esto busca complejizar la suposición que antes se hizo al considerar un grupo de clientes que nunca consume. Por tanto, el modelo con heterogeneidad no observada ahora considerará que la tasa de prueba λ se distribuye *Gamma* en la población:

$$g(\lambda) = \frac{\alpha^r \lambda^{r-1} e^{-\alpha\lambda}}{\Gamma(r)} \quad (2.25)$$

Donde r es un parámetro de forma mide la morfología. Con $r = 1$ se reduce a una exponencial y, a medida que crece, su la forma se vuelve más simétrica y similar a una normal. Por otro lado, α es un parámetro de escala que estira la distribución a medida que crece, o la comprime en la medida que decrece.

Al incorporar la heterogeneidad mencionada, la probabilidad que un cliente adquiera un producto antes de un tiempo t es la siguiente:

$$\begin{aligned} P(T \leq t) &= \int_0^\infty P(T \leq t | \lambda) g(\lambda) d\lambda \\ &= \int_0^\infty (1 - e^{-\lambda t}) \left(\frac{\alpha^r}{\Gamma(r)} \lambda^{r-1} e^{-\alpha\lambda} \right) d\lambda \\ &= \int_0^\infty \frac{\alpha^r}{\Gamma(r)} \lambda^{r-1} e^{-\alpha\lambda} d\lambda - \int_0^\infty e^{-\lambda t} \frac{\alpha^r}{\Gamma(r)} \lambda^{r-1} e^{-\alpha\lambda} d\lambda \\ &= 1 - \frac{\alpha^r}{\Gamma(r)} \int_0^\infty \frac{\lambda^{r-1} e^{-\lambda(\alpha+t)} \Gamma(r) (\alpha+t)^r}{\Gamma(r) (\alpha+t)^r} d\lambda \\ &= 1 - \frac{\alpha^r}{\Gamma(r)} \frac{\Gamma(r)}{(\alpha+t)^r} \\ &= 1 - \left(\frac{\alpha}{\alpha+t} \right)^r \end{aligned} \quad (2.26)$$

Donde en el cuarto paso se agregó un 1 en forma de $\frac{\Gamma(r)(\alpha+t)^r}{\Gamma(r)(\alpha+t)^r}$ para obtener una función de acumulación de dominio completo para la distribución gamma (lo que al integrarlo da 1).

Ejercicio guiado E3: Distribución Gamma y heterogeneidad.

¿Cuál de los siguientes factores motivan la utilización de una distribución Gamma para modelar la heterogeneidad de las tasas de adopción en un modelo de duración en tiempo continuo? (Es posible elegir más de un factor.)

- i. Consistencia con el dominio de la probabilidad de abandono en cada período.
- ii. Para generar una fórmula recursiva de fácil implementación.
- iii. Flexibilidad para acomodar distintas formas de la distribución.
- iv. Para generar una fórmula cerrada que pueda ser calculada de manera computacionalmente eficiente.

Solución

Respuestas correctas: **iii** y **iv**.

La distribución Gamma se emplea como distribución de mezcla principalmente por dos razones: (iii) su flexibilidad para representar distintas formas de distribución (sesgadas, simétricas) según los valores de sus parámetros, y (iv) porque al combinarla con la distribución exponencial produce una fórmula cerrada $(1 - (\alpha/(\alpha + t))^r)$, lo que resulta computacionalmente eficiente. La opción (i) no aplica porque la Gamma modela tasas $\lambda \in (0, \infty)$, no probabilidades en $[0, 1]$. La opción (ii) describe una propiedad del modelo Beta-Geométrico, no del Gamma-Exponencial.

2.3.3 Modelos de duración en tiempo continuo con dependencia en la duración

Otra de las grandes limitantes del modelo *Exponencial* es que posee pérdida de memoria. En algunas aplicaciones se requiere incorporar esta distinción, es decir, la probabilidad de que un evento ocurra dado que hasta este momento no ha ocurrido. Esto último se conoce como *tasa de riesgo* o *hazard rate*:

$$h(t) = \frac{f(t)}{1 - F(t)} \quad (2.27)$$

Donde

$$\begin{aligned} f(t) &= \frac{d}{dt} F(t) \\ &= -c\lambda t^{c-1} e^{-\lambda t^c} \end{aligned} \quad (2.28)$$

Ejemplo 4 (Interpretación de tasas de riesgo). Distintos fenómenos exhiben patrones de riesgo cualitativamente diferentes:

- *Respuesta a un correo electrónico*: tasa de riesgo decreciente. Si una persona no ha respondido, cada vez es menos probable que lo haga,

- pues los correos antiguos tienden a ser ignorados.
- *Llegada de un autobús*: tasa de riesgo creciente. A medida que más tiempo pasa sin que llegue, la espera remanente debería ser menor.
 - *Divorcio*: tasa de riesgo con forma de campana. Es poco probable al inicio y al final del matrimonio, con mayor riesgo en los años intermedios.
 - *Falla de un disco duro*: tasa de riesgo en forma de bañera (alta al inicio, baja en la mitad de la vida útil, alta al final).

A partir de la tasa de riesgo, se puede definir unívocamente la distribución de una variable aleatoria no negativa a través de la siguiente integral:

$$F(t) = 1 - \exp \left(- \int_0^t h(u) du \right) \quad (2.29)$$

Este concepto será útil para definir los modelos de duración en tiempo continuo en que la duración sí es un factor relevante

Modelo Weibull

A pesar de las generalizaciones de las funciones de tasas de riesgo para generar modelos de tiempo de ocurrencia, el foco será puesto en la distribución Weibull, debido a que es fácil de trabajar y entrega una fórmula cerrada muy similar a la de la distribución exponencial. Se tiene que, para la misma variable aleatoria T que se definió en la sección anterior, la probabilidad de ocurrencia de que un cliente pruebe nuestro producto en un tiempo inferior a t será:

$$F(t) = P(T \leq t) = 1 - e^{-\lambda t^c} \quad (2.30)$$

Y la tasa de riesgo asociada a esta distribución:

$$h(t) = c\lambda t^{c-1} \quad (2.31)$$

El primer parámetro λ que compone la fórmula es un parámetro de escala, mientras que el parámetro c es el parámetro de forma. Es importante notar que para $c = 1$, la distribución se convierte en la distribución exponencial, por lo que se puede decir que la distribución Weibull es una generalización de la exponencial. Notar que para $c = 1$, la tasa de riesgo es constante, lo que es consistente con la propiedad de pérdida de memoria de la distribución exponencial.

$$P(T > s + t | T > s) = \frac{P(T > s + t)}{P(T > s)} = \frac{1 - P(T \leq s + t)}{1 - P(T \leq s)} = \frac{e^{-\lambda(s+t)^c}}{e^{-\lambda s^c}} \quad (2.32)$$

Ejercicio guiado E2: Distribución Weibull.

En relación a la distribución Weibull:

- Es un caso particular de la Poisson.
- Es una generalización de la Poisson.
- Solo tiene un parámetro c .
- Es muy flexible y permite incluso generar distribuciones bimodales.
- Ninguna de las anteriores.

Solución

Respuesta correcta: **(e)** (Ninguna de las anteriores).

La distribución Weibull no guarda relación de caso particular ni de generalización con la distribución de Poisson; son distribuciones de naturaleza distinta (la Weibull modela tiempos, la Poisson modela conteos). Posee dos parámetros (λ y c), no uno solo. Si bien es flexible, no genera distribuciones bimodales; la Weibull es una generalización de la *exponencial*.

Modelo Gamma-Weibull

Una de las propiedades interesantes de la distribución Weibull, es que es sencillo introducir heterogeneidad sobre los parámetros y, de esa forma, capturar los distintos posibles comportamientos de la población.

Al igual que en el modelo Gamma-Exponencial, asumiremos que el parámetro de escala α está distribuido $\text{Gamma}(\alpha, r)$ en la población. La probabilidad de ocurrencia del consumo de los clientes se puede modelar a través de la

$$\begin{aligned}
 P(T \leq t \mid \alpha, r, c) &= \int_0^\infty \frac{(1 - e^{-\lambda t^c}) \alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} d\lambda \\
 &= \int_0^\infty \frac{\alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} d\lambda - \int_0^\infty \frac{e^{-\lambda t^c} \alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} d\lambda \\
 &= 1 - \frac{\alpha^r}{\Gamma(r)} \int_0^\infty \lambda^{r-1} e^{-\lambda(\alpha + t^c)} d\lambda \\
 &= 1 - \frac{\alpha^r}{\Gamma(r)} \frac{\Gamma(r)}{(\alpha + t^c)^r} \\
 &= 1 - \left(\frac{\alpha}{\alpha + t^c} \right)^r
 \end{aligned} \tag{2.33}$$

Para $c = 1$, se recupera el modelo Gamma-Exponencial.

Ejercicio guiado E4: Modelos de duración.

¿Cuáles de los siguientes modelos NO describen la duración de la relación de los clientes con una firma?

- Beta-Geométrica Desplazada.

- b. Beta-Geométrica NBD.
- c. Gamma-Weibull.
- d. Binomial Negativa.
- e. Ninguna de las anteriores.

Solución

Respuesta correcta: **(d)**.

La distribución Binomial Negativa (NBD) es un modelo de *conteo*, no de duración. Describe el número de veces que ocurre un evento (por ejemplo, número de compras), no el tiempo hasta que ocurre. Los modelos (a), (b) y (c) sí describen duraciones.

Ejercicio guiado E7: Tiempo discreto en modelos de duración.

“En la práctica, siempre es posible discretizar el tiempo y, por lo tanto, no hay motivos para usar modelos de duración en tiempo continuo.” Discuta la veracidad de esta afirmación.

Solución

La afirmación es **incorrecta** por al menos dos razones:

- Para eventos con gran variabilidad en los tiempos de ocurrencia, un modelo de tiempo discreto podría requerir un número muy grande de períodos para describir apropiadamente el comportamiento, lo que resulta poco parsimonioso.
- Si el comportamiento tiene *dependencia en la duración*, dichas dependencias se incorporan de manera natural en modelos de tiempo continuo mediante funciones de riesgo (*hazard*) dependientes del tiempo (por ejemplo, la distribución Weibull), lo cual puede ser más complejo de representar en tiempo discreto.

2.4 Modelos de conteo

Permiten modelar cuántas veces los consumidores incurrirán en un comportamiento determinado en un período de tiempo (ejemplo: problema de exposición publicitaria).

Algunas medidas de efectividad son:

- **Alcance:** Proporción de la población expuesta al evento al menos una vez durante el período: $1 - P(X_t = 0)$.
- **Frecuencia promedio:** número promedio de exposiciones en el período entre aquellos que han experimentado el evento (por ejemplo, ver la valla publicitaria).

$$\frac{\mathbb{E}(X_t)}{1 - P(X_t = 0)}$$

- **Puntos de rating brutos (GRPs):** número promedio de exposiciones por cada 100 personas.

$$100 \cdot \mathbb{E}(X_t)$$

El fenómeno que se quiere estudiar es el número de veces que cada individuo ve la valla publicitaria. Para ello, se define el modelo individual *Poisson*.

Modelo Poisson

lo cual corresponde a la probabilidad de que el número de exposiciones sea m en un intervalo de largo t .

$$P(N_t = m \mid \lambda) = \frac{(\lambda t)^m e^{-\lambda t}}{m!} \quad (2.34)$$

Su verosimilitud corresponde a:

$$L(\lambda) = \prod_m P(N_t = m \mid \lambda)^{n_m} = \prod_m \left(\frac{(\lambda t)^m e^{-\lambda t}}{m!} \right)^{n_m} \quad (2.35)$$

Su log-verosimilitud es:

Computacionalmente, suele ser más conveniente trabajar con la log-verosimilitud en vez de la verosimilitud. Esto porque la multiplicación de probabilidades genera muy rápidamente valores que computacionalmente son indistinguibles de cero. Recuérdese que el valor de los valores óptimos son invariantes a transformaciones monótonas como la del logaritmo.

$$LL(\lambda) = \sum_m n_m \ln \left(\frac{(\lambda t)^m e^{-\lambda t}}{m!} \right) \quad (2.36)$$

Donde m corresponde al número de ocurrencias de un suceso (cuántas personas han visto un determinado número de anuncios), n_m es el número de casos en donde hubieron m ocurrencias de un suceso (cuántas veces un usuario ha visto un anuncio) y no se utiliza cuando las observaciones están desagregadas (datos en los cuales cada fila del conjunto de datos corresponde a una observación única y específica). Cuando el tiempo es unitario, el modelo se simplifica a $t = 1$.

Al igual que en los modelos anteriores, es posible incluir heterogeneidad asumiendo que el parámetro λ no es el mismo para todos. Para el caso en donde existe una mezcla finita y hay dos segmentos, las tasas de eventos de la población pueden ser λ_1 o λ_2 , con una probabilidad π de pertenecer al primer segmento. El modelo de probabilidad queda representado por:

$$P(N_t = m \mid \lambda_1, \lambda_2, \pi) = \frac{(\lambda_1 t)^m e^{-\lambda_1 t}}{m!} \pi + \frac{(\lambda_2 t)^m e^{-\lambda_2 t}}{m!} (1 - \pi) \quad (2.37)$$

Modelo Gamma-Poisson (NBD)

Para los modelos de heterogeneidad continua, λ distribuye de acuerdo a una determinada distribución. Suponiendo que dicha distribución es *Gamma*.

$$g(\lambda \mid \alpha, r) = \frac{\alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} \quad (2.38)$$

Usando el modelo individual en (2.34) y la distribución en (2.38), se puede estimar la probabilidad de un número de exposiciones, conocido como modelo **Gamma Poisson (NBD)**:

$$\begin{aligned} P(N_t = m \mid r, \alpha) &= \int_0^\infty P(N_t = m \mid \lambda) g(\lambda) d\lambda \\ &= \int_0^\infty \frac{(\lambda t)^m e^{-\lambda t}}{m!} \cdot \frac{\alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} d\lambda \\ &= \frac{t^m \alpha^r}{m! \Gamma(r)} \int_0^\infty \lambda^m \lambda^{r-1} e^{-\lambda t} e^{-\alpha \lambda} d\lambda \\ &= \frac{t^m \alpha^r}{m! \Gamma(r)} \int_0^\infty \lambda^{(r+m)-1} e^{-\lambda(\alpha+t)} d\lambda \\ &= \frac{t^m \alpha^r}{m! \Gamma(r)} \cdot \frac{\Gamma(r+m)}{(\alpha+t)^{r+m}} \\ &= \frac{\alpha^r}{(\alpha+t)^r} \cdot \frac{t^m}{(\alpha+t)^m} \cdot \frac{\Gamma(r+m)}{\Gamma(r)m!} \\ &= \left(\frac{\alpha}{\alpha+t} \right)^r \left(\frac{t}{\alpha+t} \right)^m \frac{\Gamma(r+m)}{\Gamma(r)m!} \end{aligned} \quad (2.39)$$

Ejercicio guiado E5: Modelo NBD.

Un modelo NBD describe la demanda de botellas de oporto en los últimos 6 meses. Si con este modelo se estima la demanda del próximo mes:

- Es necesario hacer un modelo de regresión que considere la dinámica del problema.
- El cálculo no se puede hacer directamente; sin embargo, es posible recalibrar el modelo considerando un horizonte de un mes.
- El histograma del número de botellas consumidas por cliente se moverá a la izquierda.
- La probabilidad de comprar x botellas resulta ser simplemente $1/6$ veces las probabilidades calculadas para el primer semestre.

- e. Ninguna de las anteriores.

Solución

Respuesta correcta: **(c)**.

Al reducir el horizonte temporal de 6 meses a 1 mes, el parámetro t en la fórmula NBD disminuye. Esto produce que la distribución se desplace hacia la izquierda (menores conteos), ya que cada individuo tiene menos tiempo para acumular compras. La relación entre probabilidades no es simplemente lineal (opción d incorrecta), y el modelo NBD permite directamente cambiar el horizonte temporal (opción b incorrecta).

Ejercicio guiado E6: Modelos de conteo.

Un analista propone el uso de modelos de conteo para describir la intensidad de la participación de los usuarios de una red social. Los parámetros han sido estimados usando datos de 4 días de actividad. El modelo ajusta extremadamente bien. Sin embargo, al usar las estimaciones para pronosticar la actividad del quinto día, el modelo no ajusta bien. Se debiera concluir que:

- Se debe agregar la data para considerar la actividad agregada en todo el horizonte.
- Probablemente el comportamiento de los usuarios en el quinto día esté afectado por factores que no están presentes en los primeros cuatro días.
- Es necesario calcular esperanzas condicionales.
- Los supuestos de comportamiento son errados y se debe desechar el modelo.
- Todas las anteriores.

Solución

Respuesta correcta: **(b)**.

La explicación más plausible es que existan factores específicos del quinto día (por ejemplo, un evento especial, un día de la semana diferente, o un cambio estacional) que no están presentes en los datos de entrenamiento. Esto no implica que el modelo deba desecharse, sino que conviene investigar qué factores cambiaron. Las opciones (a), (c) y (d) no abordan directamente el problema de predicción fuera de muestra.

2.5 Modelos de elección binaria

Permiten modelar la probabilidad de que los individuos elijan un determinado comportamiento, dado que tienen varias opciones para elegir. Es aplicable en una situación de compras en un supermercado, exposición a varios anuncios, las variadas formas de uso de un producto, etc.

Modelo Binomial

Consideremos como variable de interés la probabilidad de que un individuo perteneciente a un segmento responda positivamente a una campaña de marketing. En el enfoque tradicional, se realiza una segmentación de clientes en grupos homogéneos, se envía mensajes a muestras aleatorias de cada segmento y se implementa una campaña en segmentos con tasa de respuesta (TR) sobre cierto corte, por ejemplo, $TR > \frac{\text{Costo de envío}}{\text{Margen unitario}}$.

Sin embargo, es posible incorporar un enfoque de modelos probabilísticos para abordar el problema. Si se considera la probabilidad de responder de manera positiva que tiene un segmento s , en particular p_s , es posible interpretar de manera sencilla la cantidad de respuestas obtenidas. Recordando que la suma de experimentos de Bernoulli corresponde a una variable aleatoria Binomial, es posible interpretar X_s como la cantidad de respuestas obtenidas de un total de m_s enviadas. Luego:

$$P(X_s = x_s \mid m_s, p_s) = \binom{m_s}{x_s} p_s^{x_s} (1 - p_s)^{m_s - x_s} \quad (2.40)$$

donde m_s es la población del segmento s y p_s es la probabilidad de respuesta del segmento s .

Se tiene que la verosimilitud es expresada como:

$$\begin{aligned} L(\theta) &= \prod_{s=1}^S P(X_s = x_s \mid m_s, \theta) \\ &= \prod_{s=1}^S \binom{m_s}{x_s} \theta^{x_s} (1 - \theta)^{m_s - x_s} \end{aligned} \quad (2.41)$$

Mientras que su log verosimilitud es:

$$\begin{aligned} LL(\theta) &= \sum_{s=1}^S \ln(P(X_s = x_s \mid m_s, \theta)) \\ &= \sum_{s=1}^S \ln \left(\binom{m_s}{x_s} \theta^{x_s} (1 - \theta)^{m_s - x_s} \right) \\ &= \sum_{s=1}^S \left[\ln \binom{m_s}{x_s} + \ln(\theta^{x_s}) + \ln((1 - \theta)^{m_s - x_s}) \right] \\ &= \sum_{s=1}^S \left[\ln \binom{m_s}{x_s} + x_s \ln(\theta) + (m_s - x_s) \ln(1 - \theta) \right] \end{aligned} \quad (2.42)$$

Con respecto a la heterogeneidad, en el caso de una mezcla finita en donde la probabilidad de éxito en cada uno de los intentos es distinta de acuerdo a dos

segmentos identificables, la probabilidad adopta el valor de θ_1 y θ_2 , donde π corresponde a la probabilidad de pertenecer al primer segmento. El modelo de probabilidad queda representado por:

$$P(X_s = x_s \mid m_s, \theta_1, \theta_2, \pi) = \binom{m_s}{x_s} [\theta_1^{x_s} (1 - \theta_1)^{m_s - x_s} \pi + \theta_2^{x_s} (1 - \theta_2)^{m_s - x_s} (1 - \pi)] \quad (2.43)$$

Modelo Beta-Binomial

En el caso de mezcla infinita, la heterogeneidad no observable se extrae aprovechando la distribución $B(\alpha, \beta)$:

$$\begin{aligned} P(X_s = x_s \mid \alpha, \beta) &= \int_0^1 P(X_s = x_s \mid m_s, \theta_s) g(\theta_s \mid \alpha, \beta) d\theta_s \\ &= \int_0^1 \binom{m_s}{x_s} \theta_s^{x_s} (1 - \theta_s)^{m_s - x_s} \frac{\theta_s^{\alpha-1} (1 - \theta_s)^{\beta-1}}{B(\alpha, \beta)} d\theta_s \\ &= \frac{\binom{m_s}{x_s}}{B(\alpha, \beta)} \int_0^1 \theta_s^{x_s + \alpha - 1} (1 - \theta_s)^{m_s - x_s + \beta - 1} d\theta_s \\ &= \binom{m_s}{x_s} \frac{B(\alpha + x_s, \beta + m_s - x_s)}{B(\alpha, \beta)} \end{aligned} \quad (2.44)$$

2.6 Heterogeneidad observable

Se ha expuesto modelos que intentan explicar y predecir el tiempo en que los individuos realizarán una determinada acción (e.g: proponer la probabilidad de fuga de un cliente), considerando que el comportamiento de los agentes se debe netamente a factores aleatorios.

En esta sección se incorporará heterogeneidad observable a un modelo de duración en tiempo continuo sin dependencia en la duración. Entendemos por heterogeneidad observable, aquellos factores observables (que están en los datos) intrínsecos a los individuos que los hacen distintos, tales como sexo, edad, nivel socioeconómico, género, entre otras.

2.6.1 Modelos de duración en tiempo discreto con heterogeneidad observable

Sea T_i la variable aleatoria que describe el instante en que el individuo i termina su relación comercial. Se modelará dicha variable con una distribución Geométrica Desplazada de parámetro θ_i , que es la probabilidad de abandono para el individuo i .

$$\mathbb{P}(T_i = t_i | \theta_i) = \theta_i (1 - \theta_i)^{t_i - 1} \quad (2.45)$$

Dado que se cuenta con información a nivel individual, es posible estimar un parámetro de abandono para cada persona.

Sea $\mathbf{x}_i$ el vector que contiene las variables explicativas del individuo i . Se modela la probabilidad de abandono θ_i utilizando una transformación logística para asegurar que el resultado se mantenga entre 0 y 1:

$$\theta_i = \frac{\exp(\beta_0 + \beta' \mathbf{x}_i)}{1 + \exp(\beta_0 + \beta' \mathbf{x}_i)} = \frac{1}{1 + \exp(-(\beta_0 + \beta' \mathbf{x}_i))} \quad (2.46)$$

donde β corresponde al vector de coeficientes asociados a las variables explicativas. La inclusión de esta función permite capturar el efecto de las covariables sin restringir el signo de los coeficientes.

En el caso donde la probabilidad de abandono depende de las características de cada individuo (heterogeneidad observable), la probabilidad de que el individuo i abandone en el tiempo t_i es:

$$\begin{aligned} \mathbb{P}(T_i = t_i | \beta_0, \beta) &= \theta_i (1 - \theta_i)^{t_i - 1} \\ \text{donde } \theta_i &= \frac{1}{1 + \exp(-(\beta_0 + \beta' \mathbf{x}_i))} \end{aligned} \quad (2.47)$$

Con lo cual, para un panel de N individuos, donde algunos abandonan en el período t_i y otros permanecen activos (censurados a la derecha), la log-verosimilitud del problema resulta:

$$LL(\beta_0, \beta) = \sum_{i \in \text{abandono}} [\ln(\theta_i) + (t_i - 1) \ln(1 - \theta_i)] + \sum_{i \in \text{activos}} t_i \ln(1 - \theta_i) \quad (2.48)$$

Para introducir heterogeneidad no observable en el modelo y así mezclar ambos efectos, es análogo al desarrollo de la integral del Modelo Beta-Geométrico desplazado. Se modelan los parámetros α_i y β_i de la distribución Beta de la siguiente forma para asegurar que sean positivos:

$$\alpha_i = \exp(\mathbf{a}' \mathbf{x}_i) \quad (2.49a)$$

$$\beta_i = \exp(\mathbf{b}' \mathbf{x}_i) \quad (2.49b)$$

La obtención de la expresión de probabilidad con heterogeneidad mixta es análoga a la obtención de la probabilidad con heterogeneidad no observable, salvo que la interpretación de los coeficientes α_i y β_i son distintas.

Finalmente, la función de log-verosimilitud para el modelo mixto resulta, con $\theta_{params} = (a, b)$:

$$LL(\theta_{params}) = \sum_{i \in \text{abandono}} \ln \left(\frac{B(\alpha_i + 1, t_i + \beta_i - 1)}{B(\alpha_i, \beta_i)} \right) + \sum_{i \in \text{activos}} \ln \left(\frac{B(\alpha_i, \beta_i + t_i)}{B(\alpha_i, \beta_i)} \right) \quad (2.50)$$

2.6.2 Modelos de duración en tiempo continuo con heterogeneidad observable

Sea T_i la variable aleatoria que describe el instante en que el individuo i realiza una determinada acción. Se modelará dicha variable aleatoria con una distribución exponencial de parámetro λ_i :

$$\mathbb{P}(T_i < t_i | \lambda_i) = 1 - e^{-\lambda_i t_i} \quad (2.51)$$

Cabe destacar que, dada la naturaleza de los datos, el comportamiento descrito se realizará de manera desagregada (dependencia de i en el parámetro), es decir, dado que existe información individual para cada individuo, es posible estimar el parámetro de cada uno de éstos (no así en los casos agregados vistos anteriormente).

Sea $\mathbf{x}_i$ el vector que contiene las variables explicativas pertinentes del individuo i . Se modela la tasa de llegada de i de la siguiente manera:

$$\lambda_i = \exp(\beta_0 + \beta' \mathbf{x}_i) = \lambda_0 \exp(\beta' \mathbf{x}_i) \quad (2.52)$$

Donde β corresponde al vector de coeficientes asociados a las variables explicativas en cuestión.

La inclusión de la exponencial se debe a que, por razones de convergencia e interpretación, la tasa de respuesta individual debe ser positiva. De esta forma, se puede capturar el efecto marginal de las variables demográficas sin restricción de signos. Así, el modelo no tendrá problemas si hay valores de β negativos.

En el caso con tasa homogénea (la misma para toda la población), la probabilidad que un individuo i realice un evento determinado antes del tiempo t_i , incluyendo su información observable, es:

$$\begin{aligned} \mathbb{P}(T_i < t_i | \beta, \lambda_0) &= 1 - e^{-\lambda_i t_i} \\ &= 1 - e^{-\lambda_0 \exp(\beta' \mathbf{x}_i) t_i} \end{aligned} \quad (2.53)$$

Con lo cual (considerando instantes de tiempo t_i^- y t_i^+ para discretizar el tiempo, un panel de N individuos y un vector de parámetros $\theta = (\beta, \lambda_0)$), la log verosimilitud del problema resulta:

$$LL(\theta) = \sum_{i=1}^N \ln \left(e^{-\lambda_0 \exp(\beta' \mathbf{x}_i) t_i^-} - e^{-\lambda_0 \exp(\beta' \mathbf{x}_i) t_i^+} \right) \quad (2.54)$$

Para incorporar adicionalmente heterogeneidad no observable, se asume que λ_0 se dejará distribuyendo de manera continua en la población según una ley $\Gamma(\alpha, r)$ pues, de esta forma, es posible mezclar tanto la heterogeneidad no observable, como la observable. El desarrollo de la integral es análogo al caso con heterogeneidad no observable, con la diferencia de que se multiplica la constante $\exp(\beta' \mathbf{x}_i)$ a la variable del tiempo t .

Finalmente, la función de log verosimilitud resulta, con $\theta = (\beta, \alpha, r)$:

$$LL(\theta) = \sum_{i=1}^N \ln \left(\left(\frac{\alpha}{\alpha + \exp(\beta' \mathbf{x}_i) t_i^-} \right)^r - \left(\frac{\alpha}{\alpha + \exp(\beta' \mathbf{x}_i) t_i^+} \right)^r \right) \quad (2.55)$$

2.6.3 Modelos de duración en tiempo continuo con dependencia de la duración y heterogeneidad observable

Cuando el tiempo en que ocurre un determinado suceso posee dependencia en la duración, el procedimiento es análogo que en el caso sin dicha dependencia, pero considerando que T_i distribuye según una ley Weibull.

$$P(T_i < t_i \mid \lambda_i, c) = 1 - e^{-\lambda_i (t_i)^c} \quad (2.56)$$

En el caso con tasa homogénea (la misma para toda la población), la probabilidad que un individuo i realice un evento determinado antes del tiempo t_i , incluyendo su información observable, es:

$$\begin{aligned} \mathbb{P}(T_i < t_i \mid \beta, \lambda_0, c) &= 1 - e^{-\lambda_i t_i} \\ &= 1 - e^{-\lambda_0 \exp(\beta' \mathbf{x}_i) (t_i)^c} \end{aligned} \quad (2.57)$$

Por lo que, la función de log verosimilitud toma la siguiente forma:

$$\begin{aligned}
LL(\theta) &= \sum_{i=1}^N \ln(\mathbb{P}(t_i^- < T_i < t_i^+ | \beta, \lambda_0, c)) \\
&= \sum_{i=1}^N \ln((\mathbb{P}(T_i < t_i^+ | \beta, \lambda_0, c)) - \mathbb{P}(T_i < t_i^- | \beta, \lambda_0, c)) \\
&= \sum_{i=1}^N \ln\left((1 - e^{-\lambda_0 \exp(\beta' \mathbf{x}_i)(t_i^+)^c}) - (1 - e^{-\lambda_0 \exp(\beta' \mathbf{x}_i)(t_i^-)^c})\right) \\
&= \sum_{i=1}^N \ln(e^{-\lambda_0 \exp(\beta' \mathbf{x}_i)(t_i^-)^c} - e^{-\lambda_0 \exp(\beta' \mathbf{x}_i)(t_i^+)^c})
\end{aligned} \tag{2.58}$$

De manera análoga al caso anterior, se puede introducir adicionalmente heterogeneidad no observable mediante el parámetro λ_0 según una distribución $\Gamma(\alpha, r)$. Dando como conocido este resultado, la log-verosimilitud queda descrita como:

$$\begin{aligned}
LL(\theta) &= \sum_{i=1}^N \ln(\mathbb{P}(t_i^- < T_i < t_i^+ | \beta, \lambda_0, r, c)) \\
&= \sum_{i=1}^N \ln\left(\left(\frac{\alpha}{\alpha + \exp(\beta' \mathbf{x}_i)(t_i^-)^c}\right)^r - \left(\frac{\alpha}{\alpha + \exp(\beta' \mathbf{x}_i)(t_i^+)^c}\right)^r\right)
\end{aligned} \tag{2.59}$$

2.6.4 Modelos de conteo con heterogeneidad observable

Sea Y_i el número de veces que el individuo i incurre en un comportamiento durante un período, modelada con distribución Poisson de parámetro $\lambda_i = \exp(\beta_0 + \beta' \mathbf{x}_i)$. La log-verosimilitud es:

$$LL(\beta_0, \beta) = \sum_{i=1}^N [y_i(\beta_0 + \beta' \mathbf{x}_i) - \exp(\beta_0 + \beta' \mathbf{x}_i) - \ln(y_i!)] \tag{2.60}$$

Para incorporar heterogeneidad no observable (modelo de *Regresión Binomial Negativa*), se asume $\lambda_0 \sim \text{Gamma}(r, \alpha)$:

$$P(Y_i = y_i | r, \alpha, \beta) = \frac{\Gamma(r + y_i)}{\Gamma(r) y_i!} \left(\frac{\alpha}{\alpha + \exp(\beta' \mathbf{x}_i)}\right)^r \left(\frac{\exp(\beta' \mathbf{x}_i)}{\alpha + \exp(\beta' \mathbf{x}_i)}\right)^{y_i} \tag{2.61}$$

2.6.5 Modelos de elección binaria con heterogeneidad observable

Sea X_i el número de éxitos en m_i intentos, con probabilidad θ_i modelada mediante transformación logística. La log-verosimilitud con heterogeneidad observable es:

$$LL(\beta_0, \beta) = \sum_{i=1}^N \left[\ln \binom{m_i}{x_i} + x_i \ln(\theta_i) + (m_i - x_i) \ln(1 - \theta_i) \right] \quad (2.62)$$

Para el modelo mixto (*Regresión Beta-Binomial*), con $\alpha_i = \exp(\mathbf{a}'\mathbf{x}_i)$ y $\beta_i = \exp(\mathbf{b}'\mathbf{x}_i)$:

$$P(X_i = x_i \mid \mathbf{a}, \mathbf{b}) = \binom{m_i}{x_i} \frac{B(\alpha_i + x_i, \beta_i + m_i - x_i)}{B(\alpha_i, \beta_i)} \quad (2.63)$$

2.7 Esperanzas condicionales

Primero, es fundamental establecer el valor esperado de las distribuciones que se usaron para modelar la heterogeneidad no observable. A continuación, se muestra el desarrollo para obtener la esperanza de las distribuciones Gamma y Beta.

2.7.1 Esperanzas de las distribuciones de mezcla

- **Esperanza de la distribución Gamma**

Para la distribución Gamma, con parámetro de forma r y de tasa α , que se utiliza para modelar tasas de ocurrencia (ej. λ), su función de densidad de probabilidad es:

$$g(\lambda|r, \alpha) = \frac{\alpha^r}{\Gamma(r)} \lambda^{r-1} e^{-\alpha\lambda} \quad (2.64)$$

La esperanza de una variable aleatoria λ que sigue esta distribución es:

$$\mathbb{E}[\lambda] = \frac{r}{\alpha} \quad (2.65)$$

Este resultado se obtiene a partir de la definición de valor esperado para una variable continua:

$$\begin{aligned} \mathbb{E}[\lambda] &= \int_0^\infty \lambda \cdot g(\lambda|r, \alpha) d\lambda \\ &= \int_0^\infty \lambda \cdot \frac{\alpha^r}{\Gamma(r)} \lambda^{r-1} e^{-\alpha\lambda} d\lambda \\ &= \frac{\alpha^r}{\Gamma(r)} \int_0^\infty \lambda^r e^{-\alpha\lambda} d\lambda \\ &= \frac{\alpha^r}{\Gamma(r)} \int_0^\infty \lambda^{(r+1)-1} e^{-\alpha\lambda} d\lambda \end{aligned}$$

Reconociendo que la integral $\int_0^\infty x^{k-1} e^{-\theta x} dx = \frac{\Gamma(k)}{\theta^k}$, con $k = r + 1$ y $\theta = \alpha$:

$$\begin{aligned}\mathbb{E}[\lambda] &= \frac{\alpha^r}{\Gamma(r)} \left[\frac{\Gamma(r+1)}{\alpha^{r+1}} \right] \\ &= \frac{\alpha^r}{\Gamma(r)} \cdot \frac{r\Gamma(r)}{\alpha^r \cdot \alpha} \\ &= \frac{r}{\alpha}\end{aligned}$$

• **Esperanza de la distribución Beta**

Para la distribución Beta con parámetros α y β que se utilizan para modelar probabilidades (ej. θ), su función de densidad de probabilidad es:

$$g(\theta|\alpha, \beta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \quad (2.66)$$

Por definición de valor esperado para una variable continua:

$$\mathbb{E}[\theta] = \int_0^1 \theta \cdot g(\theta|\alpha, \beta) d\theta \quad (2.67)$$

El desarrollo para obtener esta esperanza es el siguiente:

$$\begin{aligned}\mathbb{E}[\theta] &= \int_0^1 \theta \cdot g(\theta|\alpha, \beta) d\theta \\ &= \int_0^1 \theta \cdot \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} d\theta \\ &= \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^\alpha (1-\theta)^{\beta-1} d\theta \\ &= \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^{(\alpha+1)-1} (1-\theta)^{\beta-1} d\theta\end{aligned}$$

Reconociendo que la integral $\int_0^1 x^{a-1}(1-x)^{b-1} dx = B(a, b)$, con $a = \alpha + 1$ y $b = \beta$:

$$\begin{aligned}\mathbb{E}[\theta] &= \frac{1}{B(\alpha, \beta)} [B(\alpha + 1, \beta)] \\ &= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha + 1)\Gamma(\beta)}{\Gamma(\alpha + 1 + \beta)} \\ &= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)} \cdot \frac{\alpha\Gamma(\alpha)}{(\alpha + \beta)\Gamma(\alpha + \beta)} \\ &= \frac{\alpha}{\alpha + \beta}\end{aligned}$$

2.7.2 Modelo de tiempo discreto (Beta-Geométrico)

Para el modelo de duración en tiempo discreto, una pregunta válida es cuál es la probabilidad de abandono esperada para un cliente determinado, dado su historial con la empresa. Intuitivamente, esta probabilidad debería estar entre la tasa de abandono promedio de la población y el comportamiento observado de ese cliente.

Recordando que la distribución del parámetro θ (la probabilidad de abandono), condicionada a los datos observados de un cliente, se obtiene por el Teorema de Bayes:

$$g(\theta|\text{datos}) = \frac{\mathbb{P}(\text{datos}|\theta)g(\theta)}{\int \mathbb{P}(\text{datos}|\theta)g(\theta)d\theta} \quad (2.69)$$

donde $g(\theta)$ es la distribución a priori del parámetro (Beta) y $\mathbb{P}(\text{datos}|\theta)$ es la verosimilitud del comportamiento observado (Geométrica). Para el modelo Beta-Geométrico, la distribución posterior de θ también es una distribución Beta con parámetros actualizados.

Para el Modelo de Tiempo Discreto (Beta), la esperanza condicional $E[\theta|t]$ representa la probabilidad de abandono esperada para un cliente, la cual se actualiza y ajusta en función de su tiempo de permanencia observado t .

El cálculo de esta esperanza se basa en el Teorema de Bayes, que actualiza el conocimiento previo sobre el parámetro θ a la luz de los datos observados:

$$g(\theta|\text{datos}) = \frac{\mathbb{P}(\text{datos}|\theta) \cdot g(\theta)}{\int \mathbb{P}(\text{datos}|\theta) \cdot g(\theta)d\theta}$$

El proceso para derivar la esperanza condicional se descompone de la siguiente manera:

- **Distribución a Priori:** Se asume que la heterogeneidad en la probabilidad de abandono θ en la población sigue una distribución **Beta**:

$$g(\theta|\alpha, \beta) \sim \text{Beta}(\alpha, \beta)$$

- **Función de Verosimilitud:** El comportamiento de abandono individual se modela con una distribución Geométrica Desplazada, que indica la probabilidad de que el evento ocurra exactamente en el período t :

$$\mathbb{P}(T = t|\theta) = \theta(1 - \theta)^{t-1} \quad (2.70)$$

Con respecto a la Ley de Probabilidades Totales, ya se ha calculado en anterioridad para el Modelo Beta Geométrico-Desplazado. A continuación, se muestra el desarrollo:

$$\begin{aligned}
g(\theta|T=t) &= \frac{\mathbb{P}(T=t|\theta) \cdot g(\theta|\alpha, \beta)}{\int_0^1 \mathbb{P}(T=t|\theta) \cdot g(\theta|\alpha, \beta) d\theta} \\
&= \frac{(\theta(1-\theta)^{t-1}) \left(\frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \right)}{\frac{B(\alpha+1, \beta+t-1)}{B(\alpha, \beta)}} \\
&= \frac{\theta^\alpha (1-\theta)^{\beta+t-2}}{B(\alpha+1, \beta+t-1)}
\end{aligned} \tag{2.71}$$

La expresión resultante es la función de densidad de una distribución Beta, con los parámetros actualizados.

$$g(\theta|T=t) \sim \text{Beta}(\alpha+1, \beta+t-1)$$

De esta distribución posterior se deduce la Esperanza Condicional, que es simplemente la media de dicha distribución:

$$\mathbb{E}(\theta | T=t) = \frac{\alpha+1}{\alpha+\beta+t} \tag{2.72}$$

Esta expresión representa la probabilidad de abandono esperada y actualizada para un cliente que ha permanecido exactamente t períodos. El resultado combina la información previa sobre la población (contenida en α y β) con la observación específica del cliente (su duración t).

De forma análoga, para un cliente que sigue activo después de t períodos (observación censurada):

- **Función de Verosimilitud:** La probabilidad de que el evento aún no haya ocurrido es la función de supervivencia:

$$\mathbb{P}(T > t|\theta) = (1-\theta)^t \tag{2.73}$$

Obteniendo la distribución posterior:

$$\begin{aligned}
g(\theta|T > t) &= \frac{\mathbb{P}(T > t|\theta) \cdot g(\theta|\alpha, \beta)}{\int_0^1 \mathbb{P}(T > t|\theta) \cdot g(\theta|\alpha, \beta) d\theta} \\
&= \frac{((1-\theta)^t) \left(\frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \right)}{\frac{B(\alpha, \beta+t)}{B(\alpha, \beta)}} \\
&= \frac{\theta^{\alpha-1}(1-\theta)^{\beta+t-1}}{B(\alpha, \beta+t)}
\end{aligned} \tag{2.74}$$

La expresión resultante es la función de densidad de otra distribución Beta, con los parámetros actualizados.

$$g(\theta|T > t) \sim \text{Beta}(\alpha, \beta+t)$$

De esta distribución posterior se deduce la Esperanza Condicional, que es simplemente la media de dicha distribución:

$$\mathbb{E}(\theta \mid T > t) = \frac{\alpha}{\alpha + \beta + t} \quad (2.75)$$

Ejemplo 5 (Regla de decisión con esperanza condicional). Es posible definir una regla de retención dirigiendo una campaña a los clientes activos después de t períodos cuya probabilidad de abandono esperada supere cierto umbral:

$$\mathbb{E}(\theta \mid T > t) = \frac{\alpha}{\alpha + \beta + t} > \frac{\text{Costo de retención}}{\text{Valor del cliente}}$$

2.7.3 Modelo de tiempo continuo (Gamma-Exponencial)

Para el modelo de duración en tiempo continuo, una pregunta válida es cuál es la tasa de eventos esperada para un cliente determinado, dado su historial. Intuitivamente, esta tasa debería estar entre la tasa promedio de la población y el comportamiento observado de ese cliente.

Recordando que la distribución del parámetro λ (la tasa de eventos), condicionada a los datos observados de un cliente, se obtiene por el Teorema de Bayes:

$$g(\lambda \mid \text{datos}) = \frac{\mathbb{P}(\text{datos} \mid \lambda)g(\lambda)}{\int \mathbb{P}(\text{datos} \mid \lambda)g(\lambda)d\lambda}$$

La esperanza condicional $E[\lambda \mid t]$ representa la tasa de ocurrencia esperada para un cliente, la cual se actualiza y ajusta en función del tiempo transcurrido t .

El proceso para derivar la esperanza condicional se descompone de la siguiente manera:

- **Distribución a Priori:** Se asume que la heterogeneidad en la tasa de eventos λ en la población sigue una distribución **Gamma**:

$$g(\lambda \mid r, \alpha) \sim \text{Gamma}(r, \alpha)$$

- **Función de Verosimilitud:** El comportamiento del tiempo hasta el evento se modela con una distribución Exponencial, que indica la probabilidad (densidad) de que el evento ocurra exactamente en el instante t :

$$\mathbb{P}(T = t \mid \lambda) = f(t \mid \lambda) = \lambda e^{-\lambda t} \quad (2.76)$$

Con respecto a la Ley de Probabilidades Totales, el denominador de la expresión de Bayes corresponde a la probabilidad en heterogeneidad no observada del modelo Gamma-Exponencial. A continuación, se muestra el desarrollo de la distribución posterior:

$$\begin{aligned}
 g(\lambda|T=t) &= \frac{\mathbb{P}(T=t|\lambda) \cdot g(\lambda|r, \alpha)}{\int_0^\infty \mathbb{P}(T=t|\lambda) \cdot g(\lambda|r, \alpha) d\lambda} \\
 &= \frac{(\lambda t e^{-\lambda t}) \left(\frac{\alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} \right)}{\left(\frac{rt}{\alpha+t} \right) \left(\frac{1}{\alpha+t} \right)^r} \\
 &= \frac{(\alpha+t)^{r+1}}{\Gamma(r+1)} \lambda^r e^{-\lambda(\alpha+t)}
 \end{aligned} \tag{2.77}$$

La expresión resultante es la función de densidad de una distribución Gamma, con los parámetros actualizados.

$$g(\lambda|T=t) \sim \text{Gamma}(r+1, \alpha+t)$$

De esta distribución posterior se deduce la Esperanza Condicional, que es simplemente la media de dicha distribución:

$$\mathbb{E}(\lambda | T=t) = \frac{r+1}{\alpha+t} \tag{2.78}$$

2.7.4 Modelo de conteo (Gamma-Poisson)

Para el modelo de conteo, una pregunta válida es cuál es la tasa de eventos esperada para un cliente determinado, dado su historial de eventos en un período de tiempo t .

Recordando que la distribución del parámetro λ (la tasa de eventos), condicionada a los datos observados de un cliente, se obtiene por el Teorema de Bayes:

$$g(\lambda|\text{datos}) = \frac{\mathbb{P}(\text{datos}|\lambda)g(\lambda)}{\int \mathbb{P}(\text{datos}|\lambda)g(\lambda)d\lambda}$$

El proceso para derivar la esperanza condicional se descompone de la siguiente manera:

- **Distribución a Priori:** Se asume que la heterogeneidad en la tasa de eventos λ en la población sigue una distribución **Gamma**:

$$g(\lambda|r, \alpha) \sim \text{Gamma}(r, \alpha)$$

- **Función de Verosimilitud:** El comportamiento de conteo de eventos se modela con una distribución **Poisson**, que indica la probabilidad de que ocurran exactamente y eventos en un período de duración t :

$$\mathbb{P}(Y_t = y | \lambda, t) = \frac{(\lambda t)^y e^{-\lambda t}}{y!}$$

Con respecto a la Ley de Probabilidades Totales, el denominador de la expresión de Bayes corresponde a la probabilidad en heterogeneidad no observada del modelo Gamma-Poisson (NBD). A continuación, se muestra el desarrollo de la distribución posterior:

$$\begin{aligned} g(\lambda | Y_t = y) &= \frac{\mathbb{P}(Y_t = y | \lambda, t) \cdot g(\lambda | r, \alpha)}{\int_0^\infty \mathbb{P}(Y_t = y | \lambda, t) \cdot g(\lambda | r, \alpha) d\lambda} \\ &= \frac{\left(\frac{(\lambda t)^y e^{-\lambda t}}{y!} \right) \left(\frac{\alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} \right)}{\frac{\Gamma(r+y)}{\Gamma(r)y!} \left(\frac{\alpha}{\alpha+t} \right)^r \left(\frac{t}{\alpha+t} \right)^y} \\ &= \frac{(\alpha + t)^{r+y}}{\Gamma(r+y)} \lambda^{r+y-1} e^{-\lambda(\alpha+t)} \end{aligned} \quad (2.79)$$

La expresión resultante es la función de densidad de una distribución Gamma, con los parámetros actualizados.

$$g(\lambda | Y_t = y) \sim \text{Gamma}(r + y, \alpha + t)$$

De esta distribución posterior se deduce la Esperanza Condicional, que es simplemente la media de dicha distribución:

$$\mathbb{E}(\lambda | Y_t = y) = \frac{r + y}{\alpha + t} \quad (2.80)$$

2.7.5 Modelo de elección binaria (Beta-Binomial)

Recordando que la distribución del parámetro θ (la probabilidad de éxito), condicionada a los datos observados, se obtiene por el Teorema de Bayes:

$$g(\theta | \text{datos}) = \frac{\mathbb{P}(\text{datos} | \theta) g(\theta)}{\int \mathbb{P}(\text{datos} | \theta) g(\theta) d\theta}$$

El proceso para derivar la esperanza condicional se descompone de la siguiente manera:

- **Distribución a Priori:** Se asume que la heterogeneidad en la probabilidad de éxito θ en la población sigue una distribución **Beta**:

$$g(\theta | \alpha, \beta) \sim \text{Beta}(\alpha, \beta)$$

- **Función de Verosimilitud:** El comportamiento de elección se modela con una distribución Binomial, que indica la probabilidad de obtener exactamente x éxitos en m intentos:

$$\mathbb{P}(X = x|m, \theta) = \binom{m}{x} \theta^x (1 - \theta)^{m-x}$$

Con respecto a la Ley de Probabilidades Totales, el denominador de la expresión de Bayes corresponde a la probabilidad en heterogeneidad no observada del modelo Beta-Binomial. A continuación, se muestra el desarrollo de la distribución posterior:

$$\begin{aligned} g(\theta|X = x) &= \frac{\mathbb{P}(X = x|m, \theta) \cdot g(\theta|\alpha, \beta)}{\int_0^1 \mathbb{P}(X = x|m, \theta) \cdot g(\theta|\alpha, \beta) d\theta} \\ &= \frac{\binom{m}{x} \theta^x (1 - \theta)^{m-x} \left(\frac{\theta^{\alpha-1} (1-\theta)^{\beta-1}}{B(\alpha, \beta)} \right)}{\binom{m}{x} \frac{B(\alpha+x, \beta+m-x)}{B(\alpha, \beta)}} \\ &= \frac{\theta^{\alpha+x-1} (1 - \theta)^{\beta+m-x-1}}{B(\alpha+x, \beta+m-x)} \end{aligned}$$

La expresión resultante es la función de densidad de una distribución Beta, con los parámetros actualizados.

$$g(\theta|X = x) \sim \text{Beta}(\alpha + x, \beta + m - x)$$

De esta distribución posterior se deduce la Esperanza Condicional, que es simplemente la media de dicha distribución:

$$\mathbb{E}(\theta | X = x) = \frac{\alpha + x}{\alpha + \beta + m} \quad (2.81)$$

En el modelo de elección en donde la $P(X_s = x_s)$ quedaba definida en (2.40). Una pregunta válida que se puede hacer es cuál es la tasa de respuesta de un segmento s determinado. Intuitivamente debería estar entre la tasa de respuesta esperada de la población y la observada, es decir,

$$\mathbb{E}(\theta_s | m_s, x_s) = \gamma \frac{\alpha}{\alpha + \beta} + (1 - \gamma) \frac{x_s}{m_s}, \quad \gamma = \frac{\alpha + \beta}{\alpha + \beta + m_s} \quad (2.82)$$

Esta última igualdad se encuentra al hacer el reemplazo $\gamma = \frac{\alpha + \beta}{\alpha + \beta + m_s}$, la cual coincide con la expresión de Bayes. Se podría replantear la regla de decisión y enviar catálogos a los segmentos s tales que

Ejemplo 6 (Regla de decisión para campañas). Es posible definir una regla de envío de catálogos al segmento s cuando:

$$\mathbb{E}(\theta_s | x_s) = \frac{\alpha + x_s}{\alpha + \beta + m_s} > \frac{\text{Costo de envío}}{\text{Margen unitario}}$$

Esta regla mejora la decisión ingenua basada únicamente en la tasa observada x_s/m_s , ya que incorpora información previa sobre la distribución poblacional de las tasas de respuesta.

2.8 Customer Lifetime Value: caso contractual

Database Marketing posee dos elementos esenciales, tiempo de permanencia con la firma e intensidad de compra mientras el cliente está en la firma. Para el caso determinista se define Life Time Value (CLV) como

$$CLV = \sum_{t=0}^T m \cdot \frac{r^t}{(1+d)^t} \quad (2.83)$$

donde m es el flujo neto por período (si el cliente está activo); r es la tasa de retención; d es la tasa de descuento; y T es el horizonte de evaluación.

Para el caso estocástico, sean $\mathbb{E}(v(t))$ valor esperado de los flujos del cliente en el instante t (asumiendo que está activo); $S(t)$ la probabilidad que el cliente siga activo en el instante t ; y $d(t)$ el factor de descuento que refleja el valor presente del dinero recibido en el instante t . El cálculo de CLV es:

$$\mathbb{E}(CLV) = \int_0^\infty \mathbb{E}(v(t)) S(t) d(t) dt \quad (2.84)$$

Esta definición es inútil a menos que se operacionalice $\mathbb{E}(v(t))$, $S(t)$ y $d(t)$ para la situación particular.

Es importante distinguir entre situaciones contractuales y no contractuales:

- **Contractual:** Observamos cuando un cliente deja de estar activo. Ejemplo: suscripción a una revista, plan VTR, etc.
- **No Contractual:** No observamos cuando un cliente deja de estarlo.

El desafío de lo mercados contractuales: ¿Cómo diferenciamos aquellos clientes que han terminado su relación con la firma, de aquellos que simplemente están en un largo período de inactividad?

También se debe distinguir según la oportunidad de hacer la transacción:

- *Discreta:* la acción puede realizarse en un número discreto de ocasiones.

- *Continua*: la acción puede realizarse en cualquier momento. Ejemplo, transacción con una tarjeta de crédito.

2.8.1 Modelo contractual a tiempo discreto

En el mercado de las revistas, típicamente el 30 % renueva al final de su primera suscripción, pero ese número salta al 50 % para la segunda renovación y hasta el 75 % para subscriptores de mayor antigüedad (Fielding, Michael (2005), “Get Circulation Going: DM Redesign Increases Renewal Rates for Magazines”, *Marketing News*, September 1, 9-10).

Al evaluar las tasas de retención de una base de clientes, es necesario considerar las diferencias entre las cohortes y proyectar los comportamientos más allá de los que observamos.

Explicaciones alternativas (y complementarias) para el incremento de las tasas de retención: Dinámicas a nivel individual (incremento de lealtad) y un cambio en la mezcla de la composición de la población.

Ejemplo 7 (Rol de la heterogeneidad en CLV). Considérese una cohorte de 10.000 clientes con gasto promedio de \$100 por período, compuesta por dos segmentos:

- *Segmento 1* (1/3 de los clientes): tasa de retención constante de 0,9.
- *Segmento 2* (2/3 de los clientes): tasa de retención constante de 0,5.

Table 2.2: Rol de la heterogeneidad.

# Clientes activos				Tasa de retención		
Año	Seg-1	Seg-2	Total	Seg-1	Seg-2	Total
1	3.333	6.667	10.000			
2	3.000	3.334	6.334	0,9	0,5	0,633
3	2.700	1.667	4.367	0,9	0,5	0,689
4	2.430	834	3.264	0,9	0,5	0,747
5	2.187	417	2.604	0,9	0,5	0,798

En el Cuadro 1.1 la tasa de retención agregada (en rojo en la tabla) es decreciente aún cuando a nivel individual las retenciones son constantes en el tiempo.

El valor residual de un cliente activo del cohorte, si pertenece al segmento 1 es:

$$\mathbb{E}(RLV_1) = \sum_{t=1}^{\infty} \$100 \cdot \frac{0,9^t}{(1 + 0,1)^{t-1}} = \$495$$

Para el segmento 2:

$$\mathbb{E}(RLV_2) = \sum_{t=1}^{\infty} \$100 \cdot \frac{0,5^t}{(1 + 0,1)^{t-1}} = \$92$$

Aplicando la regla de Bayes, condicional en estar activo tras 4 renovaciones:

$$P(\text{seg-1} \mid \text{renovar 4 veces}) = \frac{0,9^4 \cdot 0,333}{0,9^4 \cdot 0,333 + 0,5^4 \cdot 0,667} = 0,84$$

Luego, el *Lifetime Value Residual* viene dado por:

$$\mathbb{E}(RLV) = 0,84 \cdot \$495 + (0,84) \cdot \$92 = \$493,08$$

En mercados contractuales, ¿cuánto se pierde si no se considera la heterogeneidad?. En este ejemplo, si se toma en cuenta la tasa de retención agregada, el valor de la base de clientes es \$4.945.049. En cambio, si se distingue por segmentos, este valor asciende a \$7.940.992.

En estudios con bases de datos reales muestran que el error en el CLV se eleva hasta el 50%. El impacto sobre el CLV de aumentar las tasas de retención es hasta un 50%. Para calcular CLV hay que hacerlo condicional en la duración.

Impacto de ignorar la heterogeneidad. En mercados contractuales, si se utiliza la tasa de retención agregada, el valor de la base de clientes se subestima significativamente. Estudios con bases de datos reales muestran que el error en el CLV puede elevarse hasta un 50% cuando no se distingue por segmentos.

Se postulan los siguientes supuestos para el caso discreto:

1. La tasa de retención a nivel individual es $1 - \theta$:

$$S(t|\theta) = (1 - \theta)^t, \quad t = 1, 2, 3, \dots \quad (2.85)$$

2. La heterogeneidad en θ es capturada por una distribución Beta:

$$f(\theta|\alpha, \beta) = \frac{\theta^{\alpha-1}(1 - \theta)^{\beta-1}}{B(\alpha, \beta)} \quad (2.86)$$

La probabilidad de que el cliente siga activo en t :

$$S(t \mid \alpha, \beta) = \frac{B(\alpha, \beta + t)}{B(\alpha, \beta)} \quad (2.87)$$

Considerando a un cliente que ha estado activo por n períodos:

$$\begin{aligned} \mathbb{E}(RLV(d \mid \text{activo en } n \text{ períodos})) &= \sum_{t=n+1}^{\infty} \mathbb{E}(v(t)) \cdot \frac{S(t|t > n)}{(1 + d)^{t-n}} \\ &= \bar{v} \sum_{t=n+1}^{\infty} \frac{S(t|t > n)}{(1 + d)^{t-n}}, \quad \text{Asumiendo flujos constantes} \end{aligned} \quad (2.88)$$

DERL es el valor esperado residual del cliente (condicional en la antigüedad). Para el caso de la distribución geométrica desplazada:

$$\begin{aligned} \text{DERL}(d \mid \text{activo en } n \text{ períodos}) &= \sum_{t=n}^{\infty} \frac{S(t)}{S(n-1)} \cdot \left(\frac{a}{a+d} \right)^{t-n} \\ &= \frac{(1-\theta)(1+d)}{d+\theta} \end{aligned} \quad (2.89)$$

Cuando la tasa de abandono θ no es observable, hay que encontrar la distribución de esta variable en la población. Para ello se usa la regla de Bayes para calcular la distribución posterior condicional en la antigüedad.

$$\begin{aligned} \text{DERL}(d \mid \alpha, \beta, \text{activo en } n) &= \int_0^1 \frac{(1-\theta)(1+d)}{d+\theta} \cdot \frac{S(n-1|\theta)f(\theta|\alpha, \beta)}{S(n-1|\alpha, \beta)} d\theta \\ &= \left(\frac{\beta+n-1}{\alpha+\beta+n-1} \right) \\ &\quad \cdot {}_2F_1 \left(1, \beta+n; \alpha+\beta+n; \frac{1}{1+d} \right) \end{aligned} \quad (2.90)$$

donde ${}_2F_1$ es la *función hipergeométrica de Gauss*.

2.8.2 Modelo contractual a tiempo continuo

Algunos supuestos son:

1. La duración de la relación de un cliente con la firma está caracterizada por una distribución exponencial, con densidad y función de sobrevivencia dadas por:

$$f(t \mid \lambda) = \lambda e^{-\lambda t} \quad (2.91)$$

$$S(t \mid \lambda) = e^{-\lambda t} \quad (2.92)$$

2. La heterogeneidad en λ es capturada por una distribución Gamma:

$$g(\lambda \mid r, \alpha) = \frac{\alpha^r \lambda^{r-1} e^{-\alpha \lambda}}{\Gamma(r)} \quad (2.93)$$

Entonces, la probabilidad de seguir activo en t es:

$$S(t \mid r, \alpha) = \int_0^{\infty} S(t \mid \lambda) g(\lambda \mid r, \alpha) d\lambda = \left(\frac{\alpha}{\alpha+t} \right)^r \quad (2.94)$$

El valor esperado de Residual Lifetime Value es:

$$\begin{aligned}\mathbb{E}(\text{RLV}(\delta \mid \text{activo en } s)) &= \int_s^\infty \mathbb{E}(v(t))S(t \mid t > s)\delta(t) dt \\ &= \bar{v} \cdot \text{DERL}(\delta \mid r, \alpha, \text{activo en } s)\end{aligned}\quad (2.95)$$

donde

$$\text{DERL}(\delta \mid r, \alpha, \text{activo en } s) = (\alpha + s)^r \delta \Psi(r; r; (\alpha + s)\delta) \quad (2.96)$$

Ψ es la *función hiper geométrica confluyente del segundo tipo*.

2.9 Resumen

Conceptos clave.

- Los modelos probabilísticos describen el comportamiento de los agentes mediante distribuciones de probabilidad, asumiendo que las decisiones provienen de procesos estocásticos.
- Se distinguen tres tipos de modelos básicos: *duración* (¿cuándo?), *conteo* (¿cuántos?) y *elección binaria* (¿cuál?).
- La *heterogeneidad no observable* se captura mediante distribuciones de mezcla (Beta para probabilidades, Gamma para tasas).
- La *heterogeneidad observable* se incorpora mediante regresiones sobre los parámetros del modelo.
- Las *esperanzas condicionales* (actualización bayesiana) permiten personalizar predicciones a nivel individual.

Decisiones de modelamiento.

- *Distribución individual*: Geométrica/Exponencial/Weibull para duración, Poisson para conteo, Binomial para elección.
- *Distribución de mezcla*: Beta para $\theta \in [0, 1]$, Gamma para $\lambda \in (0, \infty)$.
- *Dependencia en la duración*: parámetro c de la Weibull ($c = 1$ implica falta de memoria).

Métricas relevantes.

- Log-verosimilitud, AIC y BIC para comparación de modelos.
- Alcance, frecuencia promedio y GRPs en modelos de conteo.
- CLV para valoración de clientes.

Errores comunes en esta unidad.

- Confundir la *función Beta* $B(\alpha, \beta)$ con la *distribución Beta*.
- Olvidar la contribución de los individuos censurados (activos al final del período) en la verosimilitud.

- Asumir homogeneidad cuando la tasa de retención agregada varía en el tiempo (efecto de composición).
- Usar la tasa observada x/m en lugar de la esperanza condicional para decisiones individuales.
- Extrapolar modelos sin dependencia en la duración a fenómenos donde el tiempo transcurrido sí es relevante.

Referencias principales: Schmittlein et al. (1987), Fader et al. (2005a), Fader & Hardie (2010), Fader et al. (2005b), Wooldridge (2019).

2.10 Problemas

Problema 1: VTV Seguros de Salud

VTV es una empresa aseguradora, en la que una de sus principales líneas de negocio consiste en la provisión de cobertura de segunda línea para clientes corporativos. En simple, VTV ofrece un seguro de salud que se gatilla cuando ocurre un gasto médico, pero que se activa después de que operen las coberturas obligatorias de Fonasa o Isapre. El servicio se vende a empresas de distintos rubros para que sirvan como beneficio complementario para sus trabajadores.

Recientemente, VTV ha lanzado un nuevo servicio llamado *TuBienestar*. Este servicio ofrece que los empleados de las empresas clientes de VTV puedan acceder a una batería de exámenes preventivos que aspiran a detectar tempranamente problemas de consideración y así reducir los gastos en salud a largo plazo. A continuación, usaremos modelos probabilísticos para tener una primera aproximación del valor del programa *TuBienestar*. Para eso, haremos uso de la base histórica de gastos que contiene la valorización de todos los eventos de salud, incluyendo consultas médicas, hospitalizaciones, exámenes y compra de medicamentos. Aunque existe información más detallada de cada evento, nos concentraremos en n_{ijkt} , correspondiente al número de eventos de salud en el periodo t del beneficiario i , que pertenece al grupo j de la empresa k . Notar que en esta base, los eventos están agrupados por periodos trimestrales y los beneficiarios de cada empresa están separados por segmento, ya que distintos tipos de empleados podrían acceder a distintos beneficios.

1. Actualmente, VTV describe el número de eventos de cada beneficiario usando un modelo de Poisson. En este modelo, como los eventos de salud no son tan frecuentes, una gran proporción de los beneficiarios no registra eventos en un trimestre dado y , por tanto, el caso de cero eventos merece un tratamiento especial. Para modelar los eventos de gasto, se considera que, si hay un evento, el número de eventos se distribuye Poisson, pero que la probabilidad de no observar ningún evento es mayor que la de un modelo de Poisson tradicional. Escriba la log-verosimilitud de este modelo de conteo con ceros inflados. **Hint:** *Le puede resultar útil conceptualizar el modelo pensando que con probabilidad π no hay ningún evento y que con probabilidad $1 - \pi$ el proceso sigue distribución de Poisson standard.*

2. Suponga ahora que, en vez de describir el número de eventos de cada beneficiario, nos concentramos en el número de beneficiarios que registra al menos un evento dentro de cada segmento-compañía. Así, como alternativa al modelo existente, se postula describir la ocurrencia de eventos de salud como un modelo de elección binaria.
 - a. Suponiendo que puede haber segmentos con mayor propensión a registrar eventos, escriba la log-verosimilitud de un modelo binomial con dos clases latentes.
 - b. Suponga que ha estimado el modelo y los estimadores máximos verosímiles vienen dados por $(\theta_1, \theta_2, \pi) = (0.1, 0.6, 0.5)$. Considere un segmento con 824 beneficiarios que, transcurrido un trimestre, evidencia 17 eventos de salud. Escriba una expresión para la probabilidad que este segmento corresponda a la clase de mayor propensión a registrar eventos.

Para las descripciones anteriores considere que n_{jkt} es el número total de beneficiarios que tuvieron algún gasto de salud en el trimestre t dentro del segmento j de la empresa k y que m_{jkt} es el número total de beneficiarios dentro de ese segmento, empresa y trimestre.

3. Como último enfoque, se estiman tres versiones de modelos beta-binomiales. En los modelos que se incluye heterogeneidad observable, se consideran variables asociadas tanto a características del segmento como a variables estacionales y de tendencia.

Table 2.3: Estimadores máximo verosímiles de dos modelos beta-binomiales con variables explicativas.

Variable	Modelo 1	Modelo 2	Modelo 3
α	0,127 **	0,151 **	0,149 *
β	3,503 ***	3,729 ***	3,852 ***
Sector:Minería		1,234 ***	1,108 ***
Sector:Construcción		2,122 ***	1,432 **
Sector:Salud		1,784 ***	1,665 ***
Tamaño-Mediana		0,145	-0,004
Tamaño-Grande		0,372 *	0,401 *
AntigüedadContrato		0,188 **	0,193 **
TuBienestar			-0,089 **
Invierno		2,921 ***	2,955 ***
Verano		-0,539 *	-0,564 *
Tendencia		0,278 **	0,305 **
N. Obs	34.825	34.825	34.825
LL	-51.771,8	-45.282,1	-41.321,9
AIC	107.543,6	90.580,2	82.665,8

- a. Discuta si el programa *TuBienestar* ayuda a describir el comportamiento de los beneficiarios y si el programa *TuBienestar* es bueno para la salud de los beneficiarios.
- b. En otros mercados el valor esperado de la probabilidad que un beneficiario exhiba un evento de salud en un trimestre dado es 0.16. ¿Cómo testearía si los datos de Chile son distintos a ese valor medio internacional?

Solución

1. Siguiendo la indicación, la probabilidad de los eventos viene dada por:

$$\Pr(N_{ijkt} = n \mid \lambda, \pi) = \begin{cases} \pi + (1 - \pi)e^{-\lambda} & n = 0 \\ (1 - \pi)\frac{e^{-\lambda}\lambda^n}{n!} & n > 0 \end{cases}$$

Entonces, la función log-verosimilitud viene dada por:

$$LL = \sum_i \sum_j \sum_k \sum_t \left[1_{n_{ijkt}=0} \ln(\pi + (1 - \pi)e^{-\lambda}) + 1_{n_{ijkt}>0} \ln\left((1 - \pi)\frac{e^{-\lambda}\lambda^n}{n!}\right) \right]$$

2. Sean θ_1 y θ_2 las probabilidades de registrar un evento de las clases 1 y 2 respectivamente.
- a. La probabilidad de observar exactamente n eventos en el segmento de clientes j de la empresa k en el trimestre t viene dada por:

$$\Pr(n_{jkt} = n \mid \theta_1, \theta_2, \pi) = \pi \binom{m}{n_{jkt}} \theta_1^{n_{jkt}} (1 - \theta_1)^{m - n_{jkt}} + (1 - \pi) \binom{m}{n_{jkt}} \theta_2^{n_{jkt}} (1 - \theta_2)^{m - n_{jkt}}$$

Entonces, la log-verosimilitud viene dada por:

$$LL = \sum_j \sum_k \sum_t \ln\left(\Pr(n_{jkt} \mid \theta_1, \theta_2, \pi)\right)$$

- b. Aplicamos la fórmula de Bayes directamente:

$$\Pr(\lambda = \lambda_2 \mid n_{jkt} = 17) = \frac{\Pr(n_{jkt} = 17 \mid \lambda_2) \Pr(\lambda_2)}{\Pr(n_{jkt} = 17 \mid \lambda_1) \Pr(\lambda_1) + \Pr(n_{jkt} = 17 \mid \lambda_2) \Pr(\lambda_2)}$$

Donde:

$$\Pr(n_{jkt} = 17 \mid \lambda = \lambda_1) = \binom{824}{17} (0.1)^{17} (1 - 0.1)^{824-17},$$

$$\Pr(n_{jkt} = 17 \mid \lambda = \lambda_2) = \binom{824}{17} (0.6)^{17} (1 - 0.6)^{824-17},$$

$$\Pr(\lambda = \lambda_1) = \Pr(\lambda = \lambda_2) = \frac{1}{2}.$$

3. La parte a) requiere mirar los resultados de la tabla. La parte b) puede contestarse independientemente.

- a. El AIC del modelo 2 es mayor que el AIC del modelo 3 que solo agrega la variable *TuBienestar*, y por tanto, la variable tiene valor explicativo. Se puede argumentar también que el coeficiente mismo de la variable es significativo y por tanto ayuda a explicar.

Respecto al impacto en la salud, como el coeficiente es significativo y negativo, diríamos que aquellos que participan del programa tienen una menor probabilidad de generar eventos y, por tanto, el programa sería beneficioso. Sería deseable discutir que este efecto no es necesariamente causal, pero no lo consideraremos necesario.

- b. Recordar que la esperanza de una $\text{Beta}(\alpha, \beta)$ viene dada por $\frac{\alpha}{\alpha + \beta}$. Por lo tanto, lo que necesitamos testear es que $\alpha = 0.16(\alpha + \beta)$, que es una restricción lineal que puede testearse usando un test de ratios de verosimilitud.

Problema 2: Vectorix Marketing B2B

En el contexto del marketing B2B (Business to Business) para servicios profesionales, las empresas han comenzado a incorporar el marketing de contenidos (Content Marketing, CM) como parte integral de sus estrategias comerciales. Estas iniciativas buscan, principalmente, generar oportunidades de venta (leads) y fidelizar clientes existentes, mediante la entrega de información de valor. El marketing de contenidos puede adoptar múltiples formas, tanto en entornos presenciales como digitales. Las actividades presenciales incluyen eventos cara a cara, como seminarios, conferencias o talleres; mientras que las digitales abarcan webinars, seminarios virtuales y la distribución de contenido a través de plataformas digitales, como los sitios web corporativos.

En los mercados B2B, donde un número reducido de cuentas clave suele concentrar una parte importante de las ventas, la gestión del marketing de contenidos debe articularse cuidadosamente con los procesos tradicionales de ventas. Es habitual que estas organizaciones estructuren el proceso de ventas en dos grandes etapas: generación de leads y conversión de leads. Un lead representa una oportunidad de negocio que se manifiesta a través de señales tempranas de interés por parte de una cuenta clave, como una consulta por correo electrónico, una llamada comercial, la solicitud de una cotización o la descarga de un folleto técnico. Un lead se considera convertido cuando se concreta la venta y se formalizan los compromisos de pago.

Un desafío relevante para la gestión analítica del marketing de contenidos consiste en identificar qué tipos de actividades -presenciales o digitales- generan un mayor número de leads, cuáles de ellas contribuyen de forma más efectiva a su conversión. Asimismo, se plantea la hipótesis de que el nivel de participación (engagement) de los empleados de las cuentas clave podría desempeñar un rol mediador en estos procesos.

En este contexto, Vectorix, una empresa B2B que ofrece servicios profesionales,

busca comprender cuáles componentes de su estrategia de marketing de contenidos resultan más efectivos. La empresa sospecha que la participación digital (por ejemplo, en webinars o mediante el consumo de contenido online) tiene un impacto positivo en la generación y conversión de leads. Sin embargo, la efectividad relativa de las actividades presenciales frente a las digitales sigue siendo una incógnita.

Con base a sus registros históricos de actividades de marketing y resultados comerciales, Vectorix se propone desarrollar un análisis cuantitativo que le permita evaluar la efectividad comparada de las distintas acciones de marketing de contenido. El objetivo final es orientar la asignación presupuestaria para los próximos dos trimestres, priorizando aquellas tácticas que maximicen tanto la generación como la conversión de oportunidades comerciales.

Los registros históricos se han condesando en una única base de datos que contiene las siguientes columnas:

- **Idaccount:** identificador de la cuenta clave.
- **Zone:** área geográfica en que se encuentra la sede central de la cuenta clave.
- **Industry:** industria a la que pertenece la cuenta.
- **Tenure:** Número de años transcurridos desde que la empresa comenzó su relación con la cuenta.
- **Year:** año fiscal.
- **Leads:** Número de oportunidades generadas por la cuenta durante el año fiscal correspondiente.
- **ConvertedLeads:** Número de oportunidades cerradas para la cuenta durante el año fiscal correspondiente.
- **NEventOffline:** Número de eventos presenciales en los que participó la cuenta clave durante el año fiscal.
- **NeventOnline:** Número de eventos digitales en los que participó la cuenta clave durante el año fiscal.
- **NEmployeeAccess:** Número de empleados de la cuenta que ha tenido al menos algún acceso o consumo de contenido digital durante el año fiscal.
- **NAccessMean:** Número promedio de accesos y consumos de contenido digital para los empleados de la cuenta que interactúan durante el año fiscal.

1. Proponga un modelo de conteo (debe definir la variable dependiente utilizando la base de datos disponible, junto a sus índices) para describir el número de oportunidades ganadas mediante un modelo que integre heterogeneidad observable. Escriba la log-verosimilitud del modelo anterior y especifique cuántos parámetros deben estimarse. Si necesita, suponga

conocida la cardinalidad de todos los índices del modelo y que hay un año de desfase, por lo que debe considerar el t anterior. Para la construcción del modelo considere:

- a. La industria y la zona a la que pertenecen cada cuenta incide en la posibilidad de generar y convertir más o menos oportunidades.
 - b. El tiempo de relación afecta las oportunidades ganadas. El primer año de relación, en general, hay un numero grande de oportunidades, el que cae marcadamente el segundo año para repuntar y mantenerse relativamente estable a partir del tercer año.
 - c. Se espera que la participación en eventos presenciales y digitales tienen un efecto en conversión de oportunidades, pero se hipotetiza que estos dos canales son sustitutos entre sí. Considere que los datos tienen un año de desfase, por lo que debe considerar el período anterior.
 - d. El número total de interacciones de los empleados debiera aumentar las oportunidades convertidas, pero el efecto adicional de cada nueva interacción tiende a ser menor a medida que el número de interacción crece.
 - e. Los procesos de conversión son relativamente lentos, por lo que las oportunidades convertidas dependen principalmente de la actividad del año anterior y no del año en curso. Considere que los datos tienen un año de desfase, por lo que debe considerar el período anterior.
2. Usando los mismos supuestos del modelo anterior, construya un modelo de elección binaria con heterogeneidad observable para describir el número de oportunidades ganadas. Escriba la log-verosimilitud y especifique cuántos parámetros más deben estimarse con respecto al modelo anterior. ¿Qué ventajas puede tener un modelo de elección binario por sobre no de conteo (aplicado a este problema)? **Hint:** Si le resulta conveniente en su notación, puede asumir que la tasa del modelo de conteo que captura todas las componentes relevantes del problema se denota $\lambda_{it}(x_{it})$, con x_{it} un conjunto de variables observables de la cuenta i en el año t .
3. Considerando que, quizás, la heterogeneidad observable no es suficiente para capturar toda la variabilidad del fenómeno, se consideró extender el modelo para incluir heterogeneidad no observable. Aunque en este nuevo modelo el conjunto de variables explicativas es algo distinto al del modelo sin heterogeneidad no observable, el ajuste en términos de la log-verosimilitud es bastante mejor, como indica la 2.4.

Table 2.4: Log-verosimilitud modelos alternativos.

Modelo	Log-Likelihood
Regresión Binomial	-10.145,0
Regresión Beta-Binomial	-9.855,4

En relación al modelo binomial, ¿cuántos parámetros debiera tener el mod-

elo de regresión beta-binomial para que sea preferido en términos de AIC?

Solución

1. De acuerdo a las solicitudes:

a. Necesitamos incluir dummies para zonas ($Zone_{ih_1}$) y para industrias ($Industry_{ih_2}$), donde h_1 corresponde a una zona existente de la base de datos, al igual que h_2 , que corresponde a una industria existente.

b. Se pueden generar dos variables para los niveles de antigüedad (porque una de las tres debe ser la de referencia). Se genera

$Tenure2_{it}$, que es equivalente a $Tenure_{it} \mathbf{1} \begin{cases} 1 & \text{si } t = 2 \\ 0 & \text{en otro caso} \end{cases}$ y

$Tenure3_{it}$, equivalente a $Tenure_{it} \mathbf{1} \begin{cases} 1 & \text{si } t \geq 3 \\ 0 & \text{en otro caso} \end{cases}$.

c. Hay que incluir el número de eventos físicos, digitales y su interacción.

d. El número total de interacciones es la multiplicación del número de empleados por el promedio de interacciones por usuario. Dado los rendimientos decrecientes, se debe transformar la variable a logaritmo.

$$\begin{aligned} \lambda_{it} = & \left(\sum_{h_1} \alpha_{h_1} Zone_{ih_1} \right) + \left(\sum_{h_2} \alpha_{h_2} Industry_{ih_2} \right) + \beta_1 Tenure2_{it} + \beta_2 Tenure3_{it} \\ & + \beta_3 NEventOnline_{it-1} + \beta_4 NEventOffline_{it-1} \\ & + \beta_5 NEventOnline_{it-1} NEventOffline_{it-1} \\ & + \beta_6 \ln(NEmployeeAccess_{it-1} NAccessMean_{it-1}) \end{aligned}$$

Este modelo tiene $Z + I + 6$ parámetros a estimar, donde $Z = \sum_{h_1}$ e $I = \sum_{h_2}$.

La log-verosimilitud resulta de aplicar una distribución de Poisson:

$$LL = \sum_i \sum_t n_{it} \ln \left(\frac{(\lambda_{it} t)^{x_{it}} e^{-\lambda_{it} t}}{x_{it}!} \right)$$

Donde x_{it} es el número de oportunidades convertidas por la cuenta i en el año t y n_{it} es el número de individuos que tuvieron esas x_{it} oportunidades convertidas. Acá la heterogeneidad observada fue incluida en la regresión de Poisson descrita.

2. El modelo es idéntico al anterior, pero en vez de describir la verosimilitud como un modelo de Poisson, ahora es un modelo binomial. Entonces:

$$LL = \sum_i \sum_t \binom{m_{it}}{n_{it}} p_{it}^{n_{it}} (1 - p_{it})^{m_{it} - n_{it}}$$

Aquí, m_{it} es el número de *leads* generados por la cuenta en el año y la probabilidad de conversión heterogenea viene dada por

$$p_{it} = \frac{e^{\lambda_{it}(x_{it})}}{1 + e^{\lambda_{it}(x_{it})}}$$

El cual tiene el mismo número de parámetros que el caso anterior.

3. Para preferir el modelo beta binomial, el AIC debiera ser menor que el de la regresión binomial. Entonces:

$$(AIC_B = 2k_B - 2LL_B) > (2k_{BB} - 2LL_{BB} = AIC_{BB})$$

Despejando y reemplazando los valores, $k_{BB} - k_B < 290$ (es decir, el modelo de regresión beta-binomial podría tener hasta 290 parámetros más y seguiría siendo más preferido que el modelo de regresión de Poisson.

Problema 3: Harcor y El Club del Almacenero

Harcor es una importante firma latinoamericana que se concentra en la producción y venta de caramelos y snacks. Aunque la compañía tiene una estrategia multicanal, gran parte de sus ventas se concentra en el canal tradicional de almacenes y kioscos. Este segmento es muy atomizado con decenas de puntos de venta en el país y con una gran heterogeneidad entre los almaceneros. Mientras algunos almacenes tienen un desarrollo bien establecido con tiendas bien organizadas y sistemas automáticos de registros de venta, otros operan en espacios informales y con malas prácticas de gestión.

Para incentivar las ventas en el canal tradicional, Harcor ha creado un programa de capacitación que ha denominado *El Club del Almacenero*, que junto con proveer soporte en infraestructura de góndolas y estanterías con las marcas de Harcor, ofrece también un plan de capacitación con las mejores prácticas del comercio minorista, incluyendo temas de publicidad, administración de inventarios, control de costos y planificación de surtido. El plan de capacitación está inicialmente pensado en 4 niveles de módulos, desde el más básico hasta al más avanzado, de modo que para acceder a un nivel debe haberse completado el nivel anterior.

Aunque el nivel de satisfacción de los participantes del programa de capacitación es alto, el porcentaje de almaceneros que participa y completa el programa ha sido más bien bajo en los primeros dos años de operación por lo que Harcor está considerando hacer algunos ajustes al programa. Para que los ajustes sean realizados basados en evidencia, el equipo de analítica comercial se ha propuesto

analizar los datos de participación en las ediciones pasadas del programa. Para eso, a partir de los registros históricos se ha generado una tabla, que, junto con un conjunto de variables demográficas de los almaceneros, se registra x_{ikt} que toma el valor 1 si el almacenero i participó en el nivel k en el programa de capacitación realizado en el año t .

1. Suponga que el número de niveles de los cuales participa un almacenero queda descrito por un modelo beta geométrico desplazado de parámetros α y β .
 - a. (1 punto) Calcule una expresión para la probabilidad que un almacenero termine el programa de capacitación. Notar que la expresión debe poder calcularse a partir de los datos observados x_{ikt} y los parámetros α y β .
 - b. (1 punto) Escriba la log-verosimilitud del problema. Al igual que en el caso anterior, exprese la log-verosimilitud en términos de x_{ikt} , α y β .
2. Suponga que se estima el modelo usando el método de la máxima verosimilitud resultando los valores de la Tabla:

Table 2.5: Resumen de ventas para cada función.

Variable	Coefficiente
α	0.999
β	4.001
N	1.245
LL	-2.583

- a. La Figura reporta la distribución beta evaluada en los estimadores máximos verosímiles de la Tabla. Por inspección de la figura, provea una aproximación numérica a la probabilidad de que un cliente no avance al siguiente nivel sea mayor que 0.8 (usando áreas de triángulos y rectángulos).
- b. Calcule el intervalo de confianza al 95% del segundo parámetro β . Considere que el inverso del hessiano de la log-verosimilitud, evaluada en el estimador máximo verosímil, viene dado por Σ^{-1} :

$$\Sigma^{-1} = \begin{bmatrix} 0.16 & 0.04 \\ 0.04 & 0.36 \end{bmatrix}.$$

3. Suponga ahora que se rediseña el programa de modo que los contenidos de un módulo son independientes de los otros y, por tanto, un almacenero puede atender cualquier módulo sin necesidad de haber completado los anteriores. Suponga que ya se han desarrollado tres módulos y falta uno por realizar. Escriba la verosimilitud de observar que un almacenero atiende a los tres módulos y otro atiende solo a uno, suponiendo que la asistencia se describe por un modelo beta-binomial.




Figure 2.1: Distribución posterior de la probabilidad de no continuar

4. Si los estimadores máximos verosímiles de la beta binomial son $\alpha = 3.543$ y $\beta = 1.231$, escriba una expresión para el valor esperado de la probabilidad que un almacenero atienda al último módulo, si ya atendió a los tres primeros.

Solución

1. Sea D_{it} el número de niveles cursado por el almacenero i en el año de ejecución t y sea s_{ikt} una variable binaria que toma el valor 1 si el almacenero cumple el curso $s_{ikt} = \begin{cases} 1 & \text{si } \sum_h x_{iht} = 4 \\ 0 & \text{en otro caso} \end{cases}$.

- a. La expresión es directa:

$$\Pr(D_{it} = k \mid \alpha, \beta) = \frac{B(\alpha + 1, \beta + k - 1)}{B(\alpha, \beta)}$$

- b. Usando las definiciones de arriba, la log-verosimilitud:

$$LL = \sum_t \sum_i \sum_k s_{ikt} \log(\mathbb{P}(D_{it} = 4 \mid \alpha, \beta)) = \sum_t \sum_i \sum_k s_{ikt} \log\left(\frac{B(\alpha + 1, \beta + k - 1)}{B(\alpha, \beta)}\right)$$

O bien, se puede absorber la suma para cada individuo i si $n_{kt} = \sum_i s_{ikt}$, correspondiente al número de almaceneros que cursaron k niveles. En dicho caso:

$$LL = \sum_t \sum_k n_{kt} \log(\mathbb{P}(D_{it} = k \mid \alpha, \beta)) = \sum_t \sum_k n_{kt} \log\left(\frac{B(\alpha + 1, \beta + k - 1)}{B(\alpha, \beta)}\right)$$

2. Para el primer caso:

- a. La probabilidad p corresponde al área bajo la curva, que puede aproximarse como

$$p \approx 0.2 \cdot 2 + 0.2 \cdot 2/2 = 0.6.$$




Figure 2.2: Distribución posterior con área sombreada

- b. Usando el inverso del hessiano, el intervalo de confianza viene dado por $4.001 \pm 1.96\sqrt{0.36}$, donde el coeficiente β corresponde la componente Σ_{22}^{-1} .
3. Solo tenemos que multiplicar la probabilidad de los dos eventos:

$$\begin{aligned} L(\theta) &= \mathbb{P}(D_{it} = 3 \mid \alpha, \beta) \mathbb{P}(D_{it} = 3 \mid \alpha, \beta) \\ &= \binom{3}{3} \frac{\mathbb{B}(\alpha + 3, \beta)}{\mathbb{B}(\alpha, \beta)} \binom{3}{1} \frac{\mathbb{B}(\alpha + 1, \beta + 2)}{\mathbb{B}(\alpha, \beta)} \end{aligned}$$

4. La probabilidad solicitada es simplemente la esperanza condicional del parámetro. En este caso, la distribución condicional de observar tres visitas positivas en tres módulos es $\mathbb{B}(\alpha + 3, \beta)$. La esperanza condicional de la probabilidad viene dada por

$$\frac{\alpha + 3}{\alpha + \beta + 3} = 0.842$$

Problema 4: Discrepancias de precios en supermercados

En 1972, la *National Association of Food Chains* (NAFC) impulsó el uso de códigos de barras para administrar los precios en las góndolas de los supermercados en Estados Unidos. Desde aquel entonces, ha existido una continua preocupación respecto a la precisión de estos mecanismos para mantener información precisa respecto de los precios. Uno de los problemas potenciales más relevantes del sistema es que los precios cargados en el sistema podrían no estar bien coordinados con la información de precios desplegada a los clientes en los flejes de las góndolas. En simple, como la información de precios se realiza manualmente, es posible que se generen diferencias entre lo que se despliega de cara al cliente al momento de la elección, con lo que efectivamente se cobra en caja.

Motivados por este problema, se ha decidido investigar la situación actual de la precisión con que se despliegan los precios en la industria supermercadista chilena. Más allá de la existencia de discrepancias, nos interesa investigar la duración de estos eventos en que el precio informado difiere del precio efectivamente cobrado. Para investigar estas preguntas, se ha construido una base de datos que contiene alrededor de 75.000 observaciones de precios realizadas durante 28 días en una sala de supermercado de la Región Metropolitana, que considera tanto el precio registrado en el sistema de cajas como el precio exhibido en góndola. Mientras que los precios de cajas se obtienen directamente de los sistemas transaccionales de la compañía, los precios en góndola resultan de una inspección visual en sala, por un equipo de revisores entrenados para ese propósito. La medición visual se hace sobre una lista predefinida de productos sobre los que se registra el precio exhibido.

Habiendo realizado la medición, se identifica que más de un 10% de los precios registrados tiene asociada alguna discrepancia, es decir, que el precio cobrado en caja no coincide con el precio exhibido en el fleje de la góndola. Notar que las discrepancias pueden ser favorables para el cliente o favorables para el supermercado. Por convención, llamaremos discrepancias de tipo I a aquellas que favorecen al cliente y de tipo II a las que favorecen al supermercado. Para entender con más detalle este fenómeno de discrepancias, se ha seleccionado una base con todos los registros con precios discrepantes. En esta base, cada fila se compone de las siguientes variables:

- **Id:** Identificador de un evento de discrepancia de precios.
- **Day:** Día de la semana que se registra la discrepancia (con lunes = 1 y domingo = 7).
- **Type:** Variable categórica con el tipo de discrepancia (Tipo I o Tipo II).
- **Section:** Categoría del supermercado a la que pertenece el producto que presenta un diferencial (Abarrotes, Limpieza, Bebidas, Galletas y Cocktail).

- **Duration:** Número de días que dura la discrepancia de precios entre el fleje y el sistema transaccional.
- **Tag_price:** Precio que aparece en el fleje.
- **Real_price:** Precio cobrado en caja.
- **diff:** Diferencia entre precio fleje y precio real.

Para ilustrar la estructura de la base, las primeras entradas se presentan en la Tabla 2.6:

Table 2.6: Muestra de los primeros 6 registros de la base de discrepancias.

Id	Day	Type	Section	Duration	Tag_price	Real_price	diff
1	1	I	limpieza	1	1668	1467	201
2	1	II	abarrotos	7	1162	9183	-8021
3	2	I	bebidas	1	7517	6616	901
4	1	I	bebidas	1	1319	1160	158
5	5	I	galletas	3	1411	1241	169
6	3	II	galletas	2	1411	1641	-231

1. Describa un modelo de duración probabilístico que permita describir cuántos días se mantienen las discrepancias y escriba la log-verosimilitud correspondiente. Defina cuidadosamente las variables de la función, especificando qué es parámetro y qué es dato. Para los datos, indique cómo se obtienen de los datos ilustrados en la Tabla 2.6.
2. Suponga que complementario a los modelos de duración, se estiman dos modelos de regresión lineal para describir la duración de las discrepancias como variable dependiente. Los resultados de estos dos modelos se reportan en la Tabla 2.7.

Table 2.7: Resultados de dos modelos de regresión lineal para la duración de la discrepancia.

Variable	Coef. M1	p-valor M1	Coef. M2	p-valor M2
intercepto	3.55	0.0901	-1.353	0.1607
diff	-0.0002	0.7830	—	—
log(Tag_price)	-0.2688	0.3661	—	—
log(diff)	—	—	0.563	0.0019
type.I	1.51	0.0210	2.168	0.0000
type.I:diff	0.0046	0.1165	—	—
day.1	—	—	-1.013	0.0061
section.limpieza	—	—	4.394	0.0000
section.cocktail	—	—	-1.329	0.0221
R²	0,096		0,136	
Adj. R²	0,086		0,120	

Más allá de la varianza explicada por cada modelo, ¿qué modelo le parece más adecuado? Provea al menos dos razones por las cuales prefiere el modelo elegido.

3. Suponga que ahora se estiman tres modelos para describir la duración de discrepancias tipo I (aquellas que favorecen al cliente): un modelo geométrico desplazado sin heterogeneidad, un modelo beta-geométrico desplazado y un modelo de regresión geométrico desplazado en que el

parámetro del modelo se asume dependiendo de la magnitud de la discrepancia (Diff) y si corresponde a la categoría de limpieza. Para garantizar que el parámetro θ esté en el rango $[0, 1]$ para incluir variables explicativas se aplica la transformación

$$\theta_i = \frac{\exp(\beta \cdot x_i)}{1 + \exp(\beta \cdot x_i)}.$$

Los estimadores máximo-verosímiles se muestran a continuación.

Table 2.8: Estimadores y criterios de información de tres modelos de duración.

Parámetros	Geométrico desplazado	Beta geométrico	Regresión geométrica
θ_0	0.33	—	0.46
α	—	2.08	—
β	—	2.62	—
Diff	—	—	-0.43
limpieza	—	—	-0.87
LL	-788	-761	-566
AIC	1278	1526	1142

Elija dos de los modelos y, para cada uno, calcule la probabilidad de que una discrepancia para un producto de limpieza, cuya diferencia de precios es 201, dure más de 3 días (deje la expresión simbólica; no es necesario valor numérico).

Solución

- Dado que la duración la observamos en días, parece más natural considerar un modelo de duración en tiempo discreto (la muestra de datos también sugiere que el proceso podría ser bastante discreto). Sea:
 - θ = Probabilidad de que un producto deje de estar en discrepancia en un día dado.
 - T_i = la duración de la discrepancia de la observación i .
 - τ = el máximo período de observación (28 días).
 - n_t = el número de casos en que observamos que la discrepancia dura t días.

Entonces, la log-verosimilitud viene dada por:

$$LL = n_\tau \ln((1 - \theta)^\tau) + \sum_{t=1}^{\tau-1} n_t \ln((1 - \theta)^{t-1} \theta)$$

Acá, θ es el único parámetro del modelo. Los datos son n_t y n_τ y se obtienen directamente a través de un conteo condicional en los valores de la columna Duration.

- Hay varias consideraciones que sugieren que el **Modelo 2** podría ser preferible.

- `diff` no es significativo en modelo 1, pero `log(diff)` sí lo es en modelo 2.
 - El p-valor del tipo es menor en el modelo 2.
 - La interacción que agrega el modelo 1 (`type.I × diff`) no es significativa.
 - Las variables adicionales del modelo 2 sí son significativas.
3. Las expresiones se derivan directamente de las definiciones y vienen dadas por:
- **Geométrica:** $\Pr(T > 3 \mid \theta_0) = (1 - 0.33)^3$.
 - **Beta-Geométrica:**

$$\Pr(T > 3 \mid \alpha, \beta) = \frac{B(2.08, 2.62 + 3)}{B(2.08, 2.62)}.$$

- **Regresión Geométrica:**

$$\Pr(T > 3 \mid \theta_0, \theta_{\text{Diff}}, \theta_{\text{lim}}) = \left(\frac{1}{1 + \exp(0.46 + 0.43 \cdot 201 + 0.87)} \right)^3.$$

Problema 5: NotComida — Panel de compras

Se acerca el verano (sí, hay que usar la imaginación) y tu última práctica profesional. Como has sido una estudiante excepcional, pudiste elegir con cuidado dónde realizarla y después de descartar varias ofertas, decidiste aceptar la oferta de NotComida, una startup chilena exitosa que basa su propuesta de valor en el diseño y manufactura de productos alimenticios basados en plantas que funcionan como sucedáneos cercanos a otros productos de origen animal, como la leche, el helado o las hamburguesas. Cada vez que te piensas en lo que viene, se te escapa un suspiro de satisfacción. Piensas en lo terrible que sería para ti trabajar en una compañía que no esté alineada con tus ideales. A fin de cuentas, entraste a estudiar ingeniería para cambiar el mundo. Para ti este es solo el primer paso.

Todavía quedan dos semanas para que empiece la práctica, pero ya estás ansiosa, por lo que recibes con entusiasmo y sorpresa un correo electrónico de Kiara, quien será tu supervisora directa durante tu estadía en la compañía. “¡Hola! Esperando que estés muy bien, te escribo para contarte los próximos desafíos en los que vamos a estar trabajando en el equipo en los próximos seis meses. Por supuesto que no es necesario que hagas absolutamente nada, pero como queremos que te sientas integrada te vamos a ir copiando en las comunicaciones internas del equipo”. Antes de cerrar el mensaje, te das el tiempo de darle un vistazo rápido al diccionario de datos que viene adjunto:

Table 2.9: Variables del panel de compras de NotComida.

Variable	Descripción	Media
IdCliente	Identificador de cliente	—
Mes	Mes	—
Año	Año	—
Categoría	Categoría de producto	—
Tienda	Identificador de la tienda	—
Edad	Edad del panelista	31,3
Mujer	1 si la panelista se identifica como mujer	0,51
Ingreso	Ingreso mensual [millones CLP]	0,56
Zona Oriente	1 si vive en la zona oriente	0,11
NCompras	Número de compras en esa categoría y mes	2,34

Tienes súper claro que, de verdad, no tienes que hacer nada. Sin embargo, te dan unas ganas enormes de empezar ya a pensar en cómo puedes contribuir. El equipo se ha embarcado en una serie de proyectos para entender el comportamiento de compra de los clientes y tú sabes que tienes las herramientas para hacer una contribución. Aunque no estás tan segura de en qué subproyecto te quieres involucrar, ya has delineado un plan bastante claro de lo que te gustaría hacer. Considerando que la fuente de datos principal es un panel de compras con el número de unidades y montos comprados por cliente, se te ocurre que tu primer modelo puede estar basado en un modelo de conteo.

1. Proponga un modelo de regresión de Poisson en que la tasa de compra depende de cada individuo, categoría, tienda y semana. Escriba la log-verosimilitud del problema considerando que n_{icst} es el número de unidades compradas por el cliente i en la categoría c en la tienda s el mes t . Para esto considere que:
 - a. Existe un efecto fijo por categoría y uno por tienda.
 - b. El género induce diferencias relevantes en las ventas y el efecto del género es distinto para la zona oriente de la capital.
 - c. Existe una tendencia creciente en las ventas. Como el crecimiento es relativamente pequeño, puede modelarse con un efecto fijo a nivel de año.
 - d. Aunque en el consumo es relativamente constante a lo largo del año, hay dos categorías que presentan una estacionalidad relevante. Mientras los helados tienen un patrón marcadamente diferente en los meses de diciembre, enero y febrero, las hamburguesas declinan sus ventas en el mes de septiembre.
2. La investigación exploratoria de los datos sugiere que, restringiendo el análisis a la categoría $c = \text{Hamburguesas}$, podría haber dos clases latentes. Un segmento de alto consumo y otro de consumo más bien ocasional. Para acomodar esta regularidad se propone un modelo sencillo en que la tasa de compra de un cliente i , independiente del mes, viene dado por:

$$\log(\lambda_i) = \beta_{0i} + \beta_1 \text{MUJER}_i$$

Donde β_{0i} toma el valor -1 con probabilidad 0.4 y el valor 0.5 con probabilidad 0.6. ¿Cuál es la probabilidad de que un cliente hombre, con MM\$1 de ingreso que no compra en un mes ($n_i = 1$) pertenezca al segmento 1? Deje computada la probabilidad.

3. Después de revisar los resultados de los modelos anteriores, te preguntas si dado el bajo número de compras registrados cada mes, quizás podría existir un modelo alternativo que pudiera complementar los aprendizajes anteriores. Rápidamente se te ocurre que quizás puedes definir una variable y_{icst} que toma el valor 1 si el cliente i compra en la categoría c en la tienda s el mes t (sí o no). Con esto, te resulta evidente que puedes estimar un modelo de elección discreta que describa la decisión de comprar o no de los clientes de la base.

- a. Considerando los datos de la Tabla 2.10, que describen todas las compras observadas por el cliente 321045, escriba la log-verosimilitud del historial de compra de este cliente.

Table 2.10: Historial resumido de compras del cliente 321045.

IdCliente	Mes	Año	Tienda	Categoría	Edad	Mujer	Ingresos	Zona	
								Oriente	Ncompras
321045	Julio	2021	S816	Hamburguesa	26	0	1.3	0	1
321045	Septiembre	2021	S816	Hamburguesa	26	0	1.3	0	0

Solución

1. En un modelo de regresión de Poisson, la distribución ya viene dada y solo tenemos que especificar la tasa del proceso. Sea λ_{icst} la tasa de compras del cliente i en la categoría c en la tienda s el mes t . Además, definamos:
 - $\delta_{ta} = 1$ si el mes t pertenece al año a .
 - $\Delta_{ct}^1 = 1$ si $c = \text{Helado}$ y $t \in \{\text{dic, ene, feb}\}$.
 - $\Delta_{ct}^2 = 1$ si $c = \text{Hamburguesa}$ y $t = \text{septiembre}$.

Entonces, la tasa de compra puede escribirse como

$$\lambda_{icst} = \alpha_c + \alpha_s + \beta_1 \text{MUJER}_i + \beta_2 \text{MUJER}_i \cdot \text{ZORIENTE}_s + \sum_a \gamma_a \delta_{ta} + \theta_1 \Delta_{ct}^1 + \theta_2 \Delta_{ct}^2.$$

Tanto $\Delta_{ct}^1 = 1$ como $\Delta_{ct}^2 = 1$ pueden ser obtenidos usando una interacción entre Categoría, Tiempo y una indicatriz, que indique 1 cuando t pertenece al mes indicado, y 0 en caso contrario.

Con esto, la **log-verosimilitud** viene dada por:

$$LL = \sum_{i,c,s,t} \ln(\Pr(N_{icst} = n_{icst})) = \sum_{i,c,s,t} \ln\left(\frac{\lambda_{icst}^{n_{icst}} e^{-\lambda_{icst}}}{n_{icst}!}\right).$$

2. Las tasas de compra de los dos segmentos vienen dadas por:

$$\log(\lambda_{i1}) = -1 + \beta_1 \text{MUJER}_i = -1 + 0 \implies \lambda_{i1} = e^{-1}$$

$$\log(\lambda_{i2}) = 0.5 + \beta_1 \text{MUJER}_i = 0.5 + 0 \implies \lambda_{i2} = e^{-0.5}$$

Por tanto, la probabilidad de comprar una vez en cada segmento es:

$$\mathbb{P}(n_i = 1 \mid s_1) = \lambda_{i1} e^{-\lambda_{i1}} = e^{-1} e^{-e^{-1}}$$

$$\mathbb{P}(n_i = 0 \mid s_2) = \lambda_{i2} e^{-\lambda_{i2}} = e^{-0.5} e^{-e^{-0.5}}$$

Aplicando Teorema de Bayes:

$$\mathbb{P}(s_1 \mid n_i = 1) = \frac{\mathbb{P}(n_i = 1 \mid s_1) \mathbb{P}(s_1)}{\mathbb{P}(n_i = 1 \mid s_1) \mathbb{P}(s_1) + \mathbb{P}(n_i = 1 \mid s_2) \mathbb{P}(s_2)}$$

Donde $\mathbb{P}(s_1) = 0.4$ y $\mathbb{P}(s_2) = 0.6$.

3. La utilidad que deriva el cliente i por comprar en la categoría c en la tienda s en el mes t viene dado por:

$$u_{icst} = \alpha_c + \alpha_s + (\beta_1 \text{MUJER}_i = 0) + (\beta_2 \text{MUJER}_i \text{ZORIENTE}_s = 0) + \sum_a \gamma_a \delta_{ta} + (\theta_1 \Delta_{ct}^1 = 0) + \theta_2 \Delta_{ct}^2$$

Donde $\text{MUJER}_i = 0$ porque el registro es de un hombre, y $\theta_1 \Delta_{ct}^1 = 0$ porque aplica para helado y en los meses de verano, no septiembre y hamburguesa. Con esto, la log verosimilitud es:

$$LL(\hat{\theta}) = \sum_{icst} y_{icst} \ln \left(\frac{e^{u_{icst}}}{1 + e^{u_{icst}}} \right) + (1 - y_{icst}) \ln \left(\frac{1}{1 + e^{u_{icst}}} \right)$$

Problema 6: Creadores de contenido

En los últimos 20 años, hemos visto un crecimiento explosivo en el uso de redes sociales, con más de 4.4 billones de usuarios a nivel mundial y con un promedio de más de 8 cuentas por usuario en las distintas plataformas que han surgido en los últimos años. En este ecosistema, hay un creciente interés por convertirse en *creador de contenido*, que les permita generar audiencia que pueda eventualmente ser monetizada. Cualquier persona con un dispositivo móvil puede crear contenido que potencialmente puede volverse viral y captar niveles importantes

de atención de los usuarios. Ya sea tocando la guitarra y cantando, jugando videojuegos o mostrando la ejecución de sofisticadas recetas de cocina, muchos creadores buscan alcanzar altos niveles de visitas y generar interacciones significativas con sus audiencias.

Considerando que existen un alto potencial comercial en la industria de generación de contenido, se ha propuesto investigar en profundidad cuáles son los factores que inciden en el nivel de interacciones entre creadores y usuarios. Para estos efectos, se ha aliado con un nuevo portal en que creadores de contenido pueden subir su material, el que es exhibido a los usuarios de la plataforma usando un algoritmo interno que personaliza el contenido de acuerdo con la probabilidad de generar interacciones. Aunque hay varios niveles de interacción con el contenido (ver, comentar, compartir), la plataforma considera que el número de *me gusta* es la principal métrica para capturar el éxito relativo de una publicación.

El portal tiene un módulo de analítica de datos que permite recolectar algunas métricas claves de cada uno de los contenidos publicados en su primer año de operación para todos los creadores registrados en el portal. Entre los datos disponibles se encuentran las llaves para identificar cada contenido y algunas características como la categoría del contenido (información, humor o noticia), el número de caracteres, el número de imágenes y la duración del video, si existiese. Adicionalmente, y gracias a una alianza con una herramienta de inteligencia artificial, se cuenta con el puntaje de cada contenido en tres dimensiones distintos: producción, contenido y novedad.

Table 2.11: Descripción base de contenidos en la plataforma de creadores.

Variable	Descripción	Media
IdCC	Identificador de cliente	-
IdPost	Identificador del contenido	-
DatePost	Fecha de publicación del contenido	-
Category	Categoría de producto {Information, Humour, News}	-
Nchar	Número de caracteres en el texto del contenido publicado	84.4
Npic	Número de fotos en el contenido publicado	0.4
Tvid	Duración [seg] de los videos que acompañan el contenido	18.5
AIproduction	AI score en la calidad de la producción [0,1]	0.5
AIcontent	AI score en la calidad del contenido [0,1]	0.3
AINovelty	AI score en la novedad del contenido [0,1]	0.2
Nlikes	Número de <i>me gusta</i> que ha recibido la publicación	12.5

1. Modele el número de *me gusta* que recibe una publicación como un proceso de conteo con heterogeneidad observable. Para este modelo:
 - a. Justifique la inclusión de al menos dos variables explicativas indicando cuál es el signo esperado del coeficiente correspondiente.
 - b. Escriba la log-verosimilitud del problema. Indique cuáles son los parámetros para estimar y explicité cuántos parámetros tiene su modelo.

- c. Suponiendo que ha estimado el modelo y los parámetros proveen una buena descripción de la distribución del número de *me gusta* que recibirá un post. Usando dichos estimadores, escriba una expresión para la probabilidad de que un cliente reciba al menos un *me gusta*.
2. Una de las limitaciones del modelo anterior es que el uso del algoritmo interno de la plataforma implica una distribución muy heterogénea de exposiciones. Esto es, algunas publicaciones son desplegadas miles de veces, mientras que otras reciben muy poca exposición. Para hacer frente a este problema, se propone usar un modelo de elección.
 - a. Describa el proceso como un proceso de elección binaria con heterogeneidad no observable y escriba la log-verosimilitud del problema. Para eso, suponga que la base de datos también contiene una variable $Ndisp$ que, para cada post, indica el número de veces que fue expuesto.
 - b. Si al estimar el modelo, se encuentra que $\alpha = 1$ y $\beta = 2$ son los estimadores máximo-verosímiles. En promedio, ¿con qué probabilidad a un cliente le gusta una publicación en la plataforma?
 - c. Considere una publicación que ha sido desplegada 100 veces y ha recibido 10 *me gusta*. Considerando los valores de $(\alpha, \beta) = (1, 2)$, de la parte anterior, ¿cuántos *me gusta* esperaría observar luego de mostrar el contenido 200 veces?

Solución

1. Se tiene:
 - a. Cualquiera de las variables listadas puede justificarse de manera más o menos directa:
 - **Efecto fijo por creador:** hay creadores más populares que otros.
 - **Efecto fijo por fecha:** hay fechas en que los usuarios son más activos.
 - **Dummies por categoría:** hay categorías que pueden generar más *me gusta*.
 - **Nchar:** textos más largos o más cortos pueden ser más atractivos.
 - **Npic:** agregar más fotos puede ser más atractivo.
 - **Tvid:** videos más largos o más cortos pueden ser preferidos.
 - **AIproduction:** material mejor producido puede generar más *me gusta*.
 - **AIcontent:** contenido de mejor calidad puede generar más *me gusta*.

- **AInovelty:** material más novedoso puede generar más *me gusta*.
- b. Aunque cualquier combinación de las variables arriba descritas es admisible, para efectos ilustrativos consideraremos un modelo en que la tasa de *me gusta* del contenido i viene dada por:

$$\lambda_i = \lambda_0 \cdot \exp(\beta_1 \text{Nchar}_i + \beta_2 \text{Npic}_i + \beta_3 \text{Tvid}_i).$$

Con esto, la log-verosimilitud viene dada por:

$$LL = \sum_i \ln \left(\frac{\lambda_i^{\text{Nlikes}_i} e^{-\lambda_i}}{\text{Nlikes}_i!} \right).$$

- c. La probabilidad de recibir al menos un *me gusta* viene dada por:

$$\Pr(\text{Nlikes}_i > 0 \mid \lambda_0, \beta) = 1 - \Pr(\text{Nlikes}_i = 0 \mid \lambda_0, \beta) = 1 - e^{-\lambda_i}.$$

2. El modelo es una beta-binomial estándar. Recordar que la esperanza de una $\text{Beta}(\alpha, \beta)$ es $\alpha/(\alpha + \beta)$.

- a. La log-verosimilitud de una beta-binomial:

$$LL = \sum_i \ln \left(\binom{\text{NDisp}_i}{\text{Nlikes}_i} \frac{B(\alpha + \text{Nlikes}_i, \beta + \text{NDisp}_i - \text{Nlikes}_i)}{B(\alpha, \beta)} \right).$$

- b.

$$\mathbb{E}(\theta \mid \alpha, \beta) = \frac{\alpha}{\alpha + \beta} = \frac{1}{3}.$$

- c. Se tiene que despejar la esperanza condicional

$$\mathbb{E}(\theta_i \mid \alpha, \beta, \text{NDisp}_i, \text{Nlikes}_i) = \frac{\alpha + \text{Nlikes}_i}{\alpha + \beta + \text{NDisp}_i} = \frac{11}{103}.$$

Entonces, el número esperado de *me gusta* al mostrar el contenido 200 veces es:

$$200 \times \frac{11}{103} \approx 21.36.$$

Notar que $\frac{11}{103}$ es el número esperado de likes de una persona, dada su verosimilitud (información previa) por su comportamiento esperado (distribución beta). Por eso, para 200 personas simplemente se multiplica.

Problema 7: Hippi — Parkas para alta montaña

Hippi es una empresa nacional dedicada a la fabricación de productos para alta montaña. La empresa cuenta con una base de datos que registra la compras que sus clientes en cada temporada y busca estudiar el numero de parkas que los clientes comprarán en la temporada. Para esto, se ha formulado un modelo probabilístico donde el comportamiento de los clientes se describe como:

- Cada cliente compra un numero de parkas X que sigue una distribución geométrica. Esto es, condicional en el parámetro p de cada cliente, la función de probabilidad esta dada por:

$$Pr(X = x|p) = p(1 - p)^x$$

- Los clientes son heterogéneos en su parámetro p el que esta distribuido en la población de acuerdo a una distribución Beta:

$$g(p|\alpha, \beta) = \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1 - p)^{\beta-1}$$

Se puede mostrar que la distribución del número de compras para un cliente en la población, y su respectiva esperanza están dadas por:

$$Pr(X = x) = \frac{B(\alpha + 1, \beta + x)}{B(\alpha, \beta)} \quad \mathbb{E}(X) = \frac{\alpha}{\beta - 1}$$

Siguiendo la convención adoptada en el curso, llamamos a este modelo Beta-Geométrico.

1. Muestre que la penetración de mercado (fracción de clientes que compró al menos una unidad) puede expresarse como $\frac{\beta}{\alpha + \beta}$.
2. Para ello considere que la penetración de mercado es del 60 % y que el numero promedio de parkas que compra un cliente (incluyendo aquellos que no compraron) es igual a 2.5. Estime los parámetros del modelo. *Hint: Realice un sistema de ecuaciones.*
3. Extienda el modelo para incluir un segmento de clientes que nunca compra. Para este segmento de clientes, $Pr(X = 0) = 1$. Sea π la proporción de estos clientes en la población, y $(1 - \pi)$ el segmento de clientes que se comporta de acuerdo al modelo Beta-Geométrico descrito anteriormente. Suponga que conoce x_i , el numero de compras hechas por cada cliente i en la base de datos ($i = 1, \dots, n$). Deduzca la función de verosimilitud que utilizaría para estimar el modelo.

Solución

1. Despejando p_0 :

$$\begin{aligned}
 p_0 &= 1 - \Pr(X = 0) \\
 &= 1 - \frac{B(\alpha, \beta + 1)}{B(\alpha, \beta)} \\
 &= 1 - \frac{\Gamma(\alpha)\Gamma(\beta + 1)}{\Gamma(\alpha + \beta + 1)} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \\
 &= 1 - \frac{\beta \Gamma(\beta)}{(\alpha + \beta) \Gamma(\beta)} \\
 &= \frac{\alpha}{\alpha + \beta}.
 \end{aligned}$$

2. A partir de la penetración de compra se despeja α :

$$0.6 = \frac{\beta}{\alpha + \beta} \Rightarrow \beta = 0.6(\alpha + \beta) \Rightarrow 0.4\beta = 0.6\alpha \Rightarrow \alpha = \frac{2}{3}\beta$$

Despejando β utilizando el número promedio de parkas comprado por un cliente:

$$2.5 = \frac{\alpha}{\beta - 1} \Rightarrow 2.5 = \frac{\frac{2}{3}\beta}{\beta - 1} \Rightarrow \frac{2}{3}\beta = 2.5(\beta - 1) \Rightarrow \beta = \frac{15}{11}$$

Entonces, sustituyendo:

$$\alpha = \frac{2}{3}\beta = \frac{2}{3} \cdot \frac{15}{11} = \frac{10}{11}$$

3. Sea n_x el número de clientes que compra x parkas. Entonces, la verosimilitud puede escribirse como:

$$L(\alpha, \beta, \pi | x) = \prod_{x=0}^{\infty} \mathbb{P}(X = x | \alpha, \beta, \pi)^{n_x}$$

Donde,

$$\Pr(X = x | \alpha, \beta, \pi) = \pi \Pr(X = x | \text{no adopta}) + (1 - \pi) \Pr(X = x | \text{puede adoptar})$$

$$= \begin{cases} \pi + (1 - \pi) \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)}, & x = 0 \\ (1 - \pi) \frac{B(\alpha + 1, \beta + x)}{B(\alpha, \beta)}, & x > 0 \end{cases}$$

Problema 8: Pokémon Go

Para revitalizar el interés de los usuarios, Pokémon Go está pensando introducir 7 nuevos personajes Pokémon en las comunas de Melipilla, Talagante, Pirque, Colina, Alhué, Paine, Lampa y Buin. Para estudiar el impacto en el atractivo del juego, los desarrolladores han estado realizando pruebas para ver el interés de los jugadores en estos nuevos personajes. Las pruebas se han desarrollado sobre una muestra de jugadores de acuerdo a los números desplegados en la siguiente tabla:

Table 2.12: Número de veces que un determinado pokemón fue mostrado a un jugador.

Pokémon	Melipilla	Talagante	Pirque	Colina	Alhué	Paine	Lampa	Buin	Total
Wigglytuff	5	834	504	117	763	424	387	683	3.717
Slowbrow	24	975	8	342	715	362	788	793	4.007
Lickitung	101	651	200	993	562	614	691	595	4.407
Chansley	198	517	960	788	441	844	836	438	5.022
Tangela	79	990	756	868	210	944	509	233	4.589
Ditto	69	587	96	365	182	634	373	419	2.725
Phanpy	138	969	971	890	586	764	585	361	5.264

Existe dos parámetros relevantes para entender el grado de interacción entre jugadores y personajes. El primer parámetro corresponde a q_k que corresponde a la probabilidad de atrapar a un personaje, condicional de que un jugador intente atraparlo. Aunque esta probabilidad es relevante para saber en qué medida los usuarios aumentan su mazo, el parámetro es ajustado internamente en la plataforma y, por tanto, no hay incertidumbre desde el punto de vista de los usuarios. El segundo parámetro que denominamos como p_k , mide la probabilidad que un usuario intente atrapar un personaje k si este le aparece disponible en la aplicación móvil. Desde el punto de vista de la jugabilidad es importante disponibilizar personajes que los usuarios quieran atrapar. Para entender el comportamiento de esta intención de atrapar personajes, la tabla siguiente despliega el número de intentos para los personajes y comunas que forman parte del estudio piloto:

Table 2.13: Número de veces que un jugador intentó atrapar a un determinado pokemón.

Pokémon	Melipilla	Talagante	Pirque	Colina	Alhué	Paine	Lampa	Buin	Total
Wigglytuff	0	218	98	39	31	63	26	43	518
Slowbrow	8	186	4	110	393	79	240	113	1.133
Lickitung	8	47	13	98	183	180	219	60	808
Chansley	49	31	274	24	48	91	205	42	764
Tangela	14	294	71	35	59	304	116	2	895
Ditto	14	180	14	110	33	84	0	10	445
Phanpy	4	19	66	189	9	37	92	33	449

1. Usando el método de los momentos, estime un modelo binomial sin heterogeneidad para la probabilidad de que un usuario intente atrapar a wigglytuff. **Hint:** Con usar el método de los momentos, se refiere a que el primer momento de una distribución es el valor esperado, donde el valor esperado de una distribución binomial es np .

2. Escriba un modelo Beta-Binomial que incorpore heterogeneidad para cada pokémon k y comuna c .
3. Escriba la log-verosimilitud del modelo anterior.

Solución

1. Definimos una variable aleatoria que signifique lo buscado

$$X_w := \# \text{ de usuarios que intentan atrapar a wigglytuf}$$

Tenemos un número de experimentos Bernoulli ($\#$ de personas a las que se les muestra wigglytuf) y un número de “éxitos” entre estos experimentos ($\#$ de personas que intentan atrapar a wigglytuf cuando se les muestra) que ocurren con alguna probabilidad desconocida p_w fija, ya que nos piden el caso homogéneo (único valor). Por lo tanto, tenemos que la probabilidad que queremos caracterizar sería de la forma:

$$P(X_w = x_w) = \binom{n_w}{x_w} p_w^{x_w} (1 - p_w)^{n_w - x_w}$$

Donde n_w es la cantidad de personas a las que se les mostró el pokémon (dato en la primera Tabla). Es decir, $X_w \sim \text{Bin}(n_w, p_w)$. Sabemos que el primer momento de una distribución es su media y que la media de una binomial es $n_w p_w$. Por otro lado, estimamos el valor de la media con algún promedio muestras (con muestras del mismo tamaño) de número de personas que intentaron atrapar a wigglytuf, pero en este caso este número es único, por lo que usamos este valor (total de personas que intentaron atrapar a wigglytuf de la última tabla) que, en este caso, es 518. Por lo tanto, podemos obtener la probabilidad p_w con la igualdad del primer momento:

$$518 = n_w p_w \quad 518 = 3717 p_w \quad p_w \approx 0,1393$$

Esto tiene mucho sentido, ya que estamos obteniendo la probabilidad de manera empírica con la fracción de personas que intentaron atraparlo y el número de personas a las que se les mostró.

2. Como debemos considerar heterogeneidad, ahora el parámetro de la distribución que nos interesa, p_k , no lo asumimos como único, sino que sigue una distribución de probabilidad. Como el parámetro es una probabilidad ($p_k \in [0, 1]$), utilizamos la distribución a priori $\text{Beta}(\alpha_k, \beta_k)$, con α_k y β_k parámetros a estimar ($p_k \sim \text{Beta}(\alpha_k, \beta_k)$, por eso el sub k , ya que cada pokémon tiene una probabilidad p_k asociada y no tienen por qué seguir la misma distribución). Luego, tenemos que cada comuna nos va a estar aportando en realidad datos sobre la heterogeneidad existente para

cada pokemón (sería el equivalente a tener distintas observaciones para distintos individuos). Así, la probabilidad quedaría, para cada pokemón y comuna, con la v.a. anterior, pero segmentando por comuna:

$$P(X_{k,c} = x_{k,c}) = \int_0^1 P(X_{k,c} = x_{k,c} | p_k) \text{Beta}(p_k | \alpha_k, \beta_k) dp_k = \int_0^1 \left(\binom{n_{k,c}}{x_{k,c}} p_k^{x_{k,c}} (1-p_k)^{n_{k,c}-x_{k,c}} \right) \left(\frac{p_k^{\alpha_k-1} (1-p_k)^{\beta_k-1}}{B(\alpha_k, \beta_k)} \right) dp_k$$

3. Nos interesa analizar cada personaje por separado, por lo tanto vamos a tener una expresión de la log-verosimilitud del parámetro p_k para cada pokemón. Luego, la muestra que tenemos de la v.a. en cuestión para cada pokemón k es de la forma $\{x_{k,1}, x_{k,2}, \dots, x_{k,7}\}$, donde el segundo índice es para cada una de las comunas. Sigue que la log-verosimilitud es el logaritmo de la función de verosimilitud con esta muestra para cada pokemón:

$$\begin{aligned} \ell(p_k | x_{k,1}, \dots, x_{k,8}) &= \ln(\mathcal{L}(p_k | x_{k,1}, \dots, x_{k,8})) \\ &= \ln(P(X_{k,1} = x_{k,1}, \dots, X_{k,8} = x_{k,8} | p_k)) \\ &= \ln \left(\prod_{c=1}^8 P(X_{k,c} = x_{k,c} | p_k) \right) \\ &= \sum_{c=1}^8 \ln(P(X_{k,c} = x_{k,c} | p_k)) \\ &= \sum_{c=1}^8 \ln \left(\binom{n_{k,c}}{x_{k,c}} \frac{B(\alpha_k + x_{k,c}, \beta_k + n_{k,c} - x_{k,c})}{B(\alpha_k, \beta_k)} \right) \end{aligned}$$

Esta es la expresión pedida de la log-verosimilitud para cada pokemón k . En el tercer paso asumimos independencia de las v.a. entre columnas y en el último paso reemplazamos por la expresión encontrada en la parte anterior.

Problema 9: Aplicación móvil con promociones georreferenciadas

Inmersos en la era digital, los consumidores están cada vez conectados en distintos dispositivos los cuales pueden ser usados como canales durante el proceso de compra. En este contexto, algunas empresas han decidido lanzar aplicaciones móviles que funcionan en base a información georreferenciada de los dispositivos de sus clientes, y que permiten enviarles promociones personalizadas cuando identifica que este se encuentra cercano a un punto de venta.

La aplicación que más éxito ha tenido en el mercado, quiere evaluar la efectividad de las campañas que envían a sus usuarios, y así poder ofrecer un mejor servicio a las empresas que lo contratan. Para esto, cuenta con información de los m_i

mensajes promocionales que envía al cliente i , y el número x_i de esos que son efectivamente utilizados por el cliente.

1. Plantee un modelo de elección para determinar la probabilidad de respuesta de cada cliente, en cada ocasión de compra. En particular,
 - a. Escriba la log-verosimilitud del problema.
 - b. Sea N el número de clientes. Si se observa el comportamiento por T períodos y en promedio se envían M promociones por cliente, ¿cuántos parámetros deben estimarse?
2. Considere que se cuenta con información demográfica de los usuarios de la aplicación móvil, como edad, Ingreso y frecuencia de uso de la app. Reformule el modelo anterior incorporando variables explicativas considerando además que existe un segmento de clientes que realiza pocos canjes y otro que realiza muchos (es decir, un segmento canjeador C y otro no-canjeador N). **Hint:** Recuerde que si $x \in \mathbb{R}$, entonces $\frac{\exp(x)}{1+\exp(x)} \in (0, 1)$.
3. Suponga que se ha estimado el modelo anterior y se encuentra que los segmento canjeadores y no-canjeadores tienen el mismo tamaño y que los parámetros asociados a las variables explicativas son tales que para un usuario i con un vector de variables explicativas z_i , $\beta'_C x_i = \ln(2)$ y $\beta'_N x_i = \ln(1/2)$. Si al usuario le han enviado dos promociones y ha canjeado las dos, ¿cuál es la probabilidad que este usuario pertenezca al segmento de canjeadores?
4. Suponga ahora que del total de m_i mensajes que recibe un usuario este lee n_i de ellos. De los n_i mensajes que efectivamente lee, decide canjear x_i de ellos. Modele el comportamiento anteriormente descrito como un modelo integrado elección-elección. Plantee explícitamente la probabilidad de canje y la log-verosimilitud del problema.

Solución

1. Por partes:
 1. Sea X_i el número de veces que la persona i hace efectivo un cupón. La probabilidad de respuesta es

$$\mathbb{P}(X_i = x_i | p_i) = \binom{m_i}{x_i} p_i^{x_i} (1 - p_i)^{m_i - x_i}$$

donde la log-verosimilitud viene dada por

$$LL(p) = \sum_i \ln \left(\binom{m_i}{x_i} p_i^{x_i} (1 - p_i)^{m_i - x_i} \right)$$

2. Se deben estimar N parámetros, uno para cada cliente (lo que sugiere introducir heterogeneidad).

2. Modelo de elección con dos segmentos. Sea p_{iC} la probabilidad de canje si i pertenece al segmento canjeador y p_{iN} si pertenece al segmento no canjeador. Sea π la fracción de clientes canjeadores. Entonces

$$\mathbb{P}(X_i = x_i \mid \beta, \pi) = \pi \binom{m_i}{x_i} p_{iC}^{x_i} (1-p_{iC})^{m_i-x_i} + (1-\pi) \binom{m_i}{x_i} p_{iN}^{x_i} (1-p_{iN})^{m_i-x_i}$$

donde

$$p_{iC} = \frac{\exp(\beta'_C z_i)}{1 + \exp(\beta'_C z_i)}, \quad p_{iN} = \frac{\exp(\beta'_N z_i)}{1 + \exp(\beta'_N z_i)}$$

y la log-verosimilitud es

$$LL = \sum_i \ln \left(\pi \binom{m_i}{x_i} p_{iC}^{x_i} (1-p_{iC})^{m_i-x_i} + (1-\pi) \binom{m_i}{x_i} p_{iN}^{x_i} (1-p_{iN})^{m_i-x_i} \right)$$

3. Probabilidad posterior de pertenecer al segmento canjeador dado $X_i = 2$ (usando probabilidades condicionales):

$$\mathbb{P}(C \mid X_i = 2) = \frac{\mathbb{P}(X_i = 2 \mid C) \mathbb{P}(C)}{\mathbb{P}(X_i = 2 \mid C) \mathbb{P}(C) + \mathbb{P}(X_i = 2 \mid N) \mathbb{P}(N)}$$

donde, para $m_i = 2$,

$$\mathbb{P}(X_i = 2 \mid C) = \binom{2}{2} \left[\frac{\exp(\beta'_C z_i)}{1 + \exp(\beta'_C z_i)} \right]^2 \left[\frac{1}{1 + \exp(\beta'_C z_i)} \right]^{2-2} = \frac{4}{9}$$

$$\mathbb{P}(X_i = 2 \mid N) = \binom{2}{2} \left[\frac{\exp(\beta'_N z_i)}{1 + \exp(\beta'_N z_i)} \right]^2 \left[\frac{1}{1 + \exp(\beta'_N z_i)} \right]^{2-2} = \frac{1}{9}$$

y, tomando $\mathbb{P}(C) = \mathbb{P}(N) = \frac{1}{2}$,

$$\mathbb{P}(C \mid X_i = 2) = \frac{\frac{4}{9} \cdot \frac{1}{2}}{\frac{4}{9} \cdot \frac{1}{2} + \frac{1}{9} \cdot \frac{1}{2}} = \frac{4}{5}$$

4. Lectura y canje con dos etapas. La probabilidad de leer un mensaje es:

$$\begin{aligned}
\mathbb{P}(X_i = x_i \mid p_{\text{canjear}}, p_{\text{leer}}) &= \sum_{n_i=x_i}^{m_i} \mathbb{P}(X_i = x_i \mid p_{\text{canjear}}, n_i) \mathbb{P}(N_i = n_i \mid p_{\text{leer}}) \\
&= \sum_{n_i=x_i}^{m_i} \binom{n_i}{x_i} p_{\text{canjear}}^{x_i} (1 - p_{\text{canjear}})^{n_i-x_i} \binom{m_i}{n_i} p_{\text{leer}}^{n_i} (1 - p_{\text{leer}})^{m_i-n_i}
\end{aligned}$$

$$LL = \sum_i \ln(\mathbb{P}(X_i = x_i \mid p_{\text{canjear}}, p_{\text{leer}}))$$

Problema 10: Retraso en graduaciones universitarias

Uno de los fenómenos que ha acompañado el desarrollo económico de Chile en las últimas décadas es el aumento explosivo de la matrícula universitaria. Aunque un mayor nivel de educación tiene impactos universalmente favorables para el bienestar de las naciones, la provisión de los servicios educacionales es costosa desde un punto de vista privado y público. Esto motiva a que las distintas casas de estudio pongan especial atención a la duración de los estudios universitarios. Un mejor entendimiento de este fenómeno permitiría orientar decisiones de gestión de recursos y poner atención al proceso de prestación, con foco a tener un mejor balance entre los tiempos nominales y efectivos.

De acuerdo con las estadísticas disponibles, los retrasos pueden constituir un problema serio en el sistema universitario nacional. En la Tabla 2.14 se despliegan las duraciones promedio de los titulados del sistema entre los años 2012 y 2021, las que oscilan en torno a los 10 semestres. Esta cifra contrasta con la duración formal de los planes de estudios que, al 2021, ascendía a los 7.6 semestres en promedio.

Table 2.14: Duración efectiva de las carreras de la educación superior en Chile.

	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021
Semestres	10.1	10.1	10.0	9.7	9.6	9.6	9.8	9.7	9.6	10.1

Al descomponer por programas, los que más demoran en graduar a sus estudiantes son las carreras profesionales con licenciatura impartidas en universidades, con un promedio de 13,3 semestres. Considerando que la duración formal promedio de estos programas es de 10,1 semestres, se registra un retraso promedio de 3,2 semestres. En particular, las carreras de ingeniería están entre las que tienen mayor duración real. Por ejemplo, Ingeniería Civil Electrónica tiene una duración promedio de 16,8 semestres, Ingeniería Civil Metalúrgica una duración de 16,7 semestres e Ingeniería Civil Eléctrica dura 16,5 semestres en promedio.

Para entender en profundidad qué factores son los que más influyen en el retraso en las graduaciones, un equipo de la escuela de Ingeniería de la Universidad de

Chile ha armado una base de datos con los graduados de las últimas cohortes, en que se registran las siguientes variables:

- *AñoIng*: año de ingreso a la Universidad.
- *EdadIng*: edad de ingreso a la Universidad.
- *NTrabaja*: número de semestres en que trabajó mientras estudiaba.
- *Beca*: 1 si tenía alguna beca de excelencia académica.
- *Nfam*: número de integrantes en el grupo familiar.
- *Especialidad*: especialidad de la que egresó el o la estudiante.
- *Particular*: 1 si egresó de un colegio particular pagado.
- *NEM*: notas promedio de la enseñanza media.
- *Region*: 1 si el colegio de egreso no está ubicado en la Región Metropolitana.
- *PMAT*: puntaje en las pruebas de admisión de matemáticas.
- *PCIE*: puntaje en las pruebas de admisión de ciencias.
- *PLEN*: puntaje en las pruebas de admisión de lenguaje.
- *NSem*: número de semestres que demoró el o la estudiante en graduarse.

El análisis se centra en el comportamiento del número de semestres de retraso ($NRet$), el que, por simplicidad, puede suponerse que se calcula como $NRet = NSem - 12$. A partir de una exploración inicial de datos, se ha considerado que esta variable $NRet$ puede aproximarse a través de una distribución de Poisson.

1. Suponga que observa dos individuos, con tiempos de graduación de 12 ($NRet = 0$) y 13 semestres ($NRet = 1$). ¿Qué valor de λ le parece más verosímil: $\lambda = 1$ o $\lambda = 2$?

Hint: si lo necesita, puede usar los valores numéricos de la Tabla 2.15.

Table 2.15: Valores numéricos de $\log(x)$ para una selección de valores de x .

x	1	2	3
$\log(x)$	0.000	0.693	1.099

2. Suponga que se quiere estimar un modelo de Poisson con dos clases latentes, con parámetros λ_{high} y λ_{low} ($\lambda_{\text{low}} < \lambda_{\text{high}}$). Escriba una expresión para la probabilidad de que un estudiante se atrase, condicional en que pertenece al segmento con λ_{high} .
3. Suponga que ahora se quiere describir los meses de retraso como un modelo de conteo que considere tanto heterogeneidad observable como no observable.
 - a. Para este modelo, escriba una expresión para la tasa de retraso considerando al menos 2 variables observables y explique por qué la inclusión de esas variables tiene sentido. Determine cuál es el signo esperado para el coeficiente correspondiente.
 - b. Usando la definición de la tasa de retraso de la pregunta anterior, agregue heterogeneidad no observable y escriba la log-verosimilitud de observar todo el conjunto de datos.

4. Después de terminar el análisis y presentar los resultados al equipo de trabajo, un estudiante en práctica levanta la mano y le manifiesta que todo el análisis presentado es incorrecto. Esto porque el problema corresponde a un modelo de duración en tiempo discreto y, por tanto, en vez de usar un modelo de Poisson debiera usarse un modelo geométrico desplazado. Discuta respecto a la veracidad del argumento del estudiante.

Solución

1. Podríamos aplicar directamente la definición de verosimilitud, pero numéricamente es más cómodo trabajar con la log-verosimilitud:

$$LL(\lambda) = \ln(\mathbb{P}(NRet_1 = 0 \mid \lambda)) + \ln(\mathbb{P}(NRet_2 = 1 \mid \lambda)) = -\lambda + \ln(\lambda e^{-\lambda}).$$

Reemplazando en los valores propuestos:

$$\begin{aligned} LL(\lambda = 1) &= -1 + \ln(1 \cdot e^{-1}) = -2, \\ LL(\lambda = 2) &= -2 + \ln(2) + \ln(e^{-2}) = -2 + 0.693 - 2 = -3.307. \end{aligned}$$

Con lo que verificamos que $\lambda = 1$ es más verosímil que $\lambda = 2$.

2. Condicional en la pertenencia al segmento con λ_{high} , los retrasos siguen un proceso de Poisson evaluado en $\lambda = \lambda_{\text{high}}$. Luego,

$$\mathbb{P}(NRet > 0 \mid \lambda = \lambda_{\text{high}}) = 1 - \mathbb{P}(NRet = 0 \mid \lambda = \lambda_{\text{high}}) = 1 - \exp(-\lambda_{\text{high}}).$$

3. La primera parte trata de heterogeneidad observable; la segunda agrega heterogeneidad no observable.
 - a. La especificación es la misma vista en clases:

$$\hat{\lambda}_i = \lambda_0 \exp(\beta' x_i),$$

de modo que basta listar y justificar las componentes de x_i . Algunos ejemplos:

- *PMAT*: estudiantes con mejores notas en pruebas de matemáticas suelen tener mejores resultados y se espera que se retrasen menos (coeficiente negativo).
- *NEM*: estudiantes con mejores notas en enseñanza media se retrasan menos (coeficiente negativo).
- *Particular*: estudiantes de colegios particulares tienden a tener mejores resultados, se espera que se retrasen menos (coeficiente negativo).

- *Beca*: estudiantes con beca tienen mejores notas e incentivos para no retrasarse, por lo que se espera un coeficiente negativo.
- b. Al agregar heterogeneidad no observable se obtiene un modelo de regresión binomial negativa. La log-verosimilitud queda

$$LL(\hat{\lambda}_i) = \sum_i \ln \left(\frac{\Gamma(r + n_i)}{\Gamma(r) n_i!} \left(\frac{\alpha}{\alpha + \exp(\beta' x_i)} \right)^r \left(\frac{\exp(\beta' x_i)}{\alpha + \exp(\beta' x_i)} \right)^{n_i} \right).$$

4. El modelo geométrico desplazado es una alternativa razonable para caracterizar los retrasos. Sin embargo, un modelo de conteo también es válido: la elección entre uno y otro depende de cómo se interprete *NRet* (cuántos semestres adicionales son necesarios para graduarse, en una óptica de duración, frente al número de eventos de atraso, en una óptica de conteo). Para determinar cuál resulta más adecuado en este caso conviene revisar métricas de ajuste y de pronóstico fuera de muestra.

Problema 11: Tasas de respuesta en encuestas de educación superior

Los paneles de encuestas siguen siendo una herramienta importante para recoger la valoración que tienen los usuarios sobre sus experiencias en distintas industrias de servicios. Uno de los desafíos actuales de la administración de estos paneles es las bajas tasas de respuesta, lo que dificulta la recopilación de datos y potencialmente introduce sesgos en las percepciones medidas. A continuación, propondremos el estudio de las tasas de respuesta en el contexto de las evaluaciones que proveen los estudiantes a las encuestas semestrales en cada una de las materias que cursan.

Para estudiar el fenómeno, se ha preparado un panel de encuestados caracterizados por el número de matrícula, la carrera que estudian y el año de ingreso, y una muestra de 94 encuestas realizadas entre 2023 y 2025 en una institución de educación superior. Para cada encuesta, conocemos la fecha de envío, el número de días en que la encuesta está abierta y el tipo de encuesta. La variable central de análisis es una variable binaria que indica si el estudiante responde o no a la encuesta. La Tabla 2.16 despliega una muestra con los primeros 6 registros del panel. Notar que este panel solo registra los casos de estudiantes que recibieron una encuesta; si un alumno no recibe una encuesta, esa combinación de estudiante-encuesta no se registra en el panel.

Table 2.16: Muestra de los primeros seis registros del panel de encuestados.

NMat	Carrera	Año Ingreso	IdEnc	Código Curso	N	Fecha Envío	Días	Tipo Encuesta	Respuesta
945001	Ingeniería	2019	4501	ECO101		2023-11-15	14	Docencia	Sí
033012	Psicología	2020	4502	PSI205		2023-11-15	14	Docencia	No
111005	Derecho	2021	4503	DER110		2023-11-16	7	Bienestar	No
945001	Ingeniería	2019	4504	MAT200		2023-11-15	21	Docencia	No

NMat	Carrera	Año Ingreso	IdEnc	Código Curso	N	Fecha Envío	Días	Tipo Encuesta	Respuesta
200554	Medicina	2022	4505	MED010		2023-11-17	14	Docencia	Sí
033012	Psicología	2020	4506	SOC100		2023-11-15	14	Bienestar	No

1. Escriba la log-verosimilitud de un modelo de conteo con heterogeneidad observable que describa el número de respuestas provistas por cada estudiante. En su desarrollo, asuma que la tasa de respuesta anual se puede escribir como $\lambda_i(\mathbf{x}_i)$ donde $\mathbf{x}_i$ es un vector que caracteriza al estudiante i . De necesitar cualquier otro dato, explique cómo calcularlo a partir de los datos disponibles en el panel.
2. Escriba la log-verosimilitud de un modelo de conteo con heterogeneidad observable que describa el número de encuestas recibidas por cada estudiante. En su desarrollo, asuma que la tasa de recepción anual se puede escribir como $\mu_i(\mathbf{x}_i)$ donde $\mathbf{x}_i$ es un vector que caracteriza al estudiante i . De necesitar cualquier otro dato, explique cómo calcularlo a partir de los datos disponibles en el panel.

Hint: para las dos preguntas anteriores, puede asumir que todos los estudiantes de la muestra están activos durante los tres años de observación.

3. Un estudiante plantea que una de las principales razones que explican las bajas tasas de respuesta es la gran cantidad de encuestas que envía la institución, que abruman al estudiantado. En particular, el estudiante plantea que la tasa de respuesta ha ido bajando porque la tasa de envío ha ido subiendo.
 - a. Para testear que la institución ha ido aumentando el número de encuestas, el estudiante plantea que debiera estimarse un modelo homogéneo independiente para cada año y luego comparar los valores de los estimadores máximos verosímiles $\hat{\lambda}_{2023}$, $\hat{\lambda}_{2024}$ y $\hat{\lambda}_{2025}$ usando un test de ratios de verosimilitud. Comente sobre la adecuación de la propuesta del estudiante.
 - b. Más allá de la opinión que tenga de la propuesta anterior del estudiante, ¿cómo haría usted para comprobar si efectivamente la institución ha mantenido o aumentado su tasa de envíos?
4. Para avanzar en la comprensión del problema, se han estimado cuatro modelos de conteo, como se indica en la Tabla 2.17. En la lista se incluyen tanto modelos homogéneos, como modelos que incorporan heterogeneidad observable y no observable.

Table 2.17: Estimadores máximos verosímiles de cuatro modelos de conteo.

Variable	Poisson Homogéneo	Poisson Heterogéneo	NBD Homogéneo	NBD Heterogéneo
λ_0	12,58 ***	12,19 ***		
α			0,45 **	0,63 **
r			3,52 ***	4,15 ***
X_1		0,32 **		0,42 ***

Variable	Poisson Homogéneo	Poisson Heterogéneo	NBD Homogéneo	NBD Heterogéneo
X_2		0,08 .		0,15 *
X_3		0,65 ***		0,81 **
N. Obs	11.456	11.456	11.456	11.456
LL	-44.200	-44.200	-44.200	-44.200
AIC	90.400	89.000	75.760	80.200

Para el modelo que mejor ajuste a los datos, calcule la tasa esperada de un estudiante, para el próximo año, condicional a que ha contestado dos encuestas en el año recién pasado.

5. Proponga y justifique 2 variables para incluir en el vector $\mathbf{x}_i$, distintas a la fecha de envío. Junto con explicar por qué piensa que hace sentido incluir esas variables, hipotetice la dirección esperada del efecto.
6. Los modelos de conteo propuestos anteriormente suponen que las tasas de respuesta no dependen del número de encuestas realizadas. Esto es, dos estudiantes con las mismas características debieran generar, en promedio, las mismas respuestas, independientemente de si uno recibió más encuestas que el otro. Escriba la log-verosimilitud de un modelo que permita tener en cuenta que el número de respuestas generadas está asociado al número de encuestas recibidas.

Solución

1. Asumimos que el número de respuestas se distribuye Poisson con tasa $\lambda_i(\mathbf{x}_i)$. Como todos los estudiantes están activos durante los tres años de observación, la exposición es $T = 3$. Entonces la log-verosimilitud viene dada por:

$$LL = \sum_i \ln \left[\Pr(N_i = n_i) \right] = \sum_i \ln \left[\frac{(3 \lambda_i(\mathbf{x}_i))^{n_i} e^{-3 \lambda_i(\mathbf{x}_i)}}{n_i!} \right],$$

donde n_i es el número de respuestas del estudiante i , que se obtiene contando las filas del panel en que NMat = i y Respuesta = Sí.

2. La pregunta es conceptualmente idéntica a la anterior, pero se estima con otros datos. Asumiendo que el número de encuestas recibidas se distribuye Poisson con tasa $\mu_i(\mathbf{x}_i)$, la log-verosimilitud viene dada por:

$$LL = \sum_i \ln \left[\Pr(M_i = m_i) \right] = \sum_i \ln \left[\frac{(3 \mu_i(\mathbf{x}_i))^{m_i} e^{-3 \mu_i(\mathbf{x}_i)}}{m_i!} \right],$$

donde m_i es el número de encuestas recibidas por el estudiante i , que se obtiene contando las filas del panel en que NMat = i (independiente de la respuesta).

3. Las dos partes pueden contestarse separadamente:

- a. La propuesta metodológica del estudiante no tiene sentido. Primero, el test de ratios de verosimilitud (TRV) permite comparar modelos, no parámetros. Segundo, aun cuando quisiéramos comparar los modelos, el TRV requiere que un modelo esté anidado en el otro, lo que no ocurre en este caso (son tres modelos independientes estimados en submuestras distintas).
- b. Lo más sencillo es incluir los años como covariables en la tasa de envío:

$$\mu_i(\mathbf{x}_i) = \gamma_0 + \gamma_1 \text{Año}_{2023} + \gamma_2 \text{Año}_{2024} + \gamma_3 \text{Año}_{2025}.$$

Con esto, podemos aplicar un test F para evaluar si $\gamma_1 = \gamma_2$ y $\gamma_2 = \gamma_3$.

4. De acuerdo al AIC, el mejor modelo es el NBD homogéneo (AIC = 75.760). Recordando que la distribución posterior de la tasa individual en un modelo Poisson-Gamma es

$$\lambda \mid n \sim \text{Gamma}(\alpha + 1, r + n),$$

podemos calcular la esperanza condicional directamente:

$$E(\lambda \mid n = 2) = \frac{r + n}{\alpha + 1} = \frac{3,52 + 2}{0,45 + 1} \approx 3,81 \text{ [respuestas/año]}.$$

5. Hay múltiples opciones válidas. Algunos ejemplos:

- *Carrera*: es posible que algunas carreras respondan más que otras, ya sea por factores culturales o de carga académica. La dirección del signo dependerá de la carrera específica.
- *Tipo de encuesta*: es posible que algunos tipos de encuestas se contesten más que otros. Se puede postular que las encuestas de bienestar se contestan más que las de docencia, porque a los estudiantes les importan más los cambios en infraestructura.
- *Duración promedio*: si un estudiante recibe encuestas que duran más días, puede tener una mayor probabilidad de contestar y por tanto el efecto esperado sería positivo (aunque previsiblemente pequeño).
- *Número de encuestas recibidas (y su cuadrado)*: si un estudiante recibe más encuestas, tiene un universo mayor para responder y por tanto el efecto podría ser positivo. Si recibe demasiadas encuestas, quizás deja de contestar, lo que se capturaría por un efecto cuadrático negativo.

Nota: las direcciones de los efectos son especulativas. Mientras se argumente adecuadamente, se considera correcta la respuesta.

6. Asumimos que el número de respuestas, condicionado en el número de encuestas recibidas m_i , se distribuye binomial con tasa $\theta_i(\mathbf{x}_i)$. La log-verosimilitud viene dada por:

$$LL = \sum_i \ln \left[\Pr(N_i = n_i \mid m_i) \right] = \sum_i \ln \left[\binom{m_i}{n_i} \theta_i(\mathbf{x}_i)^{n_i} (1 - \theta_i(\mathbf{x}_i))^{m_i - n_i} \right],$$

donde m_i y n_i se definen como en las partes 1 y 2.

3. Modelos Estructurales

Para qué sirve esta unidad. En marketing, resulta frecuente necesitar modelos que vayan más allá de la simple descripción de correlaciones entre variables observables. Los modelos estructurales derivan relaciones estimables a partir de supuestos explícitos sobre el comportamiento de los agentes —típicamente, maximización de utilidad— lo que permite interpretar los parámetros en términos de valoraciones, elasticidades y disposición a pagar, así como evaluar contrafactuales que apoyen el diseño de estrategias comerciales.

Habilidades previas requeridas. Probabilidad y distribuciones (normal, valor extremo), estimación por máxima verosimilitud (MLE), regresión lineal y logística, álgebra matricial básica.

Qué debería poder hacer el estudiante al terminar.

- Formular modelos de utilidad aleatoria para problemas de elección discreta en marketing.
- Derivar las probabilidades de elección para los modelos logit, probit, nested logit y mixed logit.
- Estimar modelos de elección discreta mediante MLE y máxima verosimilitud simulada (SMLE).
- Evaluar la calidad de los modelos con ρ de McFadden, AIC, BIC y test de razón de verosimilitud.
- Calcular elasticidades propias y cruzadas, así como la disposición a pagar (WTP) por atributos.
- Incorporar dinámica limitada —persistencia de elección y precios de referencia— en modelos de panel.

Conexión con ejercicios. Al final del capítulo se incluyen problemas teóricos (P1–P6) con soluciones y problemas aplicados (PA1) que permiten consolidar los conceptos presentados.

3.1 Introducción a modelos estructurales

3.1.1 Modelos estructurales versus forma reducida

En esencia, un modelo econométrico estructural es aquel que deriva relaciones estimables estadísticamente a partir de supuestos bien definidos de comportamiento de los agentes que deciden respecto a las cantidades observables. En contraposición a los modelos estructurales están los modelos de forma reducida donde los modelos simplemente describen la variabilidad de alguna medida de interés en base a un conjunto de variables observables exógenas.

La disciplina económica suele llamar modelos estructurales a los resultantes de

asumir que los consumidores maximizan una utilidad subyacente y que las firmas maximizan su rentabilidad esperada. Desde el marketing, se considera también en la definición aquellos que postulan hipótesis alternativas de comportamiento incluyendo así una variedad de teorías de comportamiento que nutren la disciplina tales como teoría de prospectos (Kahneman & Tversky, 1979), contabilidad mental, elección sobre conjuntos de consideración, etc. Como se discutirá más adelante, no existe un modelo estructural puro y la línea que los separa de los modelos de forma reducida es ciertamente difusa.

Se incluirá en la discusión de modelos estructurales a cualquiera que considere alguna historia de comportamiento que permita añadir interpretabilidad a los parámetros del modelo.

3.1.2 Ejemplos motivadores

Ejemplo 1: Supóngase que un analista busca estudiar cómo el precio en la región i (p_i) se ve afectado por la presencia o no de competencia. Si además de los precios se observa la cantidad de clientes en la región (POP_i), el ingreso per cápita en la región (INC_i) y una indicatriz CMP_i que toma el valor 1 si en la región correspondiente presenta competencia (0 en caso contrario).

Entonces, un modelo de forma reducida sencillo para estudiar el problema viene dado por:

$$p_i = \beta_0 + \beta_1 POP_i + \beta_2 INC_i + \beta_3 CMP_i + \varepsilon_i$$

Bajo este enfoque, se pueden usar técnicas de regresión tradicionales para estimar β_3 que en principio indicaría el impacto de la competencia en el nivel de precios. Sin embargo, la presencia de competencia en un determinado mercado depende también del nivel de precios. Si los precios en una región son altos, la rentabilidad esperada por entrar también es alta motivando a potenciales competidores a participar. En consecuencia, un modelo como el planteado podría subestimar el efecto de la competencia.

Un modelo estructural buscaría derivar relaciones estimables a partir de supuestos básicos del comportamiento de la firma. Por ejemplo, se podría asumir que cada firma decide conjuntamente la entrada/salida de un mercado y los precios a cobrar de modo de maximizar la rentabilidad esperada.

Ejemplo 2: Supóngase que se busca describir la productividad de los miembros de la fuerza de venta medida como número de unidades vendidas q .

$$q = f(X, \beta) + \varepsilon$$

La especificación del término de error ε puede por sí solo permitir dar una interpretación estructural a los estimadores. Si simplemente se asume un error normalmente distribuido, entonces corresponderá simplemente a un ruido

blanco y la regresión simplemente indicará a través de los parámetros β cómo las variables X en promedio afectan las ventas q . Por el contrario, si se asume que el término ε considera además del ruido una componente no observable positiva asociada a la brecha de productividad de los miembros menos eficientes de la fuerza de venta, entonces la regresión describirá la frontera eficiente de ventas. Esto puede hacerse por ejemplo especificando que $\varepsilon = \epsilon - \xi$ donde ϵ está normalmente distribuida centrada en cero, pero ξ proviene de una normal truncada en los números positivos (este enfoque se le suele llamar de regresión estocástica de frontera).

Ejemplo 3. Al describir la participación de mercado de distintas marcas, un enfoque de regresión flexible podría predecir participaciones fuera del rango $[0, 1]$. Si en cambio se adopta el axioma de elección de Luce (Luce, 1959) —la probabilidad de elección depende del ratio entre la atracción de la alternativa y el atractivo total del conjunto— las participaciones quedan restringidas al rango admisible.

Ejemplo 4. La teoría económica predice que la demanda decrece con el precio. En situaciones con datos limitados, un modelo flexible puede estimar una relación positiva. La estructura permite restringir la búsqueda a modelos consistentes con la premisa teórica.

Ejemplo 5. Un retailer que vende a través de tienda física y sitio web evalúa reasignar el surtido entre canales. El análisis de ventas históricas por canal no permite predecir qué ocurriría al mover productos. Es necesario estimar primitivas de comportamiento —preferencias intrínsecas por canal y patrones de sustitución— que solo un modelo estructural puede proveer.

Ejemplo 6. En industrias con alta rotación de productos (moda, tecnología), los parámetros estables de la demanda —elasticidad al precio, factores estacionales, sustitución entre atributos— perduran más allá de un producto específico. El enfoque estructural apunta precisamente a estimar estos parámetros invariantes.

3.1.3 Ventajas de los modelos estructurales

El gran desafío de la aplicación de modelos econométricos a problemas comerciales es enriquecer el conocimiento respecto a cómo se comportan los agentes relevantes del negocio, para así tomar decisiones más consistentes y más rentables. Desde este punto de vista, se apunta a modelos que describan la lógica que determina el comportamiento de los clientes y firmas más allá de simples correlaciones estadísticas entre las variables observables. En general, son varias las ventajas de usar modelos estructurales por sobre modelos de forma reducida:

1. *La capacidad de contar una mejor historia del comportamiento de los agentes.* Esto se expresa por la capacidad de interpretación directa de los parámetros del modelo. Mientras los parámetros asociados a enfoques de regresión tradicionales típicamente indican la magnitud en que en promedio varía alguna magnitud de interés ante variaciones de otra, los

parámetros de un modelo estructural indican entre otros la valoración relativa de un atributo en la función de utilidad, los precios de referencia de un producto o la aversión al riesgo de un tomador de decisión. La provisión de una historia de comportamiento más completa no se deriva exclusivamente de la interpretación directa de los parámetros del modelo sino que también de la capacidad de derivar métricas complementarias tales como elasticidades y excedentes de consumidores. Más aún, se puede proyectar el comportamiento para calcular probabilidades y frecuencias de compra, participaciones de mercado, etc.

2. La generación de estimaciones consistentes con las expectativas de los analistas. Frecuentemente, al analizar los datos se quiere dejar la mayor libertad posible al modelo *para dejar que la data hable*. Este enfoque puede tener valor y ser recomendable en estudios exploratorios, pero para tomar decisiones se necesitan estimaciones robustas y usar tanta información como sea posible. Las teorías usadas para derivar modelos econométricos estructurales suelen estar soportadas tanto por estudios experimentales como por amplia evidencia empírica en múltiples dominios. Por lo tanto, al incorporar teoría se está implícitamente usando información que ha demostrado consistentemente su validez.
3. *Evaluación de impacto de modificación de políticas*. Una de las herramientas fundamentales de la función comercial es la generación de planes comerciales que buscan proponer un diseño del conjunto producto, plaza, precio y promoción que genere el mayor valor para el cliente y la captura del mayor excedente por parte de la firma. El rol de los modelos econométricos es estudiar el impacto que tendrían distintas estrategias en el comportamiento del consumidor. En esencia, un plan de marketing propone un cambio en las reglas del juego que han generado la data que se observa y por tanto se necesita apuntar a estimar los elementos más básicos del comportamiento que se mantendrán invariantes ante modificación de productos, precios, canales de distribución, etc. En este grupo se tienen valoraciones por atributos de productos, costo de transporte, aversión al riesgo, entre otros, que no pueden ser estimados a menos que se derive el modelo a partir de teorías individuales de comportamiento. En otras palabras, la derivación de modelos de demanda a partir de teorías de comportamiento permite evaluar contrafactuales que apoyan el diseño de propuestas de valor efectivas.
4. *Testear aplicabilidad de teoría*. Al usar un enfoque estructural, se fuerza a pensar detalladamente respecto al problema y explicitar cada uno de los supuestos de comportamiento. Las especificaciones alternativas de modelos de forma reducida simplemente corresponden a formas funcionales diferentes y por tanto no son informativas respecto a la lógica en que deciden los agentes. Por otra parte, dos modelos estructurales diferentes provienen de supuestos de comportamiento diferentes y por tanto cuando uno de ellos ajusta mejor a la data indica que hay una teoría de compor-

tamiento que es más plausible que la otra en el dominio de aplicación del modelo. Así, los modelos estructurales no solo se nutren de teoría sino que también ayudan a su desarrollo.

Las ventajas antes descritas no implican que siempre deban preferirse modelos estructurales por sobre los de forma reducida. Como se ha descrito, los modelos de forma reducida suelen proveer suficiente flexibilidad para dejar que sea la data la que hable, lo que puede ser particularmente útil en análisis exploratorios del caso bajo estudio. Además, muchas veces la inclusión de más estructura en el modelo implica rutinas de estimación más sofisticadas siendo con frecuencia altamente intensivas computacionalmente.

Es importante destacar que no existe un modelo puramente estructural. Todo modelo requiere en algún momento suponer alguna forma funcional flexible sin fundamento teórico sólido. Por ejemplo, se puede asumir que los consumidores al elegir un producto están maximizando una utilidad subyacente, pero ¿cómo describir dicha función de utilidad? ¿Qué variables explicativas usar y cuál forma funcional escoger? Ciertamente la especificidad de las teorías disponibles no alcanza a responder a estas preguntas y se debe por lo tanto escoger en base a la intuición y empíricamente entre aquellas que generen mejor ajuste y/o capacidad de pronóstico. De esta forma, un buen modelo debe balancear adecuadamente el uso de la teoría con la simpleza y flexibilidad del modelo.

Para ser convincente, un modelo estructural debe al menos (i) entregar suficiente flexibilidad para aprender de la data, (ii) derivar las ecuaciones de comportamiento de supuestos razonables respecto de los agentes involucrados y (iii) incorporar explícitamente en la descripción la naturaleza no experimental de la data.

Observación: En la discusión se ha hecho la distinción entre modelos probabilísticos y modelos estructurales. Aunque los modelos probabilísticos proveen una historia de comportamiento de los agentes, los supuestos básicos usados para derivarlos no se sustentan en ninguna teoría de comportamiento. Por ejemplo, en modelos de duración en tiempo discreto se suele suponer que los clientes dejan de estar activos con cierta probabilidad. Más que una teoría de comportamiento esto es simplemente una descripción probabilística de un fenómeno. En determinadas situaciones, especialmente en casos en que no se dispone de una descripción rica del ambiente en que los agentes toman sus decisiones, se conforma con esta descripción agregada del comportamiento. El enfoque estructural sobre el que se ahondará en esta parte resulta particularmente útil cuando se tiene suficiente información para investigar las motivaciones profundas de las elecciones. Al definir un modelo estructural, tanto las teorías de comportamiento como la descripción probabilística del sistema son fuentes válidas de estructura. Sin embargo, se considerará como modelo econométrico estructural a aquellos que se nutren de ambas fuentes.

3.1.4 Modelos estructurales en marketing

El desarrollo de modelos estructurales se ha gestado en varias áreas del conocimiento tales como economía, transportes, logística, finanzas y marketing. Entre estas áreas, la del marketing se ha constituido en un terreno particularmente fértil para el desarrollo y adopción del enfoque estructural. Se identifican al menos cuatro motivos por los cuales la adición de estructura en los modelos econométricos es particularmente útil para el análisis de problemas comerciales:

1. *Disponibilidad de datos.* Gran parte de los datos que registran las compañías dan cuenta de las interacciones entre clientes y firma como son ocasiones de compra, visitas a sitios web corporativos o llamadas a los centros de llamadas. De esta forma, un conjunto importante de los datos disponibles dentro de las organizaciones son informativos respecto a procesos claves de la función comercial. Así, los requerimientos de datos impuestos por los modelos estructurales están inmediatamente satisfechos por procesos operacionales.
2. *Atractivo de la evaluación de la intervención de sistemas.* En la función comercial, casi por definición se busca perturbar los sistemas para mejorar la oferta de valor cambiando precios, proponiendo nuevos diseños de productos, redefiniendo la cadena logística, etc. De esta forma se necesita disponer de modelos que describan la reacción de los consumidores ante dichos cambios del ambiente competitivo lo que, de acuerdo a la crítica de Lucas (Robert E. Lucas, 1976), solo puede hacerse con un modelo estructural.
3. *Importancia de heterogeneidad.* En marketing se busca hacer inferencia desagregada a nivel de cliente o segmento para poder diseñar versiones especializadas del marketing mix que sean atractivas para segmentos específicos de clientes. Como los modelos estructurales requieren especificar los supuestos de comportamiento a nivel individual, la generación de estimaciones desagregadas suele derivarse directamente.
4. *Pragmatismo en la aceptación de teorías.* Como se ha argumentado, una de las ventajas de los modelos estructurales es que permiten testear si una determinada teoría de comportamiento aplica a una situación. A diferencia de otras disciplinas, en marketing hay una tradición de revisión continua de las fuerzas que moldean el comportamiento de las personas y por tanto el enfoque de modelos estructurales entrega una herramienta alternativa a la verificación experimental de nuevas teorías.

3.1.5 Taxonomía de modelos estructurales

Metodológicamente, es útil generar una clasificación de los tipos de modelos estructurales existentes en la literatura. Como se ha consignado, uno de los costos de la inclusión de teoría en modelos econométricos es la mayor complejidad en las rutinas de estimación. Es esta complejidad la que dificulta la generación

de un mecanismo único que permita estimar modelos generales y por tanto se ve forzado a usar metodologías específicas dependiendo de la naturaleza del problema. En la discusión se basará la clasificación en la evaluación de cuatro factores.

1. *Nivel de agregación de los datos.* Se ha propuesto que un modelo estructural debe basarse en una descripción detallada de los supuestos de los tomadores de decisión a nivel individual. Por lo tanto, la disponibilidad de datos a nivel individual como la decisión de compra de cada uno de los individuos de un panel de consumidores habilita para, imponiendo las restricciones de identificación necesarias, estimar los parámetros de comportamiento de manera más o menos directa. Sin embargo, en ciertas situaciones solo se dispone de información agregada, como participaciones de mercado o datos agregados de venta. En estos casos, la identificación de parámetros de comportamiento requiere además de una descripción del mecanismo mediante el cual se agregan las decisiones individuales. Este mecanismo típicamente considera la especificación de un modelo de heterogeneidad describiendo como se distribuyen los parámetros entre los clientes la que se integra sobre la población para generar las métricas agregadas. Esto es precisamente lo propuesto por el método BLP de Berry, Levinsohn y Pakes (Berry et al., 1995), que describe un método que, basado en un modelo logit, permite estimar ofertas y demandas de un modelo oligopólico con información agregada. Por simplicidad, en esta versión se concentrará en modelos estimables directamente sobre datos desagregados a nivel individual.
2. *Temporalidad de las decisiones.* Dependiendo de la amplitud temporal considerada por los agentes al evaluar las alternativas de decisión, se distingue entre problemas estáticos y dinámicos. Básicamente, si se considera que las acciones que se observan resultan de una evaluación completa del horizonte, entonces se habla de problemas dinámicos. En caso contrario, se dice que el problema es estático. La distinción es importante desde un punto de vista metodológico. Si el tomador de decisiones basa sus decisiones exclusivamente mirando el pasado, entonces estas decisiones pueden caracterizarse directamente mediante condiciones de optimidad sencillas. Por el contrario, si el tomador de decisión además evalúa las repercusiones (inciertas) que sus acciones de hoy podrían tener en su bienestar futuro, entonces se necesita caracterizar las políticas óptimas a través de ecuaciones de Bellman que incorporen explícitamente la naturaleza multiperiodo del problema. En este caso, para encontrar la política óptima del problema se requiere usar técnicas como programación dinámica estocástica o control óptimo, aumentando de manera importante la complejidad computacional de la estimación.
3. *Naturaleza de las variables de decisión.* Si las variables sobre las que deciden los agentes son continuas (gasto, montos de inversión, unidades compradas, etc.), se habla de un modelo de decisión continuo. Si las

variables sobre las que deciden los agentes son discretas (si visita o no visita la tienda, si elige la marca A o marca B, etc.), se habla de un modelo de decisión discreto. La distinción es relevante en cuanto las soluciones de un problema de decisión continua pueden caracterizarse directamente mediante condiciones de Karush-Kuhn-Tucker, mientras que las soluciones de un problema de decisión discreta requieren una enumeración del valor de las alternativas.

4. *Identidad de los agentes.* Los modelos estructurales pueden usarse para estudiar tanto el comportamiento de los clientes como de las otras firmas en el mercado. El área que estudia el comportamiento de las firmas ha tenido un gran desarrollo en los últimos años y se conoce como organización industrial empírica. En esta versión, se concentrará la discusión en el estudio de los clientes por dos motivos principales: la disponibilidad de datos de comportamiento de cliente y la simpleza de las nociones de equilibrio requeridas para describir a los clientes. Mientras cada cliente suele tener poco poder de mercado por sí mismo, las acciones de marketing de las firmas competidoras típicamente pueden modificar de manera importante las condiciones del mercado. Así, la descripción de las decisiones de las firmas conlleva desafíos metodológicos importantes como la inclusión de nociones sofisticadas de equilibrio para internalizar que las decisiones de las firmas resultan tanto de mirar las respuestas esperadas de los clientes como las reacciones estratégicas de los competidores.

Metodológicamente es útil también distinguir los métodos de estimación de los modelos. La literatura reconoce dos grandes enfoques para estimar modelos estructurales como los aquí presentados: método de los momentos generalizados (GMM) y método de la máxima verosimilitud. Dada su eficiencia estadística (en el sentido que usa toda la información disponible), en esta primera versión se usará solo el método de la máxima verosimilitud. En lo que sigue se enfocará la discusión al estudio del comportamiento de clientes, en problemas estáticos (o con dinámica limitada a la incorporación del pasado) y con datos desagregados. Partiremos describiendo brevemente modelos de decisión continuos para luego iniciar una discusión más extensa en modelos de decisión discreta que tienen una tradición más larga en marketing.

3.2 Modelo logit

3.2.1 Modelos de elección discreta

Un modelo de elección discreta consiste básicamente en situaciones en que la naturaleza de las variables de decisión a las que se enfrenta el tomador de decisión son discretas. Para ilustrar la intuición de la diferencia con respecto a modelos de decisión continua, es útil pensar que mientras estos últimos buscan describir decisiones de “el cuánto”, los modelos de elección discreta se concentran en “el cuál”. La distinción además relevante desde un punto de vista metodológico. A

diferencia de los modelos de elección continua en que la optimidad de la elección queda bien descrita por condiciones de primer orden, al enfrentar decisiones discretas caracterizaremos la optimidad por enumeración. Ejemplos típicos en que la decisión a evaluar es de naturaleza discreta incluye la elección de una marca por sobre otra en la góndola de un supermercado, la decisión de visitar o no a una tienda, la elección del color de una prenda de vestir, de un canal de venta y la elección de las firmas respecto a entrar o no entrar a un mercado.

Para que un problema de elección discreta esté bien definido, se necesita, además de variables de decisión discretas, que el conjunto de alternativas presente las siguientes tres características:

1. *Exhaustivas*: El conjunto sobre el que los tomadores de decisión eligen deben incluir todas las alternativas posibles. En otras palabras, cualquiera sea la decisión observada, debe estar incluida en el conjunto de elección. Esta condición es poco restrictiva ya que siempre es posible incluir en el set de alternativas la posibilidad “ninguna de las anteriores” o similar que por definición incluya toda las otras posibilidades no consideradas en conjunto. Sin embargo, esta estrategia debe usarse con precaución. Por ejemplo, al estudiar la elección de marca en una categoría en que se observa que los clientes no siempre compran alguna de las marcas disponibles, se podría incluir la alternativa de no compra en el conjunto de elección. Si la proporción de no compras es alta en la muestra, la inclusión de la alternativa de no compra podría limitar la habilidad del modelo de aprender respecto a cómo los clientes eligen entre marcas. En este caso, podría convenir concentrarse en la elección de la marca condicional en haber hecho una compra en la categoría.
2. *Mutuamente excluyentes*: El conjunto de decisión debe definirse de modo que en cada ocasión el tomador de decisión seleccione solo una de las alternativas disponibles. Esto es, la elección de una alternativa implica necesariamente la no elección de cualquiera de las alternativas restantes. Aunque aparentemente restrictiva, la definición de conjunto de elección puede acomodarse para generar conjuntos mutuamente excluyentes. Por ejemplo, considérese un modelo para describir la elección de los clientes entre la *tienda física tradicional* o la *tienda virtual*. Si simplemente se permite una alternativa de elección por cada canal, entonces se excluye la posibilidad de que un mismo cliente esté en más de un canal al mismo tiempo. Para incorporar esta posibilidad, se debe redefinir las alternativas agregando la opción de *tienda tradicional y virtual*.
3. *Finito*: El conjunto de decisión debe contener un conjunto finito de alternativas. Esta condición es importante por dos motivos técnicos. Primero, un conjunto finito facilita la evaluación de la optimidad de las decisiones y, segundo, facilita la definición de probabilidades de elección. Existen situaciones en que la decisión teóricamente permite infinitas posibilidades, pero que en la práctica se concentran en un número reducido de alternativas y, por tanto, quedan bien representadas por un modelo de elección discreta.

Por ejemplo, se puede usar el número de cajas de cereal compradas por los clientes en cada visita al supermercado. Aunque teóricamente los clientes siempre podrían comprar una unidad adicional, el problema queda bien descrito considerando sólo las alternativas de 0, 1, 2, 3 o más de 3 cajas.

Utilidad aleatoria

Un modelo estructural para describir la probabilidad de elegir cada alternativa necesita especificar el mecanismo que usan los agentes para decidir entre las alternativas. Se partirá asumiendo que, en cada oportunidad de compra t , el tomador de decisión n elige la alternativa i que le reporta mayor utilidad u_{nit} . Pese a que el tomador de decisión necesita conocer la utilidad que deriva de cada una de las alternativas, desde la perspectiva del analista solo se observan algunas características del ambiente de decisión y del tomador de decisión a partir de las cuales se puede intentar aproximar la utilidad del tomador de decisión a través de una función $v_{nit}(x_{nit}, \theta)$ donde x_{nit} son las características observables del problema y θ el vector de parámetros que se busca estimar y que describen la relación de dichas características con la utilidad.

$$u_{nit} = v_{nit} + \varepsilon_{nit} \quad (3.1)$$

Ejemplo: Supóngase que se quiere describir la elección del medio de pago que usan los usuarios de una tienda determinada, la que permite pagar en efectivo o con alguna tarjeta bancaria. El analista observa 3 variables que intuye pueden ser relevantes en la elección del medio de pago: el género del cliente ($F_n = 1$ si cliente es de género femenino), su nivel de ingresos (I_n) y el monto de la transacción (M_{nt}). Son precisamente estas características las que estarían incluidas en la matriz que se ha llamado x_{nit} . A partir de esta información pueden plantearse múltiples modelos para describir v_{nit} (se asumirá que $i = 0$ corresponde al caso de pago con efectivo mientras que $i = 1$ al de pago con tarjeta).

- *Modelo Lineal Homogéneo:* Aquí, la utilidad para ambas alternativas crece linealmente con las variables observables. En este caso, los parámetros son los mismos para todos los tomadores de decisión y por tanto el vector de parámetros viene dado por $\theta = (\alpha_0, \alpha_1, \beta, \gamma, \delta)$

$$v_{nit} = \alpha_i + \beta F_n + \gamma I_n + \delta M_{nt}$$

- *Modelo lineal heterogéneo:* Aquí, la utilidad para ambas alternativas también crece linealmente con las variables observables, pero ahora los parámetros varían por alternativa y por agente, y por tanto el vector de parámetros viene dado por $\theta = (\{\alpha_{1n}\}_{n=1}^N, \beta_0, \beta_1, \gamma_0, \gamma_1, \{\delta_n\}_{n=1}^N)$

$$v_{nit} = \alpha_{in} + \beta_i F_n + \gamma_i I_n + \delta_n M_{nt}$$

La definición de que los interceptos dependen del cliente n simplemente indica que cada cliente tiene una preferencia intrínseca por cada medio de pago. Del mismo modo, se está imponiendo que la influencia que tiene el monto en el atractivo que tiene cada alternativa depende del cliente. Por ejemplo, mientras para algunos clientes el monto de la transacción puede jugar un rol importante en la decisión del medio de pago, para otros este efecto podría no ser relevante. Por último, la dependencia de la alternativa en los parámetros asociados a género e ingreso podrían usarse para por ejemplo situaciones en que el nivel de ingreso afecta el atractivo de un medio de pago pero no del otro (la intuición para el género es análoga).

Por supuesto, también se pueden postular modelos no lineales u otras especificaciones de la heterogeneidad. Por ejemplo, que la influencia del ingreso varíe por medio de pago, pero que el efecto del género sea constante entre las alternativas. Descubrir la especificación que mejor describe el problema es precisamente la tarea del analista.

Observación: En el ejemplo se ha introducido brevemente el concepto de heterogeneidad. Sin embargo, para facilitar la exposición de los temas básicos, en primera instancia se concentrará en modelos sin heterogeneidad. En marketing, los modelos que incluyen heterogeneidad en las preferencias son tan importantes que se postergará su discusión en un capítulo separado.

En la práctica, aún en situaciones en que se observa con detalle el ambiente de decisión, no se podrá describir con exactitud todos los factores que gobiernan el comportamiento de los agentes. Por lo tanto, se definirá ε_{nit} como el error (aditivo) que se comete al aproximar u_{nit} a través de v_{nit} .

La componente básica para estimar estadísticamente un modelo de elección discreta es la especificación de la probabilidad de elección de cada alternativa. Sea P_{nit} la probabilidad de que el agente n escoja la alternativa i en la oportunidad de compra t . El supuesto de maximización de utilidades implica que P_{nit} puede escribirse como:

$$\begin{aligned} P_{nit} &= \Pr(u_{nit} > u_{njt}, \forall j \neq i) \\ &= \Pr(v_{nit} + \varepsilon_{nit} > v_{njt} + \varepsilon_{njt}, \forall j \neq i) \\ &= \int \mathbf{1}(\varepsilon_{njt} - \varepsilon_{nit} > v_{nit} - v_{njt}) f(\varepsilon_{nt}) d\varepsilon_{nt} \end{aligned} \tag{3.2}$$

donde $\mathbf{1}(\cdot)$ toma el valor 1 si se cumple el argumento y el valor 0 en caso contrario. En esta expresión, $\varepsilon_{nt} = (\varepsilon_{n1t}, \varepsilon_{n2t}, \dots, \varepsilon_{nIt})$ es el vector de las componentes aleatorias de la elección del agente n en la oportunidad t , y $f(\cdot)$ la función de densidad que describe su comportamiento probabilístico. La elección de la distribución de la componente aleatoria es importante en cuanto impone restricciones a los patrones de comportamiento que pueden ser capturados por el modelo. Se concentrará la atención en los casos en que ε_{nit} se distribuye

valor extremo, que da origen al modelo *logit*, y normal, que da origen al modelo *probit*.

3.2.2 Derivación de la probabilidad logit

El modelo logit resulta de asumir que cada ε_{nit} es independientemente distribuido según una distribución Gumbel (valor extremo tipo I) (McFadden, 1974):

$$F(\varepsilon_{nit}) = e^{-e^{-\varepsilon_{nit}}}, \quad f(\varepsilon_{nit}) = e^{-\varepsilon_{nit}} e^{-e^{-\varepsilon_{nit}}} \quad (3.3)$$

Bajo este supuesto, se puede demostrar que la probabilidad de elección en un modelo logit corresponde a una fórmula cerrada sencilla. Para simplificar la notación, sea $s = \varepsilon_{nit}$.

$$\begin{aligned} P_{nit} &= \int_{-\infty}^{\infty} \left(\prod_{j \neq i} e^{-e^{-(s+v_{nit}-v_{njt})}} \right) e^{-s} e^{-e^{-s}} ds \\ &= \int_{-\infty}^{\infty} \left(\prod_j e^{-e^{-(s+v_{nit}-v_{njt})}} \right) e^{-s} ds \\ &= \int_{-\infty}^{\infty} \exp \left(\sum_j e^{-(v_{nit}-v_{njt})} \right) e^{-s} ds \end{aligned}$$

Para resolver la integral, se puede recurrir a un cambio de variables $t = e^{-s}$ y $dt = e^{-s} ds$. Con esto:

$$\begin{aligned} P_{nit} &= \int_{\infty}^0 -e^{t \sum_j e^{-(v_{nit}-v_{njt})}} dt \\ &= \frac{e^{-(v_{nit}-v_{njt})}}{\sum_j e^{-(v_{nit}-v_{njt})}} \Big|_0^{\infty} \\ &= \frac{e^{v_{nit}}}{\sum_j e^{v_{njt}}} \end{aligned} \quad (3.4)$$

En algunos libros de texto se justifica esta expresión simplemente como una regresión logística, esto es, una transformación lineal para normalizar la utilidad de modo de interpretarla directamente como una probabilidad de elección en el rango $[0,1]$. Aunque válido, resulta útil entender que, en efecto, dicha expresión puede derivarse a partir de supuestos de maximización de utilidades.

Para ganar algo de intuición respecto a la expresión de la probabilidad de elección, es útil graficarla con respecto a la utilidad derivada por cada alternativa. Por ejemplo, supóngase que se tiene una decisión binaria que, por ejemplo, corresponde a la decisión de comprar o no comprar un producto. En este caso,

la probabilidad de comprar el producto crece *sigmoidealmente* con la utilidad derivada de la compra. Esto es, al graficar la probabilidad de compra con respecto a la utilidad derivada, se obtiene una curva S como muestra la Figura 1. En la figura, se ha agregado también la curva de la probabilidad de elección en el caso en que, en vez de asumir que el error se distribuye valor extremo como demanda el modelo logit, se asume que el error está normalmente distribuido como tradicionalmente se hace en otros modelos econométricos.

```
knitr::include_graphics(rep("images/probabilidad_eleccion.png"))
```




Figure 3.1: Probabilidad de elección

3.2.3 Elasticidades

La disposición de una fórmula cerrada permite calcular métricas de sustitución de forma directa. Si $v_{nit} = v(\mathbf{x}_{nit}, \theta)$, se obtienen las siguientes expresiones.

Recuerde que una de las motivaciones para el uso de modelos estructurales es la posibilidad de analizar contrafactuales, esto es, ver qué pasaría con el mercado si hay cambio en alguna variable de control interesante. Por ejemplo que pasa con las participaciones de mercado si sube el precio de una alternativa, si se aumenta la frecuencia publicitaria, etc. Las métricas recién presentadas permiten precisamente hacer dichas evaluaciones de manera directa.

Derivada propia (variación de P_{nit} ante un cambio en un atributo de la misma alternativa):

$$\frac{\partial P_{nit}}{\partial x_{nit}} = \frac{\partial v_{nit}}{\partial x_{nit}} \cdot P_{nit}(1 - P_{nit}) \quad (3.5)$$

Derivada cruzada (variación de P_{nit} ante un cambio en un atributo de otra alternativa j):

$$\frac{\partial P_{nit}}{\partial x_{njt}} = -\frac{\partial v_{njt}}{\partial x_{njt}} \cdot P_{nit} \cdot P_{njt} \quad (3.6)$$

Elasticidad de la probabilidad de elegir la alternativa i con respecto a alguna componente de la utilidad de la misma alternativa.

$$e_{ix_{nit}} = \frac{\partial P_{nit}}{\partial x_{nit}} \cdot \frac{x_{nit}}{P_{nit}} = \frac{\partial v_{nit}}{\partial x_{nit}} x_{nit} (1 - P_{nit}) \quad (3.7)$$

Elasticidad de la probabilidad de elegir la alternativa i con respecto a alguna componente de la utilidad de otra alternativa.

$$e_{ix_{njt}} = \frac{\partial P_{nit}}{\partial x_{njt}} \cdot \frac{x_{njt}}{P_{nit}} = \frac{\partial v_{njt}}{\partial x_{njt}} x_{njt} P_{njt} \quad (3.8)$$

El modelo logit es bastante flexible para acomodar una amplia variedad de situaciones. En efecto, distintas especificaciones de las funciones de utilidades de las alternativas permiten describir múltiples fenómenos asociados a la elección. Sin embargo, es importante reconocer que los supuestos subyacentes al logit imponen importantes restricciones a cómo se describe la lógica en que los agentes evalúan las alternativas y escogen entre ellas.

Para fijar ideas, resulta útil pensar qué restricciones impone asumir que las componentes no observables de la utilidad son todas independientes entre ellas. El supuesto de independencia obliga a imponer que cualquier relación entre las utilidades de dos alternativas debe necesariamente capturarse a través de variables observables. Del mismo modo, las utilidades que se derivan por dos alternativas en ocasiones de elección diferentes solo pueden describirse a través de elementos que se puedan observar a lo largo del tiempo. Para entender mejor cómo estas limitaciones se materializan en la formulación del modelo, se discutirán formalmente tres características del modelo logit: la existencia de patrones de sustitución proporcional, la incapacidad de capturar tanto heterogeneidad aleatoria en las preferencias como componentes dinámicas no observables.

3.2.4 Propiedades del modelo logit

Patrones de sustitución

Los patrones de sustitución derivados de un modelo logit son bastante peculiares y, aunque desde un punto de vista econométrico puede resultar beneficioso, desde el punto de vista de la investigación de teorías de comportamiento suele ser considerado como bastante restrictivo. Se entenderá por patrones de sustitución a la forma en que cambia la probabilidad de elección de alguna alternativa cuando se modifica el atractivo de otra alternativa. Para entender la naturaleza de los patrones de sustitución del modelo logit es útil calcular el ratio de las probabilidades de elección de dos alternativas cualquiera i y j .

$$\frac{P_{ni}}{P_{nj}} = e^{v_{ni} - v_{nj}} \quad (3.9)$$

Este ratio solo depende de las utilidades observables de las dos alternativas consideradas lo que indica que la probabilidad relativa de elegir la alternativa i sobre la alternativa j no depende de que otras alternativas existan ni de los atributos que ellas tengan. Por ejemplo, si se agrega una alternativa al conjunto de elección, el ratio de probabilidades de las alternativas existentes se mantendrá constante independiente de las características de la nueva alternativa. Se referirá a esta característica como *independencia de alternativas irrelevantes* o *IIA*.

Para ejemplificar, considérese una botillería que ofrece dos variedades de vino, uno blanco y otro tinto. Supóngase además que estas dos alternativas tienen la misma participación de mercado, esto es la mitad de los clientes de la botillería compra vino blanco y la otra mitad compra vino tinto. En este caso, las utilidades sistemáticas debieran ser similares y, por tanto, el ratio de probabilidades de elección de vino blanco sobre vino tinto debiera acercarse a 1. Motivado por un mayor margen de los vinos tintos, el administrador de la botillería decide incorporar una nueva variedad de vino tinto. Intuitivamente se esperaría que, como la nueva variedad de vino tinto es un sustituto más cercano al tinto existente, la participación de mercado de este debiera decrecer más que la de vino blanco. Sin embargo, la propiedad de IIA impone que este ratio se mantiene constante. En otras palabras, la introducción de una nueva alternativa disminuirá la participación de todas las otras alternativas independiente de las similitudes que tengan. Esta última observación puede corroborarse calculando la elasticidad de sustitución $E_{ix_{nj}}$ que determina como cambia la probabilidad de consumir la alternativa i ante un cambio en un atributo x_{nj} de la alternativa j .

$$E_{ix_{nj}} = -\frac{\partial v_{nj}}{\partial x_{nj}} x_{nj} P_{nj}, \forall i \neq j$$

Esta expresión no depende de i , por lo que es constante para todas las alternativas de elección. Luego, si ocurre una mejora en los atributos de una alternativa, la probabilidad de elección de las demás disminuye en el mismo porcentaje independiente de la similitud entre alternativas. Se referirá a esta característica como *patrones de sustitución proporcionales*.

Una ventaja de los patrones de sustitución del modelo logit es que permite que los parámetros del modelo sean estimados consistentemente en base a un subconjunto de las alternativas. Esto es particularmente útil en ambientes de decisión de marketing donde típicamente se encuentran centenas de productos que potencialmente pueden constituir alternativas de elección en una situación de compra. De esta forma, para estimar un modelo logit se pueden seleccionar conjuntos reducidos de alternativas que capturan los elementos esenciales de la elección e ignorar qué pasa con todas las otras alternativas.

Incapacidad de capturar heterogeneidad aleatoria

La investigación de las diferencias entre las preferencias de los distintos clientes es un tema fundamental para el desarrollo de planes comerciales exitosos. Tradi-

cionalmente se distinguen dos tipos de heterogeneidad de acuerdo a la capacidad de observación del analista. En un principio, se tiene el estudio de heterogeneidad observable que indica cómo las preferencias de los tomadores de decisiones varían de acuerdo a sus características medibles. Este tipo de heterogeneidad permite, por ejemplo, estudiar diferencias en las preferencias entre hombres y mujeres, por edad o por niveles de ingreso. Sin embargo, una proporción importante de las diferencias de las preferencias no es atribuible a características observables como las recién descritas. Otro ejemplo es que dos hermanos del mismo género, de edades similares, viviendo en el mismo hogar, pueden tener preferencias completamente diferentes respecto a sabores de yogur.

El resultado fundamental en esta sección indica que un modelo logit permite estudiar variaciones de preferencias asociadas a componentes observables, pero no a componentes no observables. Para ilustrar este resultado, supóngase un tomador de decisión caracterizado por la siguiente función de utilidad:

$$u_{nit} = \alpha_i + \beta_n p_{it} + \varepsilon_{nit}$$

Es decir, la utilidad de cada alternativa tiene una componente base que es constante entre los tomadores de decisión y una penalización por precio p_{it} al que se enfrenta el tomador de decisión. Al indexar β_n por agente se está explícitamente permitiendo que algunos tomadores de decisión sean más sensibles al precio que otros. Supóngase que se postula que el coeficiente de precio viene dado por la siguiente ecuación de regresión.

$$\beta_n = \lambda_0 + \lambda_1 I_n + \mu_n$$

Donde λ_0 captura la sensibilidad base al precio, I_n el nivel de ingreso del agente n y λ_1 el coeficiente que indica cómo dichos niveles de ingresos afectan la sensibilidad al precio. Por último, μ_n es un valor aleatorio que captura todas las otras componentes que modifican la sensibilidad al precio más allá del nivel base y los ingresos.

$$\begin{aligned} u_{nit} &= \alpha_i + (\lambda_0 + \lambda_1 I_n + \mu_n) p_{it} + \varepsilon_{nit} \\ &= \alpha_i + \lambda_0 p_{it} + \lambda_1 p_{it} I_n + \xi_{nit} \end{aligned}$$

Donde $\xi_{nit} = \mu_n p_{it} + \varepsilon_{nit}$. De esta expresión debiera ser claro que la inclusión de heterogeneidad observable puede ser capturada bajo un enfoque logit. En efecto, los parámetros α_i , λ_0 y λ_1 dan cuenta respectivamente del nivel de utilidad base por alternativa, de la penalización por precio y de como dicha penalización se ve modificada por el nivel de ingresos. Lamentablemente, la variación aleatoria μ_n no puede ser incluida, ya que su inclusión necesariamente implica que las componentes errores ξ_{nit} no están idénticamente distribuidas. En efecto, se puede mostrar que $\text{Var}(\xi_{nit}, \xi_{njt}) = \text{Var}(\mu_n) p_{it}^2$ que evidentemente varía entre alternativas. Más aún, también se puede mostrar

que $\text{Cov}(\xi_{nit}, \xi_{njt}) = \text{Var}(\mu_n) p_{it} p_{jt} \neq 0$, violando también el supuesto de independencia.

Es importante notar que la incapacidad de capturar aleatoriedad aplica también a componentes dinámicas. Esto es, al observar compras repetidas en el tiempo, el modelo logit no permite capturar que hay componentes no observables que varíen en el tiempo. Por ejemplo, no se puede incorporar que, debido a factores externos no observables, en algunos períodos algunas alternativas son más atractivas para todos los agentes decidiendo en dichos períodos. Al igual que en el ejemplo anterior, incluir estas variaciones viola los supuestos de distribuciones independientes e idénticamente distribuidas para las componentes no observables.

3.2.5 Estimación

La log-verosimilitud del modelo logit se construye directamente a partir de la probabilidad de elección. Sea $y_{nit} = 1$ si el agente n elige la alternativa i en la oportunidad t :

$$LL(\theta) = \sum_n \sum_t \sum_i y_{nit} \ln \left(\frac{e^{v_{nit}(\mathbf{x}_{nit}, \theta)}}{\sum_j e^{v_{njt}(\mathbf{x}_{njt}, \theta)}} \right) \quad (3.10)$$

Esta función es cóncava y puede maximizarse con rutinas estándar de optimización convexa. Computacionalmente, suele ser más conveniente trabajar con la log-verosimilitud en vez de la verosimilitud. Esto porque la multiplicación de probabilidades genera muy rápidamente valores que computacionalmente son indistinguibles de cero. Recuérdese que el valor de los valores óptimos son invariantes a transformaciones monótonas como la del logaritmo.

Si la utilidad es lineal, $v_{nit} = \mathbf{x}'_{nit}\theta$, el gradiente adopta una forma particularmente sencilla:

$$\frac{\partial LL}{\partial \theta} = \sum_n \sum_t \sum_i \left(y_{nit} - \frac{e^{\mathbf{x}'_{nit}\theta}}{\sum_j e^{\mathbf{x}'_{njt}\theta}} \right) \mathbf{x}_{nit} \quad (3.11)$$

Del mismo modo, se pueden calcular segundas derivadas que resultan útiles para el cálculo de errores estándares de los parámetros.

Ejercicio guiado. Supóngase que se está interesado en estudiar el efecto del ingreso de los hogares en la elasticidad precio en las compras de una categoría. Explique por qué resulta informativo analizar el coeficiente δ que acompaña a Precio $\times$ Ingreso en la función de utilidad.

Ver solución

El efecto del ingreso en la elasticidad precio depende directamente del

parámetro γ_1 de la siguiente ecuación:

$$\gamma_{\text{precio}} = \gamma_0 + \gamma_1 \text{ Ingreso}$$

Al reemplazar en la función de utilidad se obtiene:

$$u_{nit} = \beta_0 + \gamma_0 \text{ Precio} + \gamma_1 \text{ Ingreso} \times \text{Precio}$$

El coeficiente γ_1 (o δ en la notación del enunciado) captura directamente cómo varía la sensibilidad al precio con el nivel de ingreso. Si $\gamma_1 > 0$, los hogares de mayores ingresos son menos sensibles al precio (la penalización total por precio se reduce); si $\gamma_1 < 0$, la sensibilidad aumenta con el ingreso.

Ejercicio guiado. ¿Cómo se calcula el Akaike Information Criterion (AIC) para un modelo cuya verosimilitud $f(\mathbf{X}|\theta)$ es maximizada en un único valor $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2)$?

Ver solución

Se aplica la definición directamente. Como $\hat{\theta}$ tiene $k = 2$ componentes:

$$AIC = -2 \ln(f(\mathbf{X}|\hat{\theta})) + 2k = -2 \ln(f(\mathbf{X}|\hat{\theta})) + 4$$

3.3 Modelos de panel: persistencia y precios de referencia

Hasta ahora se han discutido modelos de elección discreta asumiendo implícitamente que cada observación de elección es independiente de las demás. Sin embargo, cuando se dispone de datos de panel (observaciones repetidas del mismo individuo a lo largo del tiempo), es razonable esperar que las elecciones de un individuo en diferentes períodos estén relacionadas. En contextos de marketing, esta dependencia temporal puede manifestarse de diversas formas, siendo dos de las más relevantes la *persistencia de elección* (o lealtad) y la formación de *precios de referencia* (Guadagni & Little, 1983).

3.3.1 Persistencia de elección (lealtad)

Uno de los fenómenos más documentados en el comportamiento de compra es la tendencia de los consumidores a repetir sus elecciones previas, lo que comúnmente se denomina lealtad de marca o inercia en el comportamiento. Esta persistencia puede originarse en múltiples factores:

- *Costos de cambio:* Tanto físicos (esfuerzo de probar algo nuevo) como psicológicos (aversión al riesgo)
- *Aprendizaje:* Experiencias positivas pasadas reducen la incertidumbre sobre el producto

- *Satisfacción acumulada*: La utilidad experimentada en compras previas afecta la percepción actual
- *Hábito*: Rutinas de compra que simplifican el proceso de decisión

Para capturar esta persistencia en un modelo logit, se introduce una variable de *lealtad latente* z_{nit} que representa la propensión no observable del individuo n a elegir la alternativa i en el período t , basada en su historia de elecciones previas.

Modelamiento de la Persistencia:

La utilidad del individuo n por la alternativa i en el período t se especifica como:

$$u_{nit} = \alpha_i + \beta x_{it} + \gamma z_{nit} + \varepsilon_{nit} \quad (3.12)$$

donde:

- α_i es la constante alternativa-específica
- x_{it} son las covariables observables (precio, promoción, etc.)
- β es el vector de coeficientes asociados a las variables observables
- z_{nit} es la *lealtad latente* (no observable)
- γ mide el efecto de la persistencia en la elección
- ε_{nit} es el término de error i.i.d. valor extremo tipo I

Construcción de la Variable de Lealtad:

La variable de lealtad z_{nit} se construye como un promedio ponderado exponencialmente de las elecciones pasadas del individuo. Sea y_{nit} una variable indicadora que toma valor 1 si el individuo n eligió la alternativa i en el período t y 0 en caso contrario. Entonces:

$$z_{nit} = \lambda z_{nit-1} + (1 - \lambda)y_{nit-1} \quad (3.13)$$

donde $0 \leq \lambda \leq 1$ es un *parámetro de decaimiento* que determina qué tan rápido se desvanece el efecto de las elecciones pasadas. Con $\lambda = 0$ solo importa la elección inmediatamente anterior ($z_{nit} = y_{nit-1}$) y con $\lambda = 1$, todas las elecciones pasadas tienen el mismo peso (memoria perfecta).

Expandiendo recursivamente la ecuación (3.13):

$$\begin{aligned}
z_{nit} &= \lambda z_{nit-1} + (1 - \lambda)y_{nit-1} \\
&= \lambda[\lambda z_{nit-2} + (1 - \lambda)y_{nit-2}] + (1 - \lambda)y_{nit-1} \\
&= \lambda^2 z_{nit-2} + \lambda(1 - \lambda)y_{nit-2} + (1 - \lambda)y_{nit-1} \\
&= \lambda^2[\lambda z_{nit-3} + (1 - \lambda)y_{nit-3}] + \lambda(1 - \lambda)y_{nit-2} + (1 - \lambda)y_{nit-1} \\
&= \lambda^3 z_{nit-3} + \lambda^2(1 - \lambda)y_{nit-3} + \lambda(1 - \lambda)y_{nit-2} + (1 - \lambda)y_{nit-1} \\
&= \vdots \\
&= (1 - \lambda)y_{nit-1} + \lambda(1 - \lambda)y_{nit-2} + \lambda^2(1 - \lambda)y_{nit-3} + \dots + \lambda^{t-2}(1 - \lambda)y_{ni1} \\
&= (1 - \lambda) \sum_{s=1}^{t-1} \lambda^{t-1-s} y_{nis}
\end{aligned} \tag{3.14}$$

Esta expresión muestra que z_{nit} es un promedio ponderado de todas las elecciones pasadas, donde las elecciones más recientes reciben mayor peso exponencialmente decreciente.

Inicialización:

Para el primer período observado, se requiere una condición inicial. Las opciones comunes son:

- $z_{ni1} = 0$ para todas las alternativas
- $z_{ni1} = 1/J$ donde J es el número de alternativas (distribución uniforme)
- z_{ni1} basado en participación de mercado agregada

Estimación:

El parámetro λ puede ser:

1. *Fijado a priori:* Por ejemplo, $\lambda = 0$ para considerar solo la elección inmediata anterior
2. *Estimado como parte del modelo:* Se incluye λ como parámetro adicional a estimar, buscando en una grilla de valores (0, 0.1, 0.2, ..., 0.9) o mediante búsqueda numérica
3. *Específico por alternativa:* λ_i diferente para cada alternativa, permitiendo que algunas marcas generen más lealtad que otras

Interpretación de γ :

El coeficiente γ mide la magnitud del efecto de la persistencia:

- $\gamma > 0$: Existe persistencia positiva, es decir, los consumidores tienden a repetir elecciones previas
- $\gamma = 0$: No hay efecto de persistencia, por lo que las elecciones son independientes en el tiempo
- $\gamma < 0$: Hay búsqueda de variedad, es decir, los consumidores tienden a cambiar de alternativa

En la mayoría de contextos de marketing, se espera $\gamma > 0$, aunque en categorías donde la variedad es valorada (helados, restaurantes) podría observarse $\gamma < 0$.

Inicialización. Para el primer período se requiere una condición inicial: $z_{ni1} = 0$, $z_{ni1} = 1/J$ (donde J es el número de alternativas) o z_{ni1} basado en participación de mercado agregada.

Ejemplo Numérico:

Supóngase un mercado de yogur con 3 marcas (A, B, C) y un consumidor que en los últimos 5 períodos eligió: A, A, B, A, ? (período actual). Con $\lambda = 0.5$:

Para la marca A:

$$\begin{aligned} z_{A,t} &= (1 - 0.5)[1 \cdot 0.5^0 + 0 \cdot 0.5^1 + 1 \cdot 0.5^2 + 1 \cdot 0.5^3] \\ &= 0.5[1 + 0 + 0.25 + 0.125] = 0.6875 \end{aligned}$$

Para la marca B: $z_{B,t} = 0.5[0 + 1 \cdot 0.5^1 + 0 + 0] = 0.25$

Para la marca C: $z_{C,t} = 0$

Si $\gamma = 2$, entonces la marca A recibe un incremento de utilidad de $2 \times 0.6875 = 1.375$ debido a la lealtad acumulada.

3.3.2 Precios de referencia

Otro aspecto fundamental del comportamiento de compra con datos de panel es la formación de *precios de referencia* (reference prices). Los consumidores no evalúan los precios en términos absolutos, sino que los comparan con un precio de referencia interno formado a partir de precios observados en el pasado. Esta noción está bien fundamentada tanto en teoría económica (teoría de prospectos (Kahneman & Tversky, 1979)) como en evidencia empírica de marketing.

Modelamiento de Precios de Referencia:

La utilidad se especifica incorporando tanto el efecto del precio actual como de la desviación respecto al precio de referencia:

$$u_{nit} = \alpha_i + \beta_1 P_{nit} - \beta_2 (P_{nit} - RP_{nit}) + \delta x_{nit} + \varepsilon_{nit} \quad (3.15)$$

donde:

- P_{nit} es el precio actual de la alternativa i para el individuo n en período t
- RP_{nit} es el *precio de referencia* (no observable) de la alternativa i
- β_1 captura el efecto del precio absoluto
- β_2 captura el efecto de pérdida/ganancia respecto al precio de referencia
- x_{nit} son otras covariables

Interpretación de Coeficientes:

3.3. MODELOS DE PANEL: PERSISTENCIA Y PRECIOS DE REFERENCIA 165

- *Precio absoluto* (β_1): Se espera $\beta_1 < 0$, mayor precio reduce utilidad
- *Desviación de precio de referencia* (β_2): Se espera $\beta_2 > 0$
 - Si $P_{nit} > RP_{nit}$ (precio mayor que referencia): efecto negativo adicional, “pérdida percibida”
 - Si $P_{nit} < RP_{nit}$ (precio menor que referencia): efecto positivo adicional, “ganancia percibida”

La especificación captura que los consumidores son *más sensibles a desviaciones del precio de referencia* que al nivel de precio absoluto, consistente con teoría de prospectos (Kahneman & Tversky, 1979) que postula mayor sensibilidad a pérdidas que a ganancias.

Construcción del Precio de Referencia:

Similar a la lealtad, el precio de referencia se construye como promedio ponderado exponencialmente de precios pasados:

$$RP_{nit} = \lambda RP_{nit-1} + (1 - \lambda)P_{nit-1} \quad (3.16)$$

donde λ es el parámetro de persistencia del precio de referencia.

Especificación asimétrica

La teoría de prospectos (Kahneman & Tversky, 1979) sugiere que las pérdidas (precios mayores que referencia) pesan más que las ganancias (precios menores). Esto motiva especificaciones asimétricas:

$$u_{nit} = \alpha_i + \beta_1 P_{nit} - \beta_2^+ \max(P_{nit} - RP_{nit}, 0) - \beta_2^- \max(RP_{nit} - P_{nit}, 0) + \delta' \mathbf{x}_{nit} + \varepsilon_{nit} \quad (3.17)$$

donde β_2^+ captura el efecto de precios superiores a la referencia (pérdida) y β_2^- el efecto de precios inferiores (ganancia). Típicamente se encuentra $\beta_2^+ > \beta_2^-$, confirmando aversión a pérdidas.

Ejemplo Numérico:

Considérese un producto con la siguiente historia de precios: \$10, \$12, \$9, \$11, ?. Con $\lambda = 0.6$:

$$\begin{aligned} RP_t &= 0.6 \cdot RP_{t-1} + 0.4 \cdot P_{t-1} \\ RP_2 &= 0.4 \cdot 10 = 4.0 \\ RP_3 &= 0.6 \cdot 4.0 + 0.4 \cdot 12 = 7.2 \\ RP_4 &= 0.6 \cdot 7.2 + 0.4 \cdot 9 = 7.92 \\ RP_5 &= 0.6 \cdot 7.92 + 0.4 \cdot 11 = 9.152 \end{aligned}$$

Si en el período 5 el precio es \$13 y se tiene $\beta_1 = -0.5$ y $\beta_2 = 0.8$:

$$u_5 = \alpha + (-0.5)(13) - 0.8(13 - 9.152) + \dots = \alpha - 6.5 - 3.08 + \dots$$

El precio \$13 genera:

- Efecto directo: $-0.5 \times 13 = -6.5$
- Efecto de pérdida percibida: $-0.8 \times 3.848 = -3.08$
- *Efecto total*: -9.58 (más negativo que solo el efecto directo)

3.3.3 Modelo combinado

En la práctica, ambos fenómenos suelen coexistir. Un modelo integrado especificaría:

$$u_{nit} = \alpha_i + \beta_1 P_{nit} - \beta_2 (P_{nit} - RP_{nit}) + \gamma z_{nit} + \delta' \mathbf{x}_{nit} + \varepsilon_{nit} \quad (3.18)$$

donde tanto z_{nit} como RP_{nit} se construyen recursivamente usando los datos históricos del individuo:

$$\begin{aligned} z_{nit} &= \lambda_z z_{nit-1} + (1 - \lambda_z) y_{nit-1} \\ RP_{nit} &= \lambda_p RP_{nit-1} + (1 - \lambda_p) P_{nit-1} \end{aligned}$$

Ejercicio guiado. Describa cómo incluir que los consumidores eligen usando precios de referencia en un modelo logit.

Ver solución

Se define la componente determinística de la utilidad como:

$$v_{nit} = \beta_0 + \beta_1 (P_{nit} - RP_{nit})$$

donde P_{nit} es el precio de la alternativa i al que se enfrenta el cliente n en la ocasión de compra t y RP_{nit} es el precio de referencia, típicamente definido como:

$$RP_{nit} = \lambda RP_{ni,t-1} + (1 - \lambda) P_{ni,t-1}$$

Con esta especificación, la probabilidad de elección se calcula usando la fórmula estándar del modelo logit. Es posible agregar una especificación asimétrica separando las desviaciones positivas (pérdidas) y negativas (ganancias) con coeficientes distintos.

3.4 Modelo probit

3.4.1 Definición

Al introducir modelos de elección discreta, se postuló que los tomadores de decisiones disponían de una función de utilidad subyacente que se descomponía en una componente determinística y otra aleatoria. Más aún, se discutió que el modelo que describe la probabilidad de elegir cada una de las alternativas quedaba directamente determinado por la distribución que se asumiera para la componente aleatoria de la utilidad. Aunque una especificación de errores normales centrados en cero tiene una larga tradición en modelos econométricos, por simplicidad se optó por iniciar la discusión con modelos *logit* derivados de asumir que la componente aleatoria de la utilidad se distribuía valor extremo tipo I. En este capítulo se volverá al caso de componentes aleatorias normales que dan origen al modelo probit. Formalmente, un modelo *probit* resulta de los siguientes supuestos de comportamiento (Ben-Akiva & Lerman, 1985):

$$u_{ni} = v_{ni} + \varepsilon_{ni}, \quad \varepsilon_n \sim N(\mathbf{0}, \Sigma) \quad (3.19)$$

La normalidad de los errores provee bastante flexibilidad para acomodar una amplia variedad de estructuras de las preferencias. Como se verá en la discusión que sigue, un modelo con errores normales permite acomodar factores sistemáticos no observables en la utilidad. Una de las pocas limitaciones de un modelo probit viene de la normalidad de dichos factores. Por ejemplo, si se quiere incorporar el efecto que tiene el precio en la utilidad como una componente aleatoria, entonces las colas de la distribución normal implicarán una probabilidad positiva de que algunos clientes aumenten la utilidad de una alternativa si aumenta el precio de esta. Formalmente, el supuesto de la normalidad de la componente aleatoria de la utilidad implica que su función de densidad viene dada por:

$$\phi(\varepsilon_n) = \frac{1}{(2\pi)^{I/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} \varepsilon_n' \Sigma^{-1} \varepsilon_n\right) \quad (3.20)$$

Esta expresión no es más que la versión multivariada de la bien conocida densidad de la distribución $N(0, \sigma^2)$. La matriz Σ corresponde a la matriz varianza-covarianza de los errores. Por tratarse de una distribución normal, la matriz Σ es simétrica y de dimensión $I \times I$, donde I es el número de alternativas disponibles para el tomador de decisión. Por ejemplo, si hay tres alternativas disponibles, la matriz Σ tomaría la siguiente forma:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \cdot & \sigma_{22} & \sigma_{23} \\ \cdot & \cdot & \sigma_{33} \end{bmatrix} \quad (3.21)$$

Los coeficientes en la diagonal dan cuenta de la variabilidad de la componente aleatoria de la utilidad. Así, por ejemplo, si σ_{ii} tiene un valor alto indica que hay una fracción importante de la utilidad de la alternativa i que no es capturada por el modelo de la componente sistemática. Los coeficientes fuera de la diagonal dan cuenta de la correlación de las componentes no observables de cada una de las alternativas. De este modo, si σ_{ij} tiene un valor positivo alto indica que existe un elemento no observable importante que afecta simultáneamente las alternativas i y j .

Como se vio en el desarrollo del modelo *logit*, una componente fundamental para estimar un modelo de elección discreta es la derivación de una expresión para la probabilidad de que cada agente elija cada alternativa en cada ocasión. Para el modelo probit, la probabilidad de que el individuo n elija la alternativa i viene dada por:

$$\begin{aligned} P_{ni} &= Pr(v_{ni} + \varepsilon_{ni} > v_{nj} + \varepsilon_{nj}), \forall j \neq i \\ &= \int \mathbb{1}_{[v_{ni} + \varepsilon_{ni} > v_{nj} + \varepsilon_{nj}]} \phi(\varepsilon_n) d\varepsilon_n, \forall j \neq i \end{aligned} \quad (3.22)$$

Intuitivamente, simplemente se calcula el volumen bajo la densidad $\phi(\varepsilon_n)$ en la región en que los errores son tales que la alternativa i es aquella que reporta mayor utilidad al individuo n .

3.4.2 Estimación por simulación (SMLE)

A diferencia del logit, la integral que define la probabilidad de elección en el probit no tiene primitiva analítica. La probabilidad de que el individuo n elija la alternativa i es:

$$P_{ni} = \int \mathbb{1}_{[v_{ni} + \varepsilon_{ni} > v_{nj} + \varepsilon_{nj}, \forall j \neq i]} \phi(\varepsilon_n) d\varepsilon_n \quad (3.23)$$

Se aproxima mediante simulación Monte Carlo. Para cada individuo n se generan R vectores de errores $\{\varepsilon_n^{(r)}\}_{r=1}^R$ desde $N(\mathbf{0}, \Sigma)$ y se calcula:

$$\hat{P}_{ni}(\theta) = \frac{1}{R} \sum_{r=1}^R \mathbb{1}_{[v_{ni} + \varepsilon_{ni}^{(r)} > v_{nj} + \varepsilon_{nj}^{(r)}, \forall j \neq i]} \quad (3.24)$$

La log-verosimilitud simulada se construye como $\sum_n \sum_i y_{ni} \ln \hat{P}_{ni}$ y se maximiza numéricamente. A medida que $R \rightarrow \infty$, el estimador SMLE converge al MLE verdadero.

3.4.3 Patrones de sustitución

Una de las grandes ventajas de un modelo *probit* es su flexibilidad para capturar una amplia variedad de patrones de comportamiento. En efecto, un modelo *probit* no impone restricciones en los patrones de sustitución más allá de la simetría propia de la distribución normal, lo que posibilita al analista explorar el esquema que mejor se ajusta a los datos. En este sentido, es útil compararlo con el modelo *logit* que, aunque provee una fórmula analítica cerrada para la probabilidad de cada elección, impone la propiedad de sustitución proporcional (o de independencia de alternativas irrelevantes). El modelo probit no tiene esta propiedad y, por tanto, el aumento de la probabilidad de elección de una alternativa puede tener impactos diferentes en las probabilidades de elección de las alternativas remanentes. Esto permitiría, por ejemplo, identificar pares de alternativas que son mejores sustitutos (complementos) más allá de las comunales que podrían existir en las componentes determinísticas de su utilidad.

A continuación se discutirá cómo el modelo probit puede ser usado para representar algunas situaciones de elección discreta.

3.4.4 Variación aleatoria en preferencias

Una de las componentes más importantes en el diseño de un plan comercial exitoso es la identificación de cómo las preferencias de los potenciales clientes se distribuyen en la población. Identificando estas variaciones, se pueden encontrar las propuestas de valor que resulten más atractivas para cada grupo de clientes. En un modelo probit, se puede asumir que los parámetros que definen la componente determinística son heterogéneos en la población sin perder los supuestos básicos que definen el modelo. Por simplicidad, supóngase que la componente determinística de la utilidad es lineal:

$$u_{ni} = \mathbf{b}'\mathbf{x}_{ni} + \eta_{ni}, \quad \eta_n \sim N(\mathbf{0}, \hat{\Sigma}) \quad (3.25)$$

Las componentes de la matriz de varianza-covarianza resultante $\hat{\Sigma}$ pueden trazarse directamente a las componentes de la matriz Σ original como lo indica el siguiente ejemplo:

Ejemplo: Considérese un modelo de elección con dos alternativas y un modelo lineal con una única variable para describir la componente sistemática de la utilidad. En este caso, las utilidades por cada alternativa vienen dadas por:

$$\begin{aligned} u_{n1} &= \beta_n x_{n1} + \varepsilon_{n1} \\ u_{n2} &= \beta_n x_{n2} + \varepsilon_{n2} \end{aligned}$$

donde ε_{n1} y ε_{n2} son términos independientes e idénticamente distribuidos con varianza σ_ε . Si se asume que el parámetro β_n se distribuye normal con media b y varianza σ_β , entonces se puede reescribir las utilidades como:

$$\begin{aligned}u_{n1} &= bx_{n1} + \eta_{n1} \\ u_{n2} &= bx_{n2} + \eta_{n2}\end{aligned}$$

donde η_{n1} y η_{n2} están normalmente distribuidas. Cada una tiene esperanza cero: $\mathbb{E}(\eta_{ni}) = \mathbb{E}(\beta_n x_{ni} + \varepsilon_{ni}) = 0$, varianza igual a $\mathbb{V}ar(\eta_{ni}) = \mathbb{V}ar(\beta_n x_{ni} + \varepsilon_{ni}) = x_{ni}^2 \sigma_\beta + \sigma_\varepsilon$ y covarianzas $\mathbb{C}ov(\eta_{n1}, \eta_{n2}) = x_{n1} x_{n2} \sigma_\beta$. Así, la matriz de covarianza viene dada por:

$$\begin{aligned}\Sigma &= \begin{bmatrix} x_{n1}^2 \sigma_\beta + \sigma_\varepsilon & x_{n1} x_{n2} \sigma_\beta \\ x_{n1} x_{n2} \sigma_\beta & x_{n2}^2 \sigma_\beta + \sigma_\varepsilon \end{bmatrix} \\ &= \sigma_\beta \begin{bmatrix} x_{n1}^2 & x_{n1} x_{n2} \\ x_{n1} x_{n2} & x_{n2}^2 \end{bmatrix} + \sigma_\varepsilon \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\end{aligned}$$

El siguiente paso es estimar. Recordando que el comportamiento no es afectado por transformaciones multiplicativas de la utilidad, es necesario escalar esta matriz. Lo recomendable es fijar $\sigma_\varepsilon = 1$, obteniendo así:

$$\Sigma = \sigma_\beta \begin{bmatrix} x_{n1}^2 & x_{n1} x_{n2} \\ x_{n1} x_{n2} & x_{n2}^2 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

3.4.5 Dependencia temporal

Se ha discutido que bajo un modelo *probit* se pueden estudiar relaciones no observables entre las alternativas de elección. En las bases disponibles para la función comercial, las observaciones suelen estar indexadas temporalmente generando estructuras de panel que permiten estudiar aspectos interesantes de los agentes. A continuación se discute cómo usar un modelo *probit* para explorar no solo la relación entre las utilidades de alternativas, sino que también, el comportamiento de las utilidades de las alternativas en el tiempo.

Al igual que en la sección anterior, se busca encontrar patrones temporales en las componentes no observables de la utilidad, ya que las variaciones en la componente observable pueden ser fácilmente estudiadas incluyendo variables observables que describan la evolución temporal del sistema. Por ejemplo, si se cree que la utilidad de una de las alternativas es creciente en el tiempo, basta incluir el tiempo t entre las variables independientes en la descripción de la utilidad de la alternativa. En general, se debería esperar que las utilidades estén correlacionadas tanto en el tiempo como entre las alternativas, ya que los factores que no son observados por el analista suelen ser persistentes en el tiempo. Eventualmente un modelo *probit* también podría ayudar a identificar shocks en que hay variaciones instantáneas (o de unos pocos períodos) en las utilidades de varias de las alternativas.

Supóngase que se observa un panel de N clientes que deciden respecto de I alternativas en T períodos y que la utilidad del producto que el agente n deriva sobre la alternativa i en el período t viene dada por:

$$u_{ni} = v_{nit} + \varepsilon_{nit}, \quad [\varepsilon_{n11}, \dots, \varepsilon_{nI1}, \varepsilon_{n12}, \dots, \varepsilon_{nI2}, \dots, \varepsilon_{n1T}, \dots, \varepsilon_{nIT}] \sim N(0, \Sigma) \quad (3.26)$$

La matriz de covarianza Σ tiene dimensión $IT \times IT$ (como se verá, no todas las componentes son identificables y se deberá imponer ciertas restricciones). Para paneles típicos, T es grande y genera matrices de varianza-covarianza muy grandes. Por ejemplo, si se tienen datos semanales de compras de 5 marcas por un período de 2 años, se enfrentará una matriz de varianza (sin normalizar) con $5 \times 104 = 520$ filas y 520 columnas, lo que generaría no solo un modelo difícil de estimar numéricamente sino que, también, difícil de interpretar. Así, para usar un modelo *probit* con dependencia en el tiempo, típicamente se agregará estructura al modelo. Por ejemplo, se puede restringir el análisis a grupos de períodos que podría ser el caso de las decisiones antes y después de una intervención en el sistema (e.g., antes y después del lanzamiento de una campaña publicitaria).

Ejemplo: Supóngase un caso de elección binaria. El error está compuesto por una componente sistemática específica del tomador de decisión y otra que es variable en el tiempo.

$$\varepsilon_{nt} = \eta_n + \mu_{nt} \quad (3.27)$$

Si se asume que η_n está distribuida $N(0, \sigma)$ y μ_{nt} en $N(0, 1)$, entonces la varianza y covarianza son

$$\mathbb{V}ar(\varepsilon_{nt}) = \mathbb{V}ar(\eta_n + \mu_{nt}) = \sigma + 1 \quad (3.28)$$

$$\mathbb{C}ov(\varepsilon_{nt}, \varepsilon_{ns}) = \mathbb{E}((\eta_n + \mu_{nt})(\eta_n + \mu_{ns})) = \sigma \quad (3.29)$$

La matriz Σ , por lo tanto, es

$$\Sigma = \begin{bmatrix} \sigma + 1 & \sigma & \dots & \sigma \\ \sigma & \sigma + 1 & \dots & \sigma \\ \vdots & \vdots & \ddots & \vdots \\ \sigma & \sigma & \dots & \sigma + 1 \end{bmatrix} \quad (3.30)$$

3.4.6 Identificación

Para estimar un modelo *probit*, junto con los parámetros de la componente sistemática de la utilidad, se necesita estimar los coeficientes de la matriz Σ . Por tratarse de una distribución normal, la matriz Σ es simétrica, ya que sus varianzas generadas son conmutativas. Por tanto, se deben estimar $\frac{I(I+1)}{2}$ de sus componentes. Sin embargo, dicho problema no es identificable y se necesita imponer restricciones adicionales eliminando un componente. La intuición detrás de esta falta de identificación resulta de asumir que las utilidades subyacentes que maximizan los individuos son monótonas y homotéticas. En otras palabras, se puede agregar un valor constante a las utilidades de cada una de las alternativas o escalarlas en cualquier proporción y la identidad de la alternativa de mayor utilidad no cambia. En general, si se tienen I alternativas, solo se pueden identificar $\frac{I(I+1)}{2} - 1$ parámetros. A continuación se discutirán dos enfoques para generar restricciones que hagan el problema identificable.

Normalización de las funciones de utilidad

Motivados en las propiedades de la función de utilidad, este enfoque consiste en imponer directamente restricciones de escala y locación. Este enfoque es completamente general y permite además garantizar identificación con un procedimiento estándar que puede incluso automatizarse. Formalmente el proceso consiste en imponer dos restricciones:

1. FIJAR LOCACIÓN: Como el valor absoluto de las utilidades es irrelevante, se puede fijar arbitrariamente el punto de referencia sobre el cual se interpretarán las utilidades. De esta forma, se tomará la utilidad de una de las alternativas como referencia y se redefinirán las utilidades como las diferencias con respecto a la alternativa de referencia.
2. FIJAR ESCALA: Como la escala de las utilidades es irrelevante, se puede fijarla asignando un valor arbitrario a cualquiera de las componentes de la matriz de varianza covarianza. Típicamente se impondrá que la primera componente de la diagonal tome el valor 1.

Ejemplo: Considérese la normalización de una matriz Σ resultante de un problema de elección discreto de 4 alternativas.

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} & \sigma_{14} \\ \cdot & \sigma_{22} & \sigma_{23} & \sigma_{24} \\ \cdot & \cdot & \sigma_{33} & \sigma_{34} \\ \cdot & \cdot & \cdot & \sigma_{44} \end{bmatrix} \quad (3.31)$$

El primer paso en la normalización es considerar diferencias de utilidades con respecto a una alternativa de referencia, la que por simplicidad se escogerá como la primera de la lista. Al fijar esta utilidad y tomar las diferencias, se ha reducido la dimensión del vector de errores, resultando en una matriz de varianza-covarianza $\hat{\Sigma} = \{\hat{\sigma}_{ij}\}_{i,j=1}^3$ cuyas componentes vienen dadas por:

$$\begin{aligned}
\hat{\sigma}_{22} &= \sigma_{22} + \sigma_{11} - 2\sigma_{12} \\
\hat{\sigma}_{33} &= \sigma_{33} + \sigma_{11} - 2\sigma_{13} \\
\hat{\sigma}_{44} &= \sigma_{44} + \sigma_{11} - 2\sigma_{14} \\
\hat{\sigma}_{23} &= \sigma_{23} + \sigma_{11} - \sigma_{12} - \sigma_{13} \\
\hat{\sigma}_{24} &= \sigma_{24} + \sigma_{11} - \sigma_{12} - \sigma_{14} \\
\hat{\sigma}_{34} &= \sigma_{34} + \sigma_{11} - \sigma_{13} - \sigma_{14}
\end{aligned}$$

El segundo paso en la normalización es fijar en 1 (o cualquier otro real positivo) una de las componentes de la diagonal de la matriz de varianza covarianza para precisar la escala de la función de utilidad. Por simplicidad se escoge la primera componente de la diagonal. Para hacerla 1 basta con dividir toda la matriz por dicha componente, resultando en una matriz de varianza-covarianza $\hat{\Sigma} = \{\hat{\sigma}_{ij}\}_{i,j=1}^3$ cuyas componentes vienen dadas por:

$$\begin{aligned}
\hat{\sigma}_{33} &= \frac{\sigma_{33} + \sigma_{11} - 2\sigma_{13}}{\sigma_{22} + \sigma_{11} - 2\sigma_{12}} \\
\hat{\sigma}_{44} &= \frac{\sigma_{44} + \sigma_{11} - 2\sigma_{14}}{\sigma_{22} + \sigma_{11} - 2\sigma_{12}} \\
\hat{\sigma}_{23} &= \frac{\sigma_{23} + \sigma_{11} - \sigma_{12} - \sigma_{13}}{\sigma_{22} + \sigma_{11} - 2\sigma_{12}} \\
\hat{\sigma}_{24} &= \frac{\sigma_{24} + \sigma_{11} - \sigma_{12} - \sigma_{14}}{\sigma_{22} + \sigma_{11} - 2\sigma_{12}} \\
\hat{\sigma}_{34} &= \frac{\sigma_{34} + \sigma_{11} - \sigma_{13} - \sigma_{14}}{\sigma_{22} + \sigma_{11} - 2\sigma_{12}}
\end{aligned}$$

La matriz resultante $\hat{\Sigma}$ es identificable. En ella es importante trazar sus componentes originales de la matriz sigma porque ayudan a darle interpretación a los resultados obtenidos en la estimación.

Restricciones estructurales

Aunque completamente general, la normalización descrita en la sección anterior, muchas veces puede ser algo inconveniente en cuanto los parámetros estimados no tienen interpretación directa. Un enfoque que permite interpretar directamente los parámetros se obtiene al imponer estructura sobre la matriz de varianza-covarianza a partir de supuestos de comportamiento. Por ejemplo, se puede imponer que las componentes aleatorias de algunos pares de alternativas no están correlacionadas o que algún grupo de alternativas tiene la misma variabilidad de la componente no observable. El cuadro 4.1 ejemplifica algunas de las estructuras de varianza-covarianza comúnmente usadas en la literatura.

Otros modelos usados en la literatura y que están implementados en aplicaciones comerciales incluyen estructuras de bandas, Huynh-Feldt, autoregresivo

heterogéneo y simetría compuesta. Como en otros aspectos de la modelación, la elección de la estructura a elegir para la matriz de varianza-covarianza dependerá de las hipótesis de comportamiento que se tengan a la mano y la dificultad numérica de estimar el modelo resultante.

3.5 Nested logit

3.5.1 Motivación

Como se ha discutido previamente, una de las limitaciones fundamentales del modelo logit estándar es la propiedad de independencia de alternativas irrelevantes (IIA), que implica patrones de sustitución proporcionales entre todas las alternativas. Esta restricción puede resultar poco realista en muchas situaciones prácticas de marketing donde algunas alternativas son sustitutos más cercanos entre sí que con otras. El modelo *Nested Logit* (o Logit Anidado) surge como una extensión del modelo logit estándar que permite relajar parcialmente la restricción de IIA al permitir que las alternativas se agrupen en conjuntos (o “nidos”) donde la correlación entre alternativas dentro del mismo nido puede diferir de la correlación entre alternativas de nidos diferentes (Train, 2009).

La idea fundamental del nested logit es reconocer que en muchos problemas de elección existe una estructura jerárquica natural. Los tomadores de decisión primero eligen entre categorías generales de alternativas (los nidos) y luego, dentro de la categoría seleccionada, eligen una alternativa específica. Esta estructura refleja de manera más realista muchos procesos de decisión en marketing.

Por ejemplo, se tiene el problema de elección de medio de transporte en una ciudad que ofrece las siguientes alternativas: auto particular, auto compartido (carpool), bus y tren. Intuitivamente, se esperaría que auto particular y auto compartido sean sustitutos más cercanos entre sí (ambos involucran viajar en auto) que cualquiera de ellos con respecto al bus o tren. Del mismo modo, bus y tren (ambos transporte público) serían sustitutos más cercanos entre sí. Un modelo logit estándar impondría que un incremento en el costo del bus afecta igualmente la probabilidad de elegir auto particular, auto compartido y tren, lo cual parece poco razonable. El nested logit permite capturar que el incremento en el costo del bus afectará más la probabilidad de elegir tren (mismo nido de transporte público) que la de elegir auto particular.

3.5.2 Estructura del modelo

El modelo nested logit requiere una partición del conjunto de J alternativas en K subconjuntos exhaustivos y mutuamente excluyentes llamados *nidos*. Sea B_k el conjunto de alternativas en el nido k , donde $k = 1, 2, \dots, K$. La partición debe satisfacer:

1. $\bigcup_{k=1}^K B_k = \{1, 2, \dots, J\}$ (exhaustividad)
2. $B_k \cap B_m = \emptyset$ para $k \neq m$ (exclusividad mutua)

Es importante destacar que la definición de los nidos debe basarse en consideraciones teóricas sobre qué alternativas son sustitutos más cercanos, no en criterios puramente estadísticos. La teoría económica, el conocimiento del mercado y la intuición sobre el comportamiento del consumidor deben guiar esta partición.

En el modelo nested logit, la utilidad que el individuo n deriva de la alternativa i en el nido B_k se especifica como:

$$u_{ni} = v_{ni} + \varepsilon_{ni} \quad (3.32)$$

donde v_{ni} es la componente sistemática (observable) de la utilidad y ε_{ni} es la componente aleatoria. Si bien es común en la literatura descomponer el error ε_{ni} en dos componentes —una idiosincrática a la alternativa y otra común a todas las alternativas del nido— esta descomposición no es necesaria para derivar el modelo. Como muestra Train (2009), la estructura de correlación del nested logit puede motivarse directamente asumiendo que el vector completo de errores sigue una distribución de valor extremo generalizada (GEV), sin necesidad de imponer una estructura aditiva específica en los términos de error. Esta formulación más general permite capturar la correlación intra-nido a través de los parámetros de la distribución GEV.

La característica distintiva del nested logit es la estructura de correlación de los errores. A diferencia del logit estándar donde todos los ε_{ni} son independientes, en el nested logit se permite que los errores de alternativas dentro del mismo nido estén correlacionados, mientras que los errores entre alternativas de diferentes nidos permanecen independientes.

Formalmente, se asume que el vector de errores ε_n tiene una distribución de valor extremo generalizada (GEV) con función de distribución:

$$F(\varepsilon_{n1}, \dots, \varepsilon_{nJ}) = \exp \left[- \sum_{k=1}^K \left(\sum_{i \in B_k} e^{-\varepsilon_{ni}/\lambda_k} \right)^{\lambda_k} \right] \quad (3.33)$$

donde λ_k es un parámetro que gobierna el grado de correlación entre alternativas en el nido k , con $0 < \lambda_k \leq 1$:

- $\lambda_k = 1$: Las alternativas en el nido k no están correlacionadas (caso del logit estándar)
- $\lambda_k < 1$: Las alternativas en el nido k están positivamente correlacionadas; cuanto menor sea λ_k , mayor es la correlación
- $\lambda_k \rightarrow 0$: Correlación perfecta entre alternativas del nido k

La correlación entre dos alternativas i y j en el mismo nido k viene dada por:

$$\text{Corr}(\varepsilon_{ni}, \varepsilon_{nj}) = 1 - \lambda_k^2, \quad \text{para } i, j \in B_k \quad (3.34)$$

Mientras que alternativas en nidos diferentes tienen correlación cero:

$$\text{Corr}(\varepsilon_{ni}, \varepsilon_{nj}) = 0, \quad \text{para } i \in B_k, j \in B_m, k \neq m \quad (3.35)$$

3.5.3 Probabilidades de elección

Una de las ventajas computacionales del modelo nested logit es que, a pesar de permitir correlación entre errores, aún se pueden derivar fórmulas cerradas para las probabilidades de elección.

Estructura jerárquica de decisión

El nested logit puede interpretarse como un proceso de decisión secuencial en dos etapas:

1. *Etapas 1 (elección de nido)*: El individuo elige qué nido B_k le proporciona mayor utilidad esperada
2. *Etapas 2 (elección dentro del nido)*: Dado el nido seleccionado, el individuo elige la alternativa específica dentro de ese nido

Probabilidad condicional (Etapas 2)

La probabilidad de que el individuo n elija la alternativa i dado que ha elegido el nido B_k viene dada por:

$$P_{ni|B_k} = \frac{\exp(v_{ni}/\lambda_k)}{\sum_{j \in B_k} \exp(v_{nj}/\lambda_k)} \quad (3.36)$$

Esta expresión tiene la forma de un modelo logit estándar, escalando las utilidades con λ_k .

Valor inclusivo (Inclusive Value)

Un concepto fundamental en el nested logit es el *valor inclusivo* (o *log-suma*) del nido B_k , definido como:

$$IV_k = \ln \left(\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right) \quad (3.37)$$

El valor inclusivo IV_k representa la utilidad esperada (antes de conocer los shocks aleatorios ε_{nj}) que el individuo obtiene del nido k . Es una medida del atractivo agregado de todas las alternativas en el nido, ajustada por el grado de correlación entre ellas.

Interpretación Económica: El valor inclusivo captura el “valor de la opción” que proporciona tener múltiples alternativas similares disponibles. Un valor inclusivo alto indica que el nido contiene alternativas atractivas para el individuo.

Probabilidad marginal de elegir el nido (Etapas 1)

La probabilidad de elegir el nido B_k viene dada por:

$$P_{nB_k} = \frac{\exp(\lambda_k \cdot IV_k)}{\sum_{m=1}^K \exp(\lambda_m \cdot IV_m)} \quad (3.38)$$

El valor m corresponde al índice que suma las utilidades de todas las opciones del nido k . Esta probabilidad tiene también forma logit, donde la “utilidad” del nido es el valor inclusivo escalado por λ_k .

Probabilidad no condicional (Probabilidad total)

Finalmente, la probabilidad de que el individuo n elija la alternativa i en el nido B_k se obtiene multiplicando las probabilidades de las dos etapas:

$$P_{ni} = P_{ni|B_k} \cdot P_{nB_k} = \frac{\exp(v_{ni}/\lambda_k)}{\sum_{j \in B_k} \exp(v_{nj}/\lambda_k)} \cdot \frac{\exp(\lambda_k \cdot IV_k)}{\sum_{m=1}^K \exp(\lambda_m \cdot IV_m)} \quad (3.39)$$

Para reescribir esta expresión de forma más compacta, se procede de la siguiente manera. Recordando que $IV_k = \ln \left[\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right]$, se tiene que:

$$\exp(\lambda_k \cdot IV_k) = \exp \left(\lambda_k \cdot \ln \left[\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right] \right) = \left[\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right]^{\lambda_k}$$

Sustituyendo esta expresión en el numerador de la probabilidad total:

$$\begin{aligned} P_{ni} &= \frac{\exp(v_{ni}/\lambda_k)}{\sum_{j \in B_k} \exp(v_{nj}/\lambda_k)} \cdot \frac{\left[\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right]^{\lambda_k}}{\sum_{m=1}^K \left[\sum_{j \in B_m} \exp(v_{nj}/\lambda_m) \right]^{\lambda_m}} \\ &= \frac{\exp(v_{ni}/\lambda_k) \cdot \left[\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right]^{\lambda_k}}{\left[\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right] \cdot \sum_{m=1}^K \left[\sum_{j \in B_m} \exp(v_{nj}/\lambda_m) \right]^{\lambda_m}} \\ &= \frac{\exp(v_{ni}/\lambda_k) \cdot \left[\sum_{j \in B_k} \exp(v_{nj}/\lambda_k) \right]^{\lambda_k - 1}}{\sum_{m=1}^K \left[\sum_{j \in B_m} \exp(v_{nj}/\lambda_m) \right]^{\lambda_m}} \end{aligned}$$

Esto conduce a la forma compacta:

$$P_{ni} = \frac{\exp(v_{ni}/\lambda_k) \cdot [\sum_{j \in B_k} \exp(v_{nj}/\lambda_k)]^{\lambda_k - 1}}{\sum_{m=1}^K [\sum_{j \in B_m} \exp(v_{nj}/\lambda_m)]^{\lambda_m}} \quad (3.40)$$

3.5.4 Relajación parcial de IIA

Una propiedad importante del nested logit es que la restricción de IIA se mantiene *dentro de cada nido* pero no *entre nidos*. Específicamente:

Dentro del mismo nido: Para dos alternativas i y j en el mismo nido B_k :

$$\frac{P_{ni}}{P_{nj}} = \frac{\exp(v_{ni}/\lambda_k)}{\exp(v_{nj}/\lambda_k)} = \exp\left(\frac{v_{ni} - v_{nj}}{\lambda_k}\right) \quad (3.41)$$

Este ratio es independiente de otras alternativas, manteniendo IIA dentro del nido.

Entre diferentes nidos: Para alternativas en nidos diferentes, el ratio de probabilidades sí depende de las características de otras alternativas a través de los valores inclusivos, permitiendo patrones de sustitución más realistas.

3.5.5 Elasticidades

Las elasticidades propias y cruzadas en un modelo nested logit revelan cómo los patrones de sustitución difieren entre alternativas del mismo nido versus alternativas de nidos diferentes.

Elasticidad propia: La elasticidad de P_{ni} respecto a un atributo x_{ni} de la misma alternativa es:

$$\eta_{ii} = \frac{\partial P_{ni}}{\partial x_{ni}} \cdot \frac{x_{ni}}{P_{ni}} = \frac{\beta}{\lambda_k} x_{ni} (1 - P_{ni} - \lambda_k P_{ni|B_k} (1 - P_{ni|B_k})) \quad (3.42)$$

donde β es el coeficiente asociado a x_{ni} en v_{ni} .

Elasticidad cruzada dentro del nido: Para alternativas i y j en el mismo nido B_k :

$$\eta_{ij} = \frac{\partial P_{ni}}{\partial x_{nj}} \cdot \frac{x_{nj}}{P_{ni}} = \frac{\beta}{\lambda_k} x_{nj} P_{nj|B_k} (1 + \lambda_k (1 - P_{nj|B_k})) \quad (3.43)$$

Elasticidad cruzada entre nidos: Para alternativas $i \in B_k$ y $j \in B_m$ con $k \neq m$:

$$\eta_{ij} = -\beta x_{nj} P_{nj} \quad (3.44)$$

Nótese que η_{ij} (dentro del nido) depende de λ_k y es típicamente mayor en magnitud que la elasticidad cruzada entre nidos, reflejando que alternativas dentro del mismo nido son mejores sustitutos.

3.5.6 Estimación

La estimación del modelo nested logit se realiza mediante *máxima verosimilitud*. Dada una muestra de N individuos donde cada individuo n elige una alternativa i_n de su conjunto de elección, la función de log-verosimilitud viene dada por:

$$LL(\theta, \lambda) = \sum_{n=1}^N \ln P_{ni_n}(\theta, \lambda) \quad (3.45)$$

donde θ representa todos los parámetros de las utilidades sistemáticas y $\lambda = (\lambda_1, \dots, \lambda_K)$ son los parámetros de disimilitud de cada nido.

Procedimiento de Estimación:

1. Especificar la partición en nidos $\{B_1, \dots, B_K\}$
2. Especificar las funciones de utilidad v_{ni} para cada alternativa
3. Calcular valores inclusivos IV_k para cada nido
4. Calcular probabilidades P_{ni} usando la ecuación (3.39)
5. Maximizar la log-verosimilitud (3.45) con restricciones $0 < \lambda_k \leq 1$

Test de Especificación:

Un test natural es evaluar si $\lambda_k = 1$ para todos los nidos, lo que equivaldría al modelo logit estándar. Se puede usar un *test de razón de verosimilitud* comparando:

- Modelo restringido: Logit estándar (todos los $\lambda_k = 1$)
- Modelo no restringido: Nested logit con λ_k estimados

El estadístico $LR = 2(LL_{nested} - LL_{logit})$ se distribuye asintóticamente como χ^2 con K grados de libertad bajo la hipótesis nula de que el logit estándar es adecuado.

3.5.7 Ejemplo: elección de vivienda

En una situación de elección de tipo de vivienda en una ciudad hay cuatro alternativas: departamento pequeño (DP), departamento grande (DG), casa pequeña (CP) y casa grande (CG).

Estructura de Nidos: Se propone una estructura con dos nidos:

- Nido 1 (Departamentos): $B_1 = \{DP, DG\}$
- Nido 2 (Casas): $B_2 = \{CP, CG\}$

Especificación de Utilidad:

$$\begin{aligned} v_{n,DP} &= \alpha_{DP} + \beta_1 \cdot \text{precio}_{DP} + \beta_2 \cdot \text{distancia}_{DP} \\ v_{n,DG} &= \alpha_{DG} + \beta_1 \cdot \text{precio}_{DG} + \beta_2 \cdot \text{distancia}_{DG} \\ v_{n,CP} &= \alpha_{CP} + \beta_1 \cdot \text{precio}_{CP} + \beta_2 \cdot \text{distancia}_{CP} \\ v_{n,CG} &= \alpha_{CG} + \beta_1 \cdot \text{precio}_{CG} + \beta_2 \cdot \text{distancia}_{CG} \end{aligned}$$

donde α_i son constantes alternativa-específicas, $\beta_1 < 0$ captura el efecto del precio y $\beta_2 < 0$ el efecto de la distancia al centro.

Resultados Hipotéticos:

Supóngase que la estimación arroja $\lambda_1 = 0.6$ y $\lambda_2 = 0.7$. Esto implica:

- *Correlación en Nido 1 (Departamentos):* $1 - (0.6)^2 = 0.64$
- *Correlación en Nido 2 (Casas):* $1 - (0.7)^2 = 0.51$

Los departamentos presentan mayor correlación en sus componentes no observables que las casas, sugiriendo que hay factores no modelados (quizás preferencias por estilo de vida urbano, servicios comunes en edificios, etc.) que afectan similarmente la atractiva de ambos tipos de departamentos.

Implicaciones para Sustitución:

Si el precio del departamento grande aumenta, este incremento afectará más la probabilidad de elegir el departamento pequeño (mismo nido) que la probabilidad de elegir cualquiera de las casas. Formalmente, la elasticidad cruzada $\eta_{DP,DG}$ será mayor en magnitud que $\eta_{DP,CP}$ o $\eta_{DP,CG}$.

3.5.8 Extensión a múltiples niveles

El modelo nested logit puede extenderse a *estructuras jerárquicas de múltiples niveles*, donde los nidos pueden a su vez contener sub-nidos. Por ejemplo, en el contexto de elección de vehículos, se podría tener:

- *Nivel 1:* Tipo de combustión (gasolina vs. eléctrico)
- *Nivel 2:* Tamaño del vehículo (pequeño, mediano, grande)
- *Nivel 3:* Marca específica

En este caso, la decisión se modela como una secuencia de elecciones desde el nivel más alto (combustión) hasta el más específico (marca), con parámetros de disimilitud en cada nivel capturando la correlación entre alternativas dentro de cada sub-nido.

La probabilidad de elección en un nested logit de tres niveles sigue una estructura análoga:

$$P_{ni} = P_{ni|\text{nido}_3} \cdot P_{\text{nido}_3|\text{nido}_2} \cdot P_{\text{nido}_2} \quad (3.46)$$

3.6 Mixed logit

3.6.1 Motivación

Como se ha discutido anteriormente, el modelo logit estándar, aunque computacionalmente conveniente gracias a su forma cerrada, presenta limitaciones importantes que pueden restringir su aplicabilidad en contextos reales de marketing. El modelo *mixed logit* (también conocido como *random parameters logit* o *error components logit*) surgió como una generalización flexible del modelo logit estándar que permite superar las limitaciones de *logit*. La idea fundamental es permitir que los parámetros de la función de utilidad varíen aleatoriamente en la población, capturando así heterogeneidad no observable en las preferencias (Nevo, 2000; Train, 2009).

Intuición del modelo: Supóngase que se está modelando la elección de medio de transporte (auto, bus, tren) y se sabe que la sensibilidad al tiempo de viaje varía sustancialmente entre individuos. Mientras que el logit estándar asumiría un único coeficiente de tiempo de viaje para toda la población, el mixed logit permite que este coeficiente siga una distribución en la población (por ejemplo, normal con cierta media y varianza), reflejando que algunos individuos son muy sensibles al tiempo mientras otros lo son menos.

3.6.2 Especificación

En un modelo mixed logit, la utilidad que el individuo n deriva de la alternativa i en la ocasión de elección t viene dada por:

$$u_{nit} = \beta'_n \mathbf{x}_{nit} + \varepsilon_{nit} \quad (3.47)$$

donde:

- $\mathbf{x}_{nit}$ es un vector de atributos observables de la alternativa i para el individuo n en el período t .
- β_n es un vector de coeficientes *aleatorios* que varía entre individuos.
- ε_{nit} es un término de error i.i.d. valor extremo tipo I (como en el logit estándar).

La característica clave es que β_n no es un parámetro fijo, sino una *variable aleatoria* que sigue una distribución de probabilidad $f(\beta|\theta)$, donde θ son los parámetros que describen esta distribución (típicamente media y varianza-covarianza).

Especificación común: Se suele asumir que $\beta_n \sim N(\mathbf{b}, \Sigma_\beta)$, donde $\mathbf{b}$ es el vector de medias poblacionales y Σ_β es la matriz de varianzas-covarianzas.

Condicionales en β_n , la probabilidad de elección es un logit estándar:

$$L_{nit}(\beta_n) = \frac{\exp(\beta'_n \mathbf{x}_{nit})}{\sum_{j=1}^J \exp(\beta'_n \mathbf{x}_{njt})} \quad (3.48)$$

Sin embargo, como β_n no es observable, la probabilidad *no condicional* de elección se obtiene integrando sobre la distribución de β :

$$P_{nit} = \int \frac{\exp(\beta'_n \mathbf{x}_{nit})}{\sum_j \exp(\beta'_n \mathbf{x}_{njt})} f(\beta|\theta) d\beta \quad (3.49)$$

Esta integral *no tiene solución cerrada* en general, lo que distingue fundamentalmente al mixed logit del logit estándar y requiere métodos de simulación para su estimación.

3.6.3 Estimación por máxima verosimilitud simulada

La idea básica es aproximar la integral usando simulación de Monte Carlo:

1. *Extraer valores aleatorios:* Para cada individuo n , se extraen R valores de β de la distribución especificada $f(\beta|\theta)$: $\beta^{(1)}, \beta^{(2)}, \dots, \beta^{(R)}$.
2. *Calcular logit condicional:* Para cada extracción r , se calcula la probabilidad logit condicional.
3. *Promediar:* La probabilidad simulada es el promedio sobre las R extracciones:

$$\tilde{P}_{nit} = \frac{1}{R} \sum_{r=1}^R L_{nit}(\beta^{(r)}) \quad (3.50)$$

La probabilidad simulada $\tilde{P}_{nit}$ es un *estimador insesgado* de la verdadera probabilidad P_{nit} y por la ley de los grandes números, $\tilde{P}_{nit} \rightarrow P_{nit}$ cuando $R \rightarrow \infty$.

La log-verosimilitud simulada viene dada por:

$$SLL(\theta) = \sum_n \sum_t \sum_i y_{nit} \ln(\tilde{P}_{nit}) \quad (3.51)$$

El estimador de máxima verosimilitud simulada (MSLE) maximiza $SLL(\theta)$:

$$\hat{\theta}_{MSL} = \arg \max_{\theta} SLL(\theta)$$

Este método de aproximación posee propiedades asintóticas. En particular, si R crece más rápido que $\sqrt{N}$, el MSLE es consistente, asintóticamente normal y asintóticamente eficiente. En la práctica, con un valor $R = 200$ suele ser computacionalmente liviano y suficiente (Train, 2009).

3.6.4 Elección de distribución

La elección de $f(\beta|\theta)$ debe basarse tanto en consideraciones teóricas como prácticas. Las distribuciones más comunes son:

1. *Normal*: $\beta_k \sim N(b_k, \sigma_k^2)$. Permite valores positivos y negativos. Apropia-
da cuando no hay restricciones de signo.
2. *Log-normal*: $\ln(\beta_k) \sim N(b_k, \sigma_k^2)$. Garantiza $\beta_k > 0$. Útil para coeficientes
de tiempo o costo.
3. *Normal truncada*. Normal restringida a un rango. Útil cuando la teoría
sugiere un signo pero se desea flexibilidad.
4. *Uniforme*: $\beta_k \sim U[a_k, b_k]$. Útil cuando se conocen límites naturales; menos
común en aplicaciones de marketing.

Es posible especificar correlaciones entre coeficientes aleatorios usando distribu-
ciones multivariadas: $\beta_n \sim N(\mathbf{b}, \Sigma_\beta)$.

Ejercicio guiado. Explique una situación en la que un modelo mixed logit (o de heterogeneidad continua) podría preferirse en comparación a un modelo logit con clases latentes.

Ver solución

El mixed logit resulta preferible cuando la distribución de un parámetro en la población no se describe bien mediante un número reducido de puntos masa. Por ejemplo, si se espera que la distribución de la sensibilidad al precio tenga colas pesadas (una proporción significativa de la población se aleja de la media), se requerirían demasiadas clases latentes para aproximar adecuadamente la heterogeneidad. En tal caso, una distribución continua (por ejemplo, normal o log-normal) permite capturar la forma completa de la distribución con solo dos parámetros (media y varianza).

Ejercicio guiado. Supóngase que la componente determinística de la utilidad de los consumidores que pertenecen al segmento i puede calcularse como $v(\theta_i)$. ¿Cuál es la probabilidad de elección en un modelo logit binario si se asume que en la población solo existen dos clases caracterizadas por los conjuntos de parámetros θ_1 y θ_2 , y además se normaliza la utilidad de no elegir a 0?

Ver solución

Sea π la probabilidad de que un cliente pertenezca al segmento 1. La probabilidad de elección viene dada por:

$$P_{ni} = \pi \frac{\exp(v(\theta_1))}{1 + \exp(v(\theta_1))} + (1 - \pi) \frac{\exp(v(\theta_2))}{1 + \exp(v(\theta_2))}$$

La utilidad de no elegir se ha normalizado a 0, por lo que el denominador del logit binario es $1 + \exp(v(\theta_m))$ para cada clase m .

Ejercicio guiado. Supóngase que se dispone de una muestra de tamaño R de los parámetros que definen la utilidad de elección en un modelo logit. Describa cómo estimar la probabilidad de que un consumidor n elija la alternativa i .

Ver solución

Dicha probabilidad puede estimarse como:

$$\hat{P}_{ni} = \frac{1}{R} \sum_{r=1}^R \frac{\exp(v_i(\theta^{(r)}))}{\sum_k \exp(v_k(\theta^{(r)}))}$$

donde $v_i(\theta)$ es la componente determinística de la utilidad que el tomador de decisión deriva al elegir la alternativa i , evaluada en la r -ésima muestra de parámetros $\theta^{(r)}$.

3.6.5 Propiedades

Aproximación universal

Cualquier modelo de utilidad aleatoria puede ser aproximado arbitrariamente bien por un modelo mixed logit, siempre que se especifique apropiadamente la distribución de los coeficientes aleatorios (McFadden & Train, 2000). Esto significa que el mixed logit puede aproximar patrones de sustitución arbitrarios, incluyendo aquellos del modelo probit multinomial, eliminando las restricciones del IIA cuando sea necesario.

Patrones de sustitución flexibles

A diferencia del logit estándar, el mixed logit permite patrones de sustitución no proporcionales. La elasticidad cruzada entre alternativas depende de:

- Sus características específicas.
- La correlación entre sus utilidades inducida por los coeficientes aleatorios.
- La distribución de preferencias en la población.

Ejemplo: Si dos alternativas comparten muchos atributos que tienen coeficientes aleatorios correlacionados, serán sustitutos más cercanos que alternativas con atributos diferentes.

Correlación temporal

Con datos de panel, β_n es constante para el individuo n a lo largo de sus decisiones, lo que induce correlación temporal de forma natural. La probabilidad condicional de la secuencia completa de elecciones del individuo n es:

$$L_n(\beta_n) = \prod_{t=1}^T \prod_{i=1}^J L_{nit}(\beta_n)^{y_{nit}} \quad (3.52)$$

Si se observa al individuo n en T ocasiones y se define $y_{nit} = 1$ si elige alternativa i en ocasión t y 0 en caso contrario, la probabilidad no condicional es:

$$P_n = \int L_n(\beta) f(\beta|\theta) d\beta \quad (3.53)$$

Esta estructura captura naturalmente que las elecciones del mismo individuo están correlacionadas debido a sus preferencias subyacentes β_n .

3.6.6 Disposición a pagar (WTP)

Un beneficio importante del mixed logit es que permite derivar la distribución de la *disposición a pagar* (DAP) por diferentes atributos.

Si la utilidad es lineal, la DAP por una unidad adicional del atributo es:

$$DAP_n = -\frac{\beta_{n,\text{atributo}}}{\beta_{n,\text{precio}}} \quad (3.54)$$

Como ambos $\beta_{n,\text{atributo}}$ y $\beta_{n,\text{precio}}$ son aleatorios, la DAP también tiene una distribución en la población. El mixed logit permite:

1. Estimar la *distribución de la DAP* en la población.
2. Calcular estadísticos como la DAP media, mediana y percentiles.
3. Identificar segmentos con alta y baja DAP.

Si ambos coeficientes son normales, la DAP sigue una distribución de Cauchy (que puede tener momentos no definidos). Esto ha llevado a usar especificaciones alternativas como log-normal para el coeficiente de precio (Rossi et al., 2005).

3.6.7 Inferencia individual: medias posteriores

Una aplicación valiosa del mixed logit es la posibilidad de hacer *inferencia individual* sobre los parámetros β_n de cada persona, incluso cuando estos no son directamente observables.

Usando el *teorema de Bayes*, se puede calcular la distribución *posterior* de β_n dado el historial de elecciones del individuo n :

$$h(\beta_n | \mathbf{y}_n, \theta) = \frac{L_n(\beta_n) f(\beta_n | \theta)}{\int L_n(\beta) f(\beta | \theta) d\beta} \quad (3.55)$$

La *media condicional* (o posterior) es:

$$\bar{\beta}_n = E[\beta_n | \mathbf{y}_n, \theta] = \int \beta \cdot h(\beta | \mathbf{y}_n, \theta) d\beta \quad (3.56)$$

Esta integral también se aproxima por simulación:

$$\tilde{\beta}_n = \frac{\sum_{r=1}^R \beta^{(r)} L_n(\beta^{(r)})}{\sum_{r=1}^R L_n(\beta^{(r)})} \quad (3.57)$$

Estas medias posteriores tienen aplicaciones directas en personalización (recomendaciones individualizadas), segmentación (agrupación por $\tilde{\beta}_n$ similares) y targeting (identificación de individuos con alta probabilidad de respuesta).

3.6.8 Ejemplo: elección de yogur

Sea el caso de la elección de una marca de yogur (3 marcas: A, B, C) con datos de panel en el tiempo. Las variables que se disponen son:

- precio_{nit} : precio de marca i para individuo n en ocasión t .
- display_{nit} : indicadora de *display* especial.
- marca_i : indicadoras de marca (efectos fijos de marca).

La especificación del modelo corresponde a:

$$\begin{aligned} u_{nit} &= \alpha_i + \beta_{n,\text{precio}} \cdot \text{precio}_{nit} + \beta_{\text{display}} \cdot \text{display}_{nit} + \varepsilon_{nit} \\ \beta_{n,\text{precio}} &\sim N(b_{\text{precio}}, \sigma_{\text{precio}}^2) \end{aligned} \quad (3.58)$$

En un caso hipotético, donde se estima que $b_{\text{precio}} = -2.5$ y $\sigma_{\text{precio}} = 1.0$:

- El consumidor promedio tiene sensibilidad al precio de -2.5 .
- Hay heterogeneidad sustancial: aprox. 68% de consumidores (equivalente a una desviación estándar) tienen sensibilidad entre -3.5 y -1.5 .
- Aproximadamente 1% de consumidores, calculado con la distribución normal acumulada para $b_{\text{precio}} = -2.5$, podrían tener sensibilidad positiva, ya que prefieren productos caros.

El DAP por un *display* se calcula como:

$$DAP_{\text{display}} = -\frac{\beta_{\text{display}}}{\beta_{n,\text{precio}}}$$

Si $\beta_{\text{display}} = 0.5$, la DAP media sería aproximadamente $0.5/2.5 = 0.20$ dólares.

3.6.9 Logit con clases latentes

Una alternativa al mixed logit consiste en asumir que la población está compuesta por un número finito de segmentos, cada uno con parámetros homogéneos. La utilidad del individuo n para la alternativa i en la clase m es $u_{ni|m} = \beta'_m \mathbf{x}_{ni} + \varepsilon_{ni}$, y la probabilidad de elección resulta:

$$P_{ni} = \sum_{m=1}^M s_m \frac{\exp(\beta'_m \mathbf{x}_{ni})}{\sum_j \exp(\beta'_m \mathbf{x}_{nj})} \quad (3.59)$$

donde $s_m \geq 0$ es la proporción de la población en la clase m , con $\sum_m s_m = 1$. Los parámetros $\{\beta_m, s_m\}_{m=1}^M$ se estiman maximizando la log-verosimilitud directamente. Este enfoque es preferible cuando la heterogeneidad se concentra en un número reducido de segmentos bien diferenciados; el mixed logit resulta más adecuado cuando la distribución de preferencias es suave y continua.

3.7 Modelos Tobit

Los modelos Tobit son útiles cuando la variable dependiente observada está restringida por una regla de observación que impide ver el resultado latente en todo su soporte. En marketing esto ocurre, por ejemplo, cuando el gasto observado está truncado en cero, cuando el monto de descuento solo se observa para quienes usan un cupón o cuando el número de millas disponibles solo es relevante para quienes activan un programa de lealtad. La formulación original se debe a Tobin (1958), mientras que la extensión más utilizada para selección muestral corresponde a Heckman (1979); una exposición didáctica y moderna puede encontrarse en Wooldridge (2019) y Greene (2018).

3.7.1 Tobit tipo I

El *Tobit tipo I* parte de una variable latente continua:

$$y_i^* = \mathbf{x}_i' \beta + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2) \quad (3.60)$$

y una regla de observación censurada:

$$y_i = \begin{cases} y_i^* & \text{si } y_i^* > 0, \\ 0 & \text{si } y_i^* \leq 0. \end{cases} \quad (3.61)$$

Este modelo supone que la misma ecuación determina simultáneamente la incidencia y la intensidad del resultado. Por eso es apropiado cuando los ceros se interpretan como *soluciones de esquina*: muchos agentes eligen exactamente cero, pero si participaran marginalmente el mismo mecanismo que genera el monto positivo seguiría siendo válido. Un caso clásico es el gasto en una categoría no esencial durante un período dado.

La contribución a la verosimilitud difiere según si la observación está censurada o no. Si $y_i = 0$, la probabilidad observada es:

$$\Pr(y_i = 0 \mid \mathbf{x}_i) = \Pr(y_i^* \leq 0 \mid \mathbf{x}_i) = \Phi\left(-\frac{\mathbf{x}_i' \beta}{\sigma}\right) \quad (3.62)$$

Si $y_i > 0$, la contribución corresponde a la densidad normal evaluada en el valor observado:

$$f(y_i \mid \mathbf{x}_i, y_i > 0) = \frac{1}{\sigma} \phi\left(\frac{y_i - \mathbf{x}_i' \beta}{\sigma}\right) \quad (3.63)$$

Con esto, la log-verosimilitud muestral se escribe como:

$$\ell(\beta, \sigma) = \sum_{i: y_i = 0} \ln \Phi\left(-\frac{\mathbf{x}_i' \beta}{\sigma}\right) + \sum_{i: y_i > 0} \left[-\ln \sigma + \ln \phi\left(\frac{y_i - \mathbf{x}_i' \beta}{\sigma}\right) \right] \quad (3.64)$$

Una diferencia importante con OLS es que los coeficientes β no son directamente efectos marginales sobre y_i . En cambio, afectan simultáneamente:

- la probabilidad de observar un resultado positivo;
- el valor esperado del resultado latente;
- y el valor esperado del resultado observado.

En particular, el valor esperado observado satisface:

$$E[y_i \mid \mathbf{x}_i] = \Phi(z_i) \mathbf{x}_i' \beta + \sigma \phi(z_i), \quad z_i = \frac{\mathbf{x}_i' \beta}{\sigma} \quad (3.65)$$

y por tanto, para una covariable continua x_{ik} :

$$\frac{\partial E[y_i \mid \mathbf{x}_i]}{\partial x_{ik}} = \Phi(z_i) \beta_k \quad (3.66)$$

Esta expresión muestra que el efecto marginal sobre la variable observada es menor en magnitud que el efecto sobre el resultado latente, porque se encuentra atenuado por la probabilidad de no estar censurado. En términos gerenciales, esto implica que una variable como precio, ingreso o intensidad promocional puede afectar simultáneamente la decisión de participar y el nivel consumido.

El principal riesgo de usar un Tobit tipo I es imponer una restricción demasiado fuerte: que la misma combinación lineal explique tanto el salto desde cero a positivo como la intensidad condicional. Si en la práctica estas dos decisiones obedecen a mecanismos distintos, entonces conviene separar explícitamente selección e intensidad.

3.7.2 Tobit tipo II

El *Tobit tipo II* surge precisamente cuando la decisión de observar el resultado y el nivel del resultado obedecen a procesos distintos. Este es el caso clásico de *selección muestral*: el monto de descuento se observa solo si el cliente usa el cupón; las millas disponibles son relevantes solo si el individuo activa el programa; el gasto condicional se observa solo si la compra ocurre.

La formulación separa una ecuación de selección y una ecuación de resultado:

$$s_i^* = \mathbf{z}_i' \gamma + u_i, \quad s_i = \mathbb{1}[s_i^* > 0] \quad (3.67)$$

$$y_i^* = \mathbf{x}_i' \beta + \varepsilon_i, \quad y_i = y_i^* \text{ solo si } s_i = 1 \quad (3.68)$$

donde típicamente se asume que:

$$\begin{pmatrix} u_i \\ \varepsilon_i \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho\sigma_\varepsilon \\ \rho\sigma_\varepsilon & \sigma_\varepsilon^2 \end{pmatrix} \right) \quad (3.69)$$

La correlación ρ es el parámetro crucial: si $\rho \neq 0$, entonces las observaciones para las cuales y_i es visible no constituyen una submuestra aleatoria. En consecuencia, estimar por OLS la ecuación de resultado solo con los casos observados genera sesgo de selección.

El resultado central de Heckman (1979) muestra que:

$$E[y_i \mid \mathbf{x}_i, \mathbf{z}_i, s_i = 1] = \mathbf{x}_i' \beta + \rho\sigma_\varepsilon \lambda(\mathbf{z}_i' \gamma), \quad (3.70)$$

donde

$$\lambda(\mathbf{z}_i' \gamma) = \frac{\phi(\mathbf{z}_i' \gamma)}{\Phi(\mathbf{z}_i' \gamma)} \quad (3.71)$$

es la *razón de Mills inversa*. Esta expresión muestra que la esperanza condicional del resultado observado incluye un término adicional que resume la no aleatoriedad del proceso de observación. Si dicho término se omite, los coeficientes de la ecuación de resultado absorben parte de ese sesgo.

En la práctica existen dos estrategias principales de estimación:

1. *Máxima verosimilitud conjunta*, que estima simultáneamente β , γ , σ_ε y ρ .
2. *Procedimiento en dos etapas de Heckman*, que primero estima la selección mediante probit y luego incorpora la razón de Mills inversa en la ecuación de resultado.

La máxima verosimilitud es más eficiente si la normalidad conjunta está bien especificada. El estimador en dos etapas es más transparente y pedagógico, por lo que suele ser especialmente útil al introducir el modelo y al interpretar el origen del sesgo de selección.

Desde un punto de vista gerencial, el Tobit tipo II permite distinguir dos preguntas diferentes: qué factores explican la activación o uso de un mecanismo y qué factores explican la magnitud del resultado condicional una vez que la activación ocurre. En problemas de cupones, retención o lealtad, esta separación es normalmente más realista que la restricción del Tobit tipo I.

3.8 Resumen

Conceptos clave.

- Un *modelo estructural* deriva relaciones estimables a partir de supuestos de comportamiento, permitiendo interpretación de parámetros y evaluación de contrafactuales.
- La *utilidad aleatoria* se descompone en componente sistemática v_{nit} y aleatoria ε_{nit} ; la distribución de esta última determina el modelo (logit, probit, nested, mixed).
- El *logit* provee fórmula cerrada y estimación eficiente, pero impone IIA y sustitución proporcional.
- El *probit* admite correlación entre alternativas y heterogeneidad aleatoria, pero requiere simulación.
- El *nested logit* relaja parcialmente IIA agrupando alternativas en nidos con correlación intra-grupo.
- El *mixed logit* permite heterogeneidad continua en preferencias y aproxima cualquier modelo de utilidad aleatoria.
- Las *clases latentes* proveen heterogeneidad discreta; resultan preferibles cuando la población se segmenta en grupos bien diferenciados.
- Los *modelos Tobit* permiten tratar resultados limitados: censura en *Tobit I* y selección muestral en *Tobit II*.

Decisiones de modelamiento.

- Especificación de v_{nit} : variables a incluir, forma funcional, heterogeneidad observable.
- Distribución de errores: Gumbel (logit), normal (probit), GEV (nested logit).
- Tratamiento de heterogeneidad: observable (interacciones), aleatoria (mixed logit), discreta (clases latentes).
- Incorporación de dinámica: lealtad (z_{nit}), precios de referencia (RP_{nit}).
- Regla de observación del resultado: censura, truncamiento o selección, según la naturaleza del dato observado.

Métricas de evaluación.

- Bondad de ajuste: ρ de McFadden, AIC, BIC.
- Capacidad de pronóstico: MAE, MAPE (con muestra de prueba).
- Test de hipótesis: razón de verosimilitud, estadístico t .
- Métricas derivadas: elasticidades propias y cruzadas, DAP.

Errores frecuentes:

- Aplicar el modelo logit en contextos donde la propiedad de IIA es claramente inapropiada (alternativas con alto grado de similitud).
- Olvidar las restricciones de identificación del probit al estimar la matriz Σ (es necesario fijar locación y escala).
- Confundir heterogeneidad observable (capturada por interacciones con co-variables) con heterogeneidad aleatoria (requiere mixed logit o probit con errores correlacionados).
- Utilizar un número insuficiente de simulaciones R en la estimación por SMLE, lo que puede generar sesgo en los estimadores.
- Interpretar ρ de McFadden como proporción de variabilidad explicada, análogamente al R^2 de una regresión lineal.
- No verificar que $0 < \lambda_k \leq 1$ en el nested logit; un valor fuera de rango indica problemas de especificación.
- Omitir la condición inicial de z_{ni1} y RP_{ni1} al implementar modelos de panel con persistencia o precios de referencia.
- Usar *Tobit I* cuando la decisión de participar y la magnitud condicional del resultado obedecen a mecanismos distintos; en ese caso conviene un enfoque tipo Heckman o *Tobit II*.

Referencias principales: McFadden (1974), Train (2009), Ben-Akiva & Lerman (1985), Berry et al. (1995), Guadagni & Little (1983), Nevo (2000), Rossi et al. (2005), Tobin (1958), Heckman (1979), Wooldridge (2019).

3.9 Problemas

Problema 1: STUD-IA

STUD-IA es una compañía que ofrece cursos de lenguaje y matemáticas con una propuesta de valor centrada en la posibilidad de usar inteligencia artificial para adaptar los contenidos al estilo de aprendizaje de cada estudiante. Para incentivar que los estudiantes se mantengan activos en la plataforma, STUD-IA ha introducido un programa de lealtad que entrega stickers virtuales a los usuarios por cada curso que completan. Los stickers pueden descargarse y coleccionarse y para este año ha considerado cuatro colecciones de stickers: Dragon Ball, superhéroes, Snoopy y memes de Internet. Entre muchos beneficios, una de las ventajas del plan premium es que se acumula el doble de stickers por cada participación.

La compañía está interesada en describir el comportamiento de sus usuarios, por lo que propone usar modelos de elección discreta o de clasificación para

describir el estado de sus suscriptores en un trimestre dado. En particular, se busca estudiar cómo el número de stickers recibidos en un semestre afecta las suscripciones del trimestre siguiente. Para eso, STUD-IA ha armado una base de datos que registra el estado de cada cliente en cada trimestre, el que puede tomar tres niveles: suscrito en el plan premium (premium), suscrito en el plan normal (normal) y no suscrito (inactivo), como indica la Tabla 3.1.

Table 3.1: Muestra de la base de datos de STUD-IA

Idcust	gender	nsnoopy	nsuperhero	ndragon	nmeme	trimestre	precio	preciop	status
c001	Male	0	0	0	0	Q12024	15000	20000	Inactivo
c001	Male	0	0	0	0	Q22024	15000	20000	Inactivo
c001	Male	0	0	0	0	Q32024	15000	20000	Inactivo
c001	Male	0	2	1	0	Q42024	15000	20000	Normal
c001	Male	2	0	1	1	Q12025	18000	22000	Normal
c001	Male	0	1	0	0	Q22025	18000	22000	Normal
c001	Male	0	0	3	0	Q32025	18000	22000	Normal
c002	Female	0	4	0	2	Q12024	15000	20000	Premium
c002	Female	6	0	4	0	Q22024	15000	20000	Premium

1. Proponga un modelo de utilidad que, además del precio de los planes y un intercepto por cada alternativa, considere:
 - a) Recibir el primer sticker tiene un impacto muy relevante en el comportamiento. En otras palabras, aquellos que han recibido algún sticker en general tienen un comportamiento distinto de aquellos que no han recibido ningún sticker
 - b) La acumulación de stickers tiene retornos decrecientes. Es decir, recibir el n -ésimo sticker retorna una menor utilidad que el $(n+1)$ -ésimo sticker.
 - c) Las preferencias de los distintos tipos de stickers podrían diferir por género. Por ejemplo, a las mujeres les podrían gustar más los stickers de Dragon Ball, mientras que a los hombres les podrían gustar más los stickers de Snoopy.
 - d) A los usuarios del programa les gusta la variedad, es decir prefieren tener un sticker de memes y otro de superhéroes, que recibir dos de superhéroes.

Para cada una de las variables usadas en su modelo, explique como las calcularía a partir de la base de datos disponible.

2. ¿Cómo incluiría en el modelo que el intercepto de inactivo es menor que el del plan normal y está a su vez menor que el del plan premium?
3. En el contexto del efecto de los stickers en el comportamiento de suscripción discuta:
 - a) ¿Se podría justificar la imposición de que un elemento de la matriz de varianza-covarianza de un modelo probit sea cero?
 - b) ¿Cómo podría incluir que hay aversión a la pérdida en la acumulación de stickers?

4. Suponga que se desea introducir heterogeneidad no observable solo en el coeficiente de precio. Escriba la verosimilitud del modelo con dos clases latentes. Indique cómo se obtiene la probabilidad de que un cliente pertenezca al segmento 1.
5. Disconforme con la solución de clases latentes, se postula correr un modelo logit heterogéneo a través del siguiente código computacional, cuyos resultados se despliegan en la Tabla 3.2.

```
stickers <- mlogit(subs ~ price + nsnoopy + ndragon + nsuperhero + nmemes,
                  data=datastickers, rpar=c(price='n'))
```

Table 3.2: Resultados de la estimación del modelo logit heterogéneo.

Parámetro	Estimador
Mixed Logit Normal	3,452 ***
Premium	5,435 ***
Price	-2,121*
Nsnoopy	0,934**
Ndragon	0,321*
Nsuperhero	0,821**
Nmemes	0,192*
Sd(price)	2,456***
Num Obs	18,435
AIC	34,216
RMSE	0,341
McFadden R2	0,0182

¿Qué puede concluir respecto al efecto del precio en el comportamiento de suscripción?

Ver solución

1. Argumentamos cada uno de los puntos de forma independiente y luego escribimos la función de utilidad completa.
 - a) Creamos una variable binaria $Primero_{nt}$ que toma el valor 1 si el usuario n ha recibido al menos un sticker en el trimestre t . Con esto, agregamos el término $\theta Primero_{nt-1}$.
 - b) Los retornos decrecientes se pueden incorporar agregando una función logaritmo. Así, podemos agregar el término $\sum_h \gamma_h \ln(n_{nh,t-1})$ donde $n_{nh,t-1}$ es el número de sticker del tipo h que recibe el usuario en el trimestre anterior.
 - c) Para diferenciar las preferencias por género agregamos una variable al coeficiente que multiplica los logaritmos de cantidad $\sum_h (\gamma_h^0 + \gamma_h^F Female_n) \ln(n_{nh,t-1})$.
 - d) Finalmente, para considerar variedad necesitamos incluir las interacciones. Aunque hay más de una forma funcional posible, una forma razonable de hacerlo es incluir los términos $\sum_h \sum_{h' \neq h} \mu_h \ln(n_{nh,t-1} \cdot n_{nh',t-1})$.

Con esto, la función de utilidad que deriva el usuario n respecto a la alternativa de suscripción i en el trimestre t , puede expresarse como:

$$\begin{aligned} u_{nit} = & \alpha_i + \beta \cdot \text{Precio}_{nit} + \delta \cdot \text{Primero}_{nt-1} \\ & + \sum_h (\gamma_h^0 + \gamma_h^F \text{Female}_n) \cdot \ln(n_{nh,t-1}) \\ & + \sum_h \sum_{h' \neq h} \mu_h \cdot \ln(n_{nh,t-1} \cdot n_{nh',t-1}) \end{aligned}$$

En esta expresión todas las variables están directamente disponibles en la base de datos, excepto Primero_{nt} que puede calcularse calculando la suma de todos los stickers recibidos hasta ese periodo y asignando un 1 si la suma es estrictamente mayor que 0.

2. Imponemos directamente que $\alpha_{inactivo} = 0$, $\alpha_{normal} = \exp(\tilde{\alpha}_{normal})$ y que $\alpha_{premium} = \exp(\tilde{\alpha}_{normal}) + \exp(\tilde{\alpha}_{premium})$.
3. Contestamos directamente.
 - a) Como hay tres alternativas y tenemos que fijar una (por ejemplo inactivo), entonces la matriz de varianza-covarianza solo tiene dos elementos identificables. Los elementos de la diagonal evidentemente no pueden imponerse nulos por lo que el único candidato sería imponer que $\sigma_{normal,premium} = 0$. Esta restricción es muy difícil de justificar porque implicaría que no hay nada no observable que haga que al aumentar las suscripciones normales, haga que también aumenten las suscripciones premium.
 - b) Primero habría que construir un punto de referencia para el número de stickers a recibir. Por ejemplo, el número recibido el trimestre anterior, el promedio histórico de stickers recibidos cada trimestre o una combinación de ambos. Con la referencia podemos recodificar el número de stickers en $ngain_{nh,t}$ y en $nloss_{nh,t}$ dependiendo de si el número de stickers recibidos está por encima o por debajo de la referencia. Con esto en los modelos anteriores podemos reemplazar el término $\ln(n_{nh,t-1})$ por $\ln(ngain_{nh,t-1} + \lambda \cdot nloss_{nh,t-1})$.
4. Podemos usar la fórmula de verosimilitud de clases latentes de forma directa:

$$LL(\theta_1, \theta_2, \pi) = \sum_n \sum_i \sum_t y_{nit} \ln \left[\pi \frac{\exp(u_{nit}(\theta_1))}{\sum_j \exp(u_{njt}(\theta_1))} + (1 - \pi) \frac{\exp(u_{nit}(\theta_2))}{\sum_j \exp(u_{njt}(\theta_2))} \right]$$

Donde $\theta_1 = \{\alpha_i, \beta_{clase1}, \delta, \gamma_h^0, \gamma_h^F, \mu_h\}$ y $\theta_2 = \{\alpha_i, \beta_{clase2}, \delta, \gamma_h^0, \gamma_h^F, \mu_h\}$ son el vector de parámetros de la utilidad de las dos clases y π es la

probabilidad de pertenecer a la clase 1. Notar que π debe ser normalizado a $\pi = \frac{\exp(\lambda)}{1+\exp(\lambda)}$. Esta última fórmula nos permite calcular la probabilidad de pertenecer a la clase 1.

5. La clave para responder esta pregunta es entender que los resultados nos indican tanto el promedio de la elasticidad de precio (con su respectiva precisión) como la dispersión de la heterogeneidad. En simple, los resultados nos indican que:
 - a) El valor modal de elasticidad al precio es significativamente negativo con un valor de -2,121.
 - b) El valor es bastante heterogéneo con una desviación estándar de 2,456. Por ejemplo, debiéramos esperar que haya un 2.5% de los usuarios que tienen elasticidades de $2.121 + 1.96 \times 2.456 = 2.693$ o más positivas.

Problema 2: Categoría aceites

Un administrador de la categoría aceites de una sala del centro de Santiago de una importante retailer nacional, se dispone a analizar datos de panel que reportan y_{ijt} que toma el valor 1 si el hogar i compra la marca-tamaño j en la semana t y 0 en caso contrario ($i = 1, \dots, N$, $j = 1, \dots, J$, $t = 1, \dots, T$). Junto con las elecciones semanales de cada hogar, el panel provee $PRICE_{jt}$ correspondiente al precio por centímetro cúbico de la alternativa j en la semana t y $COUPON_{ijt}$ que toma el valor 1 si el cliente i dispone de un cupón de descuento para la alternativa j en la semana t (aunque el valor de descuento de los cupones varía entre alternativas y de semana a semana, los valores típicamente rondan el 10% del precio de lista).

Después de una reunión de trabajo con administradores de categoría en otras salas se ha acordado que un buen punto de partida es usar un modelo estructural en que la componente determinística de la utilidad de compra viene dada por:

$$v_{ijt} = \alpha_{ij} + \beta_{i1}PRICE_{jt} + \beta_{i2}COUPON_{ijt}$$

Sin embargo, hasta el momento no hay demasiada claridad respecto a cómo introducir heterogeneidad en el modelo, por lo que se barajan varias alternativas.

- a) Escriba la log-verosimilitud de un modelo logit con dos clases latentes. La expresión debe quedar expresada directamente en función de los parámetros que ingresarán como variables de decisión en la maximización irrestricta de la log-verosimilitud.
- b) Escriba una (aproximación a) la log-verosimilitud de un modelo logit mezclado. Al igual que en el caso anterior, la expresión debe quedar expresada directamente en función de los parámetros que ingresarán como variables de decisión en la maximización irrestricta de la log-verosimilitud. Para ello puede asumir que dispone de una función que le permite samplear

desde cualquier distribución de probabilidad generando una muestra de tamaño R del vector de parámetros α_{ij} , β_1 y β_2 .

Ver solución

a) La función de log-verosimilitud viene dada por:

$$LL = \sum_i \sum_j \sum_t y_{ijt} \ln \left[\frac{\exp(\lambda)}{1 + \exp(\lambda)} \frac{\exp(v_{ijt}^1)}{\sum_k \exp(v_{ikt}^1)} + \frac{1}{1 + \exp(\lambda)} \frac{\exp(v_{ijt}^2)}{\sum_k \exp(v_{ikt}^2)} \right]$$

donde v_{ijt}^1 y v_{ijt}^2 son las componentes sistemáticas de la utilidad de los clientes pertenecientes a las clases 1 y 2 respectivamente y vienen dadas por:

$$v_{ijt}^1 = \alpha_{ij}^1 + \beta_{i1}^1 PRICE_{jt} + \beta_{i2}^1 COUPON_{ijt}$$

$$v_{ijt}^2 = \alpha_{ij}^2 + \beta_{i1}^2 PRICE_{jt} + \beta_{i2}^2 COUPON_{ijt}$$

Los parámetros α_{ij}^1 , β_{i1}^1 y β_{i2}^1 corresponden a los parámetros caracterizando a la clase 1 y α_{ij}^2 , β_{i1}^2 y β_{i2}^2 los que caracterizan a la clase 2. El parámetro λ determina el tamaño relativo de cada clase y la transformación logística sobre λ garantiza que las proporciones estén en el rango $[0,1]$ y sumen 1.

b) La (aproximación de la) función de log-verosimilitud viene dada por:

$$LL = \sum_i \sum_j \sum_t y_{ijt} \ln \left(\frac{1}{R} \sum_r \frac{\exp(v_{ijt}^r)}{\sum_k \exp(v_{ikt}^r)} \right)$$

donde v_{ijt}^r son las componentes sistemáticas de la utilidad de los clientes si los parámetros toman los valores α_{ij}^r , β_1^r y β_2^r .

Problema 3: Margarina y modelo probit

1. Suponga que un analista propone usar un modelo logit para estudiar el comportamiento de compra de 5 marcas de margarina las que pueden ofrecerse en formato pan o pote.
 - a) Escriba la función de utilidad si los clientes tienen preferencias dependientes exclusivamente de precio y formato.
 - b) Escriba la función de utilidad si los clientes tienen preferencias dependientes de precio, marca y formato.

- c) Escriba la función de utilidad si se quiere evaluar cuánto influye la interacción entre el nivel de ingreso ING_n y el precio en la utilidad del cliente n .
2. Considere un agente que se enfrenta a la elección entre dos alternativas A y B de modo que las componentes determinísticas de su utilidad vienen dadas por $v_A = v_B = 1$. Usted como analista ha decidido modelar la elección usando un modelo probit con una matriz de varianza-covarianza completamente general, es decir sobre la cual no se ha impuesto ninguna restricción más allá de la simetría. Calcule explícitamente:

$$P_A = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}(v_A + \varepsilon_A > v_B + \varepsilon_B) \cdot \phi(\varepsilon_A, \varepsilon_B) d\varepsilon_A d\varepsilon_B$$

Justifique su respuesta e interprete el resultado.

3. Considere un cliente comprando por tres periodos en una categoría con dos marcas A y B como lo indica la siguiente tabla:

Table 3.3: Elecciones de marca por periodo.

Periodo	Marca A	Marca B
1	0	1
2	0	1
3	1	0

Calcule una medida de lealtad para cada marca y periodo usando un modelo de suavización exponencial con parámetro de factor de alisamiento λ . Para ello inicialice las medidas de lealtad en $\frac{1}{2}$ para el periodo 0 en ambas marcas.

4. Para analizar el comportamiento de compra de los clientes en un mercado de alimentos enlatados, una importante empresa consultora ha implementado una rutina de maximización de verosimilitud para estimar los parámetros de un modelo logit que se aplica sobre una base de 324 clientes que hacen 3615 compras en la categoría. En la rutina propuesta, los parámetros máximo verosímiles se obtienen usando el comando `mymle = optim(par=0.01*rep(1,3), fn=loglikel, hessian=TRUE, method="BFGS")`.

```
> mymle$par
[1] 0.124 0.486 -2.351
> mymle$value
[1] 1344.35
```

¿Cuál es el BIC del modelo estimado por la empresa consultora?

Ver solución

1. a) La utilidad que experimenta un cliente n respecto a la marca i en la ocasión de compra t viene dada por:

$$u_{nit} = \beta_{PRECIO} PRECIO_{it} + \beta_{PAN} PAN_i + \varepsilon_{nit}$$

donde PAN_i toma el valor 1 si la alternativa i corresponde al formato pan, $PRECIO_{it}$ es el precio de la alternativa i en la oportunidad de compra t y ε_{nit} independientes e idénticamente distribuidas valor extremo tipo I. Notar que por motivos de identificación, este modelo hemos fijado en cero la utilidad intrínseca de la alternativa pote.

- b) Hay al menos dos formas de modelar este problema:

- La utilidad que experimenta un cliente n respecto a la marca i en la ocasión de compra t viene dada por:

$$u_{nit} = \beta_{PRECIO} PRECIO_{it} + \beta_{PAN} PAN_i + \sum_{j=1}^4 \alpha_j M_{ij} + \varepsilon_{nit}$$

donde PAN_i toma el valor 1 si la alternativa i corresponde al formato pan, M_{ij} toma el valor 1 si la alternativa i es de la marca j , $PRECIO_{it}$ es el precio de la alternativa i en la oportunidad de compra t y ε_{nit} independientes e idénticamente distribuidas valor extremo tipo I. Notar que por motivos de identificación, este modelo hemos fijado en cero la utilidad intrínseca de la alternativa pote y de la última marca (Es por esto que la sumatoria llega hasta 4 y no hasta 5).

- La utilidad que experimenta un cliente n respecto a la marca i en la ocasión de compra t viene dada por:

$$u_{nit} = \beta_{PRECIO} PRECIO_{it} + \sum_{j=1}^{N-1} \alpha_j MF_{ij} + \varepsilon_{nit}$$

donde MF_{ij} toma el valor 1 si la alternativa i corresponde a la marca-formato j , $PRECIO_{it}$ es el precio de la alternativa i en la oportunidad de compra t y ε_{nit} independientes e idénticamente distribuidas valor extremo tipo I. Si todas las marcas están disponibles en todos los formatos, entonces tenemos $N = 2 \times 5$ marca-formatos, de los cuales solo podemos identificar $N - 1$ interceptos.

- c) Asumiendo que la utilidad que experimenta un cliente n respecto a la marca i en la ocasión de compra t depende exclusivamente del precio (si dependiera de otros factores simplemente tendríamos que

agregar los términos correspondientes), la función de utilidad puede expresarse como:

$$u_{nit} = \beta_{0p} + \beta_{1p} \text{ING}_n + \beta_{2p} \text{PRECIO}_{it} + \beta_{3p} \text{ING}_n + \text{PRECIO}_{it} + \varepsilon_{nit}$$

donde PRECIO_{it} es el precio de la alternativa i en la oportunidad de compra t y ε_{nit} independientes e idénticamente distribuidas valor extremo tipo I.

2. P_A no es más que la probabilidad de elegir la alternativa A . La clave para calcular su valor viene de observar que $v_A = v_B$. Si las dos alternativas tienen el mismo valor de la componente sistemática, entonces el cálculo de P_A corresponde a la probabilidad de que una componente sea mayor que la otra en una distribución normal bivariada centrada en 0, la que evidentemente toma el valor $\frac{1}{2}$.




Figure 3.2: Plot de variables transformadas logarítmicamente.

La interpretación es sencilla. Estamos describiendo una situación de un tomador de decisión que, a excepción de una perturbación normal centrada en cero. Dada la simetría de la normal las perturbaciones son igualmente probables de inclinar la balanza en favor de la alternativa A como de la alternativa B y por tanto la probabilidad final que el tomador de decisión elija la alternativa A es simplemente $\frac{1}{2}$.

3. Podemos calcular las medidas de lealtad con que el cliente se enfrenta a las siguientes 3 ocasiones de compra:

Table 3.4: Medidas de lealtad por periodo.

Periodo	Marca A	Marca B
2	$(1 - \lambda)/2$	$\lambda + (1 - \lambda)/2$
3	$(1 - \lambda)^2/2$	$\lambda(1 - \lambda) + (1 - \lambda)^2/2$
4	$\lambda + (1 - \lambda)^3/2$	$(1 - \lambda)\lambda + (1 - \lambda)^2 + (1 - \lambda)^3/2$

4. Por definición:

$$BIC = -2LL(\hat{\theta}) + k \ln(n)$$

donde $LL(\hat{\theta})$ es la log verosimilitud evaluada en el estimador máximo verosímil, k el número de parámetros en el modelo y n el número de observaciones sobre la que se calcula la verosimilitud. Entonces:

$$BIC = -2(-1344.35) + 3 \ln(3615) = 2713.279$$

Problema 4: Telefonía móvil en redes sociales

Una compañía de telefonía móvil de reciente ingreso al país ha iniciado una fuerte campaña en algunas redes sociales y busca estudiar el perfil de los clientes que han evaluado favorablemente la campaña. Para eso se ha construido una base de datos de 5243 usuarios de facebook que vieron al menos uno de los elementos considerados en la campaña (video, afiche, álbum de fotos, etc.). Junto con información de los usuarios considerados en la muestra, la base de datos contiene una variable y_n que toma el valor 1 si el usuario n le dio un “me gusta” a alguno de las componentes de la campaña. La siguiente tabla contiene una breve descripción de la información disponible en la base.

Table 3.5: Descripción de variables de la base de datos.

Variable	Descripción	Promedio
y_n	1 si a usuario n le gusta alguna componente de la campaña	0.093
$Hombre_n$	1 si usuario n es hombre	0.421
$Twitter_n$	1 si usuario n es usuario de Twitter	0.134
$Edad_n$	Edad usuario n	23.18

- a) Suponga que para perfilar a los clientes se propone un modelo logit en que el usuario n deriva una utilidad u_n por darle un “me gusta” a alguna de las componentes de la campaña y 0 si no. Escriba la log-verosimilitud del problema asumiendo que la componente determinística de la utilidad depende linealmente de $x_n = (Hombre_n, Twitter_n, Edad_n, Edad_n^2)$.

Suponga que analistas dentro de la compañía han codificado la verosimilitud anterior en R en una función `loglikel` que recibe como primer argumento el intercepto de la función de utilidad y los cuatro siguientes los otros parámetros de la utilidad en el orden antes planteado. Para encontrar los estimadores máximo verosímiles se ha ejecutado el siguiente comando:


```
mymle = optim(par=0.01*rep(1,5), fn=loglikel, hessian=TRUE, method="BFGS")
```

Al terminar la rutina, los analistas quieren hacer inferencia sobre los parámetros para lo que ejecutan el siguiente comandos en la consola generando los resultados correspondientes:

```
> cbind(mymle$par, sqrt(diag(solve(mymle$hessian))))
      [,1]      [,2]
[1,] -0.9623  0.2069
[2,]  3.4340  0.0518
[3,]  0.0047  0.0522
[4,]  0.0365  0.0043
[5,] -0.0048  0.0025
```

- b) ¿Cuál es la probabilidad que una mujer de 20 años que no es usuaria de twitter le de un “me gusta” a la campaña?
- c) ¿Cómo varía la probabilidad de elección anterior si la mujer sí es usuaria de twitter? Describa que implicancias podría tener su resultado en la elaboración de próximas campañas.

Ver solución

- a) La componente determinística de la utilidad viene dada por:

$$v_n = \beta_0 + \beta_1 \text{Hombre}_n + \beta_2 \text{Twitter}_n + \beta_3 \text{Edad}_n + \beta_4 \text{Edad}_n^2$$

Luego, la log-verosimilitud puede escribirse como:

$$LL = \sum_n y_n \ln \frac{\exp(v_n)}{1 + \exp(v_n)} + (1 - y_n) \ln \frac{1}{1 + \exp(v_n)}$$

- b) Para esta mujer, la componente sistemática de la utilidad viene dada por:

$$v_n = -0.9623 + 3.4340 \times 0 + 0.0047 \times 0 + 0.0365 \times 20 - 0.0048 \times 400 = -2.1523$$

Entonces:

$$Pr(y_n = 1) = \frac{\exp(v_n)}{1 + \exp(v_n)} = 0.10412$$

- c) Si fuere usuaria de twitter, basta modificar la componente determinística de la utilidad $v_n \rightarrow v_n + 0.047 = -2.1476$ y recalcular la probabilidad:

$$Pr(y_n = 1) = \frac{\exp(v_n)}{1 + \exp(v_n)} = 0.10456$$

Como el cambio de probabilidad es muy bajo, podemos concluir que ser usuario de twitter no es muy relevante para explicar si una persona le dará un “me gusta” a alguna componente de la campaña (notar que esto se puede inferir directamente de los estimadores máximo verosímiles). Para los próximos elementos de la campaña, probablemente convenga concentrarse en el género y edad de los usuarios.

Problema 5: Multitienda y tarjeta de crédito

En el departamento de estudios de una importante multitienda buscan analizar simultáneamente los montos de compra en la tienda y el uso de la tarjeta de crédito de la casa comercial. Para eso la empresa ha recopilado, para cada cliente n , una serie de variables que caracterizan su relación con la firma en el último año, como describe la siguiente tabla.

Table 3.6: Descripción de variables de la base de datos.

Variable	Descripción	Promedio
y_n	Monto total gastado por cliente n con la tienda	124.045
w_n	1 si cliente n tiene la tarjeta de crédito de la tienda	0.64
$Mujer_n$	1 si cliente n es mujer	0.462
$Edad_n$	Edad cliente n	36.21

Como primera aproximación, los analistas del departamento de estudio han propuesto describir el gasto en tienda usando el siguiente modelo:

$$y_n = \begin{cases} \beta_0 + \beta_1 Mujer_n + \beta_2 Edad_n + \varepsilon_{1n}, & \text{si } w_n = 1 \\ \beta'_0 + \beta'_1 Mujer_n + \beta'_2 Edad_n + \varepsilon_{2n}, & \text{si } w_n = 0 \end{cases}$$

Y para la decisión de adquisición de tarjeta:

$$u_n = \begin{cases} \gamma_0 + \gamma_1 Mujer_n + \gamma_2 Edad_n + \varepsilon_{3n}, & \text{adquiere tarjeta} \\ \varepsilon_{4n}, & \text{no adquiere} \end{cases}$$

1. Suponga que ε_{3n} y ε_{4n} son independientes y están idénticamente distribuidos valor extremo tipo 1. Calcule una expresión para la probabilidad que el cliente n elija adquirir la tarjeta de la tienda.
2. Suponga que ε_{1n} y ε_{2n} son independientes y están normalmente distribuidos con media 0 y varianzas σ_1 y σ_2 . Calcule una expresión para la verosimilitud de observar un gasto y_n condicional en que el cliente tiene tarjeta y otra para el gasto en que el cliente no tiene tarjeta.

3. Suponga que ε_{1n} y ε_{2n} son independientes de ε_{3n} y ε_{4n} . Escriba la log-verosimilitud de observar simultáneamente $\{y_n\}_{n=1}^N$ y $\{w_n\}_{n=1}^N$.
4. La empresa está especialmente interesada en identificar si hay alguna diferencia en los patrones de gasto entre aquellos clientes que tienen tarjeta con respecto a aquellos que no tienen. Para ello se estima el modelo antes planteado obteniendo una log-verosimilitud $LL_0 = -2.332, 57$ y luego otro en que se impone $\beta_0 = \beta'_0$, $\beta_1 = \beta'_1$, $\beta_2 = \beta'_2$ con una log-verosimilitud $LL_1 = -2.418, 42$. Basado en el test de ratios de verosimilitud, determine si la tenencia de tarjeta afecta los patrones de gasto en tienda.

Table 3.7: Valores críticos de la distribución chi-cuadrado al 5%.

ν	1	2	3	4	5	6	7	8
χ^2_ν	3.84	5.99	7.81	9.49	11.07	12.59	14.07	15.51

La tabla indica los valores de χ^2_ν tales que $Pr(\chi^2_\nu \leq \chi^2_\nu) = 0.95$.

5. Si las componentes ε_{1n} , ε_{2n} , ε_{3n} , ε_{4n} son todas independientes, discuta brevemente si hay algún beneficio de estudiar simultáneamente los comportamientos de gasto y tenencia de tarjeta.

Ver solución

1. Si ε_{3n} y ε_{4n} son independientes y distribuidos valor extremo, entonces la probabilidad que el cliente elija adquirir la tarjeta viene dada directamente por la fórmula del logit, donde la utilidad de no adquisición se ha normalizado en 0:

$$P_n = \frac{\exp(\gamma_0 + \gamma_1 \text{Mujer}_n + \gamma_2 \text{Edad}_n)}{1 + \exp(\gamma_0 + \gamma_1 \text{Mujer}_n + \gamma_2 \text{Edad}_n)}$$

2. Dada la distribución de los errores, los montos gastados para ambos casos estarán normalmente distribuidos. Entonces, las verosimilitudes condicionales vienen dadas por:

$$L(y_n | w_n = 1) = \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(-\frac{(y_n - (\beta_0 + \beta_1 \text{Mujer}_n + \beta_2 \text{Edad}_n))^2}{2\sigma_1^2}\right)$$

$$L(y_n | w_n = 0) = \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left(-\frac{(y_n - (\beta'_0 + \beta'_1 \text{Mujer}_n + \beta'_2 \text{Edad}_n))^2}{2\sigma_2^2}\right)$$

3. La respuesta se deriva directamente de la definición de verosimilitud y la fórmula de probabilidades totales:

$$LL = \sum_n \ln(P_n L(y_n | w_n = 1) + (1 - P_n) L(y_n | w_n = 0))$$

4. La restricción propuesta implicaría que los patrones de gastos entre clientes con y sin tarjeta serán equivalentes. Para testear esta hipótesis se puede usar el test de ratios de verosimilitud directamente:


$$LR = 2(LL_0 - LL_1) = 2(-2332.57 - (-2418.42)) = 171.7$$

De acuerdo al número de restricciones, el LR se distribuye $\chi^2_{k=3}$. Por tanto, como el estadístico es mayor que el valor crítico $\chi^2_{0.05,3} = 7.81$, rechazamos la hipótesis nula que el comportamiento de gasto es igual en los casos de clientes con y sin tarjeta.

5. El enfoque de modelación es útil principalmente para estudiar la interacción entre las decisiones de apertura de tarjeta y gasto. Si asumimos que los errores son independientes entonces podríamos enfrentar el problema simplemente como dos problemas separados. La respuesta esperada es que no hay beneficio en términos de la captura del fenómeno de comportamiento. Argumentar en favor de un modelo integrado en virtud de su escalabilidad y posibilidad de comparar con modelos más complejos son también respuestas correctas.

Problema 6: Preventa de tickets

Con el avenimiento de los espectáculos masivos, las productoras que organizan los eventos han puesto en práctica múltiples tácticas de discriminación de precios. A continuación nos enfocaremos en el estudio del comportamiento de clientes respecto a las ventas anticipadas de tickets o *pre-venta*, donde los clientes pueden comprar anticipadamente a un precio p_1 menor que p_2 el precio de las entradas el día del evento. Para ello, nos enfocaremos exclusivamente en los clientes interesados en comprar tickets, cuyo comportamiento se describirá usando un modelo logit anidado. En este modelo, los clientes primero deciden si comprar anticipadamente o si esperan al día del evento. En el día del evento, los clientes deciden si asistir o no, generando cuatro escenarios, tal como se aprecia en la siguiente figura.



Para completar el modelo, se han propuesto las siguientes especificaciones para las componentes sistemática de la utilidad:

$$v_{PA} = \alpha_1 - \beta p_1$$

$$v_{PN} = \alpha_2 - \beta p_1$$

$$v_{EA} = \alpha_3 - \beta p_2$$

$$v_{EN} = 0$$

1. Escriba una expresión para P_{EA} , es decir, la probabilidad que un cliente espere sin comprar en la pre-venta y que luego decida asistir al evento.
2. Suponga que observa el comportamiento de N clientes, para cada uno de los cuales se observa y_{ni} , que toma valor 1 si el cliente decide la alternativa $i \in \{PA, PN, EA, EN\}$ y 0 en caso contrario. Escriba una expresión para la log-verosimilitud $LL(\theta = (\alpha_1, \alpha_2, \alpha_3, \beta, \lambda))$. Para eso asuma conocidas las expresiones de $P_i(\theta) \forall i \in I$.
3. Como analista, le interesa investigar las restricciones de comportamiento $\alpha_1 = \alpha_3$ y $\alpha_2 = 0$. Explique qué interpretación podrían tener dichas hipótesis y cómo podrían testearse.

Ver solución

1. Partimos por calcular la probabilidad condicional de asistir al evento condicional en que esperó. Esta probabilidad viene dada directamente por la fórmula del logit:

$$P_{A|E} = \frac{\exp(\alpha_3 - \beta p_2)}{\exp(\alpha_3 - \beta p_2) + 1}$$

Luego calculamos la probabilidad de esperar no comprando en la pre-venta:

$$P_E = \frac{\exp(\lambda IV_E)}{\exp(\lambda IV_P) + \exp(\lambda IV_E)}$$

donde IV_P y IV_E son los valores inclusivos de comprar y no comprar en la prevented respectivamente:

$$IV_P = \ln(\exp(\alpha_1 - \beta p_1) + \exp(\alpha_2 - \beta p_1))$$

$$IV_E = \ln(\exp(\alpha_3 - \beta p_2) + 1)$$

Finalmente, la probabilidad total viene dada por la multiplicación de las dos probabilidades anteriores:

$$P_{EA} = P_{A|E} \cdot P_E$$

2. Aplicamos directamente la definición de la verosimilitud:

$$LL(\theta) = \sum_n \sum_{i \in I} y_{ni} \ln(P_i(\theta))$$

3. Imponer que $\alpha_1 = \alpha_3$ implicaría que la utilidad intrínseca que los clientes derivan por asistir al evento es la misma independiente de si compraron en la prevented o no. Del mismo modo, imponer que $\alpha_2 = 0$ implicaría que no hay una pérdida de utilidad por comprar los boletos y no asistir más allá del precio pagado. Para testear cada hipótesis, usamos test de ratios de verosimilitud, lo que implica (i) el cálculo de la log-verosimilitud de los modelos con (LL_A) y sin (LL_B) restricciones, (ii) el cálculo del estadístico $LR = 2(LL_A - LL_B)$ y (iii) la comparación de dicho estadístico contra el valor crítico una χ^2_1 con un grado de libertad.

Problema 7: Gasto publicitario

Una empresa busca estudiar el impacto del gasto publicitario en su producto estrella, donde tiene una posición monopólica en un mercado de tamaño conocido. Para ello ha reunido las series de precios (p_t), ventas (q_t) y gasto publicitario (ADV_t) para las últimas 205 semanas y ha propuesto un modelo de elección binaria basado en la siguiente función de utilidad:

$$u_t = \alpha + \beta \ln(p_t) + \gamma ADV_t + \nu_t + \varepsilon_t$$

donde ν_t están normalmente distribuidos con media 0 y ε_t están distribuidos valor extremo.

1. Muestre que si s_t es la participación de mercado del producto, los parámetros α , β y γ pueden estimarse usando un enfoque de mínimos cuadrados ordinarios sobre la siguiente ecuación:

$$\ln(s_t) - \ln(1 - s_t) = \alpha + \beta \ln(p_t) + \gamma ADV_t$$

2. Usando un enfoque de regresión se ha estimado el modelo, obteniendo los siguientes resultados:

Table 3.8: Estimadores del modelo de gasto publicitario.

Parámetro	MLE	s.e
α	-1.76	0.27
β	-1.23	0.02
γ	0.31	0.09

Si se mantiene el precio constante en 1 y el gasto publicitario sube de 10 a 20, ¿cuántos puntos porcentuales aumenta la demanda por el producto?

Ver solución

1. Aplicando la definición del modelo logit:

$$s_t = \frac{\exp(\alpha + \beta \ln(p_t) + \gamma ADV_t + \nu_t)}{1 + \exp(\alpha + \beta \ln(p_t) + \gamma ADV_t + \nu_t)}$$

$$1 - s_t = \frac{1}{1 + \exp(\alpha + \beta \ln(p_t) + \gamma ADV_t + \nu_t)}$$

Como los denominadores son iguales:

$$\frac{s_t}{1 - s_t} = \exp(\alpha + \beta \ln(p_t) + \gamma ADV_t + \nu_t)$$

Aplicando logaritmo y reordenando términos:

$$\ln(s_t) - \ln(1 - s_t) = \alpha + \beta \ln(p_t) + \gamma ADV_t + \nu_t$$

Como ν_t está normalmente distribuido, se satisfacen las condiciones para aplicar mínimos cuadrados ordinarios.

2. Se evalúa directamente:

$$s_t(ADV_t = 10) = \frac{\exp(-1.76 - 1.23 \ln(1) + 0.31 \times 10)}{1 + \exp(-1.76 - 1.23 \ln(1) + 0.31 \times 10)} = 0.792$$

$$s_t(ADV_t = 20) = \frac{\exp(-1.76 - 1.23 \ln(1) + 0.31 \times 20)}{1 + \exp(-1.76 - 1.23 \ln(1) + 0.31 \times 20)} = 0.988$$

Por lo tanto hay un incremento de $\Delta = 19.6$ puntos porcentuales.

Problema 8: Pizza a Pieza

Pizza a Pieza es un servicio de pizzas a domicilio que lleva varios años operando en el sector sur de la capital. Los administradores de la tienda quieren estudiar el comportamiento de compra de sus clientes. Para eso, se proponen calibrar modelos de elección discreta usando una base de clientes registrados en la compañía y que hayan comprado al menos una vez en los últimos 6 meses. La base de datos está compuesta por 763 clientes de los que se conoce su número telefónico, la edad y género del jefe de hogar y si han comprado en cada semana t durante los últimos 6 meses de operación ($y_{nt} = 1$ si el cliente n compró en la semana t). Además, para cada semana se conoce el precio de lista de las pizzas (que por políticas de la empresa es el mismo independiente de la variedad de la pizza) y si se repartieron volantes con publicidad.

1. Suponga que la utilidad que un cliente n deriva por comprar en un semana t puede describirse como $u_{nt} = \beta'_0 x_{nt} + \varepsilon_{nt}$. Si $\{\varepsilon_{nt}\}$ con $n = 1, \dots, N$ y $t = 1, \dots, T$ están independiente e idénticamente distribuidos valor extremo tipo I, escriba la log-verosimilitud de un modelo que describa las compras de la base de clientes.
2. Al revisar la data, los analistas se dan cuenta que en los últimos 6 meses de operación, los precios de las pizzas ha sido exactamente los mismos. ¿Es posible estimar la sensibilidad al precio de la demanda con datos de esta naturaleza? Si no fuera posible, describa qué otra información podría recolectarse para hacer la estimación.
3. Un largo debate en el ámbito de la planificación comercial es el rol que juega la publicidad en afectar el comportamiento del consumidor. El primer argumento indica que la publicidad afecta directamente la utilidad de elección. Bajo este argumento un consumidor obtendrá un mayor beneficio al consumir un producto sobre el que ha sido expuesto a avisaje comercial con respecto a uno en que no ha sido expuesto. Un segundo argumento indica que la publicidad no implica una mayor utilidad en el consumo, pero hace a los consumidores menos sensibles al precio. Siguiendo los pasos que se indican, proponga un procedimiento para determinar cuál de estos argumentos describe mejor el comportamiento de los clientes de Pizza a Pieza.
 - (a) Resulta plausible suponer que el efecto de la publicidad se manifiesta en el mediano plazo. Esto es, el aviso publicitario hoy no afecta sólo el comportamiento de compra hoy sino que también en los próximos días. Proponga una métrica para capturar la intensidad acumulada de la publicidad.
 - (b) Usando una métrica de intensidad acumulada de publicidad, escriba la función de utilidad que ejemplifique la situación en que la publicidad afecta directamente la utilidad del consumo.
 - (c) Usando una métrica de intensidad acumulada de publicidad, escriba

la función de utilidad que ejemplifique la situación en que la publicidad afecte indirectamente a través de la sensibilidad al precio.

- (d) Describa cómo evaluaría cuál de los dos modelos describe mejor el comportamiento de compra de los clientes.
4. Después de explorar la data se ha acordado estimar dos modelos sin heterogeneidad. El primero (M1) considera solo un intercepto y una variable de lealtad que permita diferenciar de aquellos clientes que compran mucho de aquellos que compran menos. El segundo, junto con las variables anteriores consideran además un coeficiente de precio, otro de promoción y finalmente el efecto (directo) de la publicidad (M2). Los estimadores máximo verosímiles de estos dos modelos se encuentran disponibles en la siguiente tabla:

Table 3.9: Estimadores máximo verosímiles de estos dos modelos.

Parámetros	M1	M2
Intercepto	5.23	5.54
Lealtad	3.17	X
Precio	-	-3.25
Promoción	-	4.73
Publicidad	-	0.04
$-2LL$	20.17	Y
BIC	3145	Z

Discuta si valores de X, Y y Z debieran ser, mayores o menores que los estimadores máximo verosímiles del M1.

Ver solución

- Como la componente aleatoria de la probabilidad se distribuye valor extremo tipo I, entonces resulta un modelo logit, cuya log verosimilitud viene dada por:

$$LL = \sum_n \sum_t y_{nt} \ln \frac{\exp(\beta'_0 x_{nt})}{1 + \exp(\beta'_0 x_{nt})} + (1 - y_{nt}) \ln \frac{1}{1 + \exp(\beta'_0 x_{nt})}$$

- Si no hay variabilidad entonces no podemos saber cuál es el efecto del precio. Otras variables que podrían recolectarse son algunas actividades promocionales que hagan variar el precio de lista como uso de cupones o promociones. También podría saber variabilidad de precio de alternativas cercanas como otras pizzerías cercanas o de incluso otros restaurantes con cobertura de reparto similar.
- Al igual como hemos usado para medir el impacto acumulado de algunos comportamientos, para capturar la publicidad podemos usar una media móvil. Sea $a_t = 1$ si la firma repartió volantes publicitarios en la semana t y $\lambda \in (0, 1)$, entonces la métrica acumulada de publicidad en t (ADV_t) puede definirse como:

$$ADV_t = \lambda ADV_{t-1} + (1 - \lambda) a_{t-1}$$

- b) Aunque otras formas funcionales son posibles, lo más sencillo es imponer que la publicidad acumulada entra aditivamente en la función de utilidad:

$$u_{nt} = \beta'_0 x_{nt} + \delta ADV_t + \varepsilon_{nt}$$

donde x_{nt} incluye cualquier otra variable explicativa que quiera usarse para describir la utilidad de elección.

- c) Aunque otras formas funcionales son posibles, lo más sencillo es imponer que la publicidad acumulada entra aditivamente en la sensibilidad al precio:

$$u_{nt} = \beta'_0 w_{nt} + (\beta_1 + \delta ADV_t) PRICE_{nt} + \varepsilon_{nt}$$

donde w_{nt} incluye cualquier otra variable explicativa que quiera usarse para describir la sensibilidad al precio.

- d) Habría que estimar ambos modelos y evaluar cuál de los dos ajusta mejor a la data. Para eso se deben comparar métricas como pseudo- R^2 , AIC, BIC y MAPE.
4. Como hay más variables explicativas, $-2LL$ debiera ser menor o igual (es decir Y debiera ser menor que 20.17). Como BIC penaliza usar más variables, Z puede subir o bajar. Por último, tal como vimos en clases, X debiera subir. Esto es porque al no controlar por promoción y publicidad, no podremos identificar que a veces clientes relativamente leales dejan de comprar por variaciones en la oferta.

Problema 9: Retail online

Un retailer nacional está interesado en determinar el impacto de las publicaciones en su sitio web en sus ventas online. Esto es, la evaluación de cómo la promoción de un determinado producto afecta el volumen de sus ventas. Para esto, se ha propuesto un modelo estructural en donde la componente determinística de la utilidad de comprar un producto i de cada cliente n en el día t está dada por (note que es plausible que un cliente compre más de un producto por día):

$$v_{nit} = \alpha_i + \beta_{PR} Precio_{it} + \beta_S Size_{it} + \beta_{POS} Posicion_{it} + \beta_M Mail_{nt}$$

1. Plantee un modelo logit para describir el comportamiento de compra de los usuarios. Si hay I productos disponibles y cada día t llegan a la tienda N_t clientes, escriba la log-verosimilitud del modelo.

2. Si en vez de plantear un modelo logit, se prefiriera un modelo probit, ¿qué dimensión tendría la matriz de varianzas-covarianzas?
3. Para el modelo logit, determine el número esperado de ventas del producto i en un día t .
4. Escriba la expresión aproximada de la log-verosimilitud de un mixed logit, cuyos parámetros son generados a partir de un sampleo de R valores de una distribución normal.

Ver solución

1. Bajo un modelo logit, la probabilidad que el cliente n elija compre el producto i en el día t viene dada por:

$$p_{nit} = \frac{\exp(v_{nit})}{1 + \exp(v_{nit})}$$

Luego, si y_{nit} toma el valor 1 si el cliente n compró el producto i en t , entonces la log verosimilitud viene dada por:

$$LL = \sum_i \sum_t \sum_{n=1}^{N_t} y_{nit} \ln(p_{nit}) + (1 - y_{nit}) \ln(1 - p_{nit})$$

2. La elección es binaria por lo que matriz de varianza covarianza tiene dos filas y dos columnas. Se puede argumentar también que por temas de identificación hay solo un parámetro identificable.
3. El número esperado es directamente $\sum_{n=1}^{N_t} p_{nit}$.
4. La expresión es idéntica a la anterior, pero ahora no tenemos una fórmula cerrada para p_{nit} y debemos aproximarla:

$$p_{nit} \approx \frac{1}{R} \sum_{r=1}^R \frac{\exp(v_{nit}(\theta^r))}{1 + \exp(v_{nit}(\theta^r))}$$

Problema 10: Copa América

Con el reciente sorteo de la Copa América Chile 2015 (cómo pasó tan rápido el tiempo), el comité organizador está interesado en estudiar cómo los hinchas deciden a qué partido asistir. Como primera aproximación se busca un modelo que indique si un hincha decide asistir o no a los partidos que juega su equipo preferido. Suponga que usted tiene total certeza que su equipo favorito llegará a la final. A continuación se presenta los datos con los que dispone.

Table 3.10: Variables disponibles para el modelo de asistencia.

Variable	Descripción
$DISTANCIA_{ij}$	Distancia del hincha i para el partido j de su equipo favorito
$FASE_{ij}$	Fase del partido j del equipo favorito del hincha i (eg: semifinal)
$RIVAL_{ij}$	Rival en el partido j del equipo favorito del hincha i
$PRECIO_{ij}$	Precio de la entrada del partido j del equipo favorito del hincha i

1. Escriba la utilidad para un modelo de elección discreta que considere que (i) cada fase (grupos, cuartos, semi, final) agrega más público, (ii) la distancia afecta de manera no lineal (discuta qué forma funcional podría ser adecuada) y que (iii) los rivales Brasil y Argentina atraen más público que el resto.
2. Los datos que muestra la tabla a continuación son de un espectador que podría haber asistido a 2 partidos, pero solo asiste a uno. Escriba explícitamente la log-verosimilitud de un modelo logit para este hincha.

Table 3.11: Datos de un espectador.

Partido	Compra	Fase	Rival	Precio Entrada	Distancia
1	0	Grupos	Colombia	\$5.000	5.5 km
2	1	Cuartos de Final	Brasil	\$7.000	474 km

3. Proponga un modelo de decisión anidado en dos etapas especificando las probabilidades que permitan describir el proceso de compra de abonos para la fase grupal. En esta modalidad, los hinchas deben pagar por anticipado P_{abono} por los tres partidos de la fase de grupos. Una vez comprado el abono el hincha debe decidir si asistir a uno, dos o a los tres partidos de la etapa de grupos. Por simplicidad suponga que las componentes determinísticas de las utilidades de asistir a k partidos es v_k .
4. Suponga que el gobierno instaura un programa para estudiantes que les da un descuento para que pueda asistir a un único partido de la fase de grupos. En este programa, los estudiantes pueden elegir de entre los tres partidos programados. Suponga que para estudiar este comportamiento se estima un modelo probit sobre datos de encuestas a potenciales beneficiarios y se encuentra una matriz varianza-covarianza (desnormalizada) como sigue. Interprete los resultados.

$$\Sigma = \begin{bmatrix} 0.198 & 0.533 & 0 \\ 0.533 & 0.360 & 0.258 \\ 0 & 0.258 & 0.852 \end{bmatrix}$$

Ver solución

1. Un modelo que soporta la situación descrita viene dado por:

$$v_{ij} = \beta_0 + \beta_1 \delta(\text{cuartos}_j) + \beta_2 \delta(\text{semis}_j) + \beta_3 \delta(\text{final}_j) + \beta_4 \text{distancia}_{ij} + \beta_5 \text{distancia}_{ij}^2 + \beta_6 \delta(\text{ArgBra}_j)$$

Al respecto, es útil comentar algunos puntos:

1. En este modelo la asistencia diferenciada por etapa queda incluida a través de variables dummies (una etapa debe excluirse por identificación). Alternativamente, podría crearse una variable $NumEtapa_{ij}$ que tome el valor 1 para grupos, 2 para cuartos, 3 para semis y 4 para la final e ingresarse directamente en la definición de la utilidad. Notar sin embargo que esto asume un aumento lineal.
2. En esta especificación se propone una forma polinomial flexible para el efecto de la distancia. Si por ejemplo se asume una forma logarítmica se debiera explicar porque se espera que la distancia tenga efectos decrecientes.
2. Basta reemplazar la especificación anterior con los datos de la tabla. Sean:

$$w_1 = \beta_0 + \beta_4 \times 5.5 + \beta_5 \times 5.5^2$$

$$w_2 = \beta_0 + \beta_1 + \beta_4 \times 474 + \beta_5 \times 474^2 + \beta_6$$

Entonces, la contribución a la log-verosimilitud viene dada por:

$$LL = \ln \left(\frac{1}{1 + e^{w_1}} \right) + \ln \left(\frac{e^{w_2}}{1 + e^{w_2}} \right)$$

3. Las probabilidades de los números de partidos en la segunda etapa vienen dados directamente por:

$$p_{1|A} = \frac{e^{v_1}}{e^{v_1} + e^{v_2} + e^{v_3}}$$

$$p_{2|A} = \frac{e^{v_2}}{e^{v_1} + e^{v_2} + e^{v_3}}$$

$$p_{3|A} = \frac{e^{v_3}}{e^{v_1} + e^{v_2} + e^{v_3}}$$

Finalmente, la decisión de si abonarse o no, viene dada por:

$$p_a = \frac{e^{\lambda IV - \text{Precio}_{Abono}}}{1 + e^{\lambda IV - \text{Precio}_{Abono}}}$$

donde el valor inclusivo viene dado por $IV = \ln(e^{v_1} + e^{v_2} + e^{v_3})$.

4. Aunque se puede elaborar más, es importante reconocer al menos dos factores:
 - Los términos de la diagonal son crecientes indicando que la utilidad del tercer partido tiene mayor variabilidad que el segundo y este más que el primero.
 - El 0 en la esquina superior derecha indica que no hay correlación entre las componentes no observables del primer con el tercer partido.

Problema 11: Agencia de medios

En cada periodo t , una agencia de medios está encargada de seleccionar los soportes publicitarios en que se emitirán las campañas de cada uno de sus K clientes de acuerdo a los requerimientos que ellos indiquen. Por ejemplo una marca puede indicar que quiere distribuir su presupuesto para que las piezas publicitarias sean exhibidas solo en TV o en una mezcla de radio y vallas públicas. Aunque cada cliente puede requerir presencia en cualquier tipo de medio, el 86% de los clientes elige en alguno de los siguiente paquetes:

- **Masivo multimedia:** en este paquete la agencia se compromete a alcanzar un cierto nivel de GRP para lo cuál puede hacer uso de cualquier medio. Los promedios históricos sugieren que un 40% se gasta en TV, un 25% en prensa escrita, un 20% en radio y un 10% en medios digitales.
 - **Nicho multimedia:** en este paquete la agencia se compromete a alcanzar un cierto nivel de GRP, pero concentrado en medios especializados. Así, dependiendo del rubro, la marca puede elegir entre algunas de las variantes temáticas disponible como deportes, infantil, outdoors, entre otros.
 - **Nicho radio y escrito:** Similar al paquete Nicho multimedia, pero restringiendo la parrilla a prensa escrita y a radio. A raíz de esta restricción el paquete conlleva un importante descuento en el precio.
 - **Solo online:** En este paquete, todo el avisaje se realiza a través de medios digitales incluyendo sponsored links, banners y sitios de redes sociales. Junto con el bajo costo del paquete, esta propuesta permite menor granularidad en la selección de los segmentos objetivos y un incipiente módulo de analytics para reportar la efectividad de la propuesta.
1. Escriba la utilidad total (determinista y aleatoria) que cada cliente k deriva por la elección de cada alternativa i en cada periodo t , considerando que:
 - Marcas de distintas industrias tienen distintas valoraciones intrínsecas por cada paquete. Por ejemplo, la industria bancaria tiene una gran valoración por el paquete Masivo Multimedia, mientras que los proveedores de servicios tecnológicos prefieren el Solo online.
 - Cada paquete i tiene una fracción de su GRP en el segmento ABC1 (F_{ABC1i}) y la valoración que cada cliente k tiene respecto este por-

centaje depende tanto de la penetración de la marca (PEN_{kt}) cómo de su coeficiente de exclusividad (EX_k) los que son definidos por una consultora externa.

- Considerando la baja sofisticación técnica de la industria y que existen costos relevantes en la evaluación de cada propuesta, en la práctica se evidencia una alta inercia en la elección del mix de medios (i.e, marcas tienden a elegir lo que han elegido en periodos anteriores).
2. Derive una expresión para la probabilidad que cada cliente elija cada alternativa. Para eso, considere que el paquete Solo online solo estuvo disponible en un set de semanas τ .
 3. Escriba la log-verosimilitud del problema si existen dos clases latentes. Escriba de modo que todos los parámetros puedan ser estimados directamente a través de la maximización irrestricta de la log-verosimilitud.
 4. Al estimar el modelo anterior con dos clases, el tamaño de la primera clase queda determinado por $\lambda = 0$, estimado directamente de la maximización de la log-verosimilitud. ¿Qué fracción de clientes pertenece a la clase 2?
 5. Se propone un modelo mixed logit. Para estimarlo se implementa el método de la máxima verosimilitud simulada con tres simulaciones por iteración ($R = 3$). La tabla describe los valores de la última iteración para el periodo 53 para el cliente 114. ¿Cuál es la probabilidad que dicho cliente elija Nicho Multimedia en dicho periodo?

Table 3.12: Valores de la última iteración para el periodo 53 para el cliente 114.

Paquete	R=1	R=2	R=3
Masivo multimedia	0.3	0.3	0.4
Nicho multimedia	0.2	0.3	0.3
Nicho radio y escrito	0.4	0.3	0.2
Solo online	0.1	0.1	0.1

Ver solución

1. Sea $y_{ikt} = 1$ si el cliente k elige el paquete i en la semana t y $\delta_{kj} = 1$ si el cliente k pertenece al rubro j . Entonces, la utilidad total viene dada por $u_{ikt} = v_{ikt} + \varepsilon_{ikt}$ donde ε_{ikt} distribuye valor extremo tipo I y v_{ikt} viene dada por:

$$v_{ikt}(\beta) = \sum_j \beta_{ikj} \delta_{kj} + \gamma_{kt} F_{ABC1ikt} + \omega y_{ikt-1}$$

$$v_{ikt}(\beta) = \sum_j \beta_{ikj} \delta_{kj} + (\gamma_0 + \gamma_1 PEN_{kt} + \gamma_2 EX_k) F_{ABC1ikt} + \omega y_{ikt-1}$$

2. Aplicamos directamente la fórmula del logit, con la única salvedad que el conjunto de alternativas difiere en algunos casos:

$$p_{ikt}(\beta) = \begin{cases} 0 & t \notin \tau \wedge i = 4 \\ \frac{\exp(v_{ikt}(\beta))}{\sum_{j=1}^3 \exp(v_{jkt}(\beta))} & t \notin \tau \wedge i < 4 \\ \frac{\exp(v_{ikt}(\beta))}{\sum_{j=1}^4 \exp(v_{jkt}(\beta))} & t \in \tau \end{cases}$$

3. Escribimos directamente:

$$LL(\beta_1, \beta_2, \lambda) = \sum_k \sum_i \sum_t y_{ikt} \left[\frac{\exp(\lambda)}{1 + \exp(\lambda)} \ln(p_{ikt}(\beta_1)) + \frac{1}{1 + \exp(\lambda)} \ln(p_{ikt}(\beta_2)) \right]$$

4. La probabilidad de pertenecer al segmento 2 viene dada por:

$$s_2 = \frac{1}{1 + \exp(\lambda)} = \frac{1}{2}$$

5. Simplemente tomamos el promedio de las 3 muestras:

$$p_{ikt} = \frac{1}{R} \sum_r p_{ikt}^r = \frac{0.2 + 0.3 + 0.3}{3} = 0.2667$$

Problema 12: Cupones de supermercado

Una conocida cadena supermercadista ha lanzado una campaña de descuentos a través de cupones de descuento para así aumentar el volumen de ventas totales de la cadena. La campaña consiste en enviar cupones personalizados a la base de clientes que ha comprado al menos una vez en los últimos seis meses. Aunque a nivel agregado la campaña parece haber tenido un efecto positivo en incentivar la demanda, la evaluación de la campaña requiere una descripción más fina de quién usa los descuentos y cuál es el descuento efectivo que está recibiendo cada cliente. Para esto, la compañía ha preparado una base de datos con las transacciones de todos los clientes que recibieron los cupones la cual tiene las siguientes variables:

Table 3.13: Descripción de la Base de Datos de Supermerca2

Variable	Descripción
customer_id	Identificador de cliente
item_id	Identificador de producto
selling_price	Precio de venta
other_discount	Otros Descuentos (no considerados en el cupón)
coupon_discount	Descuentos asociados al cupón
age_range	Rango de edad del cliente
family_size	Número de integrantes en el grupo familiar
category	Categoría del producto
brand_type	Tipo de marca del producto (si tiene presencia nacional o solo local)
redemption	1 si canjeó el producto (0 si no)

Para ayudarle a visualizar el contenido de la base, en la Tabla 3.14 se presenta una muestra de los datos para las variables seleccionadas para realizar este estudio.

Table 3.14: Muestra de datos

customer_id	item_id	selling_price	other_discount	coupon_discount	age_range	family_size	category	brand_type	redemption
857	12424	106.50	14.25	0	70+	1	Grocery	Established	0
857	14930	110.07	0.00	0	70+	1	Meat	Established	0
857	16657	89.05	35.26	0	70+	1	Packaged	Established	0
67	10537	32.06	0.00	0	36-45	2	Meat	Established	0
67	19560	106.86	2.85	0	36-45	2	Grocery	Local	0

La compañía está interesada en ver qué factores inciden en que un cliente use un cupón de descuento y cuánto es el descuento final que está siendo descontado para cada cliente. Aunque el cupón de descuento tiene un monto bien definido, existen interacciones con otras reglas del negocio que dificultan anticipar cuál es el monto efectivo de los descuentos. Por ejemplo, existe un número máximo de productos a los que puede aplicarse el producto y por tanto los clientes pueden elegir sobre qué producto aplicar el descuento. Además, existen algunas promociones de algunos productores específicos que no pueden aplicarse simultáneamente con los descuentos de la cadena supermercadista.

Para estudiar este problema se ha propuesto dos enfoques de solución. Primero un enfoque independiente en que la probabilidad de canjear un cupón se describe como un modelo probit y luego el monto del descuento se describe como un modelo de regresión lineal. El segundo enfoque combina la decisión de usar el cupón y el monto descontado en un único modelo tobit en dos etapas. Los resultados de estos modelos se resumen en la Tabla 3.15.

```
# probit
rmodel.glm <- glm(redemption ~ selling_price + age_range + family_size +
  brand_type + other_discount - 1,
  family = binomial("probit"), data = coupon.data)

# linear regression
rmodel.ols <- lm(coupon_discount ~ selling_price + age_range + family_size +
  brand_type + other_discount - 1,
  data = subset(coupon.data, redemption > 0))

# tobit
rmodel.2s <- selection(redemption ~ selling_price + age_range + family_size +
  brand_type + other_discount - 1,
  coupon_discount ~ selling_price + age_range +
  family_size + brand_type + other_discount - 1,
  data = coupon.data, method = "2step")
```

Table 3.15: Resultados Modelos Tobits e independientes

Variable	(1)	(2)	(3)	(4)
	redemption	coupon_discount	redemption selection	coupon_discount outcome
selling_price	0.001*** (0.0003)	0.129*** (0.006)	0.001*** (0.0003)	0.146*** (0.017)
age_range18-25	-0.163 (0.326)	18.336* (10.466)	-0.163 (0.319)	-6.235 (24.365)
age_range26-35	-1.292*** (0.147)	17.275*** (5.006)	-1.292*** (0.145)	-28.486 (40.303)
age_range36-45	-0.839*** (0.103)	17.677*** (3.382)	-0.839*** (0.100)	-19.950 (32.956)
age_range46-55	-0.270*** (0.088)	17.818*** (2.836)	-0.270*** (0.087)	-9.050 (23.565)
age_range56-70	-0.266 (0.179)	13.177** (5.365)	-0.266 (0.178)	-13.858 (24.295)
age_range70+	-0.335 (0.211)	33.918*** (7.429)	-0.335 (0.211)	5.343 (26.055)
family_size2	-0.066 (0.098)	-3.197 (3.380)	-0.066 (0.097)	-4.419 (3.905)
family_size3	0.791*** (0.151)	-11.326** (4.482)	0.791*** (0.149)	3.088 (13.580)
family_size4	0.996*** (0.150)	-7.769* (4.523)	0.996*** (0.150)	10.370 (16.666)
family_size5+	-0.004 (0.110)	-2.768 (3.747)	-0.004 (0.110)	-2.558 (4.183)
brand_typeLocal	-1.127*** (0.118)	31.243*** (5.467)	-1.127*** (0.118)	8.376 (20.663)
other_discount	0.005*** (0.001)	-0.008 (0.025)	0.005*** (0.001)	0.070 (0.074)
Observations	1,492	544	1,492	1,492
R ²		0.718		
Adjusted R ²		0.711		
Log Likelihood	-820.572			
Akaike Inf. Crit.	1,667.143			
rho			0.800	0.800
Inverse Mills Ratio			28.411 (24.596)	28.411 (24.596)
Residual Std. Error		27.784 (df = 531)		
F Statistic		103.838*** (df = 13; 531)		

Nota: * $p < 0.1$; ** $p < 0.05$; *** $p < 0.01$

1. Compare columnas (2) y (4) y discuta por qué se observan diferencias entre ambos modelos. Concluya cuál es el rol que juega el comprar una marca local y la existencia de otros descuentos.
2. Interprete en palabras simples los resultados de ρ .
3. Proponga y justifique al menos dos mejoras a los modelos planteados y explique qué espera que pase al introducir dicha mejora.

Ver solución

1. Se observan diferencias porque en el modelo (4) se incluye un factor adicional (Inverse Mills Ratio) que captura la correlación entre ambas ecuaciones. En general, los coeficientes de los modelos independientes pueden estar sesgados al no capturar que los montos no observados no son aleatorios.

Respecto a las dos variables que se preguntan:

- El efecto de local en la probabilidad de usar el cupón es negativo, pero no significativo en el monto de acuerdo al modelo tobit (que

corrige por sesgo de selección).

- El efecto de otros descuentos en la probabilidad de usar el cupón es positivo, pero no significativo en el monto de acuerdo al modelo tobit (que corrige por sesgo de selección).
2. En el modelo $\rho = 0.8$ y por tanto hay una correlación positiva entre los errores asociados al uso del cupón y el monto. Podemos suponer que hay un factor no observable que hace que aquellos que sean más probables de usar el cupón también obtengan descuentos mayores en magnitud.
 3. Las mejoras son infinitas, pero algunas para fijar ideas:
 - **Agregar la categoría tanto a la ecuación de incidencia.** Es esperable que los clientes usen los cupones en algunas categorías más que en otras.
 - **Agregar un efecto fijo de cliente tanto en las ecuaciones de incidencia como de monto** (y sacar edad y tamaño del hogar porque no sería identificable). Es esperable que algunos individuos sean más propensos a usar los cupones y generar descuentos mayores.
 - **Sacar el tipo de marca de la ecuación de monto.** Como ya controlamos por el precio, probablemente el tipo de marca no nos aporte mucho.

Problema 13: ViajesDII

Suponga que tras una sucesión de confusos incidentes, usted termina siendo el presidente de la lista 1 y gana el centro de estudiantes del departamento. Una de sus primeras acciones como presidente fue la creación de “ViajesDII”, una iniciativa que ofrece paquetes de viajes a sus compañeros. Antes de lanzar oficialmente la agencia, desea entender cómo las características de los destinos podrían influir en las preferencias de sus compañeros y así poder elegir la oferta de destinos. Para esto, decide recopilar datos de posibles clientes a través de una encuesta realizada a toda la comunidad universitaria, la cual incluye preguntas demográficas, el costo del viaje, la disponibilidad de actividades recreativas, de tal manera que la utilidad para un individuo n que elige la opción de viaje i en el día t está dada por:

$$v_{nit} = \beta_i + \beta_{gen} \cdot Genero_n + \beta_{edad} \cdot Edad_n + \beta_{precio} \cdot Precio_{it} + \beta_{act} \cdot Actividades_{it}$$

1. Plantee un modelo logit tal que describa el comportamiento de las personas encuestadas en relación a la opción de viaje elegida. Suponga que existen I alternativas de viaje y que cada día se encuestaron a N_t personas. Escriba la log-verosimilitud del modelo.

2. Si se utilizara un modelo probit, ¿qué dimensión tendría la matriz de varianza-covarianza? ¿Cómo podría aproximarse la probabilidad de elección del destino i para un individuo n en el día t ?
3. Suponga que la iniciativa ha sido tan exitosa que se definió el programa de lealtad “MillasDII”, donde los clientes acumulan puntos que luego pueden ser canjeados como viajes gratis. Para ello, suponga que tiene una base de datos de los clientes por año con la siguiente estructura:

Table 3.16: Lista de datos de actividad de clientes.

id_cliente	Año	Actividad_Cliente	Canjea_Millas	Millas_disp	Expiró
1	2026	2	0	0	0
1	2027	2	0	0	0
2	2025	3	0	0	0
2	2026	3	0	0	0
2	2027	3	1	500	0
3	2025	1	0	0	0

Usted busca evaluar la incidencia en el uso del programa y si efectivamente tiene impacto en la cantidad de viajes vendidos, a partir de un modelo Tobit tipo II. Defina el modelo utilizando $CanjeaMillas_{nt}$ como función de activación, $MillasDisp_{nt}$ como variable latente y las demás columnas como variables explicativas.

Ver solución

1. El modelo logit, que en este caso es multiclase, define la probabilidad de que el individuo n elija la opción i en el periodo t como:

$$P_{nit} = \frac{\exp(v_{nit})}{\sum_{j \in I} \exp(v_{njt})}$$

Luego la función Log-verosimilitud está dada por:

$$LL(\beta) = \sum_{i \in I} \sum_{t \in T} \sum_{n \in N_t} y_{nit} \cdot \ln(P_{nit})$$

donde $y_{nit} = 1$ si el individuo n eligió la opción i en el día t y 0 en caso contrario.

2. La matriz de varianzas-covarianzas debe ser una matriz de igual número de filas como de columnas, y por tratarse de que asumimos una distribución normal multivariada, la matriz es simétrica, en la cual la diagonal representa la varianza del error de cada alternativa y los elementos fuera de la diagonal representan la covarianza entre alternativas. Por lo que debe tener dimensión $I \times I$.

El modelo probit se puede aproximar tomando una muestra aleatoria de R muestras de la componente estocástica de la utilidad ε_{nit} :

$$P_{nit} \approx \frac{1}{R} \sum_{r=1}^R \mathbb{1}[\varepsilon_{njt}^r - \varepsilon_{nit}^r < v_{nit} - v_{njt}, \forall j \neq i]$$

3. Para modelar un Tobit tipo II es necesario definir las dos etapas. Sea g el grupo de actividad al que pertenece cada individuo, entonces las etapas del Tobit se definen como:

Etapas 1 - Ecuación de Selección: La función de activación (si canjea millas o no) se activará solo cuando la utilidad del canje sea mayor a 0:

$$CanjeaMillas_{nt} = \begin{cases} 1 & \text{si } \sum_g \beta_g^{Canje} \cdot \mathbb{1}[n \in grupo_g] + \gamma^{Canje} \cdot Expiro_{nt} + \varepsilon_{n1} > 0 \\ 0 & \text{en caso contrario} \end{cases}$$

Etapas 2 - Ecuación de Resultado: Las millas generarán utilidades para los individuos cuando la selección sea positiva:

$$MillasDisp_{nt} = \begin{cases} \sum_g \beta_g^{Millas} \cdot \mathbb{1}[n \in grupo_g] + \gamma^{Millas} \cdot Expiro_{nt} + \varepsilon_{n2} & \text{si } CanjeaMillas_{nt} = 1 \\ 0 & \text{en caso contrario} \end{cases}$$

donde $(\varepsilon_{n1}, \varepsilon_{n2})$ siguen una distribución normal bivariada con correlación ρ , lo que permite capturar la dependencia entre la decisión de canjear y el monto de millas disponibles.

Problema 14: Brebajes

Tradicionalmente, después de un largo periodo de evaluaciones, los estudiantes de un lejano país suelen juntarse a celebrar y compartir experiencias de aprendizaje. Para ello es costumbre que cada estudiante se presente al lugar de reunión con algún brebaje frutal, siendo frutilla (F) y naranja (N) las alternativas más frecuentemente elegidas. Recientemente ha surgido además una nueva tendencia de llevar jugo de cranberries (C).

Para la compra de los brebajes, los potenciales clientes tienen básicamente dos alternativas: supermercado (S) y tienda de conveniencia (C) que difieren en precios, disponibilidad de surtido y tiempo de compra. Mientras el supermercado cobra precios menores y dispone de jugo de cranberries que no está disponible en la tienda de conveniencia, al mismo requiere un tiempo de compra significativamente mayor. Interesados en describir el proceso de compra, un grupo de investigadores ha propuesto usar un modelo logit anidado en que primero se decide el lugar de compra y condicional en él, la variedad de brebaje a adquirir.

1. Discuta:

- a. ¿Son las decisiones realmente anidadas? Si no lo son, ¿puede usarse un modelo anidado?
 - b. ¿Qué restricciones a los patrones de substitución impone la descripción propuesta?
2. Sea α_f y α_c las valoraciones intrínsecas por los sabores frutilla y cranberries (por motivos de identificación se ha fijado en 0 la valoración intrínseca de por sabor naranja) y t_i y p_{ji} los tiempos de compra y precios en la tienda tipo i ($i \in \{S, C\}$ y $j \in \{N, F, C\}$). Con esto y asumiendo una utilidad lineal, derive la probabilidad de elegir cada sabor condicional en la elección de tienda.
 3. Derive la probabilidad de elección de tienda.
 4. Si se observa y_{nij} que toma el valor 1 si el tomador de decisión n elige comprar el sabor j en la tienda tipo i para una muestra de $N = 452$ clientes, derive la log-verosimilitud del problema.

Ver solución

1. Discusión:
 - a. Las decisiones no son realmente anidadas y es probable que muchos clientes elijan de manera conjunta y no secuencial. Por ejemplo, pueden escoger según el tipo de fruta y luego preocuparse sobre el lugar donde comprar. Sin embargo, este es un modelo de comportamiento y como tal puede ayudar a entender cómo los clientes toman decisiones.
 - b. En esencia, los patrones de substitución siguen siendo proporcionales dentro de cada nido, pero no entre nidos. Los patrones de substitución indican que la persona priorizará escoger un producto que venda el mismo supermercado o tienda de conveniencia, en lugar de cambiarse de sitio.
2. Para el caso del supermercado las componentes determinísticas de la utilidad vienen dadas por:

$$v_{NS} = \beta_t t_S + \beta_p p_{NS}$$

$$v_{FS} = \alpha_f + \beta_t t_S + \beta_p p_{FS}$$

$$v_{CS} = \alpha_c + \beta_t t_S + \beta_p p_{CS}$$

Luego, las probabilidades de elección vienen dadas por:

$$p_{N|S} = \frac{\exp(v_{NS})}{\exp(v_{NS}) + \exp(v_{FS}) + \exp(v_{CS})}$$

$$p_{F|S} = \frac{\exp(v_{FS})}{\exp(v_{NS}) + \exp(v_{FS}) + \exp(v_{CS})}$$

$$p_{C|S} = \frac{\exp(v_{CS})}{\exp(v_{NS}) + \exp(v_{FS}) + \exp(v_{CS})}$$

Similarmente, para el caso de la tienda de conveniencia las componentes determinísticas de la utilidad vienen dadas por:

$$v_{NC} = \beta_t t_C + \beta_p p_{NC}$$

$$v_{FC} = \alpha_f + \beta_t t_C + \beta_p p_{FC}$$

y luego, las probabilidades de elección vienen dadas por:

$$p_{N|C} = \frac{\exp(v_{NC})}{\exp(v_{NC}) + \exp(v_{FC})}$$

$$p_{F|C} = \frac{\exp(v_{FC})}{\exp(v_{NC}) + \exp(v_{FC})}$$

3. Para calcular la probabilidad de elección de tienda necesitamos calcular los valores inclusivos, los que vienen dados por:

$$I_S = \ln(\exp(v_{NS}) + \exp(v_{FS}) + \exp(v_{CS}))$$

$$I_C = \ln(\exp(v_{NC}) + \exp(v_{FC}))$$

Luego, las probabilidades de elección vienen dadas por:

$$p_S = \frac{\exp(I_S)}{\exp(I_S) + \exp(I_C)}, \quad p_C = \frac{\exp(I_C)}{\exp(I_S) + \exp(I_C)}$$

4. La probabilidad de comprar cada sabor en cada tienda es simplemente el producto de las dos probabilidades anteriores. Por lo tanto la log-verosimilitud viene directamente dada por:

$$LL = \sum_n \sum_i \sum_j y_{nij} \ln(p_{j|i} p_i)$$

Problema 15: Toallas absorbentes

Para entender la estructura de la categoría de toallas absorbentes, un retailer ha decidido estudiar las compras de las dos marcas principales, las que denominaremos A y B. Para este estudio se ha identificado que la heterogeneidad de las preferencias constituye un elemento fundamental y por tanto se ha decidido usar un modelo mixed logit. Preliminarmente, se ha propuesto que la utilidad del individuo n por la marca $i \in \{A, B\}$ queda bien representada por un intercepto y un coeficiente precio:

$$u_{ni} = \alpha_{ni} + \beta_n p_i + \varepsilon_{ni}$$

donde ε_{ni} se distribuyen valor extremo y $\alpha_{nA} = 0$ para identificar el problema. Además, la heterogeneidad se ha modelado con una distribución normal multivariada $(\alpha_{nB}, \beta_n) \sim N((\alpha_B, \beta), \Sigma)$.

1. Proponga una expresión para la log-verosimilitud del problema.

Utilizando datos transaccionales históricos de la categoría, se han estimado los siguientes valores y H la matriz hessiana de la log-verosimilitud:

$$\begin{pmatrix} \hat{\alpha}_B \\ \hat{\beta} \end{pmatrix} = \begin{pmatrix} 4.2 \\ -3.7 \end{pmatrix} \quad \hat{\Sigma} = \begin{pmatrix} 1.32 & 0.0 \\ 0.0 & 8.35 \end{pmatrix}$$

$$H(\hat{\theta})^{-1} = \begin{pmatrix} 1.8 & 1.4 & -0.7 & 0.1 \\ 1.4 & 1.1 & 3.2 & 0.3 \\ -0.7 & 3.2 & 0.2 & -0.2 \\ 0.1 & 0.3 & -0.2 & 1 \end{pmatrix}$$

donde $\hat{\theta} = (\hat{\alpha}_B, \hat{\beta}, \hat{\sigma}_{11}, \hat{\sigma}_{22})$ es el vector con los estimadores máximo verosímiles. Considerando estos valores y los puntajes-z de una distribución normal estándar disponibles en la tabla siguiente, responda:

z	-1.65	-1.28	-0.84	-0.53	-0.25	0.00
Pr(x ≤ z)	0.05	0.1	0.2	0.3	0.4	0.5

2. Construya el intervalo de confianza para β . Indique si es significativo al 10% e interprete sus resultados.
3. ¿Cuál es la probabilidad que un individuo cualquiera tenga un coeficiente de precio positivo?

Ver solución

1. Las probabilidades de elección condicionales a los parámetros aleatorios (α_{nB}, β_n) son:

$$P_{nA|(\alpha_{nB}, \beta_n)} = \frac{\exp(\beta_n p_A)}{\exp(\beta_n p_A) + \exp(\alpha_{nB} + \beta_n p_B)}$$

$$P_{nB|(\alpha_{nB}, \beta_n)} = \frac{\exp(\alpha_{nB} + \beta_n p_B)}{\exp(\beta_n p_A) + \exp(\alpha_{nB} + \beta_n p_B)}$$

Como $(\alpha_{nB}, \beta_n) \sim N((\alpha_B, \beta), \Sigma)$, las probabilidades incondicionales se obtienen integrando respecto de la densidad normal bivariada:

$$P_{nA} = \int_{\mathbb{R}^2} P_{nA|(\alpha_{nB}, \beta_n)} \phi((\alpha_{nB}, \beta_n) | (\alpha_B, \beta), \Sigma) d\alpha_{nB} d\beta_n$$

$$P_{nB} = \int_{\mathbb{R}^2} P_{nB|(\alpha_{nB}, \beta_n)} \phi((\alpha_{nB}, \beta_n) | (\alpha_B, \beta), \Sigma) d\alpha_{nB} d\beta_n$$

donde $\phi(\cdot)$ es la densidad de la normal bivariada con media (α_B, β) y matriz de varianzas-covarianzas Σ .

La log-verosimilitud poblacional del modelo es entonces:

$$\ell = \sum_n (y_{nA} \ln P_{nA} + y_{nB} \ln P_{nB})$$

Como las integrales anteriores no tienen forma cerrada, se aproximan por simulación. Si tomamos R draws $(\alpha_{nB}^{(r)}, \beta_n^{(r)})$ de la $N((\alpha_B, \beta), \Sigma)$, las probabilidades simuladas son:

$$\hat{P}_{nA} = \frac{1}{R} \sum_{r=1}^R P_{nA|(\alpha_{nB}^{(r)}, \beta_n^{(r)})}$$

$$\hat{P}_{nB} = \frac{1}{R} \sum_{r=1}^R P_{nB|(\alpha_{nB}^{(r)}, \beta_n^{(r)})}$$

y la log-verosimilitud simulada que se maximiza es:

$$\hat{\ell} = \sum_n (y_{nA} \ln \hat{P}_{nA} + y_{nB} \ln \hat{P}_{nB})$$

- Podemos construir el intervalo de confianza IC directamente usando los valores de la normal estándar y el inverso del hessiano:

$$IC = [-3.7 - 1.65 \cdot \sqrt{1.1}, -3.7 + 1.65 \cdot \sqrt{1.1}] = [-5.43, -1.97]$$

Como $0 \notin IC$ entonces β es significativo. Esto quiere decir que con un 90% de posibilidades la media poblacional de los coeficientes de precio está en el rango $[-5.43, -1.97]$.

- De los resultados sabemos que $\beta_n \sim N(-3.7, 8.35)$. Por lo tanto, para calcular numéricamente $\Pr(\beta_n \leq 0)$ basta con estandarizar la variable normal (recordar que la distribución normal es simétrica):

$$\Pr(\beta_n \geq 0) = 1 - \Pr(\beta_n \leq 0) = \Pr\left(\frac{\beta_n - (-3.7)}{\sqrt{8.35}} \leq \frac{0 - (-3.7)}{\sqrt{8.35}}\right) = \Pr(z \leq 1.28) = 0.90$$

Problema 16: Agente concierge de IA

Los agentes de inteligencia artificial son sistemas que, apoyados en modelos de lenguaje, son capaces de interpretar una solicitud, razonar sobre ella y ejecutar acciones de manera autónoma para resolverla. En los últimos años, las empresas han comenzado a incorporarlos en la automatización de la atención y los servicios al cliente, donde permiten responder consultas, gestionar requerimientos y escalar los casos más complejos con una mínima intervención humana. Una empresa nacional, líder en el mercado de los seguros, ha implementado hace algunos meses un sistema basado en agentes de inteligencia artificial que ofrece atención automatizada al cliente. El sistema está implementado usando una arquitectura de agentes entrelazados, en la que distintos agentes especializados colaboran para resolver los requerimientos de los usuarios. En el centro

de esta arquitectura se encuentra un *agente concierge*, encargado de recibir los requerimientos iniciales y decidir cómo procesarlos. Para cada requerimiento que recibe, este agente debe tomar una de tres decisiones posibles: responder directamente al cliente, derivar el caso a otro agente especializado, o derivar el caso a un agente humano.

El equipo de diseño está interesado en describir el comportamiento del agente concierge, y así poder hacer ajustes al sistema para mejorar continuamente la evaluación que hacen los clientes de la calidad del servicio. Para eso, el equipo ha armado una base de datos que pueda servir de base para la estimación de modelos de elección discreta para caracterizar el comportamiento de los agentes. La base de datos registra cada atención junto con sus características, donde la decisión del agente puede tomar tres niveles: responder al cliente (responde), derivar a otro agente especializado (damente) y derivar a un agente humano (dhumano), como indica la Tabla 1.

Table 3.17: Muestra de la base de datos para la calibración de modelos de elección discreta. La tabla considera un identificador del cliente (IDcust), un identificador de la interacción (IDinter), la fecha (date), el género y la edad del usuario (gender, edad), el número de interacciones anteriores (npastint), el texto completo con el diálogo (dialogue), el largo del diálogo en número de caracteres (length) y la decisión del agente (output).

IDcust	IDinter	date	edad	npastint	dialogue	length	output
c001	001	01/03/26	23	0	Hola, quiero saber qué pasó con el ...	145	responde
c001	002	01/03/26	23	1	Buen día, escribo para que me indiquen ...	1345	responde
c002	001	01/04/26	56	0	Necesito entender dónde encuentro ...	845	responde
c003	001	01/06/26	49	0	Estoy muy molesto, llevo semanas esperando que...	1820	dhumano
c004	001	01/03/26	29	0	¿Cuál es el número de mi póliza de ...	210	responde
c004	002	01/08/26	29	1	Quisiera saber el estado de mi solicitud de ...	320	responde
c005	001	01/07/26	62	0	Necesito hablar con alguien urgente porque...	95	dhumano
c005	002	01/09/26	62	1	Quiero cotizar un seguro automotriz adicional ...	540	damente

Al explorar la base de datos, aparecen algunas regularidades que se ilustran en la Tabla 2. Por ejemplo, vemos que el agente concierge es capaz de resolver autónomamente la mayoría (83%) de los requerimientos. Más aún, si miramos qué pasa con el largo de los diálogos, en general los requerimientos que responde el agente tienden a ser más cortos y con menos dispersión en el largo. Estos elementos nos sugieren que un modelo de elección discreta podría tener bastante capacidad explicativa incluso considerando solo unas pocas covariables.

Table 3.18: Estadísticas descriptivas de las interacciones según la decisión del agente.

output	Largo		Largo (s.d.)	Interacc. previas (prom.)	Interacc. previas (s.d.)
	porcentaje	(prom.)			
responde	83%	318	176	0.8	1.1
damente	11%	742	351	1.6	1.4
dhumano	6%	1146	603	2.3	1.8

1. Proponga una función de utilidad para describir el comportamiento del

agente concierge en su interacción i con un cliente n , que considere los siguientes elementos:

- a. Hay efectos fijos por alternativa (responde, deriva a otro agente o a un humano).
 - b. El largo de la conversación con el agente importa. Se espera que, si el texto es corto, la probabilidad de derivar sea relativamente alta, que luego disminuya y que, si la conversación se alarga, la probabilidad de derivar vuelva a aumentar.
 - c. La edad y el número de interacciones previas del usuario también influyen en el comportamiento del agente.
 - d. La presencia de ciertas palabras clave podría ser un indicador de una alta probabilidad de derivación. Suponga que dispone de un algoritmo de procesamiento de texto que permite crear variables dummy para indicar la presencia de cada una de esas palabras.
2. Suponga que en la ecuación de utilidad se incluyen efectos fijos por alternativa (un intercepto por cada decisión del agente) y se fija el intercepto de la alternativa responder en cero como categoría base ($\alpha_{\text{responde}} = 0$). ¿Qué signo espera observar para los interceptos de las otras dos alternativas, derivar a agente y derivar a humano? Justifique su respuesta.
 3. Suponga que en un instante t^* se modificó el prompt de orquestación del agente para sugerir que “si necesitas derivar a los clientes con mayor historial de interacciones, dévalos siempre a un humano”. ¿Cómo cambia el modelo propuesto en la pregunta anterior para incorporar este cambio?
 4. Suponga que se introduce heterogeneidad mediante un modelo muy sencillo con dos clases latentes de igual tamaño y funciones de utilidad que solo tienen efectos fijos por alternativa de decisión. Suponga además que se estima el modelo y, manteniendo responder como el nivel base, se encuentra que para la primera clase $(\alpha_{\text{agente}}^1, \alpha_{\text{humano}}^1) = (0, 1)$ mientras que para la segunda clase $(\alpha_{\text{agente}}^2, \alpha_{\text{humano}}^2) = (1, 0)$. Demuestre que la verosimilitud de observar dos observaciones en que la decisión del agente sea responder viene dada por $p = \left(\frac{1}{2+e}\right)^2$.
 5. Disconforme con la solución de clases latentes, se postula correr un modelo logit heterogéneo a través del siguiente código computacional, cuyos resultados se despliegan en la Tabla 3.

```
agente <- mlogit(decision ~ length + keyword1 + keyword2, data = dataconcierge,
  rpar = c(keyword1 = 'n', keyword2 = 'n'), correlation = FALSE)
```

Table 3.19: Resultados de la estimación del modelo logit heterogéneo.

	Mixed Logit
Deriva agente	-1.245 **
Deriva humano	-2.876 ***
Length	0.532 ***
Keyword1	1.234 ***
Keyword2	0.876 **

	Mixed Logit
Sd(keyword1)	1.645 ***
Sd(keyword2)	0.312 *
Num. Obs.	24137
AIC	41082
RMSE	0.318
McFadden R2	0.0241

¿Cómo interpreta que la desviación estándar estimada del parámetro de keyword1 sea mayor que la de keyword2?

- Si quisiera usar modelos de machine learning en este contexto, ¿qué haría para intentar reducir los errores de pronóstico de este tipo de enfoque en este contexto específico?

Ver solución

- Sea K el conjunto de keywords y δ_{nik} una variable dummy que toma el valor 1 si la keyword $k \in K$ está incluida en el texto de la interacción i del cliente n . Entonces la función de utilidad del agente con respecto a la decisión d , en la interacción n del cliente i , puede escribirse como:

$$u_{nid} = \alpha_d + \beta_1 \text{length}_{ni} + \beta_2 \text{length}_{ni}^2 + \beta_3 \text{edad}_i + \beta_4 \text{npastint}_{in} + \sum_{k \in K} \gamma_k \delta_{nik}$$

Acá, el largo del texto considera un término cuadrático para capturar la no linealidad del efecto del largo (de acuerdo a la descripción debíamos esperar $\beta_1 < 0$ y $\beta_2 > 0$).

Nota: En esta especificación, β_1 y β_2 no dependen de la alternativa. De acuerdo a la descripción del problema es perfectamente esperable que algunos puedan proponer que el largo afecta de forma distinta para cada alternativa y por tanto hacer que los coeficientes dependan de la alternativa (β_{1d} y β_{2d}).

- Responder es por lejos la decisión más frecuente y por tanto debíamos esperar que $\alpha_{\text{dagente}}, \alpha_{\text{dhumano}} < 0$.
- Habría que definir un indicador post_{ni} que tome el valor 1 si la fecha de la interacción ocurre después de t^* y agregarlo al modelo.

$$u_{nid} = \dots + \beta_5 \text{post}_{ni} + \beta_6 \text{post}_{ni} \cdot \text{npastint}_{in}$$

Nota 1: Como en el problema anterior, también podríamos hacer depender el parámetro de la decisión (β_{6d}).

Nota 2: La pregunta se debía haber formulado como “cambia el modelo propuesto en la primera pregunta”. En el fraseo impreso, se puede interpretar que se hace referencia a la segunda pregunta. Si lo consideraran así, entonces dos respuestas admisibles son:

- Después del cambio la probabilidad de derivar a los humanos debiera aumentar y por tanto α_{humano} debiera hacerse menos negativa (o incluso positiva).
- Hay una probabilidad intrínseca distinta antes que después del cambio y por tanto habría que tener interceptos distintos para el periodo antes y después.

4. La probabilidad de responder puede escribirse como:

$$\Pr(\text{responder}) = \frac{1}{2} \left(\frac{1}{1 + e^{\alpha_{\text{dagente}}^1} + e^{\alpha_{\text{humano}}^1}} \right) + \frac{1}{2} \left(\frac{1}{1 + e^{\alpha_{\text{dagente}}^2} + e^{\alpha_{\text{humano}}^2}} \right) = \frac{1}{2 + e}$$

Entonces la verosimilitud (L) viene dada por:

$$\begin{aligned} L &= \Pr(\text{responder})^1 \Pr(\text{dagente})^0 \Pr(\text{humano})^0 \cdot \Pr(\text{responder})^1 \Pr(\text{dagente})^0 \Pr(\text{humano})^0 \\ &= \left(\frac{1}{2 + e} \right)^2 \end{aligned}$$

5. Las desviaciones reportadas corresponden a la variación de la distribución normal subyacente que describe la heterogeneidad en la valoración/importancia que tienen esas dos keywords. Que $\text{sd}(\text{keyword1}) > \text{sd}(\text{keyword2})$ implica que la primera keyword tiene más variabilidad en su influencia que la segunda keyword. En otras palabras, keyword2 parece tener una influencia relativamente homogénea para todas las conversaciones mientras la keyword1 puede significar distintas cosas en distintas conversaciones.
6. La respuesta es abierta pero la idea principal es que los modelos de ML funcionan mejor en capturar efectos no lineales complejos cuando hay muchos datos. En este caso, el texto del diálogo tiene información potencialmente muy rica que no estamos usando (más allá de la longitud y la aparición de algunas palabras clave). Para sacar el mayor provecho a un modelo de ML habría que hacer *feature engineering* para generar más variables a partir de los textos. Otras ideas que podrían aparecer y que podrían tener mérito:
- Definir correctamente los conjuntos de entrenamiento y de testeo para evitar el sobreajuste.
 - Hacerse cargo del desbalance de clases que favorece la alternativa de responder.

A. Fórmulas útiles

- Modelo geométrico desplazado:

$$P(T = t|\theta) = \theta(1 - \theta)^{t-1}$$

$$P(T > t|\theta) = (1 - \theta)^t$$

- Modelo beta geométrico desplazado:

$$\mathbb{P}(T = t \mid \alpha, \beta) = \frac{B(\alpha + 1, t + \beta - 1)}{B(\alpha, \beta)}$$

$$\mathbb{P}(T > t \mid \alpha, \beta) = \frac{B(\alpha, t + \beta)}{B(\alpha, \beta)}$$

- Modelo de duración exponencial:

$$P(T \leq t) = 1 - e^{-\lambda t}$$

$$P(T > t) = e^{-\lambda t}$$

- Modelo gamma exponencial:

$$\mathbb{P}(T \leq t) = 1 - \left(\frac{\alpha}{\alpha + t} \right)^r$$

- Modelo de duración Weibull:

$$P(T \leq t) = 1 - e^{-\lambda t^c}$$

$$\mathbb{P}(T \leq t \mid \alpha, r, c) = 1 - \left(\frac{\alpha}{\alpha + t^c} \right)^r$$

- Modelo de conteo:

$$P(N_t = m|\lambda) = \frac{(\lambda t)^m e^{-\lambda t}}{m!}$$

- Modelo gamma Poisson:

$$\mathbb{P}(N_t = m \mid r, \alpha) = \left(\frac{\alpha}{\alpha + t} \right)^r \left(\frac{t}{\alpha + t} \right)^m \frac{\Gamma(r + m)}{\Gamma(r)m!}$$

- Modelo de elección binomial:

$$P(X_s = x_s \mid m_s, p_s) = \binom{m_s}{x_s} p_s^{x_s} (1 - p_s)^{m_s - x_s}$$

- Modelo beta binomial:

$$\mathbb{P}(X_s = x_s \mid \alpha, \beta) = \binom{m_s}{x_s} \frac{B(\alpha + x_s, \beta + m_s - x_s)}{B(\alpha, \beta)}$$

- Esperanzas condicionales:

Table A.1: Esperanzas condicionales por tipo de modelo.

Modelo	Dist. incondicional	Dist. condicional	Esperanza cond.
Tiempo discreto	$\theta \sim \text{Beta}(\alpha, \beta)$	$\theta \mid t \sim \text{Beta}(\alpha + 1, \beta + t)$	$\frac{\alpha + 1}{\alpha + \beta + t}$
Tiempo continuo	$\lambda \sim \text{Gamma}(r, \alpha)$	$\lambda \mid t \sim \text{Gamma}(r + 1, \alpha + t)$	$\frac{r + 1}{\alpha + t}$
Conteo	$\lambda \sim \text{Gamma}(r, \alpha)$	$\lambda \mid x, t \sim \text{Gamma}(r + x, \alpha + t)$	$\frac{r + x}{\alpha + t}$
Elección binaria	$\theta \sim \text{Beta}(\alpha, \beta)$	$\theta \mid x \sim \text{Beta}(\alpha + x, \beta + m - x)$	$\frac{\alpha + x}{\alpha + \beta + m}$

- Distribución *Beta*:

$$f(x \mid \alpha, \beta) = \frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)}$$

$$\mathbb{E}(X) = \frac{\alpha}{\alpha + \beta}$$

$$\mathbb{V}ar(X) = \frac{\alpha\beta}{(\alpha + \beta)^2 (\alpha + \beta + 1)}$$

- Distribución *Gamma*:

$$f(x \mid r, \alpha) = \frac{\alpha^r x^{r-1} e^{-\alpha x}}{\Gamma(r)}$$

$$\mathbb{E}(X) = \frac{r}{\alpha} \quad \mathbb{V}ar(X) = \frac{r}{\alpha^2}$$

- Función *Gamma*:

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt \quad \Gamma(z + 1) = z\Gamma(z)$$

- Función *Beta*:

$$B(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt \quad B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

- Tasa de riesgo:

$$h(t) = \frac{f(t)}{1 - F(t)} \quad F(t) = 1 - \exp \left(- \int_0^t h(u) du \right)$$

- Métricas de ajuste:

Métrica de error	Métrica de ajuste / Criterio de información
$MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	$MAPE = \frac{100}{n} \sum_{i=1}^n \left \frac{y_i - \hat{y}_i}{y_i} \right $
$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$
$\chi^2 = \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{\hat{y}_i}$	$LR = 2(LL_{NR} - LL_R) \sim \chi^2$
	$AIC = -2 \ln(L(\hat{\theta})) + 2k$
	$BIC = -2 \ln(L(\hat{\theta})) + k \ln(n)$

Referencias

- Ben-Akiva, M., & Lerman, S. R. (1985). *Discrete choice analysis: Theory and application to travel demand*. MIT Press.
- Berry, S., Levinsohn, J., & Pakes, A. (1995). Automobile prices in market equilibrium. *Econometrica*, 63(4), 841–890. <https://doi.org/10.2307/2171802>
- Fader, P. S., & Hardie, B. G. S. (2010). Customer-base valuation in a contractual setting: The perils of ignoring heterogeneity. *Marketing Science*, 29(1), 85–93. <https://doi.org/10.1287/mksc.1080.0482>
- Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005a). Counting your customers the easy way: An alternative to the Pareto/NBD model. In *Marketing Science* (Vol. 24, pp. 275–284). <https://doi.org/10.1287/mksc.1040.0098>
- Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005b). RFM and CLV: Using iso-value curves for customer base analysis. *Journal of Marketing Research*, 42(4), 415–430. <https://doi.org/10.1509/jmkr.2005.42.4.415>
- Greene, W. H. (2018). *Econometric analysis* (8th ed.). Pearson.
- Guadagni, P. M., & Little, J. D. C. (1983). A logit model of brand choice calibrated on scanner data. *Marketing Science*, 2(3), 203–238. <https://doi.org/10.1287/mksc.2.3.203>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Heckman, J. J. (1979). Sample selection bias as a specification error. *Econometrica*, 47(1), 153–161. <https://doi.org/10.2307/1912352>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>
- Kahneman, D., & Tversky, A. (1979). Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2), 263–291. <https://doi.org/10.2307/1914185>
- Luce, R. D. (1959). *Individual choice behavior: A theoretical analysis*. Wiley.
- McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. *Frontiers in Econometrics*, 105–142.
- McFadden, D., & Train, K. (2000). Mixed MNL models for discrete response. *Journal of Applied Econometrics*, 15(5), 447–470. [https://doi.org/10.1002/1099-1255\(200009/10\)15:5%3C447::AID-JAE570%3E3.0.CO;2-1](https://doi.org/10.1002/1099-1255(200009/10)15:5%3C447::AID-JAE570%3E3.0.CO;2-1)
- Nevo, A. (2000). A practitioner’s guide to estimation of random-coefficients logit models of demand. *Journal of Economics & Management Strategy*, 9(4), 513–548. <https://doi.org/10.1111/j.1430-9134.2000.00513.x>
- Robert E. Lucas, Jr. (1976). Econometric policy evaluation: A critique. In K. Brunner & A. H. Meltzer (Eds.), *The phillips curve and labor markets* (pp. 19–46). North-Holland.
- Rossi, P. E., Allenby, G. M., & McCulloch, R. (2005). *Bayesian statistics and*

- marketing*. John Wiley & Sons.
- Schmittlein, D. C., Morrison, D. G., & Colombo, R. (1987). Counting your customers: Who are they and what will they do next? *Management Science*, 33(1), 1–24. <https://doi.org/10.1287/mnsc.33.1.1>
- Tobar, F. (2024). *Aprendizaje de máquinas: Notas de clase*. <https://github.com/GAMES-UCHile/Curso-Aprendizaje-de-Maquinas>
- Tobin, J. (1958). Estimation of relationships for limited dependent variables. *Econometrica*, 26(1), 24–36. <https://doi.org/10.2307/1907382>
- Train, K. E. (2009). *Discrete choice methods with simulation* (2nd ed.). Cambridge University Press. <https://doi.org/10.1017/CBO9780511805271>
- Wooldridge, J. M. (2019). *Introductory econometrics: A modern approach* (7th ed.). Cengage Learning.